

Regresión:

Prediceir y a partir de x ($\hat{y} = \varphi(x)$)

La función costo es $\lambda(x, y) = (y - \varphi(x))^2$

Por optimalidad el mejor predictor es:

$$\varphi(x) = E[y|x=x] \quad \text{y el Error Bayesiano } E[\text{var}(y|x)]$$

$\hookrightarrow$ Mínimo (Límite) Error (Teórico)

Demostración:

Calculamos el riesgo:

$$E[\lambda(x, y)] = E[(y - \varphi(x))^2] = E[(y - \varphi(x))^2]$$

Distribuir cuadrados, agregamos sumando y restando la Esperanza condicional.

$$E[(y - E[y|x] + E[y|x] - \varphi(x))^2] =$$

$$E[(y - E[y|x])^2 + (E[y|x] - \varphi(x))^2 + 2(y - E[y|x])(E[y|x] - \varphi(x))]$$

Analizamos cada término:

$$E[(y - E[y|x])^2] = E[E[(y - E[y|x])^2|x]] = E[\text{var}(y|x)]$$

$\downarrow$ Esperanza de la Esperanza $\downarrow$ Error Bayesiano

$$E[(E[y|x] - \varphi(x))^2] \geq 0 \quad \text{con igualdad si } \varphi(x) = E[y|x].$$

$$2 \cdot E[(y - E[y|x]) \cdot (E[y|x] - \varphi(x))] = \overset{\substack{\text{Esperanza de la Esperanza} \\ \text{cte para } x, \text{ sale afuera}}}{E[E[(y - E[y|x]) \cdot (E[y|x] - \varphi(x))|x]]} =$$

$$2 \cdot E[E[(y - E[y|x]) \cdot (E[y|x] - \varphi(x))|x]] =$$

$\downarrow$ Se anula

$$2 \cdot E[E[y - E[y|x]|x] \cdot (E[y|x] - \varphi(x))] = 0$$

Se anula por que:

$$\begin{aligned} E[y - E[y|x]|x] &= E[y|x] - E[y|x] \\ &= E[y|x] - E[y|x] = 0 \end{aligned}$$

• Con Esto se ve que El Mínimo es el Error Bayesiano y se da cuando $\varphi(x) = E[y|x]$ ■

Regresión Lineal

Suponemos una recta como solución

$$(w, b) \in \underset{(w, b)}{\operatorname{Argmin}} \sum_{i=1}^n (w^T x_i + b - y_i)^2 \quad \nearrow \quad \frac{1}{n} \sum_{i=1}^n \ell(x_i, y_i)$$

Acz Buscamos w y b que minimizen el ~~Riesgo~~ ^{Riesgo} Empírico.
En forma Matricial.

$$\underset{w}{\operatorname{Argmin}} \cdot \|X \cdot w - y\|^2 \quad \text{con} \quad X = \begin{pmatrix} 1 & x_1^T \\ 1 & x_2^T \\ \vdots & \vdots \\ 1 & x_n^T \end{pmatrix}; \quad y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$
$$w = \begin{pmatrix} b \\ w \end{pmatrix}$$

La solución Óptima es:

$$w = (X^T \cdot X)^{-1} \cdot X^T \cdot y$$

Demostración: Derivamos el costo.

$$J(w) = \frac{1}{n} \|X \cdot w - y\|^2 = \frac{1}{n} \cdot (X \cdot w - y)^T (X \cdot w - y)$$

$$= \frac{1}{n} \cdot (w^T X^T X w - 2 y^T X w + y^T y)$$

$$\nabla J(w) = \frac{1}{n} \cdot (2 X^T X w - 2 X^T y)$$

Por lo tanto Hallamos el Hessiano derivando de nuevo.

$$H(J(w)) = \frac{1}{n} \cdot 2X^T \cdot X.$$

Como es definida positiva entonces el problema es
Convexo y $\nabla J(w) = \vec{0}$ es mínimo Global.

Entonces

$$\nabla J(w) = \vec{0} = \frac{1}{n} \cdot (2X^T \cdot X w - 2X^T y)$$

$$\hookrightarrow \boxed{w = (X^T \cdot X)^{-1} \cdot X^T y}$$

Gradiente Descendente

Solución Numérica.

$$\theta_{t+1} = \theta_t - \alpha \nabla J(\theta_t)$$

Tenemos que:

- $w_{t+1} = w_t - \alpha \cdot \nabla J(w_t)$
- Solo hay un w^* tal que $\nabla J(w^*) = 0$
- $H(w)$ es definido positivo.

Por Taylor

$$\nabla J(w_t) = \cancel{\nabla J(w^*)} + H(\tilde{w}) \cdot (w_t - w^*)$$

$$\nabla J(w_t) = H(\tilde{w}) \cdot (w_t - w^*)$$

Descomponemos $H(\tilde{w}) = Q^T \Lambda Q$ con $Q^T Q = I$
En diagonalización

Si estamos en Linear Regression vemos que $H(\tilde{w}) = \frac{2}{n} X^T X$
no depende de los parámetros (solo de muestras)

Volvemos al gradiente descendente.

$$w_{t+1} - w^* = w_t - w^* - \alpha \cdot \nabla J(w_t)$$

$$w_{t+1} - w^* = w_t - w^* - \alpha \cdot (Q^T \Lambda Q \cdot (w_t - w^*))$$

$$w_{t+1} - w^* = (I - \alpha Q^T \Lambda Q) (w_t - w^*)$$

$$w_{t+1} - w^* = Q^T \cdot (I - \alpha \Lambda) \cdot Q \cdot (w_t - w^*)$$

definimos $Q(w_t - w^*) = V_t$

Entonces $V_{t+1} = (I - \alpha \Lambda) V_t$.

Si desarrollamos la iteración vemos que:

$$V_t = (I - \alpha \Lambda)^t \cdot V_0 \rightarrow \text{los } \lambda \text{ son de } H.$$

La velocidad de convergencia dependerá y si lo hace o no

de $|1 - \alpha \lambda_j| < 1 \rightarrow$ Esto sale para que la exponencial converja a cero, es decir, $w_{t+1} = w^*$

Esto equivale a que $\alpha < 2/\lambda_{\max}$

dem: desarrollemos el módulo

$$-1 < 1 - \alpha \lambda_j < 1$$

$$-2 < -\alpha \lambda_j < 0$$

$$0 > \alpha \lambda_j > 0$$

$$\Rightarrow \boxed{\alpha > 2/\lambda_j \quad \forall j}$$

Teorema de Bayesiano.

Probabilidad de Error

$$P(Y \neq \varphi(x)) \geq 1 - E\left[\max_y P_{Y|X=x}(y)\right]$$

↳ Estimación.

con igualdad si $\varphi(x) = \underset{y}{\operatorname{argmax}} P_{Y|X=x}(y)$

dem:

$$P(Y = \varphi(x) | X=x) = P_{Y|X=x}(\varphi(x)) \leq \max_y P_{Y|X=x}(y)$$

menor o igual
al máximo de 12
condicionales.

Luego:

Hacer
desarrollo

Propiedad
de eliminación

$$P(Y \neq \varphi(x)) = 1 - E[P(Y = \varphi(x) | X)] \geq 1 - E\left[\max_y P_{Y|X=x}(y)\right]$$

$$\hookrightarrow 1 - E[\mathbb{1}\{Y \neq \varphi(x)\}] = 1 - E[E[\mathbb{1}\{Y \neq \varphi(x) | X\}]] = 1 - E[P(Y = \varphi(x) | X)]$$

Trabajamos más la expresión:

Partición X . R_y conjunto de $x \in X$ donde y es el
máximo de $P_{Y|X=x}(y)$

$$R_y = \{x \in X : P_{Y|X=x}(y) = \max_{y' \in \mathcal{Y}} P_{Y|X=x}(y')\}$$

Luego:

Es función
de x .

Se prende solo
para el máximo.

$$\max_{y \in \mathcal{Y}} P_{Y|X=x}(y) = \sum_{y' \in \mathcal{Y}} P_{Y|X=x}(y') \cdot \mathbb{1}\{x \in R_{y'}\}$$

$$= \sum_{y' \in \mathcal{Y}} P_{Y'}(y') \cdot \frac{P_{X|Y=y'}(x)}{P_X(x)} \cdot \mathbb{1}\{x \in R_{y'}\}$$

Como: (Expresión Anterior)

$$P(Y \neq \varphi(x)) \geq 1 - E \left[\max_{y \in \mathcal{Y}} P_{Y|X=X}(y) \right]$$

✓ definición.

$$= 1 - \int_{\mathcal{X}} P_X(x) \cdot \max_{y \in \mathcal{Y}} P_{Y|X=X}(y) dx.$$

Reemplazamos


$$P(Y \neq \varphi(x)) \geq 1 - \sum_{y \in \mathcal{Y}} P_Y(y) \cdot \int_{R_y} P_{X|Y=y}(x) dx$$

R_y

↳ de la hipótesis.

$$= 1 - \sum_{y \in \mathcal{Y}} P_Y(y) \cdot P(X \in R_y | Y=y)$$

$$= 1 - \sum_{y \in \mathcal{Y}} P_Y(y) \cdot P(X \notin R_y | Y=y)$$



Definición de q :

$$KL(p \parallel q) \geq 0.$$

Definición de KL .

$$KL(p \parallel q) = E_p \left[\log \left(\frac{p(x)}{q(x)} \right) \right] \overset{\text{invierto signo.}}{=} - E_p \left[\log \left(\frac{q(x)}{p(x)} \right) \right]$$

Usamos la propiedad $\log(x) \leq x-1$.

Entonces:

$$- E_p \left[\log \left(\frac{q(x)}{p(x)} \right) \right] \geq - E_p \left[-1 + \frac{q(x)}{p(x)} \right]$$

$$= 1 - E_p \left[\frac{q(x)}{p(x)} \right] = 1 - \sum_x \cancel{p(x)} \cdot \frac{q(x)}{\cancel{p(x)}}$$

De la
Esperanza

$$= 1 - \sum_x q(x) = 0 \Rightarrow \boxed{KL(p \parallel q) \geq 0}$$

como es
una densidad
suma 1

Clasificador Bayesiano

Propuesta

Queremos $\hat{p}(y|x)$ que minimice KL .

$$\begin{aligned} E[KL(p_{y|x}(\cdot|x) \parallel \hat{p}(\cdot|x))] &= E \left[E_p \left[\log \left(\frac{p_{y|x}(y|x)}{\hat{p}(y|x)} \right) \right] \right] \\ &= E \left[E_p [\log p_{y|x}(y|x)] - E_p [\log \hat{p}(y|x)] \right] \end{aligned}$$

$$= E \left[\underbrace{-H(y|x)}_{\text{Entropía (cte)}} + \underbrace{E_p [-\log \hat{p}(y|x)]}_{\text{Cross-Entropy Esto queremos minimizar}} \right] \Rightarrow E[-\log \hat{p}(y|x)] \geq H(y|x)$$

porque $KL \geq 0$
De ahí se ve la optimalidad

LDA

Hipotesis del Modelo: mezcla de Gaussianas.

$$Y \sim \mathcal{C} \cup \{c_1, \dots, c_K\} \quad X|Y=K \sim \mathcal{N}(\mu_K, \Sigma)$$

↓
común a todas
la normales.

X es mezcla de Gaussianas por lo que.

$$P_X(x) = \sum_{k=1}^K P_Y(k) \cdot P_{X|Y=k}(x|y_k)$$

$$P_X(x) = \sum_{k=1}^K c_k \cdot \frac{e^{-1/2(x-\mu_k)^T \cdot \Sigma^{-1} \cdot (x-\mu_k)}}{(2\pi)^{d_X/2} \cdot |\Sigma|^{1/2}}$$

Por otro lado para obtener $P_{Y|X}$

$$P_{Y|X}(y|x) = \frac{P_{X|Y}(x|y) \cdot P_Y(y)}{P_X(x)} = \frac{N(\mu_Y, \Sigma) \cdot c_Y}{\sum_{k=1}^K c_k \cdot \frac{e^{-1/2(x-\mu_k)^T \cdot \Sigma^{-1} \cdot (x-\mu_k)}}{(2\pi)^{d_X/2} \cdot |\Sigma|^{1/2}}}$$

$$P_{Y|X}(y|x) = \frac{c_Y \cdot \frac{e^{-1/2(x-\mu_Y)^T \cdot \Sigma^{-1} \cdot (x-\mu_Y)}}{(2\pi)^{d_X/2} \cdot |\Sigma|^{1/2}}}{\sum_{k=1}^K c_k \cdot \frac{e^{-1/2(x-\mu_k)^T \cdot \Sigma^{-1} \cdot (x-\mu_k)}}{(2\pi)^{d_X/2} \cdot |\Sigma|^{1/2}}}$$

Los C los metemos a la Exponencial con el Logaritmo.

$$P_{Y|X}(y|x) = \frac{e^{-1/2(x-\mu_Y)^T \cdot \Sigma^{-1} \cdot (x-\mu_Y) + \log(c_Y)}}{\sum_{k=1}^K e^{-1/2(x-\mu_k)^T \cdot \Sigma^{-1} \cdot (x-\mu_k) + \log(c_k)}}$$

desarrollando los productos matriciales llegamos a que:

$$-1/2 \cdot (x^T - \mu_y^T) \Sigma^{-1} \cdot (x - \mu_y) =$$

$$-1/2 \left[\underbrace{x^T \Sigma^{-1} x} - x^T \Sigma^{-1} \mu_y - \mu_y^T \Sigma^{-1} x + \mu_y^T \Sigma^{-1} \mu_y \right]$$

↳ común a
todos, se va
en la división

$$x^T \Sigma^{-1} \mu_y = (\mu_y^T \Sigma^{-1} x)^T$$

↳ simétrica
y cuadrada

Por propiedad:

$$x^T \Sigma^{-1} \mu_y = \mu_y^T \Sigma^{-1} x$$

Por lo tanto surge que:

$$\hat{P}_{y|x}(y|x) = \frac{e^{-1/2 \cdot \mu_y^T \Sigma^{-1} \mu_y + \mu_y^T \Sigma^{-1} x + \log c_y}}{\sum_{k=1}^K e^{-1/2 \mu_k^T \Sigma^{-1} \mu_k + \mu_k^T \Sigma^{-1} x + \log c_k}}$$

Si: $W_y = \Sigma^{-1} \mu_y$ y $b_y = -1/2 \mu_y^T \Sigma^{-1} \mu_y + \log c_y$

entonces $\hat{P}_{y|x}(y|x)$ es el softmax

Como estimamos los parámetros?

$$D_k = \{x_i \mid 1 \leq i \leq n \wedge y_i = k\}$$

$$c_k = \frac{\#(D_k)}{n}$$

$$\mu_k = \frac{1}{\#(D_k)} \sum_{x \in D_k} x$$

$$\Sigma_k = \frac{1}{\#(D_k) - 1} \sum_{x \in D_k} (x - \mu_k) \cdot (x - \mu_k)^T$$

Para Σ tomamos una
especie de mediana


$$\Sigma = \frac{1}{n-K} \sum_{k=1}^K (\#(D_k) - 1) \Sigma_k$$

Nota: QDA es lo mismo
Solo que:

$$X|Y \sim N(\mu_k | \Sigma_k)$$

El modelo es cuadrático
En este caso.

Support Vector Machines



$$Y = \{-1, 1\}.$$

$Y > 0 \rightarrow$ Muestra positiva

$Y < 0 \rightarrow$ Muestra negativa.

Quiero optimizar la frontera (lineal).

$$Z(x) = w^T x + b = 0 \rightarrow \text{con Normal } w.$$

Las clases son linearly-mark separables

$$\exists w, b / y \cdot z > 0 \quad \forall x, y \in D_n.$$

$$\text{Definimos } F_i(w, b) = y_i \cdot z(x_i) > 0.$$

$\hookrightarrow$ por ser separables.

Sea x^* la proyección de un x genérico a la frontera.

Tenemos que:

- $(x - x^*) \parallel w$ Por ser w ortogonal por lo tanto.

$$|w^T \cdot (x - x^*)| = \|w\| \cdot \|x - x^*\| \cdot \cos(1).$$

$\hookrightarrow$ producto interno.

$\hookrightarrow$ sea $\parallel$.

- Como x^* pertenece a la frontera.

$$w^T \cdot (x - x^*) = z(x).$$

$$\hookrightarrow z(x) - z(x^*) = w^T x + b - (w^T x^* + b) = w^T \cdot (x - x^*)$$

$\hookrightarrow 0$ por estar en la frontera.

Notar de acá surge que $b = -w^T \cdot x^*$ (consultar)

al cual la distancia de un x_i a la frontera

$$d(x_i) = \|x_i - x^*\| = \frac{|w^T \cdot (x_i - x^*)|}{\|w\|} = \frac{|Z(x_i)|}{\|w\|}$$

$\downarrow$ de la primera $\qquad \qquad \qquad \downarrow$ de la segunda

Por definición el módulo lo puede reemplazar por:

$$d(x_i) = \frac{\overbrace{y_i Z(x_i)}^{\text{no separables.}}}{\|w\|} = \frac{y_i \cdot (w^T x_i + b)}{\|w\|}$$

Esto es lo que queremos optimizar:

Definimos el Margen como el peor caso

$$M(w, b) = \min_{\text{texas}} \frac{y_i \cdot (w^T x_i + b)}{\|w\|} = \frac{1}{\|w\|} \min_{\text{texas}} f_k(w, b)$$

Al mínimo lo denotamos con k .

$$M(w, b) = \frac{1}{\|w\|} f_k(w, b)$$

La idea es maximizar el margen:

$$\max_{w, b} M(w, b) \quad \text{s.t.} \quad f_k(w, b) > 0 \rightarrow \text{Hay que cumplir variables separables.}$$

Como es invariante ante escalas y2 que la decisión siempre es contra 0, Proponemos $f_k(w, b) = 1$

De esta manera.

$\hookrightarrow$ vectores separables.

$$\boxed{\max_{w \in B} M(w, b) \quad \text{s.t.} \quad f_k(w, b) \geq 1}$$

$\hookrightarrow$ Mayor al mínimo

en la idea es que: Queremos minimizar $\|w\|^2$; (inverso del problema que obtuvimos, más fácil de tratar). (el cuadrado lo hacemos, es siempre creciente).

$$\min_{w, b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i (w \cdot x_i + b) \geq 1 \quad \forall i$$

Para relajar los Margenes Agregamos una penalización.

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \cdot \sum_{i=1}^n \xi_i \quad \text{s.t.} \quad \begin{cases} y_i (w \cdot x_i + b) \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases}$$

Problem dual

Lo que hacemos es usar Multiplicadores de Lagrange Para meter las Condiciones dentro de la Función.

$$J_1 = \min_{w, b} \max_{\alpha_i \geq 0} \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w \cdot x_i + b) - 1)$$

Ahora invertimos el max con el min. Para llegar al Dual.

$$J_2 = \max_{\alpha_i \geq 0} \min_{w, b} \underbrace{\frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w \cdot x_i + b) - 1)}_g$$

Ahora hacemos la minimización respecto de w y b .

$$\frac{\partial g(w, b)}{\partial w} = \frac{2}{2} w - \sum_{i=1}^n \alpha_i y_i x_i = 0$$

$$\rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\frac{\partial g(w, b)}{\partial b} = - \sum_{i=1}^n \alpha_i y_i = 0 \rightarrow$$

$$\sum_{i=1}^n \alpha_i y_i = 0$$

Vuelvo a la expresión original: y reemplazo

$$J_2 = \max_{\alpha_i \geq 0} \cdot \frac{1}{2} \left\| \left(\sum_{i=1}^n \alpha_i y_i x_i \right) \right\|^2 - \sum_{i=1}^n (\alpha_i y_i w^T x_i + \alpha_i y_i b - \alpha_i)$$

$$J_2 = \max_{\alpha_i \geq 0} \cdot \frac{1}{2} \left\| \sum_{i=1}^n \alpha_i y_i x_i \right\|^2 - \left(\sum_{i=1}^n \alpha_i y_i w^T x_i + b \sum_{i=1}^n \alpha_i y_i - \sum_{i=1}^n \alpha_i \right)$$

$$J_2 = \max_{\alpha_i \geq 0} \cdot \frac{1}{2} \left\| \sum_{i=1}^n \alpha_i y_i x_i \right\|^2 - \|w\|^2 + \sum_{i=1}^n \alpha_i$$

$$J_2 = \max_{\alpha_i \geq 0} - \frac{1}{2} \|w\|^2 + \sum_{i=1}^n \alpha_i$$

Reescribimos en forma Matricial.

$$\|w\|^2 = \left\| \sum_{i=1}^n \alpha_i y_i x_i \right\|^2 = \cancel{(X Y X^T)} \cdot \cancel{(X X^T)} = X^T Q X$$

$$\text{Con } Q_{ij} = y_i y_j x_i^T \cdot x_j$$

$$J_2 = \max_{\alpha_i \geq 0} - \frac{1}{2} X^T Q X + X^T \mathbf{1} \quad \text{s.t. } X^T y = 0$$

↓
sistema de derivada
respecto de b.

212 Calcular b y w

• w de la derivada

• b sale de los vectores soporte.

$$y_i (w^T x_i + b) = 1$$

$$y_i b = 1 - y_i w^T x_i$$

multiplicamos por y_i a ambas miembros


$$b y_i^2 = y_i - y_i^2 w^T x_i$$

$$b = y_i - 1 w^T x_i$$

Principal Analysis Component

Es un tipo de Auto Encoder. Consiste en bajar la dimensión y reconstruir para aprender el Manifold

Basicamente lo que se hace es proyectar las muestras a la dirección de un Autovector.



Buscamos El principal Autovector.
Con criterio de ECM.

Tenemos que:

$$\|v_1\| = 1 \rightarrow \text{Es Versor}$$

$$\langle x_i - x_i \cdot v_1, v_1 \rangle = 0 \rightarrow \text{Ortogonalidad.}$$

$$\min_{v: \|v\|=1} \sum_{i=1}^n \|x_i - x_i \cdot v\|^2 \rightarrow \text{ECM que queremos minimizarlo. Para todo } x_i.$$

• De ortogonalidad.

$$\langle x_i, v_1 \rangle - x_i \cdot \underbrace{\langle v_1, v_1 \rangle}_{\|v_1\|^2=1} = \langle x_i, v_1 \rangle - x_i = 0$$

$$\hookrightarrow x_i = \langle x_i, v_1 \rangle \rightarrow x_i^2 = \langle x_i, v_1 \rangle^2 = (v_1^T \cdot x_i) \cdot (x_i^T \cdot v_1)$$

Ahora planteamos el ECM

$$\sum_{i=1}^n \|x_i - x_i \cdot v\|^2 = \sum_{i=1}^n \|x_i\|^2 + x_i^2 \cdot \|v\|^2 - 2 \cdot x_i \cdot \underbrace{\langle x_i, v \rangle}_{x_i \cdot v}$$

$$\sum_{i=1}^n \|x_i\|^2 + x_i^2 \cdot 1 - 2 x_i^2 = \sum_{i=1}^n \|x_i\|^2 - x_i^2$$

Optimizamos respecto de x_i ; como los x_i son cte $\rightarrow$ no afectan a la optimización.

$$\min_{v: \|v\|=1} \sum_{i=1}^n -x_i^2 = \max_{v: \|v\|=1} \frac{1}{n} \sum_{i=1}^n \langle x_i, v \rangle^2 = \max_{v: \|v\|=1} \frac{1}{n} \sum_{i=1}^n v^T \cdot x_i \cdot x_i^T \cdot v$$

Sacamos afuera V_1 y λ que no depende de i :

$$\max_{V_1: \|V_1\|^2=1} \frac{1}{N} V_1^T \left(\sum_{i=1}^N X_i X_i^T \right) V_1$$

Covarianza $\rightarrow \Sigma$

Por multiplicadores de Lagrange planteamos la Maximización Metiendo las condiciones adentro de la Ecuación.

$$J(V_1) = N_1^T \cdot \Sigma \cdot V_1 - \lambda \cdot (N_1^T \cdot N_1 - 1)$$

$\hookrightarrow$ Multiplicador $\hookrightarrow$ Condición

Derivamos e igualamos a cero:

$$\nabla J(V_1) = 2 \Sigma V_1 - 2 \lambda N_1 = 0.$$

$$\hookrightarrow \boxed{\Sigma V_1 = \lambda V_1 \rightarrow \text{Resultado } \lambda \text{ es AVE. que } V_1 \text{ es AVE.}}$$

$\hookrightarrow$ Esto de signo. $\leftarrow$

Nos quedamos con las direcciones con AVE mayor.
Esto se repite para cada componente Principal.

$$\mu = V \cdot x$$

$$\hat{x} = V^T \cdot \mu$$

* V contiene
Autovectores
Principales.

Algoritmo EM:

Partimos de máxima verosimilitud:

$$\hat{\theta}_{mv} = \underset{\theta}{\operatorname{Argmax}} \prod_{i=1}^n p(x_i | \theta)$$

$$\hat{\theta}_{mv} = \underset{\theta}{\operatorname{Argmax}} \sum_{i=1}^n \log p(x_i | \theta)$$

$$\hat{\theta}_{mv} = \underset{\theta}{\operatorname{Argmin}} \left(-1/n \right) \cdot \sum_{i=1}^n \log p(x_i | \theta).$$

↳ esto depende; en principio no se usa

Tenemos una variable latente z con densidad condicional $p(z|x, \theta)$ y p la familia de todas las densidades condicionales de $z|x=x$.
Metemos esto en la verosimilitud.

$$\hat{\theta} = \underset{\theta}{\operatorname{Argmax}} \max_{q \in \mathcal{P}} \underbrace{\sum_{i=1}^n \log p(x_i | \theta) - \operatorname{KL}(q(\cdot | x_i) \| p(\cdot | x_i, \theta))}_{\text{Esto se llama ELBO}(\theta; q)}$$

Esto no modifica la expresión original y2 que el primer máximo hace que KL sea dual.
Primero maximizamos con q : este es el paso de Expectation
es evidente que:

$$q_{(z|x)}^{(t)} = p(z | x_i; \theta^{(t-1)}) \text{ de esta manera KL se vuelve } \underline{\text{mínima?}}$$

Por lo que

$$\theta^{(t)} = \underset{\theta}{\operatorname{Argmax}} \sum_{i=1}^n \log p(x_i | \theta) - \operatorname{KL}(p(z | x_i; \theta^{(t-1)}) \| p(z | x_i, \theta))$$

En el paso Maximization: hacemos la Maximización de la Expresión. Reescribimos los sumandos.

$$\log(p(x_i|\theta)) - KL(q(z|x_i) \parallel p(z|x_i, \theta))$$

$$= \log p(x_i|\theta) - E_q \left[\log \frac{q(z|x_i)}{p(z|x_i, \theta)} \middle| x \right]$$

~~entonces~~ $\log p(x_i|\theta) = E_q[\log(q(z|x_i))] + E_q[\log(p(z|x_i, \theta))]$
 Mero el $\log$ adentro de la Esperanza.

=

$$= E_q \left[\log \frac{p(z|x_i, \theta) \cdot p(x_i|\theta)}{q(z|x_i)} \middle| x \right]$$

$$= E_q \left[\log \frac{p(z, x_i|\theta)}{q(z|x_i)} \middle| x \right]$$

$$= \underbrace{-E_q[\log q(z|x_i)|x]}_{H(q)} + E_q[\log p(z, x_i|\theta)|x]$$

$H(q)$
 no depende
 de θ .

↓
 Queda solo esto.

Por lo que queda:

$$\theta^{(4)} = \underset{\theta}{\operatorname{Argmax}} \sum_{i=1}^n E_{q^{(4)}}[\log p(z, x_i|\theta) | x_i]$$

Mono tonio.

$$\sum_{i=1}^n \log(p(x_i | \theta^t)) \geq \sum_{i=1}^n \log p(x_i | \theta^{t-1}).$$

Plantez mas

$$\begin{aligned} & \sum_{i=1}^n \log p(x_i | \theta^t) - \text{KL}(p(\cdot | x_i, \theta^{t-1}) \| p(\cdot | x_i, \theta^t)) \\ & \geq \sum_{i=1}^n \log p(x_i | \theta^t) - \text{KL}(\cancel{p(\cdot | x_i, \theta^{t-1})} \| p(\cdot | x_i, \theta^{t-1})) \\ & = \sum_{i=1}^n \log p(x_i | \theta^{t-1}) \end{aligned}$$

Como $\text{KL} \geq 0 \rightarrow$ per Martinez (2) guided

$$\log p(x_i | \theta^t) \geq \log p(x_i | \theta^{t-1}).$$

Variational Bayes

z es no observable y es prohibido
Calcular la posterior $p(z|x)$, entonces
la vamos a aproximar.

La solución es:

$$\operatorname{Argmin}_{q \in \mathcal{P}} K_L(q(\cdot|x) \| p(\cdot|x))$$

$$= \operatorname{Argmax}_{q \in \mathcal{P}} H(q(\cdot|x)) + E_q[\log(p(x,z)) | x=x]$$

De donde sale esta demostración:

$$K_L(q(\cdot|x) \| p(\cdot|x)) = E_q\left[\log\left(\frac{q(z|x)}{p(z|x)}\right) | x=x\right]$$

$$= -E_q[\log(p(z|x)) | x=x] + E_q[\log(q(z|x)) | x=x]$$

$$= -E_q[\log(p(z|x)) | x=x] - H(q(\cdot|x))$$

↓ reescribo

$$= -E_q\left[\log\left(\frac{p(z,x)}{p(x)}\right) | x=x\right] - H(q(\cdot|x))$$

$$= -E_q[\log p(z,x) | x=x] + \log p(x) - H(q(\cdot|x))$$

↳ Salio afuera porque
la esperanza es en z .

• Fijate que cambio el min

por el max debido a la

inversión de signos. y el $\log$ de $p(x)$ se va porque

no es función de $q(z|x)$.

Entonces usamos la Mean Field approximation
para reducir el problema

$$Q(z|x) = Q_1(u|x) \cdot Q_2(\phi|x)$$

Vemos como quedan los términos

$$H(Q(\cdot|x)) = -E_Q [\log(Q(z|x)) | x=x]$$

$$= -E_Q [\log(Q_1(u|x) \cdot Q_2(\phi|x)) | x=x]$$

$$= H(Q_1(\cdot|x)) + H(Q_2(\cdot|x)) \rightarrow \text{Son independientes}$$

Lo agregamos al problema original, entonces resulta:

$$\text{Argmax}_{Q \in \mathcal{P}} H(Q_1(\cdot|x)) + H(Q_2(\cdot|x)) + E_Q [\log(p(x,z)) | x=x]$$

Buscamos Q_1 y Q_2 que maximicen:

$$ELBO(Q) = H(Q_1(\cdot|x)) + H(Q_2(\cdot|x)) + E_Q [\log(p(x,z)) | x=x].$$

El segundo término como lo desarrollamos?

Lo que hay que hacer es desarrollar la
esperanza

$$E_z [\log(p(x, z)) | x = x].$$

$$= \int_{\mathbb{R}} q_z(z|x) \cdot \log p(x, z) dz.$$

$$= \int_{\mathbb{R}} q_1(u|x) \cdot q_2(\phi|x) \cdot \log p(x, z) dz.$$

$$= \int_{\mathbb{R}^2} q_1(u|x) \cdot q_2(\phi|x) \cdot \log p(x, u, \phi) du d\phi.$$

Divido la integral definiendo ahora q_1 .

$$= \int_U q_1(u|x) \left(\int_{\phi} q_2(\phi|x) \log p(x, u, \phi) d\phi \right) du.$$

Lo mismo sucede con q_2 .

$$= \int_{\phi} q_2(\phi|x) \left(\int_U q_1(u|x) \log p(x, u, \phi) du \right) d\phi.$$

Estas dos expresiones son equivalentes. Definimos.

$$E_1(x, u) = \int_{\phi} q_2(\phi|x) \cdot \log p(x, u, \phi) d\phi = F(q_2)$$

$$E_2(x, \phi) = \int_U q_1(u|x) \cdot \log p(x, u, \phi) du = F(q_1)$$

La integración mata una dependencia en cada caso.

ahora volvemos a la Expresión Original.
y descomponemos uno de los q y maximizamos
respecto del otro:

o Por Ejemplo respecto de q_1 (dejamos q_2).

$$\underset{q_1 \in \mathcal{P}}{\text{Argmax}} H(q_1(\cdot|x)) + H(q_2(\cdot|x)) + \int q_1(u|x) \cdot E_1(x,u) du$$

$\downarrow$ NO aporta a la maximización.

$$= \underset{q_1 \in \mathcal{P}}{\text{Argmax}} H(q_1(\cdot|x)) + E_{q_1}[E_1(x,u) | x=x]$$

$$= \underset{q_1 \in \mathcal{P}}{\text{Argmax}} E_{q_1}[-\log(q_1(u|x)) | x=x] + E_{q_1}[E_1(x,u) | x=x]$$

Juntamos las Esperanzas:

$$= \underset{q_1 \in \mathcal{P}}{\text{Argmax}} E_{q_1} \left[\log \left(\frac{e^{E_1(x,u)}}{q_1(u|x)} \right) \middle| x=x \right] \rightarrow \text{Esto es } -KL.$$

$$= \underset{q_1 \in \mathcal{P}}{\text{Argmin}} E_{q_1} \left[\log \left(\frac{q_1(u|x)}{e^{E_1(x,u)}} \right) \middle| x=x \right]$$

$$= \underset{q_1 \in \mathcal{P}}{\text{Argmin}} KL(q_1(\cdot|x) \| e^{E_1(x,\cdot)})$$

Resulta entonces que para minimizar esto,

$$q_1(u|x) \propto e^{E_1(x,u)}$$

Lo mismo sucede para q_2

$$q_2(\phi|x) \propto e^{E_2(x,\phi)}$$

El Resultado anterior se desprende que
Si reemplazamos en la Expresión Original dejando
uno fijo tenemos:

$$q_1(\cdot|x) = \underset{q_1 \in \mathcal{P}}{\operatorname{Argmax}} H(q_1(\cdot|x)) + E_{q_1}[E_1(x,u)|x=x].$$

$$= \underset{q_1}{\operatorname{Argmax}} E_{q_1}[-\log(q_1(u|x)|x=x)] + E_{q_1}[E_1(x,u)|x=x]$$

$$= \underset{q_1}{\operatorname{Argmax}} \int_U q_1(u|x) \cdot \log\left(\frac{e^{E_1(x,u)}}{q_1(u|x)}\right) du$$

Similarmente para q_2 :

$$q_2(\cdot|x) = \underset{q_2}{\operatorname{Argmax}} \int_{\Phi} q_2(\phi|x) \cdot \log\left(\frac{e^{E_2(x,\phi)}}{q_2(\phi|x)}\right) d\phi$$

- Con Esto llegamos al resultado (No Entiendo igualmente
Como se Supon que se debe iterar entre estas dos
Funciones)