


SVM $\rightarrow$ tenemos 2 clases linealmente separables

tal que $\forall z(x) \geq 0$, $\forall \in \{-1, 1\}$, $z(x) = w^T x + b$

Esto es pedir que los puntos $\gamma > 0$ queden separados de los $\gamma < 0$ por la recta/plano/hiperplano que se busca.

1) Dibujo el problema



x' es la proyección de x sobre la frontera.

$$x - x' \text{ es } \perp \text{ a } w \quad \therefore \langle w, x - x' \rangle = \|w\| \|x - x'\| \cos \theta$$

$\uparrow$
 $= 1$

La distancia de x a la frontera es $\|x - x'\|$

Como $\langle w, x - x' \rangle = \|w\| \|x - x'\| \rightarrow \|x - x'\| = \frac{\langle w, x - x' \rangle}{\|w\|}$ forma alternativa

Como $|w^T x' + b| = 0$ porque x' está sobre la frontera

$$\rightarrow \text{dist} = \frac{\langle w^T x \rangle - \langle w^T x' \rangle + b - b}{\|w\|} = \frac{|w^T x + b|}{\|w\|} = \frac{\gamma_i (w^T x_i + b)}{\|w\|}$$

esto solo el módulo que $\gamma_i (w^T x_i + b) \geq 0$

2) Buscar el margen: Será la dist mínima $\rightarrow \min_x \frac{\gamma_i (w^T x_i + b)}{\|w\|}$

esto se ajusta suponiendo un escalador tal que el $x_{\min}$ que minimiza cumple $w^T x_{\min} + b = 1$

3) Maximizar margen: Queremos que el margen, que es la dist min, sea el MAX posible:

$$\text{Margen} = \max_{w, b} \left(\min_x \frac{1}{\|w\|} \right) = \max_{w, b} \frac{1}{\|w\|} \xleftrightarrow{\text{equiv.}} \min_{w, b} \frac{1}{2} \|w\|^2 \text{ s.t. } \gamma_i (w^T x_i + b) \geq 1$$

el mínimo a más

Expresión final

Como no depende de x por el escalador

4) Márgenes relajados: Se puede relajar el problema metiendo que $\gamma_i (w^T x_i + b) \geq 1 - \epsilon_i$ que permite que haya puntos dentro de (0,1) pero lo penaliza:

$$\min_{w, b, \epsilon} \frac{1}{2} \|w\|^2 + \alpha \sum_i \epsilon_i \text{ s.t. } \begin{cases} \gamma_i (w^T x_i + b) + \epsilon_i \geq 1 & \forall i \\ \epsilon_i \geq 0 & \forall i \end{cases}$$

hiperparámetro

Problema dual $\rightarrow$ surge de querer optimizar poro PC.

Problema dual Hard Margin:

Si $P_{\text{primal}} = \min_{w,b} \frac{1}{2} \|w\|^2$ st $\underbrace{\delta_i (w^T x_i + b)}_{-\delta_i (w^T x_i + b) + 1 \leq 0} \geq 1 \leftarrow$ minimizar esto equivale a maximizar su equivalente dual

1) armamos el lagrangiano:

$$\mathcal{L} = \frac{1}{2} \|w\|^2 + \langle \lambda, -\delta_i (w^T x_i + b) + 1 \rangle$$

$$\mathcal{L} = \frac{1}{2} \|w\|^2 + \sum_i \lambda_i (-\delta_i (w^T x_i + b) + 1)$$

$$\mathcal{L} = \frac{1}{2} \|w\|^2 - \sum \lambda_i \delta_i w^T x_i - \sum \lambda_i \delta_i b + \sum \lambda_i$$

$\hookrightarrow \|w\|^2 = w w^T$

2) Resolver $\nabla_{w,b} \mathcal{L}$

$$\nabla_w \mathcal{L} = w - \sum \lambda_i \delta_i x_i = 0 \rightarrow w = \sum \lambda_i \delta_i x_i$$

$$\nabla_b \mathcal{L} = -\sum \lambda_i \delta_i = 0 \rightarrow \sum \lambda_i \delta_i = 0$$

Entonces ahora tenemos

$$\max_{\lambda_i} \left[\min \frac{1}{2} \|w\|^2 - \sum \lambda_i \delta_i w^T x_i - \sum \lambda_i \delta_i b + \sum \lambda_i \right]$$

$$\max_{\lambda_i} \frac{1}{2} \left\| \sum \lambda_i x_i \delta_i \right\|^2 - \sum \lambda_i \delta_i w^T x_i + \sum \lambda_i$$

$$\max_{\lambda_i} \frac{1}{2} \left\| \sum \lambda_i x_i \delta_i \right\|^2 - w^T w + \sum \lambda_i$$

$$\max_{\lambda_i} \frac{1}{2} \|w\|^2 - \|w\|^2 + \sum \lambda_i = \max_{\lambda_i} -\frac{1}{2} \|w\|^2 + \sum \lambda_i \text{ st } \begin{cases} \lambda_i \geq 0 \\ \sum \lambda_i \delta_i = 0 \end{cases}$$

$$= \max_{\lambda_i} -\frac{1}{2} \left\| \sum \lambda_i \delta_i x_i \right\|^2 + \sum \lambda_i \text{ st } \begin{cases} \lambda_i \geq 0 \\ \sum \lambda_i \delta_i = 0 \end{cases}$$

matricial es $-\frac{1}{2} \lambda^T Q \lambda + \mathbb{1} \lambda \text{ st } \begin{cases} \mathbb{1} \lambda \geq 0 \\ (\mathbb{1} \lambda)^T \delta = 0 \end{cases}$

$\hookrightarrow Q_{i,j} = \delta_i \delta_j x_i x_j^T$

Show el problema dual con Soft Margin

$$1 - \epsilon_i - \gamma_i (w^T x_i + b) \leq 0$$

$$\min_{w, b, \epsilon} \frac{1}{2} \|w\|^2 + \alpha \sum_i \epsilon_i \quad \text{s.t.} \quad \begin{cases} \gamma_i (w^T x_i + b) + \epsilon_i \geq 1 & \forall i \\ \epsilon_i \geq 0 \end{cases}$$

(hiperparámetro)

$\rightarrow -\epsilon_i \leq 0$

$$\rightarrow \mathcal{L} = \frac{1}{2} \|w\|^2 + \alpha \sum \epsilon_i + \sum \lambda_i (1 - \epsilon_i - \gamma_i (w^T x_i + b)) + \sum \beta_i (-\epsilon_i)$$

$$\mathcal{L} = \frac{1}{2} \|w\|^2 + \alpha \sum \epsilon_i + \sum \lambda_i - \sum \lambda_i \epsilon_i - \sum \lambda_i \gamma_i w^T x_i - \sum \lambda_i \gamma_i b - \sum \beta_i \epsilon_i$$

Gradiente respecto de las variables anteriores:

$$\nabla_w \mathcal{L} = w - \sum \lambda_i \gamma_i x_i = 0 \rightarrow w = \sum \lambda_i \gamma_i x_i$$

$$\nabla_b \mathcal{L} = -\sum \lambda_i \gamma_i = 0 \rightarrow \sum \lambda_i \gamma_i = 0$$

Sin la sumatoria

$$\nabla_{\epsilon_i} \mathcal{L} = \alpha - \lambda_i - \beta_i = 0 \rightarrow \alpha - \lambda_i = \beta_i \geq 0$$

Con las condiciones nuevas

$$\begin{cases} \beta_i \geq 0 \\ \lambda_i \geq 0 \end{cases}$$

Reemplazamos en $\mathcal{L}$:

$$\mathcal{L} = \frac{1}{2} \|w\|^2 + \alpha \sum \epsilon_i + \sum \lambda_i - \sum \lambda_i \epsilon_i - \sum \lambda_i \gamma_i w^T x_i - \sum \lambda_i \gamma_i b - \sum \beta_i \epsilon_i$$

$$\mathcal{L} = \frac{1}{2} \|w\|^2 + \cancel{\alpha \sum \epsilon_i} + \sum \lambda_i - \cancel{\sum \lambda_i \epsilon_i} - \underbrace{\sum \lambda_i \gamma_i w^T x_i}_{\|w\|^2} - \cancel{\sum \lambda_i \gamma_i b} - \cancel{\sum \beta_i \epsilon_i}$$


$$\mathcal{L} = -\frac{1}{2} \|w\|^2 + \sum \lambda_i \quad \text{s.t.} \quad \begin{cases} \lambda_i \geq 0 \\ \alpha - \lambda_i \geq 0 \\ \sum \lambda_i \gamma_i = 0 \end{cases} \quad \text{de antes}$$

Se busca el $\max_{\lambda_i} -\frac{1}{2} \|w\|^2 + \sum \lambda_i$ s.t. $\begin{cases} \lambda_i \geq 0 \\ \alpha \geq \lambda_i \\ \sum \lambda_i \gamma_i = 0 \end{cases}$

$w = \sum \lambda_i \gamma_i x_i$

$$-\frac{1}{2} \sum_{i,j=1}^n \lambda_i \lambda_j \gamma_i \gamma_j x_i x_j$$

PCA $\rightarrow$ Buscamos el espacio vectorial que minimiza el error de reconstrucción implícito en n valores de una dimensión mayor o menor.



Vamos a buscar proyectar en las direcciones de los autovectores

1) Normalizamos en media y desvía $\rightarrow$

$$x_{nj}^{(i)} = \frac{x_j^{(i)} - \mu_j}{\sigma_j}$$

muestr*i*
textura *j*

$$\sigma_j^2 = \frac{1}{n} \sum (x - \mu_j)(x - \mu_j) \quad ; \quad \mu_j = \frac{1}{n} \sum x_j$$

2) Supongamos que queremos proyectar los datos sobre solo 1 dimensión de dirección v , dado por el vector v , $\|v\|=1$.


la proyección es $y_i = \langle x_i, v \rangle = v^T x_i$ y la reconstrucción es $\hat{x}_i = v^T x_i v$

El ECM de reconstrucción es $\propto$

$$\sum_{i=1}^n \|x_i - v^T x_i v\|^2 = \sum \|x_i\|^2 - \sum \|v^T x_i\|^2$$

$$= \sum x_i^T x_i - \sum v^T x_i x_i^T v$$

rola v
ortogonalidad
del error a v
error $\perp v$



Buscamos v tal que $ECM_{min} = \min_v \sum x_i^T x_i - \sum v^T x_i x_i^T v$

$$\propto \min_v C_x - v^T C_x v$$

$$\min C_x - v^T C_x v \text{ s.t. } \|v\|=1 \rightarrow v^T v - 1 = 0$$

lagrange

$$\max \min C_x - v^T C_x v + \lambda (v^T v - 1) \text{ s.t. } \lambda > 0$$

$$\nabla_v ECM = 0 = 2C_x v + 2\lambda v \rightarrow 2C_x v = -2\lambda v \rightarrow v \text{ es autovector}$$

λ es autovalor

Y el resultado más fuerte todavía es que son las direcciones de C_x
∴ se puede computar C_x y su descomposición en autovalores y autovectores
y usar por las direcciones sobre los que, al reconstruir, se minimiza el ECM.

Chapter 12

Principal components analysis

In this set of notes, we will develop a method, Principal Components Analysis (PCA), that tries to identify the subspace in which the data approximately lies. PCA is computationally efficient: it will require only an eigenvector calculation (easily done with the `eig` function in Matlab).

Suppose we are given a dataset $\{x^{(i)}; i = 1, \dots, n\}$ of attributes of n different types of automobiles, such as their maximum speed, turn radius, and so on. Let $x^{(i)} \in \mathbb{R}^d$ for each i ($d \ll n$). But unknown to us, two different attributes—some x_i and x_j —respectively give a car's maximum speed measured in miles per hour, and the maximum speed measured in kilometers per hour. These two attributes are therefore almost linearly dependent, up to only small differences introduced by rounding off to the nearest mph or kph. Thus, the data really lies approximately on an $n - 1$ dimensional subspace. How can we automatically detect, and perhaps remove, this redundancy?

For a less contrived example, consider a dataset resulting from a survey of pilots for radio-controlled helicopters, where $x_1^{(i)}$ is a measure of the piloting skill of pilot i , and $x_2^{(i)}$ captures how much he/she enjoys flying. Because RC helicopters are very difficult to fly, only the most committed students, ones that truly enjoy flying, become good pilots. So, the two attributes x_1 and x_2 are strongly correlated. Indeed, we might posit that the data actually lies along some diagonal axis (the u_1 direction) capturing the intrinsic piloting “karma” of a person, with only a small amount of noise lying off this axis. (See figure.) How can we automatically compute this u_1 direction?

EM Suponemos que hay una variable latente z , y θ depende de z :

no podemos maximizar la verosimilitud de una.

$$\hat{\theta}_{ML} = \underset{\theta}{\operatorname{argmax}} \sum \log p(x_i | \theta)$$

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

Entonces $p(z|x_i, \theta) = \frac{p(x_i|z, \theta) p(z|\theta)}{p(x_i|\theta)}$

↪ no igualamos no logs

lo dist de z (arbitrario)

$$\therefore p(x_i|\theta) = \frac{p(x_i|z, \theta) p(z|\theta)}{p(z|x_i, \theta)} \cdot \frac{q(z)}{q(z)}$$

$$p(x, z|\theta) = p(x|z, \theta) p(z|\theta) = p(z|x, \theta) p(x|\theta)$$

$$p(x|\theta) = \frac{p(x|z, \theta) p(z|\theta)}{p(z|x, \theta)}$$

no repetido todo

No es lo que es en su totalidad

$$\log p(x_i|\theta) = \log \left(\frac{p(x_i|z, \theta) p(z|\theta)}{q(z)} \right) + \log \left(\frac{q(z)}{p(z|x_i, \theta)} \right)$$

Aplica esperanza (Des. de Jensen es $E[f(x)] \leq f(E[x])$ si $f(x)$ es cóncava)

$$\int q(z) \log p(x_i|\theta) = \int q(z) \log \frac{p(x_i|z, \theta) p(z|\theta)}{q(z)} + \underbrace{\int q(z) \log \left(\frac{q(z)}{p(z|x_i, \theta)} \right)}_{\text{lo KL}}$$

Pasa E) mínimo respecto de $q(z)$

$$\underset{\theta}{\operatorname{argmax}} \underset{q \in \mathcal{P}}{\max} \int q(z) \log \frac{p(x_i|z, \theta) p(z|\theta)}{q(z)} + \int q(z) \log \left(\frac{q(z)}{p(z|x_i, \theta)} \right)$$

Sucede cuando $q(z) = p(z|x_i, \theta)$

↪ el paso M se minimiza θ . lo KL es mínimo del paso anterior :

$$\underset{\theta}{\operatorname{argmax}} \int q(z) \log \frac{p(x_i|z, \theta) p(z|\theta)}{q(z)} \propto \underset{\theta}{\operatorname{argmax}} \int q(z) \log (p(x_i|z, \theta) p(z|\theta))$$

↗ del paso anterior

Bayes $\rightarrow$ los parámetros son realizaciones de una V.A. T con dist. a priori conocida. $p(\theta)$

Si se conoce el parámetro las muestras son iid $\therefore \ell(\theta|x) = \prod_{i=1}^n p(x_i|\theta)$

$$\wedge \quad \overset{\text{post}}{\pi(\theta|x=x)} = \frac{\overset{\text{los datos}}{p(x|\theta)} \underset{p(x)}{p(\theta)}}{p(x)} \propto p(\theta) \prod p(x_i|\theta)$$

predictivo: $p(x_{\text{test}} | \text{datos}) = \int_{\theta} p(x_{\text{test}} | \theta) \pi(\theta|x) d\theta$

Naive Bayes $\rightarrow$ Supone muestras iid y una relación de causalidad.

Variational Bayes: minimizando la KL, que es pedir que la dist. estimado sea la real.

$$\argmin_{q \in \mathcal{P}} KL(q(\cdot|x) || p(\cdot|x)) \iff \argmax_{q \in \mathcal{P}} ELBO(q)$$

$$KL = E \left[\log \frac{q(\cdot|x)}{p(\cdot|x)} \right] = E_q \left[\log q(z|x|x) \right] - E_q \left[\log p(z|x|x) \right]$$

$$KL = -H(q(z|x)) - E_q \left[\log p(z|x|x) \right] = -H(q(z|x)) - E_q \left[\log \frac{p(z,x)}{p(x)} \right]$$

$$KL = -H(q(z|x)) + E[\log p(x)|x] - E[\log p(z,x)|x]$$

$$KL = -H(q(z|x)) + \log p(x) - E[\log p(z,x)|x]$$

Ahora si $q(z|x) = q_1(u|x) q_2(\phi|x)$

$$KL = -H(q_1(u|x)) - H(q_2(\phi|x)) + \log p(x) - E[\log p(z,x)|x]$$

Si minimizamos lo KL es maximizar el negativo de esto

$$\arg\max_{q \in \mathcal{P}} H(q_1) + H(q_2) - \log P(x) + E_q[\log P(z|x)]$$

Veamos eso espere:

$$E_q[\log P(z|x)] = \int_{\mathbb{R}} q(z|x) \log P(z|x) dz =$$

$$= \int_{\mathbb{R}} \int_{\mathbb{R}} q_1(u|x) q_2(\phi|x) \log P(z|x) du d\phi \rightarrow$$

son indep. o.

$$\rightarrow \int_U q_1(u|x) \int_{\Phi} q_2(\phi|x) \log P(z|x) d\phi du = E_{q_1} \left[\underbrace{\int_{\Phi} q_2 \log P(z|x) d\phi}_{\text{lo llamo } A_{q_2}} \right]$$

o al revés (con q_2)

Si buscamos q_1 max fijos q_2 & queda:

$$\arg\max_{q_1} H_{q_1} + \int q_1(u|x) \cdot \int_{\Phi} q_2(\phi|x) P(z|x) d\phi du =$$

$$= E_{q_1}[-\log q_1] + E_{q_1}[A_{q_2}] = E_{q_1} \left[-\log \frac{e^{A_{q_2}}}{q_1} \right] \simeq -KL(e^{A_{q_2}} \| q_1)$$

$$A_{q_2} = \log e^{A_{q_2}}$$

$\uparrow$
 se minimiza con $e^{A_{q_2}} \propto q_1$

Es decir:

$$q_1 \propto e^{A_{q_2}}$$

$$q_2 \propto e^{A_{q_1}}$$

Optimalidad de $E[Y|X]$:

Partimos del ECM: $E[(Y - \phi(X))^2] \leftarrow$ lo vamos a minimizar

sumando y restando $E[Y|X]$:

$$\begin{aligned}
 E[(Y - E[Y|X] + E[Y|X] - \phi(X))^2] &= \overset{1^{er} \text{ término}}{E[(Y - E[Y|X])^2]} + \overset{2^{do} \text{ término}}{E[(E[Y|X] - \phi(X))^2]} - 2 \overset{3^{er} \text{ término}}{E[(Y - E[Y|X])(E[Y|X] - \phi(X))]} \\
 &= E[(Y - E[Y|X])^2] + E[(E[Y|X] - \phi(X))^2] - 2 E[(Y - E[Y|X])(E[Y|X] - \phi(X))] \\
 &= E[E[(Y - E[Y|X])^2|X]] + E[E[Y|X] - \phi(X)]^2 - 2 E[E[Y - E[Y|X]|X] (E[Y|X] - \phi(X))] \\
 &= E[\text{Var}(Y|X)] + E[E[Y|X] - \phi(X)]^2 - 2 E[\underbrace{(E[Y|X] - E[Y|X])}_{=0} (E[Y|X] - \phi(X))] \\
 \text{ECM} &= E[\text{Var}(Y|X)] + E[(E[Y|X] - \phi(X))^2]
 \end{aligned}$$

Se minimiza si $\phi(X) = E[Y|X]$ error bayesiano = $E[\text{Var}(Y|X)]$

Veamos el estimador lineal: $\ell(X) = \Delta X + b$

$$\text{ECM} = E[(Y - \Delta X - b)^2] = E[Y^2 + (\Delta X + b)^2 - 2Y(\Delta X + b)] = E[Y^2] + E[\Delta^2 X^2 + 2\Delta bX + b^2] - 2E[Y(\Delta X + b)]$$

$$= E[Y^2] + \Delta^2 E[X^2] + 2\Delta b E[X] + b^2 - 2\Delta E[XY] - 2b E[Y]$$

$$\frac{\partial}{\partial \Delta} = 2\Delta E[X^2] + 2b E[X] - 2E[XY]$$

$$\frac{\partial}{\partial b} = 2\Delta E[X] + 2b - 2E[Y] = 0 \rightarrow b = E[Y] - \Delta E[X]$$

$$\rightarrow \frac{\partial}{\partial \Delta} = 0 = 2\Delta E[X^2] + 2E[Y]E[X] - 2\Delta E[X]^2 - 2E[XY]$$

$$0 = 2\Delta [E[X^2] - E[X]^2] - 2(E[XY] - E[X]E[Y]) =$$

$$2\Delta \text{Var}(X) - 2\text{Cov}(X, Y) = 0 \rightarrow \Delta = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

$$\Delta X + b = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} X + E[Y] - E[X] \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

$$\Delta X + b = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} (X - E[X]) + E[Y]$$

$$\text{Var}(X) = E[(X - \mu_X)^2] = E[X^2 - 2X\mu_X + \mu_X^2] = E[X^2] - 2E[X]\mu_X + \mu_X^2 = E[X^2] - E[X]^2$$

Tomamos lo regularizado sin y con reg.

Sea $\hat{y} = Xw$ (X tiene una columna de unos δ $b \in w$)

la función costo es al ECM con algo extra:

$$J = \frac{1}{2} \sum_{i=1}^n (\delta_i - \hat{\delta}_i)^2 \xRightarrow{\text{matricial}} \frac{1}{2} \|y - \hat{y}\|^2 = \frac{1}{2} \|y - Xw\|^2$$

Regularización $l_2 \rightarrow \frac{1}{2} \|y - Xw\|^2 + \frac{\lambda}{2} \|w\|^2 \xrightarrow{w^T w}$

$$J = \frac{1}{2} \|y - Xw\|^2 = \frac{1}{2} (y - Xw)^T (y - Xw) = \frac{1}{2} (y^T - w^T X^T) (y - Xw) = \frac{1}{2} (y^T y - y^T Xw - w^T X^T y + w^T X^T X w)$$

$\nabla_w J = 0 - \frac{2}{2} X^T y + X^T X w$

sin reg $w = (X^T X)^{-1} X^T y$; $\nabla_w^2 = X^T X > 0$
 $\uparrow$ defnido positivo

con reg $+ \frac{2\lambda w}{2}$
 $0 = -X^T y + X^T X w + \lambda w$
 $w = (X^T X + \lambda I)^{-1} X^T y$

$\nabla_w^2 = X^T X + \lambda > 0$, es un mínimo
 $\uparrow$ defnido positivo $\uparrow$ positivo

Si es por gradiente descendiente: $\theta^{(n+1)} = \theta^{(n)} - \alpha \nabla J$ $\leftarrow$ nos movemos opuesto a la dirección de max crecimiento

Se linealiza ∇J en torno a un θ^* que es tal que $\nabla J(\theta^*) = 0$
 $\hookrightarrow$ cond. 1^{er} orden

$$\nabla J(\theta^n) = \nabla J(\theta^*) + H_J \cdot (\theta^n - \theta^*)$$

$$\theta^{(n+1)} = \theta^n - \alpha H_J (\theta^n - \theta^*)$$

Como H_J es simétrico y cuadrado lo descompongo en $Q \Lambda Q^T$.

$$\underbrace{\theta^{(n+1)}}_{N^{(n+1)}} - \theta^* = \underbrace{\theta^{(n)} - \theta^*}_{N^{(n)}} - \alpha Q^T \Lambda Q (\theta^n - \theta^*)$$

$$N^{(n+1)} = Q^T (1 - \alpha \Lambda) Q N^{(n)}$$

Esto motu determina la convergencia del sistema aplicado a la ECE en d.b. Como Λ es diagonal δ tiene los autovalores puede elegir como criterio de convergencia que $|1 - \alpha \lambda_{\max}| \leq 1$

• Sean A y B matrices con elementos en un anillo A y sea c $\in$ A:
 $(A + B)^t = A^t + B^t$

Demostración

Lineal

$(cA)^t = cA^t$

Demostración

• Para el producto usual de las matrices A y B,
 $(AB)^t = B^t A^t$

Es decir, que los autovalores discretos estén dentro del círculo unitario en el plano z -ts.
Esto haría que el sistema tenga polos estables como mínimo.

$$S_1 \quad |1 - \alpha \lambda_{\max}| < 1 \quad \longrightarrow \quad -1 < 1 - \alpha \lambda_{\max} < 1$$

$\uparrow$ el autovalor más grande

$$2 > \alpha \lambda_{\max} > 0$$

$$0 < \alpha < \frac{2}{\lambda_{\max}}$$

LDA & QDA $\rightarrow$ gaussianos (modelos de cjt)

$$Y \sim \text{cat} \quad X|Y = k \sim \mathcal{N}(\mu_k, \Sigma_k)$$

$$P(x) = \sum_{k=1}^K \underbrace{C_k}_{P(Y)} \underbrace{\frac{1}{2\pi^{d/2}} |\Sigma_k|^{-1/2} e^{-1/2(x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k)}}_{P(X|Y)}$$

$$P(Y|X) = \frac{P(X|Y) P(Y)}{P(X)} = \frac{C_Y \frac{1}{2\pi^{d/2}} |\Sigma_Y|^{-1/2} e^{-1/2(x-\mu_Y)^T \Sigma_Y^{-1}(x-\mu_Y)}}{\sum_k C_k \frac{1}{2\pi^{d/2}} |\Sigma_k|^{-1/2} e^{-1/2(x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k)}}$$

en LDA se cancelan x que son iguales

(uno matriz de covarianza única para las gaussianas)

El exponente es $-1/2 (x^T - \mu^T) \Sigma^{-1} (x - \mu_Y)$

$$\begin{aligned} & -1/2 x^T \Sigma^{-1} x + \frac{x^T \Sigma^{-1} \mu_Y}{2} + \frac{\mu_Y^T \Sigma^{-1} x}{2} - 1/2 \mu_Y^T \Sigma^{-1} \mu_Y \\ & = -1/2 x^T \Sigma^{-1} x + x^T \Sigma^{-1} \mu_Y - \frac{\mu_Y^T \Sigma^{-1} \mu_Y}{2} \end{aligned}$$

Como $-1/2 x^T \Sigma^{-1} x$ es invariante entre clases se cancela con el del denominador

$$\rightarrow P(Y|X) = \frac{e^{x^T \Sigma^{-1} \mu_Y - 1/2 \mu_Y^T \Sigma^{-1} \mu_Y + \log C_Y}}{\sum_k e^{x^T \Sigma^{-1} \mu_k - 1/2 \mu_k^T \Sigma^{-1} \mu_k + \log C_k}}$$

Y los μ, Σ se estiman como: $D_k = \#$ muestras de clase k

$$C_k = \frac{D_k}{n_{\text{tot}}} \quad \mu_k = \frac{1}{D_k} \sum X \quad i \ x \in \text{clase } k$$

$$\Sigma_k = \frac{1}{D_k - 1} \sum (x - \mu_k)^2 \quad \sim \quad \sum = \frac{1}{n - K} \sum^k (D_k - 1) \Sigma_k$$

$\uparrow$ para QDA $\uparrow$ para LDA $\nwarrow$ #clases

Es como un promedio

(Se clasifica con $\hat{Y} = \arg \max_Y P(Y|X)$)

En LDA $P(Y|X)$ parece un softmax, en QDA Y es un

Clasificador Bayesiano:

Minimizar el costo $\rightarrow$ la proba de equivocarse

$$P(\gamma \neq \phi(x)) = E[P(\gamma \neq \phi(x)|x)] = E[1 - P(\gamma = \phi(x)|x)] =$$

lo P de acerto

$$= 1 - E[P(\gamma = \phi(x)|x)]$$

$$\min_{\phi(x)} 1 - E[P(\gamma = \phi(x)|x)] \longrightarrow \max_{\phi(x)} E[P(\gamma = \phi(x)|x)]$$

El costo se minimiza cuando elegimos el γ más probable $\rightarrow P(\gamma = \phi(x)|x) = p_{\gamma|x}(\phi(x))$

$$\rightarrow \phi(x) = \underset{\gamma}{\operatorname{argmax}} p_{\gamma|x}(x)$$

$\uparrow$

Es decir, de la posterior usamos la clase más probable para el x .

$$\max p_{\gamma|x} \propto \max p_{x|\gamma} p_{\gamma} \leftarrow \text{podemos usar la likelihood } \text{fub}$$

Región logística binaria

→ A mi me gusta ir por máximo la likelihood → minimizar la $-\log(\text{likelihood})$

Sea $\ell(x) = \theta^T x$ el estimado $\gamma \in \{0, 1\}$ (2 clases binarias)

Sea $\sigma(z) = \frac{1}{1 + e^{-z}}$ la función sigmoide $\sigma(z): \mathbb{R} \rightarrow (0, 1)$ mapea todo z a $(0, 1)$

Imple que $\sigma'(z) = \sigma(z)(1 - \sigma(z))$

Por comodidad le aplicamos $\sigma(z)$ a $\theta^T x$ y lo llamamos $H_\theta \in (0, 1)$

$\mathbb{P}(\gamma = 1 | x, \theta) = H_\theta$ proba de clasificar como 1. (como una bernoulli)

$\mathbb{P}(\gamma = 0 | x, \theta) = 1 - H_\theta$ " " " " 0.

la likelihood $\Leftrightarrow \ell(x_i | \theta) = \prod_{i=1}^n H_\theta^{\gamma_i} (1 - H_\theta)^{1 - \gamma_i}$

→ la $-\log(\ell) = -\sum \gamma_i \log H_\theta - \sum (1 - \gamma_i) \log(1 - H_\theta) = J$

(Esto es la entropía cruzada, que se obtiene de querer minimizar la divergencia de KL de $\ell(x)$ con $p_{\gamma|x}(x)$)

Haz el gradiente $\nabla_\theta = 0 = -\sum \gamma_i \frac{1}{H_\theta} \cdot H_\theta(1 - H_\theta)x - \sum (1 - \gamma_i) \frac{1}{1 - H_\theta} (-H_\theta)(1 - H_\theta)x_i$
(buidado,
 $\nabla_\theta H_\theta = H_\theta(1 - H_\theta)x$)

$$\nabla_\theta = -\sum \gamma_i (1 - H_\theta)x_i + \sum (1 - \gamma_i) H_\theta x = 0$$

$$= -\sum (\gamma_i x_i - \cancel{\gamma_i H_\theta x_i} - H_\theta x_i + \cancel{\gamma H_\theta x_i}) = -\sum (\gamma_i - H_\theta) x_i$$

$$\nabla_\theta = -\sum x_i (\gamma_i - H_\theta(x_i)) \xrightarrow{\text{matrices}} X^T (h(X) - \gamma) \quad \text{tal vez le falta un } \frac{1}{n}$$

$$\text{con } \theta^{(n+1)} = \theta^{(n)} - \alpha \nabla_\theta$$