

2/2 → Modelos de lenguaje, sistemas de recomendación

Modelos de lenguaje

¿Cómo vectorizamos una serie de documentos?

Primera opción: one-hot-encoding. $V = \{w_1, w_2, \dots, w_{|V|}\} \rightarrow$ Vocabulario

$$w_i \rightarrow \boxed{\text{Encoder}} \rightarrow x_i = \begin{pmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{pmatrix} \in \mathbb{R}^{|V|} \quad \text{Muy bruto}$$

↘ i -ésima posición

Segunda opción: Transformación tf-idf (Term frequency - inverse document frequency)

Sea t un término y d un documento perteneciente a una colección de m documentos

$$tf(t, d) = \frac{\#(t \in d)}{|d|} \rightarrow \text{Veces que } t \text{ aparece en } d$$

$|d| \rightarrow$ cantidad de términos en d

$$\Rightarrow tf-idf(t, d) = tf(t, d) \cdot idf(t)$$

$$idf(t) = 1 - \log \frac{df(t)}{m} \rightarrow \text{Cantidad de documentos que tienen el término } t$$

$$0 < df(t) \leq n \rightarrow 0 < \frac{df(t)}{n} \leq 1 \Rightarrow -\infty < \log \frac{df(t)}{n} \leq 0$$

Una palabra q' aparece muchas veces en un solo documento tendrá un $tf(t,d)$ alto y un $idf(t)$ alto
 $\Rightarrow$ $tf-idf$ grande (la palabra caracteriza al documento)

Una palabra q' aparece muy pocas veces en casi todos los documentos tendrá $tf(t,d)$ bajo y $idf(t)$ bajo
 $\Rightarrow$ $tf-idf$ chico (la palabra podría ser de cualquier documento)

Aparece pocas veces en pocos documentos $\rightarrow$ intermedia

Aparece muchas veces en muchos documentos $\rightarrow$ "

Vectorización: cada documento puede expresarse como un vector:

$$v_d = [tf-idf(w_1, d) ; tf-idf(w_2, d) \dots tf-idf(w_{|V|}, d)]^T$$

OJO: vectoriza documentos, no palabras

Preprocesamientos comunes: - sacar las palabras no informativas (artículos, preposiciones, etc)

- " " " más comunes

- " " " menos comunes

- convertir todo a minúsculas

$$SC(u, v) = \frac{u \cdot v}{\|u\| \|v\|} \rightarrow \begin{cases} s_i = 1, & u \text{ y } v \text{ son palabras similares} \\ s_i = 0, & u \text{ y } v \text{ son palabras ortogonales} \end{cases}$$

Sistemas de recomendación y filtro colaborativo

Partimos de una base de datos $y \in \mathbb{N}^{M_{\text{items}} \times M_{\text{users}}}$, donde y_{ij} es la valoración sobre el item i -ésimo del usuario j -ésimo. $R = \{(i, j) \text{ con dato cargado}\}$. Objetivo: a partir de los datos en y , llenar los espacios vacíos. Lo haremos así:

Para algún (i, j) sin valoración: $\hat{y}_{ij} = \theta_j^\top \cdot x_i$, donde $\theta_j \in \mathbb{R}^r$, $x_i \in \mathbb{R}^r$, donde

r es la dimensión de un espacio latente y θ_j y x_i son parámetros a entrenar.

Estos parámetros los organizaremos así:

$$X = \begin{pmatrix} \sim x_1 \sim \\ \sim x_2 \sim \\ \vdots \\ \sim x_{M_{\text{items}}} \sim \end{pmatrix}, \quad X \in \mathbb{R}^{M_{\text{items}} \times r}$$

$\xleftarrow{\quad} r \text{ elementos} \xrightarrow{\quad}$

$$\theta = \begin{pmatrix} \sim \theta_1 \sim \\ \vdots \\ \sim \theta_{M_{\text{users}}} \sim \end{pmatrix}, \quad \theta \in \mathbb{R}^{M_{\text{users}} \times r}$$

$\xleftarrow{\quad} r \text{ elementos} \xrightarrow{\quad}$

Es decir, queremos entrenar m items vectores $x_i \in \mathbb{R}^r$ y m sets vectores $\theta_j \in \mathbb{R}^r$

Minimizamos el ECM, incluyendo una sana regularización L2:

$$\min_{x, \theta} \frac{1}{2} \sum_{(i,j) \in \mathcal{R}} (\theta_j^\top x_i - y_{i,j})^2 + \frac{\lambda}{2} \sum_{i=1}^{m_{it}} \|x_i\|^2 + \frac{\lambda}{2} \sum_{j=1}^{m_{us}} \|\theta_j\|^2$$

Definimos: $\min_{x, \theta} J(x, \theta)$

$$\frac{\partial J}{\partial x_i} = \sum_j (\theta_j^\top x_i - y_{i,j}) \cdot \theta_j + \lambda \cdot x_i = 0 \rightarrow \text{No se puede despejar } x_i \text{ en función de } y_{i,j} \text{ y } \lambda, \text{ pero se puede entrenar por GD.}$$

$$\frac{\partial J}{\partial \theta_j} = \sum_i (\theta_j^\top x_i - y_{i,j}) x_i + \lambda \cdot \theta_j = 0$$

Quiero llegar a la expresión: $x^{(t)} = x^{(t-1)} - \alpha \cdot \nabla_x J$ ↗ Va a depender de $x^{(t-1)}$ y de $\theta^{(t-1)}$

$$\nabla_x J \in \mathbb{R}^{mit \times w} \quad X = \begin{pmatrix} x_1^T \\ \vdots \\ x_{mit}^T \end{pmatrix} = \begin{pmatrix} x_1 & \dots & x_{mit} \end{pmatrix}^T$$

$$X - \alpha \cdot \nabla_x J = (x_1 \dots x_{mit})^T - \alpha \left(\frac{\partial J}{\partial x_1} \dots \frac{\partial J}{\partial x_{mit}} \right)^T \rightarrow \frac{\partial J}{\partial x_i} \in \mathbb{R}^r$$

→ Lo pongo acá para trabajar más cómodo

$$\Rightarrow (\nabla_x J)^T = \left[\sum_j (\theta_j^T x_1 - y_{1,j}) \cdot \theta_j + \lambda x_1 \dots \sum_j (\theta_j^T x_{mit} - y_{mit,j}) \cdot \theta_j + \lambda x_{mit} \right] =$$

→ CL de los $\theta_j \Rightarrow \Theta^T \cdot (\cdot)$

$$= \left[\sum_j \theta_j \cdot (\theta_j^T x_1 - y_{1,j}) \dots \sum_j \theta_j \cdot (\theta_j^T x_{mit} - y_{mit,j}) \right] + \lambda [x_1 \dots x_{mit}] =$$

$$= \begin{bmatrix} \Theta^T \begin{bmatrix} \theta_1^T x_1 - y_{1,1} \\ \vdots \\ \theta_{mus}^T x_1 - y_{1,mus} \end{bmatrix} \dots \Theta^T \begin{bmatrix} \theta_1^T x_{mi} - y_{mi,1} \\ \vdots \\ \theta_{mus}^T x_{mi} - y_{mi,mus} \end{bmatrix} \end{bmatrix} + \lambda X^T =$$

$$= \Theta^T \left(\begin{bmatrix} \theta_1^T \cdot x_1 & \dots & \theta_1^T x_{mit} \\ \vdots & & \vdots \\ \theta_{nvs}^T \cdot x_1 & \dots & \theta_{nvs}^T x_{mit} \end{bmatrix} - \begin{bmatrix} y_{1,1} & \dots & y_{mit,1} \\ \vdots & & \vdots \\ y_{1,nvs} & \dots & y_{mit,nvs} \end{bmatrix} \right) + \lambda X^T =$$

$$= \Theta^T (\Theta \cdot X^T - Y^T) + \lambda X^T$$

$$\Rightarrow (\nabla_x J)^T = \Theta^T (\Theta \cdot X^T - Y^T) + \lambda X^T$$

$$\Rightarrow \nabla_x J = (X \Theta^T - Y) \Theta + \lambda X \quad \checkmark$$

→ Para no agregar elementos q' no tengan rotación:

$$\nabla_x J = (X \theta^T - y) \odot R \cdot \theta + \lambda X \quad \odot: \text{producto elemento a elemento}$$

$$\nabla_\theta J = (\theta X^T - y^T) \odot R \cdot X + \lambda \theta$$

Otra forma (más fácil):

$$J(x, \theta) = \sum_{(i,j) \in R} (x_i^T \cdot \theta_j - y_{i,j})^2 + \frac{\lambda}{2} \sum_i \|x_i\|^2 + \frac{\lambda}{2} \sum_j \|\theta_j\|^2 =$$

$$= \frac{1}{2} \|X \cdot \theta^T - y\|^2 + \frac{\lambda}{2} \|X\|^2 + \frac{\lambda}{2} \|\theta\|^2$$

Prop: $\frac{\partial \|X\|^2}{\partial X} = 2X, X \in \mathbb{R}^{a \times b} \quad \|X\|^2 = \text{tr}(X^T X)$

$$(X \theta^T - y)^T (X \theta^T - y) = (\theta X^T - y^T) \cdot (X \theta^T - y) = \theta X^T X \theta^T - \theta X^T y - y^T X \theta^T + y^T y$$

→
transpuestas

$$\text{tr}((\Theta X^T - Y)^T (\Theta X^T - Y)) = \text{tr}(\Theta X^T X \Theta^T) - 2 \text{tr}(\Theta X^T Y) + \text{tr}(Y^T Y)$$

$$\Rightarrow J(X, \Theta) = \frac{1}{2} \text{tr}(\Theta X^T X \Theta^T) - \text{tr}(\Theta X^T Y) + \frac{1}{2} \text{tr}(Y^T Y) + \frac{\lambda}{2} \text{tr}(X^T X) + \frac{\lambda}{2} \text{tr}(\Theta^T \Theta)$$

$$\begin{aligned} \frac{\partial J}{\partial X} &= X \Theta^T \Theta - Y \Theta + 0 + \lambda X = \\ &= \underline{(X \Theta^T - Y) \Theta} + \lambda X \end{aligned}$$

$$\begin{aligned} \frac{\partial J}{\partial \Theta} &= \Theta X^T X - X^T Y + 0 + \lambda \Theta = \\ &= \Theta X^T X - Y^T X + \lambda \Theta = \\ &= \underline{(\Theta X^T - Y^T) X} + \lambda \Theta \end{aligned}$$

Prop 1:

$$\frac{\partial}{\partial X} \text{tr}(B X^T X B^T) = 2 X B^T B$$

$$\frac{\partial}{\partial X} \text{tr}(A X B) = B \cdot A$$

$$\begin{aligned} \frac{\partial}{\partial X} (X B X^T) &= X B^T + X B \\ &= 2 X B \text{ si } B^T = B \end{aligned}$$

Más fácil todavía: $J(x, \theta) = \frac{1}{2} \|X \cdot \theta^T - y\|^2 + \frac{\lambda}{2} \|x\|^2 + \frac{\lambda}{2} \|\theta\|^2$

$$\|X\theta^T - y\|^2 \xrightarrow{\partial/\partial x} (X\theta^T - y) \cdot \theta$$

$$\frac{\partial Xx^T}{\partial x} = A \rightarrow \text{Esto es incorrecto,}$$

pero podés hacer de
cuenta q' me.

$$\|X\theta^T - y\|^2 = \|\theta x^T - y^T\|^2 \xrightarrow{\partial/\partial \theta} (\theta x^T - y^T) \cdot x$$

$$\|x\|^2 \xrightarrow{\partial/\partial x} 2x$$

$$\|\theta\|^2 \xrightarrow{\partial/\partial \theta} 2\theta$$

**V ME DEJÁS DE ROMPER
LAS PELOTAS**

Falta un detalle: ¿Qué pasa con los pares (i, j) q' no tienen valoración?

$$\text{Así como está: } \|X\theta^T - y\|^2 = \sum_{\forall (i,j)} (x_i^T \cdot \theta_j - y_{i,j})^2$$

Corrijo con la matriz R / $R_{i,j} = \mathbb{1} \{ (i,j) \in R \}$

$$\rightarrow \|R \odot (X\theta^T - y)\|^2 = \sum_{\forall (i,j)} R_{i,j}^2 \cdot (x_i^T \theta_j - y_{i,j})^2 = \sum_{(i,j) \in R} (x_i^T \theta_j - y_{i,j})^2$$

Que era lo q' quería en primer lugar

$R \odot (X \theta^T - y) = R \odot E \rightarrow$ No estoy intentando valoraciones, estoy diciendo que las posiciones sin valoración no suman al error (y por lo tanto no van a influir en la minimización)

La predicción final puede tener distintas formas según convenga

$$\hat{y}_{i,j} = \underset{\substack{\downarrow \\ \text{hiperparámetro}}}{p} \cdot (x_i^T \cdot \theta_j) + (1 - p) \cdot \bar{y}_i$$

$\nearrow$ valoración
promedio de las
usuales

	Andrea	Bluma	Camila
Item 1		✓	✓
2	X	✓	
3			X
4	✓	X	
5		✓	✓

Se desea hacer una recomendación a Camila sobre el item 4

$$x_4 = [1/4 \quad 1/4]^T$$

$$\theta_c = [-1/2 \quad -1/2]^T$$

Ponderar a partes iguales el filtro y el valor promedio

$$\bar{y}_4 = \frac{1 + 0}{2} = 1/2$$

$$\hat{y}_{4,c} = \frac{1}{2} x_4^T \cdot \theta_c + \frac{1}{2} \bar{y}_4 = \frac{1}{2} [1/4 \quad 1/4] \begin{bmatrix} -1/2 \\ -1/2 \end{bmatrix} + \frac{1}{2} \cdot \frac{1}{2} =$$

$$\frac{1}{2} \cdot \cancel{2} \cdot -\frac{1}{2} + 1/4 = 1/8$$