

Regla mala

¿Qué significa aprendizaje
(No) supervisado?

28/01 → Hasta PCA

Supervisado → Tenemos un conjunto de datos x_i y datos (regresión) o etiquetas (clasificación) $y_i \rightarrow \{(x_i, y_i)\}_{i=1}^n$

Nuestro objetivo último es estimar la distribución de $Y|X=x$

No supervisado → Tenemos los mismos datos x_i y solo algunos o ningún y_i .

Nos interesa estudiar el conjunto $\{(x_i)\}_{i=1}^n$, tiene valor intrínseco.

Estaremos estudiando $p_X(x)$. Esto nos puede interesar para:

- 1) aplicar como etapa de preprocesamiento a un algoritmo supervisado (semi-supervisado)
- 2) aplicaciones intrínsecamente no supervisadas, como el detector de anomalías
- 3) Reducir dimensiones

Autoencoders: $x \in \mathbb{R}^{d_x}$



$\rightarrow$ Si $\mathbb{Z}$ es un conjunto finito

como $\{1, 2, 3\}$ hablamos de clustering

$\rightarrow$ Si $\mathbb{Z} = \mathbb{R}^{d_z}$ con $d_z < d_x$ hablamos de aprender el manifold o de reducción de la dimensionalidad

Algoritmos semisupervisados: Estudiar primero p_x puede o no ser relevante para estudiar $p_{y|x}$ ¿cuándo sí será relevante?

Mecanismo Causal:



$$p_{x,y} = p_{y|x=x}(y) \cdot p_x(x)$$

No habla relación entre

p_x y $p_{y|x=x}$. no tiene

sentido una etapa supervisada

Mecanismo anticausal:




$$p_{x,y} = p_{x|y=y}(x) \cdot p_y(y)$$

No hay relación entre p_y y $p_{x|y=y}$, pero


sí entre p_x y $p_{y|x=x}$. Tiene sentido una etapa supervisada

Mecanismo no causal:



Parece q' siempre hay un modelo no causal y un modelo causal, pero uno es más simple q' el otro. Elegimos creer en el más simple

Ejemplo 4.1 Estudiar la relación de causalidad para $(X, Y) \sim \mathcal{U}(\Lambda)$, donde Λ es de la forma:



En este tipo de ejercicios tenemos que analizar si es más sencillo descomponer la distribución conjunta como $p_{XY}(x, y) = p_{Y|X=x}(y)p_X(x)$ o como $p_{XY}(x, y) = p_{Y|X=x}(y)p_X(x)$. Este ejemplo en particular caracteriza las distribuciones condicionales como:

$$Y|_{X=x} \sim \mathcal{U}(x, x+1) \equiv x + \mathcal{U}(0, 1), \quad X|_{Y=y} \sim \begin{cases} \mathcal{U}(0, y) & 0 < y < 1 \\ \mathcal{U}(y-1, 1) & 1 < y < 2 \end{cases} \quad (4.1)$$

$\hookrightarrow$ más simple
más complejo

Elegimos creer que $X \rightarrow Y$, $p_{XY} = p_{Y|X=x} \cdot p_X$

3.1 Dos variables físicas (X, Y) poseen una densidad de probabilidad conjunta de la forma

$$p_{XY}(x, y) = \frac{e^{-(2x + \frac{y}{4x+2})}}{2x+1} \cdot \mathbb{1}\{x > 0, y > 0\}.$$

Encontrar un mecanismo simple que permita generar una de las variables aleatorias en función de la otra y un ruido independiente. Sugiera que variable posiblemente sea la causa y cual el efecto.

👁: Notar que si $T \sim \mathcal{E}(\lambda)$, entonces $kT \sim \mathcal{E}(\lambda/k)$ con $k > 0$.


$$p_{XY}(x, y) = 2 e^{-2x} \mathbb{1}\{x > 0\} \cdot \frac{1}{2x+1} \cdot e^{-\frac{y}{4x+2}} \mathbb{1}\{y > 0\} =$$

$$= 2 e^{-2x} \mathbb{1}\{x > 0\} \cdot \frac{1}{4x+2} e^{-\frac{1}{4x+2} \cdot y} \mathbb{1}\{y > 0\}$$

$p_X \sim \mathcal{E}(2)$
 $p_{Y|X=x} \sim \mathcal{E}(\frac{1}{4x+2})$

Descomponerlo en $p_Y \cdot p_{X|Y=y}$ sería demasiado difícil

Reducción de la dimensionalidad: No sirve aprender cualquier biyección.



$\rightarrow$ con un ancho suficientemente fino puedo reconstruir cualquier valor, pero ¿qué aprendí? Para evitar esto existen los detectores de anomalías: tengo un dato x anómalo, lo transformo $y = T(x)$ y lo reconstruyo $T^{-1}(y) = \hat{x}$

→ Si verdaderamente aprendí el manifold el error $(x - \hat{x})^2$ será grande

→ Si aprendí cualquier cosa, $(x - \hat{x})^2$ será chico

Ejemplo 4.3 Se utiliza un autoencoder para implementar un detector de anomalías.

Los errores cuadráticos de cada muestra fueron

0.1, 0.8, 1.3, 1.9, 2.2

→ anómalo

↪ anómalo

Sabiendo que las únicas muestras realmente anómalas fueron las de error 1.3 y 2.2.

- Graficar la curva ROC. Indicar los puntos correspondientes a todos los umbrales posibles e interporlar dichos puntos con rectas.
- Indicar el EER y el AUC, basado en la interpolación anterior.

ROC: TPR vs. FPR Detector de anomalías con umbral t : $\phi(x) = \mathbb{1}\{(x - \hat{x})^2 > t\}$

$Y \sim \text{Ber}$ $Y = 1$ si es anómalo. $\phi = 1$ si la detecta como anómalo. Es un problema de clasificación binaria.

$FPR = \mathbb{P}(\phi = 1 \mid Y = 0)$ $TPR = \mathbb{P}(\phi = 1 \mid Y = 1)$

Hay 6 intervalos de interés para t

i) $0 \leq t \leq 0,1 \rightarrow$ Son todos anómalos $TPR = \frac{\#(\varphi=1, y=1)}{\# y=1} = \frac{2}{2} = 1$
 $\rightarrow$ punto $(1, 1)$

$$FPR = \frac{\#(\varphi=1, y=0)}{\# y=0} = \frac{3}{3} = 1$$

ii) $0,1 < t \leq 0,8$ 0.1, 0.8, 1.3, 1.9, 2.2 $\rightarrow$ detectados como anómalos

$$TPR = 2/2 = 1 \rightarrow (2/3, 1)$$


$$FPR = 2/3 = 0,6$$

iii) $0,8 < t \leq 1,3$ 0.1, 0.8, 1.3, 1.9, 2.2 $TPR = 2/2$ $FPR = 1/3 \rightarrow (1/3, 1)$

iv) $1,3 < t \leq 1,9$ 0.1, 0.8, 1.3, 1.9, 2.2 $TPR = 1/2$ $FPR = 1/3 \rightarrow (1/3, 1/2)$

v) $1,9 < t \leq 2,2$ $TPR = 1/2$ $FPR = 0/3 \rightarrow (0, 1/2)$

vi) $2,2 < t$ $TPR = 0$ $FPR = 0 \rightarrow (0, 0)$



$$AUC = 1 - \frac{1}{3} \cdot \frac{1}{2} = 5/6$$

$EER = P(\varphi = 1 | Y = 0) = 1 - P(\varphi = 1 | Y = 1) = P(\varphi = 0 | Y = 1)$
 o sea, los errores $\varphi = 1 | Y = 0$ y $\varphi = 0 | Y = 1$ tienen la misma probabilidad

$$EER = 1/3$$

PCA


Vamos a proyectar sobre un subespacio, así que es obligatorio normalizar en la media

Podés normalizar en varianza si querés comparar cosas o resolver problemas numéricos

Si las muestras originales son $\{x_i\}_{i=1}^m$ a las muestras centradas las llamamos $\{\tilde{x}_i\}_{i=1}^m$

A cada muestra la proyectaremos sobre una dirección principal indicada por el vector

$v_1 \rightarrow \tilde{x}_i$ se proyecta a $\alpha_i \cdot v_1$



la dirección principal será aquella que minimice el error entre $\tilde{x}_i$ y $\alpha_i \cdot v_1$

$$\Rightarrow v_1 = \underset{v_1 \in \mathbb{R}^{dx}: \|v_1\|=1}{\operatorname{argmin}} \quad \frac{1}{n} \sum_{i=1}^n \|\tilde{x}_i - \alpha_i v_1\|^2 \quad \text{tq} \quad v_1^T (\tilde{x}_i - \alpha_i v_1) = 0 \quad \forall i$$

Este es el planteo del problema de PCA. Se resuelve así:

Primero: $v_1^T (\tilde{x}_i - \alpha_i v_1) = v_1^T \tilde{x}_i - \alpha_i v_1^T v_1 = v_1^T \tilde{x}_i - \alpha_i = 0$

$$\Rightarrow \alpha_i = v_1^T \tilde{x}_i$$

segundo: $\|\tilde{x}_i - \alpha_i v_1\|^2 = (\tilde{x}_i - \alpha_i v_1)^T (\tilde{x}_i - \alpha_i v_1) =$

$$= \|\tilde{x}_i\|^2 - 2 \alpha_i v_1^T \tilde{x}_i + \alpha_i^2 \|v_1\|^2 = \|\tilde{x}_i\|^2 - 2 \alpha_i^2 + \alpha_i^2 =$$

$$= \|\tilde{x}_i\|^2 - \alpha_i^2 = \|\tilde{x}_i\|^2 - (v_1^T \tilde{x}_i)^2$$

tercero: $v_1 = \arg \min_{v_1 \in \mathbb{R}^{dx}: \|v_1\|^2 = 1} \frac{1}{n} \sum_{i=1}^n \|\tilde{x}_i - \alpha_i v_1\|^2 =$

cte, no depende de v_1

$$= \arg \min \frac{1}{n} \sum \|\tilde{x}_i\|^2 - \frac{1}{n} \sum (v_1^T \tilde{x}_i)^2 =$$

cambia el min por max

$$= \arg \max \frac{1}{n} \sum_{i=1}^n v_1^T \tilde{x}_i \cdot v_1^T \tilde{x}_i, \text{ obs: } v_1^T \tilde{x}_i = \tilde{x}_i^T v_1$$

$$= \arg \max \frac{1}{n} \sum_{i=1}^n v_1^T \tilde{x}_i \cdot \tilde{x}_i^T v_1$$

$$= \arg \max v_1^T \left(\frac{1}{n} \sum_{i=1}^n \tilde{x}_i \cdot \tilde{x}_i^T \right) v_1$$

matriz de covarianza

$$= \arg \max_{v_1 \in \mathbb{R}^{dx}} v_1^T \cdot \Sigma \cdot v_1 \quad \text{tq} \quad \|v_1\|^2 - 1 = 0$$

$$\text{o} \quad v_1^T v_1 - 1 = 0$$

cf
Lagrangian: $J(v_1) = v_1^T \Sigma v_1 - \lambda (\|v_1\|^2 - 1)$ Recordar: $\frac{\partial \|v_1\|^2}{\partial v_1} = 2 v_1$

$$\frac{\partial}{\partial v_1} J(v_1) = (\Sigma^T + \Sigma) v_1 - \lambda 2 v_1 =$$

$$= 2 \Sigma v_1 - 2 \lambda v_1 = 0$$

$$\frac{\partial}{\partial v_1} (v_1^T A v_1) = (A^T + A) v_1$$

$$\Rightarrow \boxed{\Sigma v_1 = \lambda v_1} \Rightarrow \lambda \text{ y } v_1 \text{ son ara y ave de } \Sigma$$

$$\Rightarrow \arg \max_{v_1} v_1^T \Sigma v_1 = \arg \max_{v_1} \lambda \cdot \|v_1\|^2 = \arg \max_{v_1} \lambda$$

eso: λ depende de v_1 , xq' para cada ara hay un único ave unitario

$\rightarrow v_1$ es el ave asociado al mayor autovale

El encoder funciona así: Proyectamos sobre $Z = \mathbb{R}^{d_z}$. $V \in \mathbb{R}^{d_x \times d_z}$ es la matrix con los primeros d_z axes

$$\rightarrow V = \begin{pmatrix} | & | & & | \\ v_1 & v_2 & \dots & v_{d_z} \\ | & | & & | \end{pmatrix}$$

Encoder: $z = V^T \cdot x$

Decoder: $\hat{x} = V \cdot z$

OJO: $V \cdot V^T = I$ solo si $V \in \mathbb{R}^{d_x \times d_x}$, i.e., si usa todos los axes y V es cuadrada

30/1 $\rightarrow$ k-means y EM

Clustering

A cada dato x_i le agregaremos una etiqueta $k \in \Sigma = \{1, 2, \dots, K\}$


Es la versión no supervisada de clasificación

Decodificación: dada la clase k devolver el centroide $\hat{x}_k$

Aplicación importante: evitar la paradoja de Simpson

$\rightarrow$ Si observo la tendencia total veo una cosa, pero si primero separo las clases veo otra.

Si primero aplico k-means
estoy analizando el
manifold



K-means: Inicialización $\rightarrow$ Elegir K muestras al azar, que serán los centroides μ_k

M: minimización $\rightarrow$ a cada x_i le asigna una clase z_i según:

$$z_i = \arg \min_{k \in \mathbb{Z}} \|x_i - \mu_k\|$$

E: Expectación $\rightarrow$ recalcular los centroides

$$\mu_k = \frac{1}{|I_k|} \sum_{i \in I_k} x_i \quad \text{donde } I_k = \{i / z_i = k\}$$


$\rightarrow$ Agregar la condición de corte que más te guste

! Importante: Al ser la inicialización aleatoria, hay q' correr el algoritmo varias veces y asegurar q' sea consistente

$\rightarrow$ Este paso se llama expectación xq' lo q' se calcula es una expectativa (o valor esperado)

Ejemplo 4.4 Clusterizar, via algoritmo K-means, el siguiente conjunto de datos. Inicializar los centroides como (0,3) y (1,1). Indicar los resultados parciales de cada paso del algoritmo.

idx	x_1	x_2
0	0	3
1	1	1
2	2	0
3	3	2



$$Z = \{1, 2\}$$

$IT=1) M)$

i	z_i	x_1	x_2
0	1	0	3
1	2	1	1
2	2	2	0
3	2	3	2

E) $u_1 = (0, 3)$

$u_2 = (2, 1)$

$IT=2) M)$

i	z_i	x_1	x_2
0	1	0	3
1	2	1	1
2	2	2	0
3	2	3	2

E) $u_1 = (0, 3)$

$u_2 = (2, 1)$

$\left\{ \begin{array}{l} \rightarrow \text{No cambian los} \\ \text{centroides, termina} \end{array} \right.$

Expectación-Maximización

Antes de avanzar cabe hacer un par de aclaraciones:

$\vec{x} \rightarrow$ vector de muestras iid

$$p(\vec{x}) = \prod_i p_x(x_i) \quad \log p(\vec{x}) = \sum_i \log p_x(x_i)$$

Primero se presenta la versión general de EM, pero en realidad para trabajar con EM se necesita asumir un modelo para los datos. Típicamente se modelan como una mezcla de Gaussianas, donde hay una variable latente z que (típicamente) se distribuye $z \sim \text{Cat}\{c_1, c_2, \dots, c_K\}$. z es la mezcladora. Se llama latente x q' uno no la observa directamente pero subyacentemente está ahí.

Luego los datos se modelan como: $x|z=k, \theta_k \sim \mathcal{N}(\theta_k)$, con $\theta_k = (\mu_k, \Sigma_k)$

x y z tienen una distribución conjunta q' depende de los parámetros θ

$$(x, z) \sim p(x, z|\theta) = p(x|z, \theta) \cdot p(z|\theta) = p(z|x, \theta) \cdot p(x|\theta)$$

También trabajaremos con $q(z|x)$, una distribución auxiliar que tenderá a $p(z|x, \theta)$, pero que solo depende de los datos observados x .

Pero todas estas son asunciones particulares.

EM, en general, es así:

Nuestro objetivo último es determinar $p_X(x)$. Asumiremos que p_X es una distribución con parámetros $\theta \in \Theta$ (x'ej $\theta = (\mu=1, \sigma^2=4)$).

Para hallar esos parámetros podríamos maximizar la verosimilitud de las muestras observadas

$$\hat{\theta}_{MV} = \arg \max_{\theta \in \Theta} p(\vec{x}|\theta) = \arg \max_{\theta \in \Theta} \prod_i p(x_i|\theta) = \arg \max_{\theta \in \Theta} \sum_i \log p_X(x_i|\theta)$$

OBS interesante (pero irrelevante): maximizar la log-verosimilitud equivale a minimizar la entropía cruzada empírica

Recordar que

$$\hat{\theta}_{MV} = \arg \max_{\theta \in \Theta} \sum_i \log p_X(x_i|\theta) = \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_i -\log p(x_i|\theta) \quad \frac{1}{n} \sum_i -\log p_X(x_i|\theta) \approx \mathbb{E}[-\log p_X(X|\theta)]$$

Siguiendo con EM: habrá un vector aleatorio z q' representará las variables no observadas del problema. Tendrá una distribución $p_Z(\cdot|x, \theta) \in \mathcal{P}$, donde $\mathcal{P}$ es cierta familia de distribuciones.

Por otro lado, estará $q(\cdot|\vec{x}) \in \mathcal{P}$, otra distribución que tenderá a parecerse a $p_Z(\cdot|x, \theta)$ a medida que el algoritmo itere. $\hat{\theta}_{MV}$ puede escribirse:

observación: no depende de θ

$$\hat{\theta}_{MV} = \arg \max_{\theta \in \Theta} \log p(\vec{x}|\theta) = \arg \max_{\theta \in \Theta} \max_{q \in \mathcal{P}} \left[\log p(\vec{x}|\theta) - KL(q(\cdot|\vec{x}) \| p_Z(\cdot|\vec{x}, \theta)) \right]$$

→ ELBO(θ, q)

La igualdad vale $xq \text{ KL} \geq 0$ siempre. observar que:

$$\max_{q \in \mathcal{P}} \log(\vec{x}|\theta) - \text{KL}(q||p) = \log(\vec{x}|\theta), \text{ y recupera la igualdad original}$$

$\downarrow$
 $q = p$

La igualdad es válida, y más q' resolver el problema parece complicarlo. Pero la gracia viene acá: EM propone resolver el problema de forma iterativa, resolviendo $\max_{q \in \mathcal{P}}$ y luego $\arg \max_{\theta \in \Theta}$ y así partiendo de un $\theta_0 \in \Theta$. Sea $t \in \mathbb{N}$, la iteración del algoritmo

$$E) q^{(t)} = \arg \max_{q \in \mathcal{P}} \text{ELBO}(\theta^{(t-1)}, q) = \arg \max_{q \in \mathcal{P}} \log p(\vec{x}|\theta^{(t-1)}) - \text{KL}(q(\cdot|\vec{x}) || p(\cdot|\vec{x}, \theta^{(t-1)}))$$

$$M) \theta^{(t)} = \arg \max_{\theta \in \Theta} \text{ELBO}(\theta, q^{(t)}) = \arg \max_{\theta \in \Theta} \log p(\vec{x}|\theta) - \text{KL}(q^{(t)}(\cdot|\vec{x}) || p(\cdot|\vec{x}, \theta))$$

Propiedad importante: la convergencia a $\hat{\theta}_{\text{mv}}$ no está asegurada, pero en cada paso

la verosimilitud solo puede mejorar.

$$\rightarrow p(\vec{x}|\theta^{(t-1)}) \leq p(\vec{x}|\theta^{(t)})$$

D/ En cada iteración la ELBO aumenta ya q' se trata de maximizaciones sucesivas
(q se va pareciendo cada vez más a p y $KL \rightarrow 0$)

Paso M

Paso E

$$\rightarrow ELBO(\theta^{(t-1)}, q^{(t)}) \xrightarrow{\text{Paso M}} ELBO(\theta^{(t)}, q^{(t)}) \xrightarrow{\text{Paso E}} ELBO(\theta^{(t)}, q^{(t+1)})$$

si $q^{(t)}$ es tq. $KL = 0$

$$\Rightarrow ELBO(\theta^{(t-1)}, q^{(t)}) = \log p(\vec{x} | \theta^{(t-1)}) + 0$$

$$\rightarrow ELBO(\theta^{(t)}, q^{(t)}) = \log p(\vec{x} | \theta^{(t)}) + 0$$

$$\Rightarrow ELBO(\theta^{(t)}, q^{(t+1)}) = \log p(\vec{x} | \theta^{(t)}) + 0$$

$$\Rightarrow \log p(\vec{x} | \theta^{(t-1)}) \leq \log p(\vec{x} | \theta^{(t)})$$

$$\Rightarrow \boxed{p(\vec{x} | \theta^{(t-1)}) \leq p(\vec{x} | \theta^{(t)})}$$

va no depende de q, así q' el paso E no hace nada y $q^{(t+1)} = q^{(t)}$

Nota: si no querés andar usando $\vec{x}$ el ELBO puede escribirse así:

$$\text{ELBO}(\theta, q) = \log p(\vec{x}|\theta) - \text{KL}(q(\cdot|\vec{x}) \parallel p(\cdot|\vec{x}, \theta)) = \sum_{i=1}^n \log p(x_i|\theta) - \text{KL}(q(\cdot|x_i) \parallel p(\cdot|x_i, \theta))$$

Trabajemos con el término del ELBO, ya que así como está no se puede hacer nada

Recordar: $\text{KL}(q(\cdot|x) \parallel p(\cdot|x, \theta)) = \sum_{z \in \text{sup}} \log \frac{q(z|x)}{p(z|x, \theta)} \cdot q(z|x) = \mathbb{E}_q \left[\log \frac{q(z|x)}{p(z|x, \theta)} \mid x=x \right]$

Cada término de la sumatoria del ELBO te queda:

$$\log p(x_i|\theta) - \mathbb{E}_q \left[\log \frac{q(z|x_i)}{p(z|x_i, \theta)} \mid x_i=x_i \right] = \mathbb{E}_q \left[\log p(x_i|\theta) + \log \frac{p(z|x_i, \theta)}{q(z|x_i)} \mid x_i=x_i \right] = \mathbb{E}_q[\cdot | X=x] = \int (\cdot) \cdot q(z|x) \cdot dz$$

conjunta

$$= \mathbb{E}_q \left[\log \frac{p(z|x_i, \theta) \cdot p(x_i|\theta)}{q(z|x_i)} \mid x_i=x_i \right] = \mathbb{E}_q \left[\log p(x_i, z|\theta) - \log q(z|x_i) \mid x_i=x_i \right] =$$

$$= \mathbb{E}_q \left[\log p(x_i, z|\theta) \mid x_i=x_i \right] + \mathbb{E}_q \left[-\log q(z|x_i) \mid x_i=x_i \right]$$

La condición $X=x$ significa q' la densidad q' uso como peso en la esperanza es $q(z|x)$ y no $q(z)$ nada más

→ El segundo término no depende de θ , el paso de maximización $\arg \max_{\theta \in \Theta}$ se

convierte en:

M) $\arg \max_{\theta \in \Theta} \sum_{i=1}^n \mathbb{E}_{q^{(t)}} [\log(x_i, z_i | \theta) | x_i = x_i] \rightarrow$ Hay q' derivar¹ respecto a θ e igualar a 0, pero tenemos q' asumir una distribución para (x, z)

En el paso E simplemente harás $q^{(t)}(z | \vec{x}) = p(z | \vec{x}, \theta^{(t-1)})$

→ otra vez, tenés q' asumir una distribución para $p(\cdot | x, \theta)$

En síntesis: El problema original era:

$$\hat{\theta}_{MV} = \arg \max_{\theta \in \Theta} \max_{q \in \mathcal{P}} \frac{1}{n} \sum_{i=1}^n \log p(x_i | \theta) - KL(q(\cdot | x_i) || p(\cdot | x_i, \theta))$$

EM propone resolver el problema en 2 pasos:

0) Inicializo $\theta^{(0)}$

E) $q^{(t)}(z | \vec{x}) = p(z | \vec{x}, \theta^{(t-1)}) \rightarrow \max_{q \in \mathcal{P}} \rightarrow$ minimizo la KL para $\theta = \theta^{(t-1)}$ fijo

M) $\theta^{(t)} = \arg \max_{\theta \in \Theta} \sum_{i=1}^n \mathbb{E}_{q^{(t)}} [\log p(x_i, z_i | \theta) | x_i = x_i]$

Ejemplo 4.5 Los habitantes de Smallville pueden ser considerados trabajador registrado, trabajador informal o desempleado con probabilidades $\frac{\theta}{2}$, $\frac{1-\theta}{2}$ y $\frac{1}{2}$ respectivamente, donde $0 \leq \theta \leq 1$. El municipio posee 10.000 habitantes y cuenta con 4.000 trabajadores registrados.

1. Estimar θ por máxima verosimilitud.
2. Deducir matemáticamente una recursión, vía algoritmo EM, que permita estimar θ .
3. Se denomina puntos fijos a los valores de θ que no varían al iterar un paso del algoritmo. Encontrar los puntos fijos del problema de recursión definido por EM.
4. ¿A que punto converge el problema si $\theta_0 = 0.999$? Analizar resultado.

1) X : # trabajadores registrados

Y : # Informales

Z : # Desempleados

$$X|p \sim \text{Bim}(n=10.000, p=\theta/2) = \binom{n}{x} p^x (1-p)^{n-x}$$

observo $x=4.000$

$$\hat{p}_{MV} = \arg \max_p \log p(x|p)$$

$$\log p(x|p) = \log \binom{n}{x} + x \log p + (n-x) \log (1-p)$$

$$\frac{\partial}{\partial p} = \frac{x}{p} + (n-x) \frac{1}{1-p} \cdot (-1) = x/p + (x-n)/(1-p) = \frac{x(1-p) + p(x-n)}{p(1-p)} = \frac{x - p \cdot n}{p(1-p)} = 0$$

$$\Rightarrow p = x/n \quad \text{y si} \quad p = \frac{\theta}{2} = x/n \Rightarrow \hat{\theta}_{MV} = 2 \cdot x/n = 4/5$$

$$\boxed{\hat{\theta}_{MV} = 4/5}$$

2) La variable que yo observo es $X \sim \text{Bim}(n=10.000, p=\theta/2)$

Tengo q' elegir la variable latente, eso ya depende de cómo esté planteado el problema.

Las posibles variables latentes son Y y Z , las cuales no observo. Elijo Z como variable latente

$$Z|X=4k \sim \text{Bim}(n=6.000, p_z) \quad \text{Donde} \quad p_z = \mathbb{P}(\text{Desempleado} | \text{No es registrado}) = \frac{\mathbb{P}(\text{Des, No reg})}{\mathbb{P}(\text{No reg})} = \frac{\mathbb{P}(\text{Des})}{\mathbb{P}(\text{No reg})} = \frac{1/2}{1-\theta/2} = \frac{1}{2-\theta}$$

$\downarrow$
 $10k - 4k$

$\Rightarrow z | X=4000, \theta \sim \text{Bin}(n=6k, p = \frac{1}{2-\theta}) \rightarrow$ De acá saco $p(y|\vec{x}, \theta^{(t-1)})$ para el paso E

Para el paso M necesito la distribución de (X, z) , $p(x, y|\theta)$

$$(X, Y, Z) \sim M(n=10000, \theta/2, \frac{1-\theta}{2}, 1/2)$$

$$(X, Z) \sim ? \quad p(x, y) = p(y|x) \cdot p(x) \quad z | X=x, \theta \sim \text{Bin}(10k-x, p = \frac{1}{2-\theta}) = \binom{10k-x}{y} \left(\frac{1}{2-\theta}\right)^y \left(\frac{1-\theta}{2-\theta}\right)^{10k-x-y}$$

$$X \sim \text{Bin}(10k, \theta/2) = \binom{10k}{x} \left(\frac{\theta}{2}\right)^x \cdot \left(\frac{2-\theta}{2}\right)^{10k-x}$$

$$p(x, y|\theta) = \binom{10000-x}{y} \left(\frac{1}{2-\theta}\right)^y \left(\frac{1-\theta}{2-\theta}\right)^{10k-x-y} \cdot \binom{10k}{x} \left(\frac{\theta}{2}\right)^x \left(\frac{2-\theta}{2}\right)^{10k-x} \propto \rightarrow \text{maximizar sobre } \theta, \text{ todo lo q' no tenga a } \theta \text{ lo dejo } x \text{ q'}$$

dsp se cancela con la derivada

$$\propto \underbrace{(2-\theta)^{-y}} \underbrace{(2-\theta)^{-10k+x+y}} (1-\theta)^{10k-x-y} \cdot \theta^x \underbrace{(2-\theta)^{10k-x}} =$$

$$= (1-\theta)^{10k-x-y} \cdot \theta^x \Rightarrow p(x, y) = k \cdot (1-\theta)^{10k-x-y} \cdot \theta^x$$

$$\log p(x, y|\theta) = \log k + (10000 - x - y) \cdot \log(1-\theta) + x \log(\theta)$$

$$\text{Busco } \mathbb{E}_{q(t)} [\log p(x, z|\theta) | X=x] = \mathbb{E}_{q(t)} [\log p(4000, z|\theta) | X=4000]$$

$$\mathbb{E}_{q^{(t)}} [\log p(4000, z | \theta) | X = 4000] = \mathbb{E}_{q^{(t)}} [\log k + (6000 - z) \cdot \log(1 - \theta) + 4000 \log(\theta) | X = 4000] =$$

$$= \log k + 4000 \log \theta + \log(1 - \theta) \cdot [6000 - \mathbb{E}_{q^{(t)}} [z | X = 4000]]$$

$$q^{(t)} = p(y | X = 4000, \theta^{(t-1)}) \sim \text{Bin}\left(6000, \frac{1}{2 - \theta^{(t-1)}}\right)$$

$$\Rightarrow \mathbb{E}_{q^{(t)}} [z | X = 4000] = \sum y \cdot p(y | X = 4000, \theta^{(t-1)}) = 6000 \cdot \frac{1}{2 - \theta^{(t-1)}} \quad \text{cte calculada en el paso anterior}$$

$$\Rightarrow \mathbb{E}_{q^{(t)}} [\log p(4000, z | \theta) | X = 4000] = \log k + 4000 \log \theta + \log(1 - \theta) \cdot 6000 \cdot \left(1 - \frac{1}{2 - \theta^{t-1}}\right)$$

$$= \log k + 4000 \log \theta + \log(1 - \theta) \cdot 6000 \cdot \frac{1 - \theta^{(t-1)}}{2 - \theta^{(t-1)}}$$

$$M) \theta^{(t)} = \arg \max_{\theta \in \mathbb{R}} \mathbb{E}_{q^{(t)}} [\log p(x, z | \theta) | X = x] \rightarrow \text{derivar e igualar a 0 para despejar } \theta^{(t)}$$


$$\frac{\partial}{\partial \theta} E_{q(t)} [\log p(4000, z | \theta) | X = 4000] = 0 + \frac{4000}{\theta} + 6000 \cdot \frac{1 - \theta^{(t-1)}}{2 - \theta^{(t-1)}} \cdot \frac{1}{1 - \theta} (-1) = 0$$

$$\frac{4000}{\theta} = 6000 \cdot \frac{1 - \theta^{(t-1)}}{2 - \theta^{(t-1)}} \cdot \frac{1}{1 - \theta} = A \cdot \frac{1}{1 - \theta}$$

$$\frac{\theta}{4000} = \frac{1}{A} (1 - \theta) = 1/A - \theta/A \rightarrow \theta (1/4000 + 1/A) = 1/A$$

$$\theta = \frac{1/A}{1/4000 + 1/A} = \frac{1}{A/4000 + 1} = \frac{1}{\frac{6}{4} \frac{1 - \theta^{t-1}}{2 - \theta^{t-1}} + 1} = \frac{4 \cdot (2 - \theta^{t-1})}{6(1 - \theta^{t-1}) + 4(2 - \theta^{t-1})} =$$

$$= \frac{8 - 4\theta^{(t-1)}}{14 - 10\theta^{(t-1)}} = \frac{2\theta^{(t-1)} - 4}{5\theta^{(t-1)} - 7} = \theta^{(t)}$$



o) inicializar $\theta^{(0)}$

$$E) q^{(t)}(y) = p(y | x = 4000, \theta^{t-1})$$

$$M) \theta^{(t)} = \frac{2\theta^{(t-1)} - 4}{5 \cdot \theta^{(t-1)} - 7} \rightarrow \text{En realidad, para deducir esto usé E)}$$

3) Puntos fijos donde $\theta^t = \theta^{t-1} = \theta$

$$\rightarrow \theta = \frac{2\theta - 4}{5\theta - 7} \Rightarrow 5\theta^2 - 7\theta = 2\theta - 4 \Rightarrow 5\theta^2 - 9\theta + 4 = 0$$

$$\Rightarrow \theta = 4/5 \text{ ó } 1 \quad \left(0 < \frac{\theta}{2} < 1 \Rightarrow 0 < \theta < 2 \right) \rightarrow \text{Solo este rango tiene sentido}$$


$\hat{\theta}_{MN}$

4) $\theta_0 = 0,999 \rightarrow$ va cayendo de a poco hasta llegar a $4/5$

$$\theta_1 = 0,9998 \quad \theta_2 = 0,997 \quad \theta_3 = 0,997 \quad \theta_4 = 0,995 \quad \theta_5 = 0,993 \quad \theta_6 = 0,989$$

$$\theta_7 = 0,984 \quad \theta_8 = 0,977 \quad \theta_9 = 0,968 \quad \theta_{10} = 0,955 \quad \theta_{13} = 0,901$$

$$\theta_{20} = 0,811 \quad \theta_{67} = 0,8 \rightarrow \text{y de acá no se mueve}$$



$$\theta_0 = 1,5 \xrightarrow{t \rightarrow \infty} 4/5$$

$$\theta_0 = 1,1 \xrightarrow{t \rightarrow \infty} 4/5$$

$$\theta_0 = -5 \xrightarrow{t \rightarrow \infty} 4/5$$

$$\theta_0 = 0,5 \xrightarrow{t \rightarrow \infty} 4/5$$

Modelo de mezcla

Como decía antes, para trabajar con EM es necesario asumir cierta distribución para los datos y la variable latente. Asumamos primero q' $Z \sim \text{Cat}\{c_1, \dots, c_K\}$, la variable mezclada. Cada muestra x_i proviene de una mezclada z_i .

$\theta = \{c_k, \theta_k\}_{k=1}^K$, donde θ_k son los parámetros de la distribución $X|Z=k$.

$Q(k|x) \rightarrow$ prob de q' $x \in$ clase k . Es lo q' antes llamaba $q(z|x)$, pero enfatiza q' Z es discreta con la Q mayúscula.

$$\theta^{(t)} = \left\{ c_k, \theta_k^{(t)} \right\}_{k=1}^K$$

vector de valors de z

$$\text{Paso E)} \quad Q^{(t)}(\vec{y} | \vec{x}) = \prod_{i=1}^n P(y_i | x_i, \theta^{(t-1)}) \Rightarrow Q^{(t)}(k | x) = P(k | x, \theta^{(t-1)}) = \frac{p(x, k | \theta^{(t-1)})}{p(x | \theta^{(t-1)})} =$$

$$= \frac{p(x, k | \theta^{(t-1)})}{\sum_{k'} p(x, k' | \theta^{(t-1)})} = \frac{p(k | \theta^{(t-1)}) \cdot p(x | z=k, \theta_k^{(t-1)})}{\sum_{m=1}^K p(m | \theta^{(t-1)}) \cdot p(x | z=m, \theta_m^{(t-1)})} =$$

$$= \frac{c_k^{(t-1)} \cdot p(x | z=k, \theta_k^{(t-1)})}{\sum_{m=1}^K c_m^{(t-1)} \cdot p(x | z=m, \theta_m^{(t-1)})} \Rightarrow$$

$$Q^{(t)}(k | x) = \frac{c_k^{(t-1)} \cdot p(x | z=k, \theta_k^{(t-1)})}{\sum_{m=1}^K c_m^{(t-1)} \cdot p(x | z=m, \theta_m^{(t-1)})}$$

↳ A partir de acá, tenés q' arribar algo sobre la distribución $p(x | z=k, \theta_k^{(t-1)})$

Paso M) Re-calcular los parámetros. $c_k^{(t-1)} \rightarrow c_k^{(t)}$, $\theta_k^{(t-1)} \rightarrow \theta_k^{(t)} \Rightarrow \theta^{(t-1)} \rightarrow \theta^{(t)}$

$$\theta^{(t)} = \arg \max_{\theta \in \Theta} E_{Q^{(t)}} [\log p(\vec{x}, \vec{y} | \theta^{(t-1)}) | \vec{x} = \vec{x}]$$

V.A.

$$\begin{aligned} \mathbb{E}_{Q^{(t)}} [\log p(\vec{x}, \vec{z} | \theta^{(t-1)}) | \vec{X} = \vec{x}] &= \mathbb{E}_{Q^{(t)}} [\log \prod_{i=1}^n p(x_i, z_i | \theta) | \vec{X} = \vec{x}] = \\ &= \sum_{i=1}^n \mathbb{E}_{Q^{(t)}} [\log p(x_i, z_i | \theta) | X_i = x_i] \stackrel{\uparrow}{=} \sum_{i=1}^n \sum_{k=1}^K Q^{(t)}(k | x_i) \cdot [\log c_k + \log p(x_i | z_i = k, \theta_k)] \end{aligned}$$

Hay q maximizar el último término respecto de θ con la condición $\sum_{k=1}^K c_k = 1$. Usamos multiplicadores de Lagrange. Derivamos respecto de c_k , igualamos a 0 y despejamos $c_k^{(t)}$

$$\rightarrow J(\theta) = \sum_{i=1}^n \sum_{k=1}^K Q^{(t)}(k | x_i) \cdot [\log c_k + \log p(x_i | z_i = k, \theta_k)] + \lambda \cdot \left(1 - \sum_{k=1}^K c_k\right)$$

$$\frac{\partial J(\theta)}{\partial c_k} = \sum_{i=1}^n Q^{(t)}(k | x_i) \cdot \frac{1}{c_k} + \lambda (-1) = 0 \Rightarrow c_k = \frac{1}{\lambda} \cdot \sum_{i=1}^n Q^{(t)}(k | x_i)$$

Para verlo bien, sumar $\sum_k$ a ambos lados de la expresión en rosa

→ obs: $\lambda = n$ para q' $\sum c_k = 1$

$$\Rightarrow c_k^{(t)} = \frac{1}{n} \sum_{i=1}^n Q^{(t)}(k | x_i)$$

→ Promedio de probabilidad de pertenecer a la clase k

Ahora habría que derivar $J(\theta)$ respecto de los θ_k , pero primero tengo que asumir alguna distribución para $X|Z=k, \theta$

Mezcla de Gaussiana Asumiremos $Z \sim \text{cat}\{c_1 \dots c_K\}$, $X|Z=k, \theta \sim \mathcal{N}(\mu_k, \Sigma_k)$

Siguiendo la notación de antes: $\theta = \{c_k, \theta_k\}$, con $\theta_k = \{\mu_k, \Sigma_k\}$. Mientras el algoritmo itere, los 3 parámetros se irán actualizando. $\theta^{(t)} = \{c_k^{(t)}, \mu_k^{(t)}, \Sigma_k^{(t)}\}$

$$J(\theta) = \sum_{i=1}^n \sum_{k=1}^K \Phi^{(t)}(k|x_i) \cdot [\log c_k + \log p(x_i|z=k, \theta_k)] + \lambda \cdot \left(1 - \sum_{k=1}^K c_k\right)$$

Vamos de a poco: $\log p(x_i|z=k, \mu_k, \Sigma_k) = \text{cte} - \frac{1}{2} \log |\Sigma| - \frac{1}{2} (x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k)$

$$\frac{\partial}{\partial \mu_k} [\log p(x_i|z=k, \mu_k, \Sigma_k)] = 0 - 0 - \frac{1}{2} (\Sigma_k^{-1} + (\Sigma_k^{-1})^T) (x_i - \mu_k) (-1) =$$

$\rightarrow \Sigma_k$ simétrica

$$= \Sigma_k^{-1} (x_i - \mu_k)$$

$$\Rightarrow \frac{\partial \mathcal{J}(\theta)}{\partial \mu_k} = \sum_{i=1}^n Q^{(t)}(k|x_i) \cdot \Sigma_k^{-1} (x_i - \mu_k) = 0$$

$$\Rightarrow \sum_{i=1}^n Q^{(t)}(k|x_i) \cdot \Sigma_k^{-1} x_i - \left[\sum_{i=1}^n Q^{(t)}(k|x_i) \Sigma_k^{-1} \right] \mu_k = 0$$

$$\cancel{\sum_k} \sum_{i=1}^n Q^{(t)}(k|x_i) \cdot \cancel{\Sigma_k^{-1}} x_i = \cancel{\sum_k} \left[\sum_{i=1}^n Q^{(t)}(k|x_i) \cancel{\Sigma_k^{-1}} \right] \mu_k$$

$$\Rightarrow \mu_k = \frac{\sum_{i=1}^n Q^{(t)}(k|x_i) \cdot x_i}{\sum_{i=1}^n Q^{(t)}(k|x_i)}$$

$$\Rightarrow \mu_k^{(t)} = \frac{\sum_{i=1}^n Q^{(t)}(k|x_i) \cdot x_i}{\sum_{i=1}^n Q^{(t)}(k|x_i)}$$

→ similar to $c_k^{(t)}$

Vamos com $\partial \mathcal{J} / \partial \Sigma_k$:

$$\log p(x_i | z=k, \mu_k, \Sigma_k) = \text{cte} - \frac{1}{2} \log |\Sigma_k| + \frac{1}{2} (x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k)$$

$$\frac{\partial}{\partial \Sigma_k} \left[\log p(x_i | z=k, \mu_k, \Sigma_k) \right] = 0 - \frac{1}{2} \Sigma_k^{-1} + \frac{1}{2} \Sigma_k^{-1} (x_i - \mu_k) (x_i - \mu_k)^T \Sigma_k^{-1}$$

$$\frac{\partial \mathcal{J}(\theta)}{\partial \Sigma_k} = \sum_{i=1}^n Q^{(t)}(k | x_i) \left[-\cancel{\frac{1}{2} \Sigma_k^{-1}} + \cancel{\frac{1}{2} \Sigma_k^{-1}} (x_i - \mu_k) (x_i - \mu_k)^T \cancel{\Sigma_k^{-1}} \right] = 0$$

$$\Rightarrow \sum_{i=1}^n Q^{(t)}(k | x_i) \left[-I \cdot \Sigma_k + (x_i - \mu_k) (x_i - \mu_k)^T \cancel{\Sigma_k^{-1}} \cancel{\Sigma_k} \right] = 0$$

$$\Rightarrow \Sigma_k = \frac{\sum_{i=1}^n (x_i - \mu_k) (x_i - \mu_k)^T \cdot Q^{(t)}(k | x_i)}{\sum_{i=1}^n Q^{(t)}(k | x_i)}$$

$$\therefore \Sigma_k^{(t)} = \frac{\sum_{i=1}^n Q^{(t)}(x_i - \mu_k^{(t)}) (x_i - \mu_k^{(t)})^T}{\sum_{i=1}^n Q^{(t)}(k | x_i)}$$

numéricamente

En resumen: El algoritmo EM permite estimar[↑] los parámetros θ de la distribución $p(x)$. Esto es útil especialmente cuando resulta imposible hacerlo por máxima verosimilitud. Sea $\{x_i\}_{i=1}^m$ una serie de muestras iid. Sea z una variable latente con distribución $p(z|\theta)$ o $p(z|x_i, \theta)$. El vector (x, z) tendrá cierta distribución conjunta $p(x, z|\theta) = p(x|z, \theta) \cdot p(z|\theta) = p(z|x, \theta) \cdot p(x|\theta)$. Sea $q(z|x)$ una distribución q' se aproximará a $p(z|x, \theta)$. Importante: $q(z|x)$ no depende de los parámetros θ .

M.V. sería: $\hat{\theta}_{MV} = \underset{\theta \in \Theta}{\operatorname{argmax}} \log p(\vec{x}|\theta) = \underset{\theta \in \Theta}{\operatorname{argmax}} \sum_{i=1}^m \log p(x_i|\theta)$

nota: $q(\vec{z}|\vec{x})$ significa

En cambio, EM es:

$$q(\vec{z}|\vec{x}) = \frac{1}{n} \sum_{i=1}^n q(z_i|x_i)$$

$$\hat{\theta} = \underset{\theta \in \Theta}{\operatorname{argmax}} \max_{q \in \mathcal{P}} \log p(\vec{x}|\theta) - KL(q(\cdot|\vec{x}) || p(\cdot|\vec{x}, \theta))$$

Primero resuelve $\max_{q \in \mathcal{P}}$ (paso E) y luego resuelve $\underset{\theta \in \Theta}{\operatorname{argmax}}$ (paso M)

→ Asume una distribución para z y para $x|z=k$ (como en mezcla de gaussianas) o para x y para $z|x=x$ (como en el ejemplo de Smallville). En cualquier caso puede

Comocer $p(x, y | \theta) = p(x | z = y, \theta) \cdot p(y) = p(y | x = x, \theta) \cdot p(x)$

Para E: $q^{(t)}(\vec{y} | \vec{x}) = p(\vec{y} | \vec{x}, \theta^{(t-1)}) = \frac{p(\vec{x}, \vec{y} | \theta)}{\sum_{\vec{y}} p(\vec{x}, \vec{y} | \theta)}$ $\rightarrow$ La conjunta me da las puestas a todo

Para M: $\theta^{(t)} = \underset{\theta \in \Theta}{\operatorname{argmax}} E_{q^{(t)}} [\log p(\vec{x}, \vec{y} | \theta^{(t-1)}) | \vec{X} = \vec{x}] \rightarrow$ No es obvio q' esto equivale al ELBO

Para el caso particular en el q' se modele $z \sim \operatorname{cat}\{c_1, \dots, c_k\}$ y $x | z = k \sim \mathcal{N}(\mu_k, \Sigma_k)$

E) $q^{(t)}(k | x_i) = p(k | x_i, \theta^{(t-1)}) = \frac{c_k^{(t-1)} \cdot \mathcal{N}(x_i | \mu_k^{(t-1)}, \Sigma_k^{(t-1)})}{\sum_{m=1}^k c_m^{(t-1)} \cdot \mathcal{N}(x_i | \mu_m^{(t-1)}, \Sigma_m^{(t-1)})}$ $\rightarrow$ densidad de la normal multivariada

M) $c_k^{(t)} = \frac{1}{n} \sum_{i=1}^n q(k | x_i)$; $\mu_k^{(t)} = \frac{\sum_{i=1}^n q(k | x_i) \cdot x_i}{\sum_{i=1}^n q(k | x_i)}$; $\Sigma_k^{(t)} = \frac{\sum_{i=1}^n q(k | x_i) \cdot (x_i - \mu_k^{(t)}) (x_i - \mu_k^{(t)})^T}{\sum_{i=1}^n q(k | x_i)}$

Asumiendo una mezcla de Gaussianas ¿cómo sería el problema de MV?

$$p(x, y) = p(x|z=k) \cdot p_z(k) = c_k \cdot \mathcal{N}(u_k, \Sigma_k)$$

$$\rightarrow p_x(x) = \sum_{\forall k} c_k \mathcal{N}(u_k, \Sigma_k)(x)$$

$$\hat{\theta}_{MV} = \arg \max_{\theta \in \Theta} \sum_{i=1}^n \log p_x(x_i) = \arg \max_{\theta \in \Theta} \sum_{i=1}^n \log \left(\sum_{\forall k} c_k \cdot \mathcal{N}(u_k, \Sigma_k)(x_i) \right) \quad \text{tq} \quad \sum_{\forall k} c_k = 1$$

$$\frac{\partial}{\partial c_k} = \sum_{i=1}^n \frac{1}{\sum_m c_m \cdot \mathcal{N}_m(x_i)} \cdot \mathcal{N}_k(x_i) - 1 = 0 \rightarrow \text{¿cómo despejar } c_k \text{ de acá?}$$

Factor analysis

→ Me chupa un huevo. No lo vimos en clase, así q' teja puta q'mo lo tome

Ejercicio hecho en clase: Plantea EM para la mezcla de exponenciales

$$Z \sim \text{cat}\{c_1, \dots, c_K\} \quad X|Z=k \sim \mathcal{E}(\lambda_k)$$

$$\theta = \{c_1, \dots, c_K, \lambda_1, \dots, \lambda_K\}$$

$$p(x, k | \theta) = p(k | \theta) \cdot p(x | k, \theta) = c_k \cdot \lambda_k e^{-\lambda_k \cdot x} \mathbb{1}\{x \geq 0\}$$

$$p(k | x, \theta) = \frac{p(x, k | \theta)}{\sum_{m=1}^K c_m \lambda_m e^{-\lambda_m x} \mathbb{1}\{x \geq 0\}} = \frac{c_k \cdot \lambda_k e^{-\lambda_k \cdot x}}{\sum_{m=1}^K c_m \lambda_m e^{-\lambda_m x}} \mathbb{1}\{x \geq 0\}$$

$$E) \quad q(k | x) = p(k | x, \theta^{(t-1)}) = \frac{c_k^{(t-1)} \lambda_k^{(t-1)} \exp\{-\lambda_k^{(t-1)} \cdot x\}}{\sum_{m=1}^K c_m^{(t-1)} \cdot \lambda_m^{(t-1)} \exp\{\lambda_m^{(t-1)} \cdot x\}} \mathbb{1}\{x \geq 0\}$$

$$M) \quad \theta^{(t)} = \underset{\theta \in \Theta}{\text{arg max}} \mathbb{E}_{q^{(t)}} \left[\sum_{i=1}^n \log p(x_i, z | \theta) \mid \vec{X} = \vec{x} \right]$$

$$\log p(x, k | \theta) = (\log c_k + \log \lambda_k - \lambda_k \cdot x) \mathbb{1}_{\{x \geq 0\}}$$

$$\mathbb{E}_{q^{(t)}}[\log p(\vec{x}, z | \theta) | \vec{X} = \vec{x}] = \sum_{i=1}^n \mathbb{E}_{q^{(t)}}[\log p(x_i, z | \theta) | X_i = x_i] =$$

$$= \sum_{i=1}^n \sum_{k=1}^K q^{(t)}(k | x_i) \cdot [\log c_k + \log \lambda_k - \lambda_k \cdot x_i] \quad \text{tq} \quad 1 - \sum_{k=1}^K c_k = 0 \quad \sum c_k - 1 = 0$$

¿qué pasa si planteo

$$\rightarrow J(\theta) = \sum_{i=1}^n \sum_{k=1}^K q^{(t)}(k | x_i) \cdot [\log c_k + \log \lambda_k - \lambda_k \cdot x_i] + \alpha \cdot \left(1 - \sum_{k=1}^K c_k \right)$$

$$\frac{\partial J(\theta)}{\partial c_k} = \sum_{i=1}^n q^{(t)}(k | x_i) \cdot \frac{1}{c_k} + \alpha \cdot (-1) = 0 \Rightarrow c_k = \frac{1}{\alpha} \sum_{i=1}^n q^{(t)}(k | x_i)$$

$$\boxed{\alpha = n} \quad \text{para que} \quad \sum c_k = 1$$

$$\rightarrow \mu_k^{(t)} = \frac{1}{n} \sum_{i=1}^n q^{(t)}(k|x_i)$$

$$\frac{\partial \mathcal{J}(\theta)}{\partial \lambda_k} = \sum_{i=1}^n q^{(t)}(k|x_i) \left[\frac{1}{\lambda_k} - x_i \right] + 0 = 0$$

$$\rightarrow \frac{1}{\lambda_k} \cdot \sum_{i=1}^n q^{(t)}(k|x_i) - \sum_{i=1}^n q^{(t)}(k|x_i) \cdot x_i = 0$$

$$\rightarrow \lambda_k = \frac{\sum_{i=1}^n q^{(t)}(k|x_i)}{\sum_{i=1}^n q^{(t)}(k|x_i) \cdot x_i} \Rightarrow \lambda_k^{(t)} = \frac{\sum_{i=1}^n q^{(t)}(k|x_i)}{\sum_{i=1}^n q^{(t)}(k|x_i) \cdot x_i} = \frac{1}{\mu_k}$$

→ para el caso de mezcla de Gaussiana. Tiene sentido $\lambda q'$ $E[\exp] = \frac{1}{\lambda}$

Finalmente: ①) inicializo $\{c_k^{(0)}, \lambda_k^{(0)}\}_{k=1}^K$

$$E) \quad q^{(t)}(k|x_i) = \frac{c_k^{(t-1)} \cdot \lambda_k^{(t-1)} \cdot \exp\{-\lambda_k^{(t-1)} \cdot x_i\}}{\sum_{m=1}^K c_m^{(t-1)} \cdot \lambda_m^{(t-1)} \exp\{-\lambda_m^{(t-1)} \cdot x_i\}} \quad \mathbb{1}_{\{x_i \geq 0\}}$$

$$M) \quad c_k^{(t)} = \frac{1}{n} \sum_{i=1}^n q^{(t)}(k|x_i) \quad \lambda_k^{(t)} = \frac{\sum_{i=1}^n q^{(t)}(k|x_i)}{\sum_{i=1}^n q^{(t)}(k|x_i) \cdot x_i}$$
