

22/1 $\rightarrow$ Optimalidad, Clasificador bayesiano. Hasta KL sin incluir

Objetivo: a partir de una observación x asignar una clase $\hat{y} = \varphi(x)$, donde $\hat{y} \in Y$, con Y un conjunto finito

Nueva función costo: hard-error
$$l(x, y) = \mathbb{1}\{y \neq \varphi(x)\} = \begin{cases} 1 & \text{si me equivoco} \\ 0 & \text{si no} \end{cases}$$

Riesgo esperado: $E[\mathbb{1}\{Y \neq \varphi(X)\}] = P(Y \neq \varphi(X))$

(Tener en cuenta q' $E[\mathbb{1}\{X \in A\}] = \int \mathbb{1}\{X \in A\} f(x) dx = \int_A f(x) dx = P(X \in A)$)

Clasificador y error

Bayesiano

En regresión lo mejor a lo q' podríamos aspirar era $\varphi(x) = E[Y|X=x]$ con error $E[\text{var}(Y|x)]$. En clasificación tenemos algo similar.

Busquemos el clasificador bayesiano. Antes, una propiedad:

$$P(Y \in R) = E_X [P(Y \in R | X)]$$

Pensar así: $P(Y \in R | X = x) = f(x) \rightarrow$ función de x , lo puedo evaluar en una V.A. X

$\Rightarrow P(Y \in R | X = X) = P(Y \in R | X) = f(X) \rightarrow$ otra V.A., le tomo la esperanza

$$P(Y \in R) = E[f(X)] = E[P(Y \in R | X)]$$

Esto es: la probabilidad de que Y esté en R es el promedio (esperanza) de las probabilidades de que Y esté en R condicionado a $X = x$ para todos los x posibles.

Se parece mucho a $E[Y] = E[E[Y|X]] \rightarrow$ El promedio de Y es el promedio de la esperanza de $Y|X = x$ para todos los x posibles

$$D/ P(Y \in R) = E[\mathbb{1}_{\{Y \in R\}}] =$$

Recordar: $E[Z] = E[E[Z|X]]$

$$= E[E[\mathbb{1}_{\{Y \in R\}} | X]]$$

$$= E[P(Y \in R | X)] \quad \square$$

o también: Sea $f(x) = \mathbb{P}(Y \in R | X = x)$. Demostar q' $\mathbb{P}(Y \in R) = \mathbb{E}[f(x)]$

$$\begin{aligned} \text{D/ } \mathbb{E}[f(x)] &= \sum_x f(x) \cdot \mathbb{P}(X=x) = \sum_x \mathbb{P}(Y \in R | X=x) \cdot \mathbb{P}(X=x) = \\ &= \sum_x \mathbb{P}(Y \in R, X=x) = \mathbb{P}(Y \in R) \quad (\text{en particular, para el caso discreto}) \end{aligned}$$

• $\mathbb{P}(Y \in R) = \mathbb{E}[\mathbb{P}(Y \in R | X = \textcircled{X})]$ → en realidad, vera lo escribe $\mathbb{E}[\mathbb{P}(Y \in R | X)]$, pero no hay que perder de vista q' es una función evaluada en una V.A. X

Ahora sí: clasificador Bayesiano Función costo: hard-error 1-0

$$\mathbb{P}(Y \neq \varphi(x)) \geq 1 - \mathbb{E}\left[\max_y \mathbb{P}_{Y|X=x}(y)\right], \text{ con igualdad si } \varphi(x) = \arg\max_y \mathbb{P}_{Y|X=x}(y)$$

A esa función $\varphi(x)$ la llamamos clasificador bayesiano

$$\text{D/ } \mathbb{P}(Y \neq \varphi(x)) = 1 - \mathbb{P}(Y = \varphi(x)) = 1 - \mathbb{E}[\mathbb{P}(Y = \varphi(x) | X)] =$$

Se puede acotar $\mathbb{P}(Y = \varphi(x) | X)$:

$$P(y = \varphi(x) | x = x) = P_{y|x=x}(\varphi(x)) \leq \max_y P_{y|x=x}(y). \text{ con igualdad si}$$

$$\varphi(x) = \arg \max_y P_{y|x=x}(y)$$

$$\Rightarrow E[P(y = \varphi(x) | x)] \leq E[\max_y P_{y|x=x}(y)]$$

$$\Rightarrow 1 - E[P(y = \varphi(x) | x)] \geq 1 - E[\max_y P_{y|x=x}(y)]$$

$$\therefore P(y \neq \varphi(x)) = 1 - E[P(y = \varphi(x) | x)] \geq 1 - E[\max_y P_{y|x=x}(y)]$$

$$\text{con igualdad si } \varphi(x) = \arg \max_y P_{y|x=x}(y)$$

El resultado del clasificador no es sorprendente. Si observo x agarró el y q' maximiza la probabilidad $P_{y|x=x}(y)$, agarró el y más probable. Lo que no es tan fácil de analizar es el error bayesiano.


Si elijo el clasificador bayesiano, el error esperado es:

$$\mathbb{E}[L(x, y)] = \mathbb{E}[\mathbb{1}\{y \neq \phi(x)\}] = \mathbb{P}(y \neq \phi(x)) = 1 - \mathbb{E}[\max_y P_{y|x=x}(y)]$$

Trabajemos la expresión dentro de la esperanza:

$\rightarrow \max_y P_{y|x=x}(y) \rightarrow$ Pensar que por cada x tengo una distribución distinta para $y|x=x$,
y para cada una de esas funciones voy a tener un máximo distinto

El espacio de las x queda dividido en una partición. Dentro de cada partición hay un valor de y que maximiza $P_{y|x=x}(y)$



$\forall x \in R_1: \phi(x) = 1$ (porque $y=1$ maximiza $P_{y|x=x}$)

$\forall x \in R_2: \phi(x) = 2$

Idem

Cada partición R_{y_0} es tal que $\phi(x) = y_0 \forall x \in R_{y_0}$

todos los x pertenecen a un solo conjunto R_{y_0}

Esto me permite escribir el máximo así: $P_{Y|X=X}(y) = p_{X|Y=y}(x) \cdot \frac{P_Y(y)}{p_X(x)}$ $p \rightarrow \text{PDF}$
 $P \rightarrow \text{PMF}$

$$\max_y P_{Y|X=X}(y) = \sum_{\forall y} P_{Y|X=X}(y) \cdot \mathbb{1}_{\{x \in R_y\}} =$$

va a quedar una
sola indicadora

$$= \sum_{\forall y} P_Y(y) \cdot \frac{p_{X|Y=y}(x)}{p_X(x)} \cdot \mathbb{1}_{\{x \in R_y\}} \rightarrow \text{Esto lo vamos a poner en la integral de la esperanza}$$

$$1 - E\left[\max_y P_{Y|X=X}(y)\right] = 1 - \int_{\text{SoP}(X)} p_X(x) \cdot \max_y P_{Y|X=X}(y) dx =$$

$$= 1 - \int_{\text{SoP}(X)} \sum_{\forall y} P_Y(y) \cdot p_{X|Y=y}(x) \cdot \mathbb{1}_{\{x \in R_y\}} dx = 1 - \sum_{\forall y} \int_{R_Y} P_Y(y) \cdot p_{X|Y=y}(x) \cdot dx =$$

$$= 1 - \sum_{y \in \mathcal{Y}} P_Y(y) \cdot \int_{R_y} p_{X|Y=y}(x) dx = 1 - \sum_{y \in \mathcal{Y}} P_Y(y) \cdot \mathbb{P}(X \in R_y | Y=y) =$$

$$= \sum_{y \in \mathcal{Y}} P_Y(y) - \sum_{y \in \mathcal{Y}} P_Y(y) \cdot \mathbb{P}(X \in R_y | Y=y) = \sum_{y \in \mathcal{Y}} P_Y(y) \cdot \mathbb{P}(X \notin R_y | Y=y)$$

Finalmente, el error bayesiano es:


Área bajo una curva

$$1 - \mathbb{E} \left[\max_y P_{Y|X=x}(y) \right] = \sum_{y \in \mathcal{Y}} \underbrace{P_Y(y)}_{\text{Peso}} \cdot \mathbb{P}(X \notin R_y | Y=y)$$

Ejemplo: Imaginemos las siguientes distribuciones: $Y \in \{1, 2\}$

$P_Y(1) \cdot p_{X|Y=1}(x)$

$P_Y(2) \cdot p_{X|Y=2}(x)$



Si observo un x acá $\leftarrow R_1$ $R_2 \rightarrow$ si observo un x acá elijo $Y=2$
 elijo $Y=1$

OBS: $\varphi(x) = \underset{y}{\operatorname{argmax}} P_{y|x=x}(y) = \underset{y}{\operatorname{argmax}} \frac{p_{x|y=y}(x) \cdot P_y(y)}{\left[\frac{p_{x|y=y}(x)}{p_{x|y=y}(x)} \right]}$

$$P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

→ No depende de y , se va

• $\varphi(x) = \underset{y}{\operatorname{argmax}} P_{y|x=x}(y) = \underset{y}{\operatorname{argmax}} P_y(y) \cdot p_{x|y=y}(x)$

→ cualquiera de las 2 formas es equivalente.

En el gráfico se ve q' la partición responde a esto

¿cómo es el error bayesiano? $\text{Err} = \sum_{y \in Y} P_y(y) \cdot \mathbb{P}(x \notin R_y | y = y) =$

$= P_y(1) \cdot \mathbb{P}(x \notin R_1 | y = 1) + \rightarrow \text{área azul}$

$+ P_y(2) \cdot \mathbb{P}(x \notin R_2 | y = 2) \rightarrow \text{Área roja}$

Cualquier clasificador será peor q' el bayesiano, pero debe ser mejor q' el azaroso o el dummy

Azaroso: Elige al azar entre las k clases $\rightarrow \mathbb{P}(y \neq \phi(x)) = 1 - \left[\frac{1}{k} \right]$ ^{Probabilidad de} _{acierto}

Dummy: Elige siempre $\arg \max_y P_y(y)$, sin tener en cuenta el x observado

$$\rightarrow \mathbb{P}(y \neq \phi(x)) = 1 - \max_y P_y(y)$$

$\Rightarrow$ cualquier clasificador como la gente debe cumplir:

$$\sum_{y \in \mathcal{Y}} P_y(y) \cdot \mathbb{P}(x \notin R_y | y = y) \leq \mathbb{P}(y = \phi(x)) \leq 1 - 1/k$$

$$\text{e: } \sum_{y \in \mathcal{Y}} P_y(y) \cdot \mathbb{P}(x \notin R_y | y = y) \leq \mathbb{P}(y = \phi(x)) \leq 1 - \max_y P_y(y)$$

Ejemplo 3.1 Por un canal de comunicaciones se emiten bits de forma aleatoria, siendo el 40% de ellos 1. Dependiendo del bit transmitido, la comunicación es afectada por un ruido aditivo normal de media nula y varianzas: 4 si el bit es un 0 y 1 si el bit es un 1. Sea X la señal recibida y Y el bit emitido. Hallar el clasificador bayesiano y su respectivo error. Expresar el resultado en función de $\Phi(\cdot)$ (función de distribución de la normal estándar).

$$Y \sim \text{Ber}(p=0.4)$$


$$X|Y=0 \sim \mathcal{N}(0, \sigma^2=4)$$

$$X|Y=1 \sim \mathcal{N}(1, \sigma^2=1)$$

$$\varphi(x) = \arg \max_y P_{Y|X=x}(y) \rightarrow \text{no tengo } Y|X, \text{ pero sí tengo } X|Y$$

$$\varphi(x) = \arg \max_y P_Y(y) \cdot p_{X|Y=y}(x)$$

$$P_Y(1) \cdot p_{X|Y=1}(x)$$



$$P_Y(1) \cdot p_{X|Y=1}(x) = 0,4 \cdot \frac{1}{\sqrt{2\pi} \cdot 1} e^{-\frac{(x-1)^2}{2 \cdot 1}}$$

las iguala y saco la intersección

$$P_Y(0) \cdot p_{X|Y=0}(x) = 0,6 \cdot \frac{1}{\sqrt{2\pi} \cdot 2} \cdot e^{-\frac{x^2}{2 \cdot 4}}$$


$$0,4 \cdot \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{(x-1)^2}{2}\right\} = 0,3 \cdot \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{x^2}{8}\right\}$$

$$\exp\left\{-\frac{(x-1)^2}{2}\right\} = \frac{3}{4} \exp\left\{-\frac{x^2}{8}\right\} = \exp\left\{-\frac{x^2}{8} + \ln(3/4)\right\}$$

$$\rightarrow -\frac{(x-1)^2}{2} = -\frac{x^2}{8} + \ln(3/4)$$

$$x^2/2 - x + \frac{1}{2} = x^2/8 - \ln(3/4)$$

$$3/8 \cdot x^2 - x + \frac{1}{2} + \ln 3/4 = 0 \rightarrow x_1 = 2,434 ; x_2 = 0,233$$



$$\psi(x) = \begin{cases} 0 & \text{si } x \leq 0,233 \\ 1 & \text{si } 0,233 < x \leq 2,434 \\ 0 & \text{si } 2,434 < x \end{cases}$$

$$\text{Error} = \sum_{y \in Y} P_Y(y) \cdot P(X \notin R_y | Y=y) =$$

$$= 0,6 \cdot P(X \notin R_0 | Y=0) + \\ + 0,4 \cdot P(X \notin R_1 | Y=1)$$

$$X|Y=0 \sim \mathcal{N}(0, 4) = \Phi_0$$

$$X|Y=1 \sim \mathcal{N}(1, 1) = \Phi_1$$

$$\Rightarrow \text{Error} = 0,6 \cdot [\Phi_0(2,434) - \Phi_0(0,233)] +$$

$$+ 0,4 [\Phi_1(0,233) + 1 - \Phi_1(2,434)] \rightarrow \text{Area azul}$$

area roja

Según Vera: Error = 0,324

Azalaga: 0,5

Dummy: 0,4 (siempre elige 0)

Ejemplo 3.2 Se quiere clasificar un conjunto de datos en dos clases. La etiqueta posee distribución $Y \sim \text{Ber}(1/2)$, mientras que los predictores $X \in \mathbb{R}^2$ poseen distribución $X|_{Y=0} \sim \mathcal{N}\left(\begin{bmatrix} 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}\right)$ y $X|_{Y=1} \sim \mathcal{N}\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}\right)$. Hallar la frontera de decisión y el clasificador bayesiano.

Falopa. Ver DSP

23/01 → Entropía cruzada, KL

Entropía

Que quito, lpm.

No me gusta la función hamilton-error yq' no se puede derivar ni nada

$Q(x) = \arg \max_y P_{y|x=x}(y) \rightarrow$ aprender o estimar $P_{y|x=x}(y) \forall x, \forall y \rightarrow \hat{P}_{y|x}$
↳ hacer el $\arg \max_y$ de $\hat{P}_{y|x}$

o sea con la notación $P_{y|x=x}(y) = P_{y|x}(y|x)$

⇒ Necesitamos medir la distancia entre pmf's y minimizar la distancia entre

$P_{y|x}(y|x)$ (la verdadera) y $\hat{P}_{y|x}(y|x)$ (la estimada)

Kullback - Leibler

Sean $P(y)$ y $Q(y)$ 2 pmf's

$$KL(P \parallel Q) = \sum_{\forall y} P(y) \log \left[\frac{P(y)}{Q(y)} \right] = \mathbb{E}_P \left[\log \left(\frac{P(y)}{Q(y)} \right) \right]$$

Donde $\mathbb{E}_P$ significa q' se usan los valores de $P(y)$ para calcular la esperanza y no los de $Q(y)$

OBS: $KL(P \parallel Q) \neq KL(Q \parallel P)$

Propiedad importante $KL(P \parallel Q) \geq 0$ con = si $P(y) = Q(y) \forall y$

De ahí q' sirva como métrica de similitud entre P y Q

Nueva función costo: $\ell(x, y) = -\log \hat{P}(y|x)$, donde $\hat{P}$ es la función q' aprendo

Error esperado: $\mathbb{E}[\ell(x, y)] = \mathbb{E}[-\log \hat{P}(X|Y)] \rightarrow$ Entropía cruzada

Propiedades 3.2 $\mathbb{E}[-\log \hat{P}(Y|X)] \geq \mathbb{E}[-\log P_{Y|X=X}(Y)]$ con igualdad si y solo si $\hat{P}(y|x) = P_{Y|X}(y|x)$ para todo (x, y) , donde las esperanzas involucradas son con respecto a la verdadera distribución conjunta de (X, Y) .

Función costo:
log-loss

Esto es: la mejor aproximación de $P_{Y|X}(y|x)$ es $P_{Y|X}(y|x)$ y el error mínimo es $\mathbb{E}[-\log P_{Y|X}(Y|X)]$

Pero antes hay q' entender la entropía: Sea Y una V.A. discreta con pmf $P_Y(y)$

$$H(Y) = \mathbb{E}_Y[-\log P_Y(Y)] = \sum_{\forall y} -\log[P_Y(y)] \cdot P_Y(y)$$

$$(\text{Recordar: } \mathbb{E}[g(x)] = \sum_{\forall x} g(x) \cdot P_X(x))$$

$H(Y)$ mide cuán impredecible es Y

Moneda balanceada: $H(Y) = -\log(1/2) \cdot 1/2 - \log(1/2) \cdot 1/2 = 0,69 \rightarrow$ más impredecible

moneda 10%/90%: $H(Y) = -\log(0,9) \cdot 0,9 - \log(0,1) \cdot 0,1 = 0,33 \rightarrow$ menos impredecible

Veamos qué significan las 2 esquemas del teorema:

Nota: recordar q' ahora el problema es otro, no quiere hallar $\phi(x)$ q' minimice la probabilidad de error $\mathbb{P}(Y \neq \phi(X)) = \mathbb{E}[\mathbb{1}_{Y \neq \phi(X)}] = \mathbb{E}[\text{hard-error}]$, sino hallar la $\hat{P}(y|x)$ q' mejor aproxima $P_{Y|X}(y|x)$

→ distribución q' estimo

$$\mathbb{E}[-\log \hat{P}(Y|X)] = \int \int -\log \hat{P}(y|x) \cdot p_{X,Y}(x,y) dx dy$$

Entropía cruzada

$S_{\text{CP}}(Y)$ $S_{\text{CP}}(X)$

→ verdadera distribución de (X, Y)

$$\mathbb{E}[-\log P_{Y|X=X}(Y)] = \int \int -\log P_{Y|X}(y|x) \cdot p_{X,Y}(x,y) dx dy$$

Entropía condicional

$S_{\text{CP}}(Y)$ $S_{\text{CP}}(X)$

$H(Y|X)$

Ahora sí, demostración de q' $\mathbb{E}[-\log \hat{P}(Y|X)] \geq \mathbb{E}[-\log P_{Y|X}(Y|X)]$ con igualdad

si $\hat{P}(y|x) = P_{Y|X}(y|x)$

$$\text{D/ } \mathbb{E}[-\log \hat{P}(Y|X)] = \mathbb{E}\left[\log\left(\frac{1}{\hat{P}(Y|X)} \cdot \frac{P_{Y|X}(Y|X)}{P_{Y|X}(Y|X)}\right)\right] =$$

$$= \mathbb{E}\left[\log \frac{P_{Y|X}(Y|X)}{\hat{P}(Y|X)}\right] + \mathbb{E}[-\log P_{Y|X}(Y|X)] =$$

Recordar q' la integral de esta

entropía es con respecto a $p_{X,Y}(x,y) = P_{Y|X}(y|x) \cdot p_X(x)$

→ Esta esperanza es con respecto a $p_X(x)$

$$= \mathbb{E}_X [KL(P_{Y|X}(\cdot|x) || \hat{P}(\cdot|x))] + \mathbb{E}[-\log P_{Y|X}(Y|x)]$$

$$\Rightarrow \mathbb{E}[-\log \hat{P}(Y|x)] = \mathbb{E}_X [KL] + \mathbb{E}[-\log P_{Y|X}(Y|x)]$$

→ Esta esperanza es con respecto a (x, y)

$$= \mathbb{E}_X [KL] + H(Y|X) \rightarrow \text{Acá se ve bien q' minimizar el riesgo esperado es minimizar la KL entre } \hat{P}(y|x) \text{ y } P_{Y|X}(y|x)$$

$$\because KL \geq 0 \Rightarrow \mathbb{E}_X [KL] \geq 0$$

$$\therefore \mathbb{E}[-\log \hat{P}(Y|x)] \geq H(Y|X) \quad \text{con igualdad si } \hat{P}(y|x) = P_{Y|X}(y|x)$$

El menor error q' puedo cometer es $H(Y|X) = \mathbb{E}[-\log P_{Y|X}(Y|x)] =$

$$= \iint -\log P_{Y|X}(y|x) \cdot p_{X,Y}(x, y) dx dy$$

Nota: minimizando la entropía cruzada minimizamos la impredecibilidad de $\hat{P}_{Y|X}$. Es decir, para un mismo x , $\hat{P}_{Y|X}$ va a estar muy incrementada a un y particular

$H(y|x) \rightarrow$ incertidumbre q' queda en y luego de observar x

24/1 $\rightarrow$ Regresión logística

Regresión logística

Regresión logística binaria

Recordar: queremos estimar $P_{y|x=x}(y) \forall x, y \rightarrow$ una función por cada valor de y

El caso binario es el más fácil. $y \in \{0, 1\}$, si tenemos $\hat{P}_{y|x}(1|x) \forall x$ también tenemos

$$\hat{P}_{y|x}(0|x) = 1 - \hat{P}_{y|x}(1|x)$$

Función sigmoide: $\sigma(z) = \frac{1}{1 + e^{-z}} \in \{0, 1\} \rightarrow$ con esto modelamos probabilidades

lo vamos a modelar así: $\hat{P}_{y|x}(1|x) = p(x) = \sigma(w^T \cdot x + b)$

$$\hat{P}_{y|x}(0|x) = 1 - \sigma(w^T \cdot x + b)$$

$$\hat{P}_{y|x}(y|x) = \begin{cases} 1 - \sigma(w^T \cdot x + b) & \text{si } y=0 \\ \sigma(w^T \cdot x + b) & \text{si } y=1 \end{cases}$$

Por cada valor de y tengo una función de x

oBS La frontera de decisión es lineal:

La frontera de decisión es cuando $\hat{P}_{y|x}(1|x) = \hat{P}_{y|x}(0|x)$

$$\rightarrow \sigma(w^T \cdot x + b) = 1 - \sigma(w^T \cdot x + b)$$

$$\rightarrow \sigma(w^T \cdot x + b) = 1/2 \Leftrightarrow w^T x + b = 0 \rightarrow \text{Hiperplano}$$

si $w^T x + b > 0 \Rightarrow \hat{P}_{y|x}(1|x) > \hat{P}_{y|x}(0|x) \Rightarrow$ clasifica como $y=1$

si $w^T \cdot x + b < 0 \Rightarrow$ clasifica como $y=0$

¿qué pasa con el error? $\ell(x, y) = -\log \hat{P}_{y|x}(y|x) =$

$$= \begin{cases} -\log(1 - \sigma(w^T x + b)) & \text{si } y=0 \end{cases}$$

$$= -(1-y) \cdot \log[1 - \sigma(w^T x + b)] - y \cdot \log[\sigma(w^T x + b)]$$

$$\begin{cases} -\log(\sigma(w^T x + b)) & \text{si } y=1 \end{cases}$$

Vamos a calcular $\frac{d}{dw} l(x,y)$ y $\frac{d}{db} l(x,y)$ para luego calcular el gradiente del

Riesgo empírico $J(w,b) = \frac{1}{n} \sum_{i=1}^n l(x,y)$ **Minimizamos el riesgo empírico**

Recordar: $\sigma'(z) = - \left(\frac{1}{1+e^{-z}} \right)^2 \cdot (-e^{-z}) = \sigma(z) \cdot (1 - \sigma(z))$

$$\left(\log \sigma(z) \right)' = \frac{1}{\sigma(z)} \cdot \sigma(z) \cdot (1 - \sigma(z)) \cdot z' ; \left(\log [1 - \sigma(z)] \right)' = \frac{1}{1 - \sigma} \sigma(z)(\sigma(z) - 1) \cdot z'$$

$$l(x,y) = -(1-y) \log[1 - \sigma(x^T w + b)] - y \cdot \log[\sigma(x^T w + b)]$$

$$\frac{d}{dw} l(x,y) = \cancel{(1-y)} \cdot \frac{\cancel{1}}{1 - \cancel{\sigma(x^T w + b)}} \cdot \cancel{\sigma(x^T w + b)} \cdot (\cancel{\sigma(x^T w + b)} - 1) \cdot x -$$

$$- y \cdot \frac{\cancel{1}}{\cancel{\sigma(x^T w + b)}} \cdot \cancel{\sigma(x^T w + b)} (1 - \cancel{\sigma(x^T w + b)}) \cdot x$$

$$= (1-y) \sigma(\cdot) \cdot x - y (1 - \sigma(\cdot)) \cdot x = \sigma(\cdot) x - \cancel{y \sigma(\cdot) x} - y x + \cancel{y \sigma(\cdot) x}$$

$$= \underline{(\sigma(w^T x + b) - y) x}$$

$$\frac{d\ell}{db}(x, y) = \cancel{(1-y)} \cdot \frac{1}{1-\cancel{\sigma(\cdot)}} \cdot \cancel{\sigma(\cdot)} (\cancel{\sigma(\cdot)} - 1) \cdot 1 - y \frac{1}{\cancel{\sigma(\cdot)}} \cancel{\sigma(\cdot)} (1 - \cancel{\sigma(\cdot)}) =$$

$$= (1-y) \cdot \sigma(\cdot) - y (1 - \sigma(\cdot)) = \sigma(\cdot) - \cancel{y\sigma(\cdot)} - y + \cancel{y\sigma(\cdot)} = \underline{\sigma(w^T x + b) - y}$$

$$\therefore \frac{d\ell}{dw} = (\sigma(w^T x + b) - y) \cdot x \quad \frac{d\ell}{db} = \sigma(w^T x + b) - y$$

$$J(w, b) = \frac{1}{n} \sum_{i=1}^n \ell(x_i, y_i)$$

$$\frac{dJ}{dw} = \frac{1}{n} \sum_{i=1}^n (\sigma(w^T x_i + b) - y_i) x_i$$

$$\frac{dJ}{db} = \frac{1}{n} \sum_{i=1}^n \boxed{\sigma(w^T x_i + b) - y_i}$$

→ anular el gradiente equivale a anular

$$\sigma(w^T x + b) - y_i = 0 \Rightarrow y_i = \sigma(w^T x_i + b)$$

Regresión logística categórica

¿Que pasa si tengo más clases? $\rightarrow y \in \{1, 2 \dots K\}$

Modelo identificable $\rightarrow$ me chupa un huevo

$\rightarrow$ Modelo softmax. Sea a un vector / $a = (a_1, a_2 \dots a_K)$

$$\text{Softmax}(q|a) = \frac{e^{a_q}}{\sum_{i=1}^K e^{a_i}} \rightarrow \text{operación softmax}$$

Calcularemos $\hat{P}_{y|x}(y|x)$ de la siguiente forma: habrá K vectores w_i y K constantes b_i

$$\hat{P}_{y|x}(y|x) = \frac{e^{w_y^T x + b_y}}{\sum_{i=1}^K e^{w_i^T x + b_i}} \mathbb{1}\{y \in \{1, 2 \dots K\}\}$$

Es decir, si tuviera el vector $\bar{W} = (w_1^T x + b_1, w_2^T x + b_2 \dots w_K^T x + b_K)$ tengo que

$$\hat{P}_{y|x}(y|x) = \text{Softmax}(y|\bar{W})$$

La decisión hard es maximizar $\hat{P}_{y|x}(y|x)$, que es maximizar $e^{w_y^T x + b_y}$ (todos los denominadores son iguales), que es maximizar $w_y^T x + b_y$

$$\Rightarrow \varphi(x) = \underset{y}{\operatorname{argmax}} w_y^T x + b_y$$

Nuevamente, calculamos $\ell(x, y)$ para luego hallar el gradiente del riesgo empírico

$$\ell(x, y) = -\log \hat{P}_{y|x}(y|x) = -(w_y^T x + b_y) + \log \left[\sum_{i=1}^K e^{w_i^T x + b_i} \right]$$

$$\frac{d\ell}{dw_k} = -x \cdot \mathbb{1}\{k=y\} + \frac{1}{\sum_{i=1}^K e^{w_i^T x + b_i}} \cdot e^{w_k^T x + b_k} \cdot x =$$

$$= -x \cdot \mathbb{1}\{k=y\} + \hat{P}_{y|x}(k|x) \cdot x = \left(\hat{P}_{y|x}(k|x) - \mathbb{1}\{k=y\} \right) \cdot x$$

$$\Rightarrow \frac{d\ell}{dw_k} = \left(\hat{P}_{y|x}(k|x) - \mathbb{1}\{k=y\} \right) \cdot x$$

$$\frac{d l}{d b_k} = -1 \cdot \mathbb{1}\{k=y\} + \hat{p}_{y|x}(k|x)$$

$$J(\theta) = \frac{1}{n} \sum_{i=1}^n l(x_i, y_i) \quad \theta \text{ incluye a todos los } w_k \text{ y } b_k$$

$$\frac{\partial J}{\partial w_k} = \frac{1}{n} \sum_{i=1}^n \left(\hat{p}_{y|x}(k|x_i) - \mathbb{1}\{k=y_i\} \right) \cdot x_i$$

Nuevamente, si el gradiente se anula se llega a que

$$\hat{p}_{y|x}(k|x_i) = \mathbb{1}\{y_i=k\}$$

$$\frac{\partial J}{\partial b_k} = \frac{1}{n} \sum_{i=1}^n \hat{p}_{y|x}(k|x_i) - \mathbb{1}\{k=y_i\}$$

Regresión Logística Polinómica

Como en regresión, si la complejidad no alcanza (alta riesgo empírico) se pueden usar fronteras polinómicas

con un predictor: observable x . Considera q' mi observación es $\tilde{x} = \begin{pmatrix} x^3 \\ x^2 \\ x \\ 1 \end{pmatrix}$

$$\hat{p}(1|x) = \sigma(w^T \tilde{x}) \quad \text{con } w = \begin{pmatrix} w_3 \\ w_2 \\ w_1 \\ b \end{pmatrix} \quad (\text{para regresión binaria})$$

Hay q' normalizar. Si hay overfitting se regulariza

¿Etapas de calibración?

25/1 → Figuras de mérito

Figuras de Mérito

Análisis del discriminante

I) Clasificación binaria → Precision, Recall, F1 score, curva ROC, AUC, EER

Precision = $\mathbb{P}(Y=1 | \Phi(X)=1)$ → P'edigo un 1 ¿Probabilidad de acierto?

Precision alto → siempre q' p'edigo 1 f' de 1

Precision bajo → Estoy teniendo muchos falsos positivos

⚠ Una buena Precision me protege de falsos positivos ⚠

Recall = $\mathbb{P}(\Phi(X)=1 | Y=1)$ → Tengo un 1 ¿Probabilidad de q' clasifique 1?

Recall alto → siempre q' tengo un uno lo clasifico como 1

Recall bajo → siempre q' tengo un uno lo clasifico mal → muchos falsos negativos

⚠️ Un buen recall me protege contra falsos negativos ⚠️

Precision $\rightarrow$ FP Recall $\rightarrow$ FN

Este 2 asegura q' $0 \leq F_1 < 1$

$$F_1 = 2 \cdot \left(\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}} \right)^{-1} = 2 \cdot \frac{P \cdot R}{P + R} \quad \text{Media armónica}$$

¿Para q' sirve la F_1 ? $\rightarrow$ Si las clases están desbalanceadas y la clase 1 es muy probable voy a tener una muy buena precision, pero mal recall y accuracy

$\rightarrow$ Si $\Phi(x) = 1 + x$ voy a tener buena recall, pero mal precision y accuracy

$\Rightarrow$ Un buen F_1 se consigue solo con buen precision y recall

Ejemplo 3.4 Un clasificador es evaluado con un conjunto de testeo. El análisis informo 120 verdaderos positivos, 60 falsos negativos, 30 falsos positivos y 9790 verdaderos negativos. Calcular accuracy, precision, recall y F1-score.

clase predicha	clase verdadera	
	0	1
0	9790	60
1	30	120

$\rightarrow$ clase verdadera

$$n = 10.000$$

Hubo 9820 0's
y 180 1's

$$Acc = P(Y = \phi(x)) = \frac{3730 + 120}{10000} = 0,991$$

$$Precision = P(Y = 1 | \phi(x) = 1) = \frac{P(Y = 1, \phi(x))}{P(\phi(x) = 1)} = \frac{120 / 10000}{150 / 10000} = \frac{120}{150} = 0,8$$

$$Recall = P(\phi(x) = 1 | Y = 1) = \frac{120}{60 + 120} = 0,6$$

$$F_1 = 2 \cdot 0,8 / 0,6 = 0,727$$

Comparémosla con un dummy (q' siempre predice 0)

$$Acc = \frac{3821}{10000} = 0,9821 \rightarrow \text{empeoró un poco}$$

$$Precision = P(Y = 1 | \phi(x) = 1) = 1/1 = 1 \rightarrow \text{mejoró, no tengo FP}$$

$$Recall = P(\phi(x) = 1 | Y = 1) = \frac{1}{113} = 0,008 \rightarrow \text{empeoró mucho, tengo mucho FN}$$

$$F_1 = 2 \cdot P / R = 0,0153 \rightarrow \text{empeoró mucho}$$

$\phi \backslash Y$	0	1
0	3820	119
1	0	1

$\rightarrow$ tengo q' ponerlo xq' si no tuve/am los números

Una posible forma de corregir el desbalance es sesgar con un umbral


Normalmente $\phi(x) = \mathbb{1}\{\hat{P}(1|x) > 1/2\}$ (siempre para el caso binario)

Cambiemos el umbral: $\phi_t(x) = \mathbb{1}\{\hat{P}(1|x) > t\}$

$t = 0 \Rightarrow \phi = 1 \forall x \rightarrow$ predigo siempre clase 1

$t = 1 \Rightarrow \phi = 0 \forall x \rightarrow$ predigo siempre clase 0

Para cada t voy a tener un TPR (true positive rate o recall) $P(\phi_t(x)=1 | y=1)$
y un FPR $P(\phi_t(x)=1 | y=0)$.



Si $t = 0$ $\phi(x) = 1$ siempre

$$\rightarrow P(\phi(x)=1 | y=1) = P(\phi(x)=1 | y=0) = 1$$

Si $t = 1$, $\phi = 0$ siempre

$$\rightarrow P(\phi(x)=1 | y=1) = P(\phi(x)=1 | y=0) = 0$$

ROC $\rightarrow$ receiver operating characteristic

AUC

EER? $\rightarrow$ me chupa un huevo

II) Clasificación categórica $\rightarrow$ matrix de confusión, F_1 -score

		Clase predicha		
		A	B	C
Clase verdadera	A	<u>30</u>	2	1
	B	3	<u>25</u>	2
	C	0	4	<u>27</u>

(a)

$\rightarrow$ aciertos

F_1 -score: generalización del F_1 . Se descompone la clasificación de k clases en k clasificaciones binarias (una clase contra todas). se hace el promedio de las k F_1

En este ejemplo: A) Precision = $P(Y=1 | \hat{Y}=1) = \frac{P(Y=1, \hat{Y}=1)}{P(\hat{Y}=1)} = \frac{\text{Elemento de la diagonal}}{\text{suma Filas}} = \frac{30}{33}$

Recall = $P(\hat{Y}=1 | Y=1) = \frac{P(Y=1, \hat{Y}=1)}{P(Y=1)} = \frac{\text{Diagonal}}{\text{columnas}} = \frac{30}{33}$

$F_{1A} = 30/33 //$

B) $P_k = 25/31$ $Re = 25/30$ $F_{1B} = 50/61 //$

$$c) P_t = 27/30 \quad R_e = 27/30 \quad F_{1c} = 54/61 //$$

$$F_1\text{-score} = 0.871$$

Análisis del discriminante

En secciones anteriores se demostró que las soluciones óptimas para diferentes funciones costo se definen a partir de la distribución condicional de $Y|_{X=x}$. El error cuadrático medio se minimiza estimando $\varphi(x) = \mathbb{E}[Y|X=x]$ (Prop. 1.8), la probabilidad de error con el clasificador bayesiano $\varphi(x) = \arg \max_y P_{Y|X=x}(y)$ (Prop. 3.1) y la entropía cruzada estimando la verdadera probabilidad condicional $\hat{P}(y|x) = P_{Y|X=x}(y)$ (Prop. 3.2). En todos los casos basta con modelar la distribución condicional, sin hacer ninguna suposición sobre la marginal $p_X(x)$. Pero que sea suficiente con modelar la condicional de $Y|_{X=x}$ no impide modelar también la marginal de X .

comparación de las 3 cosas q' vimos hasta ahora. clave.

Modelos discriminativos: Modelan solamente $P_{Y|X}$

Modelos generativos: Modelan también X , hallando su distribución y pudiendo generar datos nuevos $X \sim p_X$

Los modelos generativos son más complejos y necesitan más hipótesis

Asumiremos: $Y \sim \text{cat}\{c_1 \dots c_K\}$ y que $X|Y=k \sim \mathcal{N}(\mu_k, \Sigma_k)$

Con estas 2 hipótesis ¿cómo será $P(y|x)$? $x \in \mathbb{R}^{d_x}$

conjunta: $p(x, k) = p_{X|Y=k}(x) \cdot p_Y(k) = c_k \cdot \frac{1}{(2\pi)^{d_x/2} \sqrt{|\Sigma_k|}} \cdot \exp\left\{-\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k)\right\}$

$$p_X(x) = \sum_k p(x, k) = \sum_k c_k \frac{1}{(2\pi)^{d_x/2} \sqrt{|\Sigma_k|}} \cdot \exp\left\{-\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k)\right\}$$

y ahora agarrate:

$$p(y|x) = \frac{p(x, y)}{p(x)} = \frac{c_y \cdot \frac{1}{(2\pi)^{d_x/2} \sqrt{|\Sigma_y|}} \cdot \exp\left\{-\frac{1}{2}(x - \mu_y)^T \Sigma_y^{-1} (x - \mu_y)\right\}}{\sum_k c_k \frac{1}{(2\pi)^{d_x/2} \sqrt{|\Sigma_k|}} \cdot \exp\left\{-\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k)\right\}}$$

$$\frac{c_y}{\sqrt{|\Sigma_y|}} = \exp \left\{ \log c_y - \frac{1}{2} \log |\Sigma_y| \right\}$$

$$= \frac{\exp \left\{ \log c_y - \frac{1}{2} (x - \mu_y)^T \Sigma_y^{-1} (x - \mu_y) - \frac{1}{2} \log |\Sigma_y| \right\}}{\sum_k \exp \left\{ \log c_k - \frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) - \frac{1}{2} \log |\Sigma_k| \right\}}$$

$$\sum_k \exp \left\{ \log c_k - \frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) - \frac{1}{2} \log |\Sigma_k| \right\}$$

Obs clave: $P(y|x) = \text{softmax} \left(\log c_y - \frac{1}{2} (x - \mu_y)^T \Sigma_y^{-1} (x - \mu_y) - \frac{1}{2} \log |\Sigma_y| \right) =$

$$= \text{softmax} \left(\delta_y(x) \right) \quad \delta: \text{función discriminante (cuadrática)}$$

$$P(y|x) \propto e^{\delta_y(x)} \propto \delta_y(x)$$

$$\Rightarrow \Phi(x) = \underset{y}{\text{argmax}} P(y|x) = \underset{y}{\text{argmax}} \delta_y(x) \rightarrow \delta \text{ define las fronteras de decisión.}$$

Predicción soft: softmax de $\delta_y(x)$

Predicción hard: $\underset{y}{\text{argmax}}$ de $\delta_y(x)$

Hay muchos parámetros y puede haber overfitting. Una posible simplificación es

$$\text{asumir } \Sigma_k = \Sigma \quad \forall k$$

$$S_k(x) = \log c_k - \frac{1}{2} (x - u_k)^T \Sigma^{-1} (x - u_k) - \frac{1}{2} \log |\Sigma| =$$

$$= \log c_k - \frac{1}{2} (x^T \Sigma^{-1} - u_k^T \Sigma^{-1}) (x - u_k) - \frac{1}{2} \log |\Sigma| =$$

$$= \log c_k - \frac{1}{2} x^T \Sigma^{-1} x + \frac{1}{2} x^T \Sigma^{-1} u_k + \frac{1}{2} u_k^T \Sigma^{-1} x - \frac{1}{2} u_k^T \Sigma^{-1} u_k - \frac{1}{2} \log |\Sigma|$$

son iguales

$$= \log c_k - \frac{1}{2} x^T \Sigma^{-1} x + x^T \Sigma^{-1} u_k - \frac{1}{2} u_k^T \Sigma^{-1} u_k - \frac{1}{2} \log |\Sigma|$$

Ahora bien, como $P(k|x) = \text{softmax}(S_k(x))$ todos los términos de S q' no tengan k se van a cancelar en el numerador y denominador.

Además, $\hat{\varphi}(x) = \arg \max_k S_k(x)$, por lo q' todos los términos sin k suman constantes

→ los términos cuadrados no sirven para la decisión soft ni la hard.

Defino um novo discriminante com esses termos

$$\tilde{S}_k(x) = \log C_k + x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k \rightarrow \text{Discriminante } \underline{\text{linear}}$$

Entrenamiento: $C_k, \mu_k, \Sigma_k, \Sigma$ se calculan a partir de los datos

m : número de datos

$D_k = \{x_i : 1 \leq i \leq m \text{ and } y_i = k\} \rightarrow$ datos separados por categoría

$$\hat{C}_k = \frac{\# D_k}{m} \quad \hat{\mu}_k = \frac{1}{\# D_k} \sum_{x \in D_k} x$$

$$\hat{\Sigma}_k = \frac{1}{\# D_k - 1} \sum_{x \in D_k} (x - \hat{\mu}_k) \cdot (x - \hat{\mu}_k)^T$$

$$\hat{\Sigma} = \frac{1}{m - K} \sum_{k=1}^K (\# D_k - 1) \hat{\Sigma}_k \rightarrow \text{Este no lo entiendo}$$

$\hookrightarrow$ con esto da impreciso

Se puede demostrar q' todos
estos estimadores son
imprecisos, i.e.:

$$\mathbb{E}[\hat{C}_k] = C_k$$

La demostración es una
mierda

26/01 $\rightarrow$ KNN, SVM

KNN

Modelo no paramétrico $\rightarrow$ No voy a asumir ninguna distribución para $\hat{P}_{Y|X}$ ni $p_X(x)$

No voy a calcular medias ni varianzas ni nada, voy a calcular $\hat{P}_{Y|X}$ con los datos directamente

KNN: Tengo un dato x^* . Quiero estimar $\hat{P}_{Y|X}(y|x) \forall y$ y hacer $\hat{y}(x) = \arg\max_y \hat{P}_{Y|X}(y|x)$


1) me llega x^* . Agarro los k vecinos más cercanos

2) calculo $\hat{P}_{Y|X}(y|x) = \frac{k_y}{k}$ donde k_y es la cantidad de vecinos de la clase y

3) $\hat{y} = \arg\max_y \hat{P}_{Y|X}(y|x)$

Ejemplo 3.5 Graficar $\hat{P}(1|x)$ para una clasificación binaria mediante un algoritmo 2NN cuyos datos de entrenamiento pueden verse en la siguiente tabla.

X	1.2	0.2	2.3	0.4	2.0	1.6	1.0	2.5	2.7
Y	0	1	0	0	0	1	1	1	1




SVM

Nunca la entendí

"... se basa en maximizar el margen entre las muestras y la frontera de decisión"
 chúpate esa mandarina.

SVM estándar solo sirve para clasificación binaria y cuando existe una frontera lineal. Después se le agregan patches

$$y = -1$$



$$z(x) = w^T x + b$$

$$\text{si } z(x) \geq 0 \Rightarrow \hat{y} = 1$$

$$\text{si } z(x) < 0 \Rightarrow \hat{y} = -1$$

$$\hat{y} = \text{Sigm } z(x)$$

maximizar estos márgenes

Asumimos q' las muestras son linealmente separables, i.e., $y_i \cdot z(x_i) > 0 \quad \forall (x_i, y_i)$

$$\text{Definiremos } f_i(w, b) = y_i \cdot z(x_i) = y_i \cdot (w^T x_i + b) > 0 \quad \forall 1 \leq i \leq m_{tr}$$

Busquemos una forma de expresar el margen matemáticamente y maximizarlo

OBS 1: $w \parallel (x - x^*) \rightarrow |w^T (x - x^*)| = \|w\| \cdot \|x - x^*\|$

OBS 2: $z(x^*) = 0$ xq' está en la frontera $\Rightarrow z(x) = z(x) - z(x^*) =$

$$= w^T (x - x^*), \text{ ya no tenemos } b$$

La distancia de un punto x_i a la frontera será:

$$\|x_i - x_i^*\| = \frac{\|x_i - x_i^*\| \cdot \|w\|}{\|w\|} = \frac{|w^T(x_i - x_i^*)|}{\|w\|} = \frac{|z(x_i)|}{\|w\|} = \frac{y_i \cdot z(x_i)}{\|w\|}$$

$$= \frac{b_i(w, b)}{\|w\|} \Rightarrow \|x_i - x_i^*\| = \frac{b_i(w, b)}{\|w\|}$$

El margen será la mínima de todas estas distancias y dependerá de w y de b

$$m(w, b) = \min_i \frac{b_i(w, b)}{\|w\|} = \frac{b_k(w, b)}{\|w\|} \quad \text{donde } k \text{ es la muestra q' está sobre el margen}$$

!! Queremos maximizar este margen !!

$$\max_{w, b} m(w, b) \quad \text{tal que} \quad b_i(w, b) > 0 \quad \forall i$$

Aca hay un problema, q' es a la vez una simplificación. Yo puedo decir que

la frontera de decisión es $w^T x + b \geq 0$ o que es $(\alpha w)^T \cdot x + \alpha \cdot b \geq 0$, $\alpha \in \mathbb{R}^+$

y da lo mismo

Para $f_i(w, b)$ tenemos $f_i(\alpha w, \alpha b) = \alpha f_i(w, b)$ y para el margen tenemos $m(\alpha w, \alpha b) = m(w, b)$. Es decir, el problema es invariante a este reescalamiento, lo q' parece una cagada porque hay infinitas soluciones para w, b pero en realidad es una ventaja xq' podemos elegir α tal que:

$f_k(w, b) = 1$. Es decir: justo en el margen w y b serán tales que

$$f_k(w, b) = y_k (w^T x_k + b) = 1, \text{ donde } k \text{ es el índice del vector soporte } x_k$$

El margen queda: $m(w, b) = \frac{f_k(w, b)}{\|w\|} = \frac{1}{\|w\|}$

Entonces, el problema a resolver es:

$$\max_{w, b} \frac{1}{\|w\|} \quad \text{tal que} \quad f_i(w, b) \geq 1 \quad \forall i$$

↪ esto es q' todas las muestras queden por fuera de los márgenes

Por monotomía podemos reescribir el problema así:

$$\min_{w, b} \frac{1}{2} \|w\|^2 \quad \text{tal que} \quad y_i (w^T x_i + b) \geq 1 \quad \forall i \rightarrow \text{Problema primal de SVM}$$

Parches

1) Permitir la penetración de las muestras. Por cada muestra tendremos un $\xi_i \geq 0$ q' representará el grado de penetración de la muestra i .

$$\min_{w, b, \xi_1, \dots, \xi_n} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad \text{tq} \quad \begin{cases} y_i (w^T x_i + b) \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases}$$

hiperparámetro $\rightarrow$ penalización

$\xi_i = 0 \rightarrow$ la muestra está por fuera del margen bien clasificada

$0 < \xi_i \leq 1 \rightarrow$ la muestra está entre el margen y la frontera, bien clasificada

$\xi_i > 1 \rightarrow$ la muestra está del lado incorrecto de la frontera

Si $C \rightarrow \infty$: los ξ_i deben ser muy chicas, por lo q' se permiten pocas excepciones

Si $C = 0$: los ξ_i se pueden ir a la mierda y deja de tener sentido.

QDO: Es al revés que regularización

2) No linealidad. Se transforman las muestras a través de una función $\phi(\cdot)$ q' las lleve a un espacio donde sí sean linealmente separables

$$\min_{w, b} \frac{1}{2} \|w\|^2 \quad \text{tq} \quad y_i (w^T \cdot \phi(x_i) + b) \geq 1 \quad \forall i$$

3) Adaptar el algoritmo a la clasificación categórica (y no solo a la binaria)

Hay 2 opciones:

A) Entrenar algoritmos q' compaten las clases de a 2. k = número de clases.

Necesita $\frac{k(k-1)}{2}$ algoritmos. La clase con más votos gana (one vs. one)

B) Entrenar k - clasificadores binarios. Cada uno indica si la muestra pertenece o no a

esa clase. Se clasifica con $\phi(x) = \arg \max_k W_k^T \cdot \phi(x) + b_k \rightarrow$ la clase en la q' el margen quede más lejos

4) SVM se puede adaptar a regresión. Me chupa un huevo
Todo bien con SVM, pero ¿cómo ahora se resuelve?

Dualidad

Breve comentario sobre multiplicadores de Lagrange

Problema: hallar (x', y') = $\underset{(\pm \max)}{\operatorname{argmin}} f(x, y)$ sujeta a $g(x, y) =$

Recordar este dibujo


Equivalo a resolver

$$\nabla f = \alpha \nabla g, \quad g(x, y) = 0$$

$$\rightarrow \mathcal{L} = f(x, y) - \alpha g(x, y) = 0$$

$$g(x, y) = 0$$

Lagrange me agarramela con la mano



Entonces, el problema es hallar $(x, y) / \frac{\partial \mathcal{L}}{\partial (x, y)} = 0$ y $g(x, y) = 0$

Si hubiera más restricciones, $g_1 = g_2 = 0$, el Lagrangiano es:

$$\mathcal{L} = f - \alpha_1 g_1 - \alpha_2 g_2$$

Volvemos a la programación habitual:

El problema era

$$J_1 = \min_{w, b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i (w^T \phi(x_i) + b) \geq 1 \quad \forall \quad \underline{1 \leq i \leq m} \quad \begin{array}{l} \rightarrow \text{número de muestras} \\ \rightarrow m \text{ restricciones} \end{array}$$

Esto lo podemos reescribir así:

$$J_1 = \min_{w, b} \max_{\alpha_i \geq 0} \frac{1}{2} \|w\|^2 - \sum_{i=1}^m \alpha_i \cdot [y_i \cdot (w^T \phi(x_i) + b) - 1]$$

Esta equivalencia no es trivial.

→ Para las muestras q' cumplan $y_i (w^T \phi(x_i) + b) > 1$, la maximización sobre α_i tenderá a que $\alpha_i = 0$

→ Vectores soporte

→ Para las muestras q' cumplan $y_i(w^T \phi(x_i) + b) = 1$, el α_i es irrelevante xq' el término entre corchetes es nulo.

Estas 2 cosas ocurren siempre ya q' el problema es linealmente separable en el espacio de $\phi(\cdot)$ (hipótesis importante)

Este es un problema min-max, pero se puede invertir y resolver el problema max-min. (Esto no es trivial, pero bueno, me importa)

$$J_1 = \max_{\alpha_i \geq 0} \min_{w, b} \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i [y_i (w^T \phi(x_i) + b) - 1] =$$

$$= \max_{\alpha_i \geq 0} \min_{w, b} \mathcal{L}^{\text{opt}}(w, b, \alpha_1, \dots, \alpha_n)$$

Para resolver el problema del mínimo igualamos las derivadas del lagrangiano a 0

$$\frac{\partial \mathcal{L}^{\text{opt}}}{\partial w} = w - \sum_{i=1}^n \alpha_i y_i \phi(x_i) = 0 \quad ; \quad \frac{\partial \mathcal{L}^{\text{opt}}}{\partial b} = - \sum_{i=1}^n \alpha_i y_i = 0$$

$$\Rightarrow w = \sum_{i=1}^m \alpha_i y_i \phi(x_i) = w^* \quad ; \quad \sum \alpha_i y_i = \vec{\alpha} \cdot \vec{y} = 0 \rightarrow \text{nueva condición}$$

valor óptimo para w $\swarrow$ donde $\vec{\alpha} = (\alpha_1 \dots \alpha_m)$; $y = (y_1 \dots y_m)$

El Lagrangiano evaluado en los valores óptimos w^*, b^* será:

$$\begin{aligned} \mathcal{L}(w^*, b^*) &= \frac{1}{2} \|w^*\|^2 - \sum_{i=1}^m \alpha_i [y_i (w^{*T} \phi(x_i) + b^*) - 1] = \\ &= \frac{1}{2} \|w^*\|^2 - \sum_{i=1}^m \alpha_i y_i w^{*T} \phi(x_i) - \sum_{i=1}^m \alpha_i y_i b^* - \sum_{i=1}^m \alpha_i (-1) = \\ &= \frac{1}{2} \|w^*\|^2 - w^{*T} \sum_{i=1}^m \alpha_i y_i \phi(x_i) - b^* \sum_{i=1}^m \alpha_i y_i + \sum_{i=1}^m \alpha_i = \\ &= \frac{1}{2} \|w^*\|^2 - \|w^*\|^2 - 0 + \sum_{i=1}^m \alpha_i = \\ &= \vec{\alpha} \cdot \vec{1} - \frac{1}{2} \|w^*\|^2 = \end{aligned}$$

ω^{*T} ω^*

$$= \vec{\alpha} \cdot \vec{1} - \frac{1}{2} \left(\sum_{i=1}^m \alpha_i y_i \phi(x_i)^T \right) \cdot \left(\sum_{j=1}^m \alpha_j y_j \phi(x_j) \right) =$$

$$= \vec{\alpha} \cdot \vec{1} - \frac{1}{2} \sum_{j=1}^m \left(\sum_{i=1}^m \alpha_i y_i \phi(x_i)^T \right) \alpha_j y_j \phi(x_j) =$$

$$= \vec{\alpha} \cdot \vec{1} - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(x_i)^T \cdot \phi(x_j) =$$

$$= \vec{\alpha} \cdot \vec{1} - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \cdot y_i \phi(x_i)^T \cdot y_j \phi(x_j) \cdot \alpha_j =$$

$$= \vec{\alpha} \cdot \vec{1} - \frac{1}{2} \vec{\alpha}^T \cdot Q \cdot \vec{\alpha}$$

$$\Rightarrow \mathcal{L}(\omega^*, b^*, \vec{\alpha}) = \vec{\alpha} \cdot \vec{1} - \frac{1}{2} \vec{\alpha}^T \cdot Q \cdot \vec{\alpha}$$

$$\text{donc } Q_{ij} = y_i \phi(x_i)^T y_j \phi(x_j)$$

$$\Rightarrow J_2 = \max_{\vec{\alpha}} \mathcal{L}(\omega^*, b^*, \vec{\alpha}) = \max_{\vec{\alpha}} \vec{\alpha} \cdot \vec{1} - \frac{1}{2} \vec{\alpha}^T Q \vec{\alpha} \quad \text{s.t. } \vec{\alpha}^T \vec{y} = 0 \\ \text{y } \alpha_i \geq 0 \quad \forall i$$

Última simplificación importante:

Para las muestras q' no sean vectores soporte, $\alpha_i = 0$. Sea S el conjunto de índices de los vectores soporte. El producto $\vec{\alpha}^T Q \vec{\alpha}$ se simplifica a:

$$\vec{\alpha}^T Q \vec{\alpha} = \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(x_i)^T \phi(x_j) = \sum_{i \in S} \sum_{j \in S} \alpha_i \alpha_j y_i y_j k(x_i, x_j)$$

donde $k(x_i, x_j) = \phi(x_i)^T \phi(x_j)$ es el kernel

$$\Rightarrow J = \max_{\vec{\alpha}} \vec{\alpha} \cdot \vec{1} - \frac{1}{2} \sum_{i \in S} \sum_{j \in S} \alpha_i \alpha_j y_i y_j k(x_i, x_j)$$

Pregunta para el Shat

La etapa de entrenamiento sería hallar los α_i no nulos ¿Gradiente descendente?

Una vez q' tenes eso: $w^* = \sum_{i \in S} \alpha_i y_i \phi(x_i)$

¿cómo se calcula b ?

para los rectores soporte se cumple $y_i (w^{*\top} \phi(x_i) + b^*) = 1$

$$\Rightarrow b^* = y_i - w^{*\top} \phi(x_i) = (\text{obs: } y_i = \frac{1}{y_i} \text{ xq' } y_i \in \{-1, 1\})$$

$$= y_i - \left(\sum_{j \in S} \alpha_j y_j \phi(x_j)^\top \right) \cdot \phi(x_i)$$

$$= y_i - \sum_{j \in S} \alpha_j y_j k(x_i, x_j)$$

Para mayor estabilidad se hace un promedio de todos estos valores

$$b^* = \frac{1}{|S|} \sum_{i \in S} \left(y_i - \sum_{j \in S} \alpha_j y_j k(x_i, x_j) \right)$$

Decisión soft: $z(x) = w^* \cdot \phi(x) + b^* = \sum_{i=1}^S \alpha_i y_i k(x, x_i) + b^*$

Decisión hard: $\psi(x) = \text{sig}[z(x)]$


ABS clave: Tanto $\phi(x)$ como w^* pueden ser de dimensión infinita!

Esto es xq' nunca los tengo q' calcular, siempre paso por el kernel y

$k(x_i, x_j) \in \mathbb{R}$. Buenaborda

28/01 $\rightarrow$ Árboles

Árboles de decisión



La etapa de entrenamiento consiste en para cada nodo m el índice j_m , que indica qué predictor debe compararse y el umbral t_m

$$x_{j_m} \leq t_m$$

Luego, correr el algoritmo sobre los datos y elegir la clase más frecuente de cada hoja

El problema de optimización se define así:

Q_m : conjunto de datos en el modo m

$$\begin{aligned} Q_m^L(j_m, t_m) &= \{ (x, y) \in Q_m : x_{j_m} \leq t_m \} \\ Q_m^R(j_m, t_m) &= \{ (x, y) \in Q_m : x_{j_m} > t_m \} \end{aligned} \quad \left. \vphantom{\begin{aligned} Q_m^L(j_m, t_m) &= \{ (x, y) \in Q_m : x_{j_m} \leq t_m \} \\ Q_m^R(j_m, t_m) &= \{ (x, y) \in Q_m : x_{j_m} > t_m \} \end{aligned}} \right\} \rightarrow \text{dependen de } j_m \text{ y } t_m$$

Habr  una funci n q  mida la impureza de los nodos:


$$H(Q_m^R) \text{   } H(Q_m^L). \text{ la misma puede ser } H(Q) = \sum_{k=1}^K p_k (1 - p_k) \rightarrow \text{Gini}$$

$$\text{  } H(Q) = \sum_{k=1}^K -p_k \cdot \log_2(p_k) \rightarrow \text{entrop a}$$

Donde hay K clases y p_k es la prob. de pertenecer a la clase k seg n los datos en Q

$$p_k = \frac{|\{y \in Q : y = k\}|}{|Q|}$$

Para el caso de una clasificación binaria, las impurezas se ven así:



Donde $P(y=1) = x$, $P(y=0) = 1-x$

Si $x=1/2$ hay mucha impureza

la entropía es más estricta

Cada nodo tiene su impureza y por cada umbral que tomemos vamos a generar una impureza posterior en los nodos subsiguientes. Esa impureza es:

$$G_m(j_m, t_m) = \underbrace{\frac{|Q_m^R(j_m, t_m)|}{|Q_m|}}_{\text{Pesos}} \cdot H(Q_m^R(j_m, t_m)) + \underbrace{\frac{|Q_m^L(j_m, t_m)|}{|Q_m|}}_{\text{Pesos}} \cdot H(Q_m^L(j_m, t_m))$$

Los valores óptimos serán: $(j_m^*, t_m^*) = \arg \min_{j_m, t_m} G_m(j_m, t_m)$

Se hace por prueba y error (???)

No se utiliza GD, no hace falta normalizar xq' la predicción se hace de a un predictor a la vez, así q' no se comparan predictores

Algo particular de los árboles es q' nos permiten analizar qué predictores son importantes y ver cómo "piensa" el árbol.

Ganancia del nodo n en impureza: $\Delta_n = H(Q_n) - G(j_n^*, t_n^*)$ ¿> 0?
→ impureza del nodo
↳ impureza posterior

Feature importance: $FI(j_n) = \sum_{n \in J_n} \Delta_n$ donde J_n es el conjunto de nodos donde se utiliza el feature j_n para computar
Una FI por feature

→ se suelen normalizar para q' sumen 1

¿cuando para el árbol? → Árbol maximal: Todas las hojas tienen una sola clase (overfitting)

↳ Preestablecer una profundidad máxima

↳ Establecer un número mínimo de muestras q' deba tener un nodo

Podado: $T \rightarrow$ árbol maximal $L(T) \rightarrow$ conjunto de hojas $\#L(T) \rightarrow$ número de hojas

$m \rightarrow$ cantidad de datos. $m = \sum_{m \in L(T)} \#Q_m$

Definimos la función costo complejidad:

$$H_\alpha(T) = \sum_{m \in L(T)} \frac{\#Q_m}{m} \cdot H(Q_m) + \alpha \cdot \#L(T)$$

Diagram annotations:


- Costo** (with an arrow pointing to the first part of the equation)
- Proporción de datos en la hoja** (with an arrow pointing to $\frac{\#Q_m}{m}$)
- impureza de la hoja** (with an arrow pointing to $H(Q_m)$)
- hiperparámetro** (with an arrow pointing to α)
- complejidad** (with an arrow pointing to $\#L(T)$)

Nos quedaremos con el árbol que minimice $H_\alpha(T)$. $T^* = \underset{T}{\operatorname{argmin}} H_\alpha(T)$


si $\alpha = 0$, solo queda el término del costo y buscaré árboles que tengan impureza nula (aunque tengan pocas muestras en cada hoja)

Ejemplo 3.7 Sea el árbol de decisión maximal presentado en la Fig. 3.14a.


1. Indicar todos los posibles subárboles.
2. Indicar el costo-complejidad para cada subárbol, como función de α .
3. Elegir el subárbol de menor costo-complejidad para $\alpha = 0.1$ e indicar la feature importance.




T_2 [y₀, y₁, y₂]




$T_3)$



$T_4)$



$T_5)$



$$2) H_\alpha(t) = \sum_{m \in L(t)} \frac{|Q_m|}{n} \cdot H(Q_m) + \alpha \cdot \#L(t)$$

$n = 10$

Para T_1 : $\#L(T_1) = 5$, $H(Q_m) = 0 \quad \forall m \in L(T_1)$

$$\rightarrow H_\alpha(T_1) = 0 + \alpha \cdot 5$$

Para T_2 : $\#L(T_2) = 4$, Una sola hoja tiene impureza máxima

$$H_\alpha(T_2) = \frac{3}{10} \cdot 0,444 + \alpha \cdot 4 = 0,133 + 4\alpha$$

Para T_3 : $\#L(T_3) = 3$. Hay una sola hoja con $H(Q_n) \neq 0$

$$H_\alpha(T_3) = \frac{5}{10} \cdot 0,32 + 3 \cdot \alpha = 0,16 + 3\alpha$$

Para T_4 : $\#L(T_4) = 2$

↑ sube costo

$$H_\alpha(T_4) = \frac{6}{10} \cdot 0,5 + 2\alpha = 0,3 + 2\alpha \rightarrow \text{baja complejidad}$$

Para T_5 : $H_\alpha(T_5) = \frac{10}{10} \cdot 0,58 + \alpha = 0,58 + \alpha$

3) $\alpha = 0,1 \Rightarrow H(T_1) = 0,5$

$$H(T_2) = 0,533$$

$$H(T_3) = 0,46$$

$$H(T_4) = 0,5$$

$$H(T_5) = 0,68$$

FI: $\Delta_0 = H(Q_0) - G(j_0 = 0, t_0 = 0,343)$

$$H(Q_0) = 0,58 \quad G = \frac{4}{10} \cdot 0 + \frac{6}{10} \cdot 0,5 = 0,3$$

$$\Delta_0 = 0,28$$

$$\Delta_1: H(Q_1) = 0,5 \quad G = \frac{5}{6} \cdot 0,32 + \frac{1}{6} \cdot 0 = 0,267$$


$$\Delta_1 = 0,5 - 0,267 = 0,233$$

FI para x_0 : x_0 solo se usa en $m=0$: $FI(x_0) = \Delta_0 = 0,28$

FI para x_1 : x_1 " " " " $m=1$: $FI(x_1) = \Delta_1 = 0,233$

Normaliza: $FI(x_0) = 0,546$

$FI(x_1) = 0,454$



El problema de los árboles es el overfitting.

Bosques $\rightarrow$ Entrenamos B árboles $\rightarrow$ Lo hacemos con predictores distintos (si tienes d_x predictores lo hacemos con B_x predictores elegidos al azar)

$\rightarrow$ Lo hacemos con conjuntos de datos distintos (a partir de los n datos creamos B conjuntos de datos distintos con n elementos sacados del conjunto original con reposición).

La clase predicha es la más votada por todos los árboles del bosque

Problema para practicar: Resolver el problema dual de SVM con márgenes relajados ¿muy turbio?