

Recta final - Bayes, basura, ves ses la dictadura

Antes de ir de lleno con los temas nuevos, un repaso de estadística bayesiana

Estadística bayesiana

Estadística frecuentista: Modela los datos a través de una distribución con parámetro θ . θ es fijo, pero desconocido. De alguna forma estima θ (por máxima verosimilitud, por ej.)

Estadística bayesiana: Modela los datos con una distribución que depende de θ , pero a su vez, θ es una variable aleatoria con distribución $p_T(\theta)$. Una vez observados los datos D , la distribución de θ cambia.

$p_T(\theta) \rightarrow$ dist. a priori $p_T(\theta|D) \rightarrow$ dist. a posteriori $p(x|T=\theta) \rightarrow$ distribución de los datos cuando θ es conocido

Estas 3 se relacionan a partir de la regla del hijo de mil putas de Bayes:

$$p_T(\theta|x) = \frac{p(x|\theta) \cdot p_T(\theta)}{p(x)} \propto p(x|\theta) \cdot p_T(\theta)$$

→ V.A. → realización

Digamos q' observo una serie de datos $\vec{X} = \vec{x} = (x_1, x_2 \dots x_m)$

La independencia vale si primero conocemos a θ :

$$p_{\vec{X}}(\vec{x} | T = \theta) = p_{\vec{X}}(\vec{x} | \theta) = \prod_{i=1}^m p_X(x_i | \theta)$$

La posterior queda:

$$p_T(\theta | \vec{X} = \vec{x}) = p_T(\theta | \vec{x}) \propto p_T(\theta) \cdot p_{\vec{X}}(\vec{x} | \theta) \propto p_T(\theta) \cdot \prod_{i=1}^m p_X(x_i | \theta)$$

Acá ya podemos estimar θ :

$$\hat{\theta}_{MAP} = \arg \max_{\theta \in \Theta} p_T(\theta | \vec{x}) \rightarrow \text{Para el caso discreto}$$

→ máximo a posteriori

$$\hat{\theta}_{Bay} = \mathbb{E}[T | \vec{X} = \vec{x}] = \int_{\theta \in \Theta} \theta \cdot p(\theta | \vec{x}) \cdot d\theta \rightarrow \text{Para el caso continuo}$$

Pero esto de estimar θ ya lo podemos hacer con la estadística frecuentista. El

plato fuerte es conocer la distribución predictiva $p_{X_{test} | \vec{X} = \vec{x}}(x_{test})$

donde x_{test} es un nuevo dato no observado en $\vec{x}$. Obs no hace falta conocer θ antes de calcular esta densidad.

hago de cuenta q' conozco θ

$$\rightarrow p_{x_{test} | \vec{x} = \vec{x}}(x_{test}) = \int_{\theta \in \Theta} \boxed{p_X(x_{test} | \theta)} \cdot p_T(\theta | \vec{x}) d\theta \quad \hookrightarrow \text{pondere por todos los } \theta \text{ posibles, una vez observados los datos}$$

$$p_{x_{test} | \vec{x} = \vec{x}}(x_{test}) = E[p_X(x_{test} | T) | \vec{x} = \vec{x}]$$

función de la variable aleatoria

Es decir, pensar q' para x_{test} fijo, $p_X(x_{test} | \theta)$ es una función de θ $f(\theta)$

$$\rightarrow p_{x_{test} | \vec{x} = \vec{x}}(x_{test}) = E[f(T) | \vec{x} = \vec{x}] = \int_{\theta \in \Theta} f(\theta) \cdot p_T(\theta | \vec{x}) d\theta$$

Nota: para mí $p_{X|T=\theta}(x) = p_{X|T}(x|\theta) = p_X(x|\theta)$ es todo lo mismo

Ejemplo 1.3 El tiempo de vida (en años) de un transistor es una variable aleatoria con distribución exponencial de parámetro θ . A priori se modela θ como una variable aleatoria con distribución $\Gamma(2, 3)$. Si en 20 transistores se observó una duración total $\sum_{i=1}^{20} x_i = 7$.

1. Hallar la distribución a posteriori del parámetro θ .

2. Hallar la distribución predictiva del tiempo de vida de un transistor.

$$1) X|T=\theta \sim \text{Exp}(\theta) \rightarrow \theta e^{-\theta \cdot x} \mathbb{1}\{x \geq 0\}; T \sim \Gamma(2, 3) \rightarrow \frac{3^2}{2!} \theta^{2-1} \cdot e^{-3\theta} \mathbb{1}\{\theta \geq 0\}$$

$$p_{T|\vec{X}}(\theta|\vec{x}) \propto p_T(\theta) \cdot p_{\vec{X}|T}(\vec{x}|\theta) \propto \theta e^{-3\theta} \mathbb{1}\{\theta \geq 0\} \cdot \prod_{i=1}^{20} \theta e^{-\theta x_i} \mathbb{1}\{x_i \geq 0\} =$$

$$= \theta^{21} e^{-3\theta} e^{-\theta \cdot \sum_{i=1}^{20} x_i} \cdot \mathbb{1}\{\theta \geq 0\} = \theta^{21} e^{-10 \cdot \theta} \mathbb{1}\{\theta \geq 0\} \propto \Gamma(\alpha=22, \lambda=10)$$

$$\Rightarrow T|\vec{X}=\vec{x} \sim \Gamma(22, 10) \text{ En general, si observo } \sum_{i=1}^n x_i = S \text{ y } \theta \sim \Gamma(\alpha, \beta)$$

$$T|\vec{X}=\vec{x} \sim \Gamma(\alpha+n, \beta+S) \quad \text{MV: } \hat{\theta} = 20/7 \approx 2,86$$

$$\text{BAY: } \hat{\theta} = \frac{22}{10} = 2,2$$

¿Y cómo sé cual es mejor?

$$2) p_{X_{\text{test}}|\vec{X}}(x_{\text{test}}|\vec{x}) = \int_{\theta \in \Theta} p_{X|\tau}(x_{\text{test}}|\theta) \cdot p_{\tau|\vec{X}}(\theta|\vec{x}) d\theta =$$

$$\Gamma(23, x_{\text{test}} + 10)$$

$$= \int_0^{+\infty} \theta e^{-\theta \cdot x_{\text{test}}} \cdot \mathbb{1}\{x_{\text{test}} \geq 0\} \cdot \frac{10^{22}}{22!} \theta^{21} e^{-10 \cdot \theta} d\theta \propto \int_0^{+\infty} \theta^{22} e^{-(x_{\text{test}} + 10) \cdot \theta} d\theta =$$

$$= \int_0^{+\infty} \frac{(x_{\text{test}} + 10)^{23}}{23!} e^{-(x_{\text{test}} + 10) \cdot \theta} d\theta \cdot \frac{23!}{(x_{\text{test}} + 10)^{23}} = 1 \cdot \frac{23!}{(x_{\text{test}} + 10)^{23}} \cdot \mathbb{1}\{x_{\text{test}} \geq 0\}$$

$$\therefore p_{X_{\text{test}}|\vec{X}}(x_{\text{test}}|\vec{x}) \propto \frac{1}{(x_{\text{test}} + 10)^{23}} \mathbb{1}\{x_{\text{test}} \geq 0\} \sim \text{Lomax}(\alpha = 22, 10)$$

Estadístico suficiente: Si $S(\vec{x})$ me da la misma info q $\vec{x}$, $S(\vec{x})$ es estadístico suficiente

$\rightarrow p_{\tau|\vec{X}=\vec{x}}(\theta) = p_{\tau|S(\vec{x})=S(\vec{x})}(\theta) \rightarrow$ no me hace falta conocer todo $\vec{x}$, solo $S(\vec{x})$

Inferencia bayesiana

"El pensamiento bayesiano consiste en actualizar las creencias tras considerar nueva evidencia"

Ejemplo 6.1 Lucas dispara a un blanco y el disparo impacta en un punto aleatorio $(X, 0)$ con X (en decímetros) una variable aleatoria con distribución normal de media nula y varianza $1/\tau$, donde τ representa la precisión de Lucas. A priori la precisión τ tiene una distribución chi-cuadrado de 8 grados de libertad. Lucas tiro 10 veces al blanco y observó $\sum_{i=1}^{10} x_i^2 = 17$. En virtud a la información muestral,

1. Hallar la distribución a posteriori.

2. Hallar la distribución predictiva.

$$T \sim \chi^2_8 \cdot p_T(\tau) \propto \tau^{8/2-1} e^{-\tau/2} = \tau^3 \cdot e^{-\tau/2} \quad \{X|T=\tau\} \sim N(0, \sigma^2 = \frac{1}{\tau})$$

$$1) \quad p_{T|\vec{x}}(\tau|\vec{x}) \propto p_T(\tau) \cdot \prod_{i=1}^{10} p_{X|T}(x_i|\tau) \propto \tau^3 e^{-\tau/2} \prod_{i=1}^{10} \sqrt{\tau} e^{-\frac{1}{2}\tau x_i^2} =$$

$$= \tau^3 e^{-\tau/2} \left(\tau^{1/2}\right)^{10} e^{-\frac{1}{2}\tau \sum_{i=1}^{10} x_i^2} = \tau^8 e^{-9\tau} \sim \Gamma(9, 9)$$

$$\Rightarrow \tau | \vec{x} = \vec{x} \sim \Gamma(g, g)$$

$$2) \quad p_{x_{test} | \vec{x}}(x_{test} | \vec{x}) = \int_0^{+\infty} p_{x | \tau}(x_{test} | \tau) \cdot p_{\tau | \vec{x}}(\tau | \vec{x}) d\tau \propto$$

$$\propto \int_0^{+\infty} \sqrt{\tau} e^{-\frac{1}{2}\tau x_{test}^2} \tau^g e^{-g \cdot \tau} d\tau = \int_0^{+\infty} \tau^{17/2} e^{-(\frac{x_{test}^2}{2} + g)\tau} d\tau =$$


$$\Gamma\left(\kappa = \frac{19}{2}, \lambda = \frac{x_{test}^2}{2} + g\right)$$

$$= \frac{\Gamma(19/2)}{\left(\frac{x_{test}^2}{2} + g\right)^{19/2}} \propto \frac{1}{\left(\frac{x_{test}^2}{2} + g\right)^{19/2}} \propto \left(\frac{x_{test}^2}{18} + g\right)^{-\frac{18+1}{2}} \sim t_{18}$$

$$\Rightarrow x_{test} | \vec{x} = \vec{x} \sim t_{18}$$

Redes bayesianas

Son una visualización del modelo



Solo x e y son observables

X y V No son independientes, pero

$X|U=u$ y $V|U=u$ sí lo son

Muy simpático todo esto, pero la verdad q' se me está complicando el tema de las distribuciones


$$p_{X,Y,U,V}(x,y,u,v) = p_U(u) \cdot p_{X|U}(x|u) \cdot p_{V|U}(v|u) \cdot p_{Y|U,V}(y|u,v)$$

Recordar el ejemplo de los mensajes: X_i : mensajes recibidos el día i $X_i | \Lambda_i = \lambda_i \sim \text{Poi}(\lambda_i)$

$$\lambda_i = \begin{cases} \beta_1 & \text{si } i \leq \tau \\ \beta_2 & \text{si } i > \tau \end{cases}$$

, donde $\beta_1, \beta_2 \sim \text{Exp}(\alpha)$, con α un valor fijo, $\alpha = \frac{1}{m} \sum_{i=1}^m X_i$

y por última $\tau \sim U\{1, \dots, m\}$



$$p(x_i | \lambda_i, \beta_1, \beta_2, \tau) (x_i) \sim \text{Poi}(\lambda_i)$$

observo $\vec{x}$

¿cómo se distribuyen $\lambda_i | \vec{X} = \vec{x}$, $\beta | \vec{x} = \vec{x}$, $\tau | \vec{x} = \vec{x}$ y $\tau | \vec{x} = \vec{x}$?

$$p_{\lambda_i, \beta_1, \beta_2, \tau}(\lambda_i, \beta_1, \beta_2, \tau) = p_{\lambda_i}(\lambda_i | \beta_1, \beta_2, \tau) \cdot p_{\beta_1}(\beta_1) \cdot p_{\beta_2}(\beta_2) \cdot p_{\tau}(\tau) = p_{\Theta}(\theta)$$

$$p_{\Theta | \vec{x}}(\theta | \vec{x}) \propto p_{\vec{x} | \Theta}(\vec{x} | \theta) \cdot p_{\Theta}(\theta)$$

↓
L variables, algunas continuas, algunas discretas

$$\hat{\theta}_{\text{Bay}} = \mathbb{E}[\Theta | \vec{X} = \vec{x}] = \int_{\theta \in \Theta} \theta \cdot p_{\Theta}(\theta | \vec{x}) \cdot d\theta \rightarrow \text{integral cuádruple, q' es en parte una suma}$$


¿ θ se puede ir haciendo por partes? primero para τ, β_1, β_2 y luego para λ_i

Me cuentas de $p_{x_{\text{test}} | \vec{x}}(x_{\text{test}} | \vec{x})$. La cuestión es q' se nos fue de las manos

Más sobre esto luego. Analicemos primero algunos de los modelos más simples

Bayes Naive

Asumiremos la relación causal $Y \rightarrow \vec{X} = \begin{pmatrix} x_1 \\ \vdots \\ x_d \end{pmatrix}$ y cada x_j es independiente de los otros una vez conocidos $Y=k$ (hipótesis naive)



Una vez observado $\vec{x}$:

$$p(y|\vec{x}) \propto \underbrace{p(y)}_{\text{prior}} \cdot \overset{\text{naive}}{p(\vec{x}|y)} = p(y) \cdot \prod_{j=1}^d p(x_j|y)$$

Si no observo Y ¿cómo sé $\#y=k$?
 ¿Algún algoritmo de clustering?
 ↑ como k-means? ¿Entender

Para la prior tiene sentido elegir $Y \sim \text{Cat}\{c_1, \dots, c_k\}$, $c_k = \frac{\#y=k}{n}$

los priors con EM?
 En realidad, esto es un
 algoritmo de aprendizaje
 supervisado

Lo siguiente que podemos hacer es asignarle una distribución a cada $p(x_j|y)$

Bayes Naive Gaussiano

Básicamente es una mezcla de Gaussianos:

$$Y \sim \text{cat}\{c_1, \dots, c_K\} \quad x_j | Y=k \sim \mathcal{N}(\mu_j^{(k)}, \sigma_j^{2(k)}) \rightarrow (\text{de dimensión 1})$$

Es decir, el vector aleatorio $\begin{pmatrix} x_1 \\ \vdots \\ x_d \end{pmatrix} | Y=k \sim \mathcal{N}(\mu^{(k)}, \Sigma^{(k)})$ donde

$$\mu^{(k)} = \begin{pmatrix} \mu_1^{(k)} \\ \mu_2^{(k)} \\ \vdots \\ \mu_d^{(k)} \end{pmatrix} ; \quad \Sigma^{(k)} = \begin{pmatrix} \sigma_1^{2(k)} & 0 & \dots & 0 \\ 0 & \sigma_2^{2(k)} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_d^{2(k)} \end{pmatrix}$$

Naive (Independencia)

Si tengo vectores en $\mathbb{R}^d$ y K clases

LDA: K medias $\in \mathbb{R}^d$ y una matriz $\in \mathbb{R}^{d \times d}$ $\rightarrow K \cdot d + \frac{d(d+1)}{2}$ parámetros a estimar
SIMÉTRICA!!!

GNB: K medias $\in \mathbb{R}^d$ y K matrices diagonales $\in \mathbb{R}^{d \times d} \rightarrow K \cdot d + K \cdot d$


QDA: " " " " K matrices $\in \mathbb{R}^{d \times d} \rightarrow K \cdot d + K \cdot \frac{d(d+1)}{2}$

SIMÉTRICAS!!!

$K \cdot \frac{d(d+1)}{2}$

↓ + complejidad

Naive Bayes Multinomial



Hipótesis naive:

$X_i | Y = k$ indep. de $X_j | Y = k$
para $i \neq j$

Ahora asumiremos el siguiente modelo: $Y \sim \text{Cat}\{c_1, \dots, c_K\}$; $X_j | Y = k \sim \text{Cat}\{\theta_1^{(k)}, \theta_2^{(k)}, \dots, \theta_V^{(k)}\}$
Y puede tomar K valores distintos, hay K categorías

$X_j | Y = k$ puede tomar V valores distintos. En procesamiento de texto, hay V palabras

Observo $\vec{x} = (x_1, \dots, x_d)$

naive

$$\rightarrow p(y | \vec{x}) \propto p(y) \cdot p(\vec{x} | y) \stackrel{\hat{}}{=} c_y \cdot \prod_{j=1}^d p(x_j | y) = c_y \cdot \prod_{j=1}^d \theta_{x_j}^{(y)} = c_y \cdot \prod_{m=1}^V \left(\theta_m^{(y)} \right)^{N_m}$$

N_m : cantidad de veces q' apareció un m entre todos los x_j

(cantidad de veces q' apareció la palabra m en el texto $\vec{x}$)

$$\theta_1 \cdot \theta_1 \cdot \theta_1 \dots \theta_3 \cdot \theta_3 \dots \theta_V \theta_V = \theta_1^3 \dots \theta_3^2 \dots \theta_V^2$$

La palabra 1 apareció 3 veces, etc.

$p(y | \vec{x}) \rightarrow$ probabilidad de que el texto pertenezca a la clase y

$$\left(\hat{y} = \text{argmax}_y p(y | \vec{x}) = \text{argmax}_y \log p(y | \vec{x}) \right)$$

debe haber algunos $\theta_{x_j}^{(y)}$

$\Delta \rightarrow$ en la Π q' se repitan

$\rightarrow$ potencia sobre las palabras

Definimos $\vec{N} = (N_1, N_2 \dots N_v)$ $\rightarrow \vec{N} \cdot \vec{1} = \sum_{m=1}^v N_m = d \rightarrow$ Largo del documento $\vec{x}$

Estadística suficiente, da lo mismo

observar $\vec{x}$ o $\vec{N}$

$$\rightarrow \vec{N} | y=k \sim \mathcal{M}(d, \{\theta_1^{(k)}, \theta_2^{(k)} \dots \theta_v^{(k)}\})$$

$$\log p(y|\vec{x}) = \text{cte} + \log c_y + \sum_{m=1}^v N_m \cdot \log \theta_m^{(y)}$$

$\rightarrow$ suma ponderada por los pesos $\log \theta_m^{(y)}$?

Para poder hacer el argmax de eso necesita haber estimado los c_y y los $\theta_m^{(k)}$ para todas las clases

Entrenamiento: observar los siguientes m datos (m documentos): $\{(\vec{N}_i, y_i)\}_{i=1}^m$

$\rightarrow$ Supervisado

$$\rightarrow c_k = \frac{\#\{y_i = k\}}{m}$$

Estimar los $\theta_m^{(k)}$ es más complicado

Primero concatenamos todos los textos de clase k , nos quedaremos solo con k textos, 1 por clase

$$\tilde{N}_m^{(k)} = \sum_{i=1}^m N_{i,m} \cdot \mathbb{1}\{y_i = k\} \rightarrow \text{cantidad de veces q' apareció la palabra } m \text{ en todos los textos de clase } k$$

$\tilde{N}_m^{(k)} \rightarrow$ Es estadística suficiente, da lo mismo observar $(\tilde{N}_1^{(k)}, \tilde{N}_2^{(k)} \dots \tilde{N}_v^{(k)})$ q' observar $\{(\vec{N}_i, y_i)\}_{i=1}^n$

Ahora viene la parte propiamente bayesiana.

Distribución a priori de $\theta_m^{(k)}$: $\vec{T}_k = (\theta_1^{(k)}, \theta_2^{(k)} \dots \theta_v^{(k)}) \sim \text{Dir}([\alpha_1, \alpha_2 \dots \alpha_v])$

La densidad de la Dirichlet tiene esta pinta:

$$p(\theta_1^{(k)}, \theta_2^{(k)}, \dots, \theta_v^{(k)}) = \frac{\prod_{m=1}^v \Gamma(\alpha_m)}{\Gamma(\sum_{m=1}^v \alpha_m)} \cdot \prod_{m=1}^v [\theta_m^{(k)}]^{\alpha_m-1} \cdot \mathbb{1}_{\left\{ \theta_m \geq 0, \sum_{m=1}^v \theta_m^{(k)} = 1 \right\}}$$

Prop. importante: La marginal $T_m^{(k)} \sim \beta(\alpha_m, \sum_{n \neq m} \alpha_n) \rightarrow$ Así se distribuye $\theta_m^{(k)}$

$\rightarrow$ Acá sería más lógico poner $\Pi_m^{(k)}$, me sé xq' este tipo usa T

$$\Rightarrow E[T_m^{(k)}] = \frac{\alpha_m}{\sum_{n=1}^v \alpha_n}$$

Por otro lado, si conocemos los $\theta_m^{(k)}$, podemos modelar la distribución de los $\tilde{N}_m^{(k)}$ como una multinomial:

$$(\tilde{N}_1^{(k)}, \tilde{N}_2^{(k)}, \dots, \tilde{N}_V^{(k)}) | \vec{T}_k = (\theta_1^{(k)}, \dots, \theta_V^{(k)}) \sim \mathcal{M}(\tilde{d}^{(k)}, [\theta_1^{(k)}, \dots, \theta_V^{(k)}])$$

Donde $\tilde{d}^{(k)}$ es el largo de la concatenación de los documentos de clase k

OBS: $p(\tilde{N}_1^{(k)}, \dots, \tilde{N}_V^{(k)} | \vec{T}_k) \propto \prod_{m=1}^V [\theta_m^{(k)}]^{\tilde{N}_m^{(k)}} \quad (\text{es la forma de la multinomial})$

Ahora viene lo importante: Al conocer $p(\theta_1^{(k)}, \dots, \theta_V^{(k)})$ y $p(\tilde{N}_1^{(k)}, \dots, \tilde{N}_V^{(k)} | \vec{T}_k)$ podemos conocer la distribución a posteriori de $\vec{T}_k = (\theta_1^{(k)}, \dots, \theta_V^{(k)})$ y estimar los $\theta_1^{(k)}, \dots, \theta_V^{(k)}$ una vez observados los datos $\tilde{N}_1^{(k)}, \dots, \tilde{N}_V^{(k)}$. (Esta es la q' veníamos haciendo en los ejercicios, esto es hacer bayes, conocer la dist. a posteriori de los θ)

$$p(\theta | \vec{x}) \propto p(\vec{x} | \theta) \cdot p(\theta)$$



Manos a la obra

$$p(\theta_1^{(k)} \dots \theta_v^{(k)} | \tilde{N}_1^{(k)} \dots \tilde{N}_v^{(k)}) \propto p(\tilde{N}_1^{(k)} \dots \tilde{N}_v^{(k)} | \theta_1^{(k)} \dots \theta_v^{(k)}) \cdot p(\theta_1^{(k)} \dots \theta_v^{(k)}) =$$

$$= \prod_{m=1}^v [\theta_m^{(k)}]^{\tilde{N}_m^{(k)}} \cdot \prod_{m=1}^v [\theta_m^{(k)}]^{\alpha_m - 1} \cdot \mathbb{1}\{\theta_m^{(k)} \geq 0, \sum_{m=1}^v \theta_m^{(k)} = 1\} =$$

$$= \prod_{m=1}^v [\theta_m^{(k)}]^{\tilde{N}_m^{(k)} + \alpha_m - 1} \cdot \mathbb{1}\{\theta_m^{(k)} \geq 0, \sum_{m=1}^v \theta_m^{(k)} = 1\} \sim \text{Dir}([\alpha_1 + \tilde{N}_1^{(k)}, \dots, \alpha_v + \tilde{N}_v^{(k)}])$$

$$\Rightarrow \vec{T}_k | \tilde{N}_1^{(k)} \dots \tilde{N}_v^{(k)} \sim \text{Dir}([\alpha_1 + \tilde{N}_1^{(k)}, \dots, \alpha_v + \tilde{N}_v^{(k)}])$$

Para estimar los $\theta_m^{(k)}$ usamos la media a posteriori, y q' las marginales de la dirichlet son betas

$$T_m^{(k)} | \tilde{N}_1^{(k)} \dots \tilde{N}_v^{(k)} \sim \beta(\alpha_m + \tilde{N}_m^{(k)}, \sum_{n \neq m} \alpha_n + \tilde{N}_n^{(k)})$$

$$\Rightarrow \text{A posteriori } \theta_m^{(k)} = \mathbb{E}[T_m^{(k)} | \tilde{N}_1^{(k)} \dots \tilde{N}_v^{(k)}] = \frac{\alpha_m + \tilde{N}_m^{(k)}}{\sum_{n=1}^v \alpha_n + \tilde{N}_n^{(k)}}$$

En resumen, el entrenamiento es 1) $c_k = \frac{\#\{y_i = k\}}{m}$

$$2) \theta_m^{(k)} = \frac{\alpha_m + \tilde{N}_m^{(k)}}{\sum_{n=1}^V \alpha_n + \tilde{N}_n^{(k)}} \quad 1 \leq m \leq V \quad 1 \leq k \leq K$$

¿Qué representan los α_m ?

→ Son los parámetros a priori de la distribución de T_k . A priori, tengo que $E[T_m^{(k)}] = \frac{\alpha_m}{\sum_{n=1}^V \alpha_n}$

⇒ α_m : "Conteo" a priori (imaginario) de la palabra m

$\tilde{N}_m^{(k)}$: Conteo a posteriori (real) de la palabra m

En general $\alpha_m = 1 \forall m$, lo q' representa q' a priori todas las palabras son equiprobables

Todo muy simpático, pero el plato fuerte de la estadística bayesiana era calcular la distribución predictiva

Recordar siempre

T : V.A.

θ : realización de T

(H) : dominio de θ

$$p(x_{\text{test}} | \vec{x}) = \int_{\theta \in (H)} p(x_{\text{test}} | \theta) \cdot p(\theta | \vec{x}) d\theta = E[p(x_{\text{test}} | T) | \vec{X} = \vec{x}]$$

¿Cómo hacemos esto?

Bayes Variacional Gaussiano

la puta q' me pario'

Antes de avanzar, recordar que:

Sea $q(z|x)$ una densidad evalúa la V.A. z en $q(\cdot|x)$

$$H(q(\cdot|x)) = E[-\log q(z|x) | X=x] = \int_{\text{sup}(z)} \boxed{-\log q(z|x)} \cdot \boxed{q(z|x)} dz = \int_{\text{sup}(z)} q(z|x) \cdot \log \frac{1}{q(z|x)} dz$$

Peso ↑


Sea $p(\cdot|x)$ otra densidad

$$KL(q(\cdot|x) || p(\cdot|x)) = E_q \left[\log \frac{q(z|x)}{p(z|x)} \mid X=x \right] = \int_{\text{sup}(z)} \boxed{\log \frac{q(z|x)}{p(z|x)}} \cdot \boxed{q(z|x)} dz$$

función de la V.A. z ← pesos ↑

Como en EM, primero presentamos el caso general, pero este algoritmo funciona asumiendo algún tipo de modelo (de base que va a ser una mezcla de Gaussianas)

Supongamos que tenemos algún tipo de modelo, como $x'ej'$:



→ Solo observamos x_i

→ Tenemos un vector de variables latentes $\vec{z} = (\vec{\pi}, \vec{u}, \vec{\lambda}, \vec{\mu})$

Típicamente asumiremos una distribución para $\vec{z}$ y una para x_i , de manera q' podamos hallar la distribución a posteriori de $\vec{z}$: $p(\vec{z} | \vec{x})$

Pero se está volviendo prohibitivo

Haremos lo siguiente: 1) Aproximamos el modelo, eligiendo distribuciones para $\vec{\pi}$, $u_i | \vec{\pi}$ ($1 \leq i \leq n$), λ_k , $\mu_k | \lambda_k$

y $x_i | u_i, \lambda, \mu$

2) Tenemos una función $q(\vec{z} | \vec{x})$ que se aproximará a $p(\vec{z} | \vec{x})$ a medida q' avance el algoritmo y q' minimicemos la siguiente KL:

$$q(\vec{z} | \vec{x}) = \arg \min_{q \in \mathcal{P}} KL(q(\cdot | \vec{x}) || p(\cdot | \vec{x}))$$

OBS: En el vector $\vec{z} = (\vec{\pi}, \vec{u}, \vec{\lambda}, \vec{\mu})$ distinguimos 2 tipos de variables

a) Variables q' son parámetros de las distribuciones del modelo → En GVB: $\vec{\pi} = (\pi_1, \dots, \pi_K)$, $\vec{\mu} = (\mu_1, \dots, \mu_K)$ y $\vec{\lambda} = (\lambda_1, \dots, \lambda_K)$

b) Variables latentes → En GVB: $\vec{u} = (u_1, \dots, u_n)$

Nota importante sobre la notación: Si la densidad es continua: letra minúscula $\rightarrow p$ o q

Si es discreta: mayúscula $\rightarrow P$ o Q .

Manos a la obra:

$$\text{Objetivo: } q(\vec{z}|\vec{x}) = \arg \min_{q \in \mathcal{P}} KL(q(\cdot|\vec{x}) \| p(\cdot|\vec{x}))$$

Desarrollamos la KL:

$$KL = \mathbb{E}_q \left[\log \frac{q(\vec{z}|\vec{x})}{p(\vec{z}|\vec{x})} \mid \vec{X} = \vec{x} \right] = \mathbb{E}_q \left[\log \frac{q(\vec{z}|\vec{x}) \cdot p(\vec{x})}{p(\vec{x}, \vec{z})} \mid \vec{X} = \vec{x} \right] =$$

$p(\vec{z}|\vec{x}) = \frac{p(\vec{x}, \vec{z})}{p(\vec{x})}$

No depende de $\vec{z}$, es cte

$$= \mathbb{E}_q \left[\log p(\vec{x}) \mid \vec{X} = \vec{x} \right] - \mathbb{E}_q \left[-\log q(\vec{z}|\vec{x}) \mid \vec{X} = \vec{x} \right] - \mathbb{E}_q \left[\log p(\vec{x}, \vec{z}) \mid \vec{X} = \vec{x} \right] =$$

$$= \log p(\vec{x}) - \left\{ H(q(\cdot|\vec{x})) + \mathbb{E}_q \left[\log p(\vec{x}, \vec{z}) \mid \vec{X} = \vec{x} \right] \right\} = \log p(\vec{x}) - ELBO(q(\cdot|\vec{x}))$$

$\rightarrow$ minimizar la KL es lo mismo q' maximizar el ELBO

$$q(\cdot|\vec{x}) = \arg \min_{KL} = \arg \max ELBO$$

Añadimos la siguiente hipótesis: $\vec{z} = (\vec{u}, \phi)$, donde $\vec{u}$ es un vector de variables latentes y ϕ son los parámetros del modelo, distribuidos según alguna distribución a priori (*¿Es ϕ un vector?*)

Supondremos que la siguiente factorización es válida: $q(\vec{z}|\vec{x}) = q_1(\vec{u}|\vec{x}) \cdot q_2(\phi|\vec{x})$

donde $\vec{u} \in \mathcal{U}$, $\phi \in \Phi$

Luego, podemos describir el ELBO: $H(q(\cdot|\vec{x})) = H(q_1(\cdot|\vec{x})) + H(q_2(\cdot|\vec{x}))$

la entropía cruzada puede escribirse de 2 formas:

$$\begin{aligned} \mathbb{E}_q[\log p(\vec{x}, \vec{z}) | \vec{x} = \vec{x}] &= \int_{\mathcal{U}} \int_{\Phi} q_1(\vec{u}|\vec{x}) \cdot q_2(\phi|\vec{x}) \cdot \log p(\vec{x}, \vec{u}, \phi) d\phi d\vec{u} = \\ &= \int_{\mathcal{U}} q_1(\vec{u}|\vec{x}) \cdot \left[\int_{\Phi} q_2(\phi|\vec{x}) \cdot \log p(\vec{x}, \vec{u}, \phi) d\phi \right] d\vec{u} = \int_{\Phi} q_2(\phi|\vec{x}) \cdot \left[\int_{\mathcal{U}} q_1(\vec{u}|\vec{x}) \cdot \log p(\vec{x}, \vec{u}, \phi) d\vec{u} \right] d\phi \end{aligned}$$

$E_1(\vec{x}, \vec{u}) \rightarrow \text{depende de } q_2$
 $E_2(\vec{x}, \phi) \rightarrow \text{depende de } q_1$

El ELBO puede reescribirse como:

$$\begin{aligned}\text{ELBO} &= H(q_1(\cdot|\vec{x})) + H(q_2(\cdot|\vec{x})) + \int_{\mathcal{U}} q_1(\vec{u}|\vec{x}) \cdot E_1(\vec{x}, \vec{u}) d\mathbf{u} = \\ &= H(q_1(\cdot|\vec{x})) + H(q_2(\cdot|\vec{x})) + \int_{\Phi} q_2(\phi|\vec{x}) \cdot E_2(\vec{x}, \phi) d\phi\end{aligned}$$

Queremos maximizar esto respecto a $q = q_1 \cdot q_2$. Esto parece una cagada xq' ahora tenemos q' maximizar sobre 2 funciones en lugar de una, pero es una ventaja: primero suponemos q_2 fija y maximizamos respecto de q_1 , con esa solución maximizamos respecto de q_2 y así.

Si q_2 es fija, lo que hay que maximizar respecto de q_1 es:

$$\text{ELBO} = H(q_1(\cdot|\vec{x})) + \overset{\text{cte, no depende de } q_1}{H(q_2(\cdot|\vec{x}))} + \int_{\mathcal{U}} q_1(\vec{u}|\vec{x}) E_1(\vec{x}, \vec{u}) d\mathbf{u} \propto$$

$$\propto \mathbb{E}_{q_1}[-\log q_1(\vec{u}|\vec{x}) | \vec{x} = \vec{x}] + \mathbb{E}_{q_1}[E_1(\vec{x}, \vec{u}) | \vec{x} = \vec{x}] =$$

$$= \mathbb{E}_{q_1} \left[\log \frac{\exp\{E_1(\vec{x}, \vec{u})\}}{q_1(\vec{u}|\vec{x})} \mid \vec{x} = \vec{x} \right] = - \mathbb{E}_{q_1} \left[\log \frac{q_1(\vec{u}|\vec{x})}{\exp\{E_1(\vec{x}, \vec{u})\}} \mid \vec{x} = \vec{x} \right]$$

→ Esto es casi una KL, pero no lo es xq' lo de abajo no es una densidad (xq' no integra 1)

Sea $k_1(\vec{x}) = \left(\int \exp\{E_1(\vec{x}, \vec{u})\} d\mu \right)^{-1} \Rightarrow k_1(\vec{x}) \cdot \exp\{E_1(\vec{x}, \vec{u})\}$ es una densidad

$$= - \mathbb{E}_{q_1} \left[\log \frac{q_1(\vec{u}|\vec{x}) \cdot \cancel{k_1(\vec{x})}}{\exp\{E_1(\vec{x}, \vec{u})\} \cdot \cancel{k_1(\vec{x})}} \mid \vec{x} = \vec{x} \right] = - \mathbb{E}_{q_1} \left[\log \frac{q_1(\vec{u}|\vec{x})}{\exp\{E_1(\vec{x}, \vec{u})\} \cdot k_1(\vec{x})} \mid \vec{x} = \vec{x} \right] +$$

$$+ \mathbb{E}_{q_1} [\log k_1(\vec{x})] \propto - \mathbb{E}_{q_1} \left[\log \frac{q_1(\vec{u}|\vec{x})}{\exp\{E_1(\vec{x}, \vec{u})\} \cdot k_1(\vec{x})} \mid \vec{x} = \vec{x} \right] =$$

no depende de q_1

$$= -KL \left(q_1(\cdot|\vec{x}) \parallel \exp\{E_1(\vec{x}, \vec{u})\} \cdot k_1(\vec{x}) \right)$$

La cuestión es que

$$q_1 = \arg \max_{q_1: q_2 = \text{cte}} ELBO = \arg \min_{q_1} KL \left(q_1(\cdot|\vec{x}) \parallel k_1(\vec{x}) \cdot e^{E_1(\vec{x}, \vec{u})} \right)$$

La KL se minimiza (se hace 0) cuando $q_1(\vec{u}|\vec{x}) = k_1(\vec{x}) \cdot e^{E_1(\vec{x}, \vec{u})}$

Como se que q_1 debe integrar 1, me basta con saber que $q_1 \propto e^{E_1}$

Entonces, luego de asumir q_2 fijo, el primer paso es calcular

$$q_1(\vec{u}|\vec{x}) \propto \exp \left\{ \int \underbrace{q_2(\phi|\vec{x})}_{\substack{\text{La asumí} \\ \text{fija}}} \cdot \underbrace{\log p(\vec{x}, \vec{u}, \phi)}_{\substack{\text{La comencé x' el modelo} \\ \text{q' planteo desde el principio}}} d\phi \right\}$$

Para el siguiente paso hay q' hacer lo mismo con q_2 . Siguiendo el mismo razonamiento donde dice q_1 debe decir q_2 y donde dice $\vec{u}$ debe decir ϕ . Además, definimos $k_2(\vec{x})$:

$$k_2(\vec{x}) = \left(\int_{\vec{\Phi}} \exp \{ E_2(\vec{x}, \phi) \} d\phi \right)^{-1} \text{ de manera tal que } k_2(\vec{x}) e^{E_2(\vec{x}, \phi)} \text{ sea una densidad}$$

$$\rightarrow q_2(\phi|\vec{x}) = \arg \min_{q_2} KL \left(q_2(\cdot|\vec{x}) \parallel k_2(\vec{x}) \cdot e^{E_2(\vec{x}, \cdot)} \right)$$


$$\Rightarrow q_2(\phi|\vec{x}) \propto e^{E_2(\vec{x}, \phi)} = \exp \left\{ \int_{\vec{u}} q_1(\vec{u}|\vec{x}) \cdot \log p(\vec{x}, \vec{u}, \phi) d\vec{u} \right\}$$

A partir de ahora queda asumir un modelo y encontrar valores precisos para α , y α_2

n muestras K clases

Mezcla de Gaussiana

Distribuciones a priori:



1) $\pi \sim \text{Dir}([\alpha \dots \alpha]) \rightarrow \pi$ es un vector aleatorio de K componentes, cada una de las cuales representa una probabilidad $\pi = (\pi_1 \dots \pi_K)$

$$0 \leq \pi_k \leq 1, \sum \pi_k = 1$$

2) $u_i | \pi \sim \text{cat}\{\pi\} = \text{cat}\{\pi_1, \dots, \pi_K\} \rightarrow u_i$ puede tomar K valores distintos, es la mezcla que determina los parámetros de la gaussiana

$$3) \lambda_k \sim \Gamma(\tau, \beta) \quad 4) \mu_k | \lambda_k \sim \mathcal{N}(m, (\beta \lambda_k)^{-1}) \quad 5) x_i | u_i, \mu, \lambda \sim \mathcal{N}(\mu_{u_i}, \lambda_{u_i}^{-1})$$

β
precisión

m
media

α, τ, β, m y β son los parámetros del modelo y se irán actualizando a medida que avanza el algoritmo

ojo con la notación: $\pi = (\pi_1, \dots, \pi_k)$, $\mu = (\mu_1, \dots, \mu_k)$, $\lambda = (\lambda_1, \dots, \lambda_k)$

$\vec{z} = (\vec{u}, \phi) \rightarrow \vec{u} = (u_1, \dots, u_m) \rightarrow$ Variable latente

$\rightarrow \phi = (\pi, \mu, \lambda) \rightarrow$ parámetros del modelo (variables aleatorias)

El siguiente paso es escribir la conjunta $p(\vec{x}, \vec{u}, \phi) = p(\vec{x}, \vec{u}, \pi, \mu, \lambda) = p(\vec{x}, \vec{z}) =$
 $= p(\vec{x} | \vec{z}) \cdot p(\vec{z})$

$$p(\vec{x}, \vec{u}, \pi, \mu, \lambda) = p(\pi) \cdot p(\mu, \lambda) \cdot p(\vec{u} | \pi) \cdot p(\vec{x} | \vec{u}, \mu, \lambda)$$

$$p(\pi) = p(\pi) \quad (1)$$

$$p(\mu, \lambda) = \prod_{k=1}^K p(\mu_k, \lambda_k) = \prod_{k=1}^K p(\mu_k | \lambda_k) \cdot p(\lambda_k) \quad (2)$$

indep $\uparrow$ $\rightarrow$ V.A. discreta

$$p(\vec{u} | \pi) = \prod_{i=1}^m P(u_i | \pi) \quad (3)$$

$$p(\vec{x} | \vec{u}, \mu, \lambda) = \prod_{i=1}^m p(x_i | u_i, \mu, \lambda) \quad (4)$$

$$p(\vec{x}, \vec{u}, \pi, \mu, \lambda) = p(\pi) \cdot \prod_{k=1}^K p(\mu_k | \lambda_k) \cdot p(\lambda_k) \cdot \prod_{i=1}^n P(u_i | \pi) \cdot \prod_{i=1}^n p(x_i | u_i, \mu, \lambda)$$

$$= p(\pi) \prod_{k=1}^K p(\mu_k | \lambda_k) \cdot p(\lambda_k) \cdot \prod_{i=1}^n P(u_i | \pi) \cdot p(x_i | u_i, \mu, \lambda)$$

Def: distribución Normal-Gamma

El vector (λ_k, μ_k) tiene dist. Normal-Gamma de parámetros (τ, β, m, S) si

$$\lambda_k \sim \Gamma(\tau, \beta) \text{ y } \mu_k | \lambda_k \sim N(m, (S \lambda_k)^{-1})$$

$$p(\lambda_k, \mu_k) = p(\lambda_k) \cdot p(\mu_k | \lambda_k) = \frac{\beta^\tau}{\Gamma(\tau)} \lambda_k^{\tau-1} e^{-\beta \lambda_k} \mathbb{1}_{\{\lambda_k \geq 0\}} \cdot \frac{1}{\sqrt{2\pi}} \sqrt{S \lambda_k} e^{-\frac{1}{2} S \lambda_k (\mu_k - m)^2}$$

$$= \frac{\beta^\tau}{\Gamma(\tau)} \sqrt{\frac{S}{2\pi}} \lambda_k^{\tau-1/2} e^{-\lambda_k (\beta + \frac{S}{2} \cdot (\mu_k - m)^2)} \mathbb{1}_{\{\lambda_k \geq 0\}}$$

Distribuciones a posteriori: Mean field approximation: $q(\vec{u}, \pi, \lambda, \mu | \vec{x}) = Q_1(\vec{u} | \vec{x}) \cdot q_2(\pi, \lambda, \mu | \vec{x})$

Escribimos E_1 y E_2 , pero antes voy a necesitar $\log p(\vec{x}, \vec{u}, \phi)$:

$$\log p(\vec{x}, \vec{u}, \pi, \mu, \lambda) = \log p(\pi) + \sum_k \log [p(\mu_k | \lambda_k) \cdot p(\lambda_k)] + \sum_i \log P(u_i | \pi) + \sum_i \log p(x_i | u_i, \mu, \lambda)$$

$$E_1(\vec{x}, \vec{u}) = \int_{\vec{\phi}} q_2(\phi | \vec{x}) \cdot \log p(\vec{x}, \vec{u}, \phi) d\phi =$$

$$= \int q_2 \cdot \log p(\pi) d\phi + \sum_k \int q_2 \cdot \log p(u_k | \lambda_k) \cdot p(\lambda_k) d\phi + \sum_{i=1}^n \int q_2(\pi, \mu, \lambda | \vec{x}) \cdot \log P(u_i | \pi) d\phi$$

$$+ \sum_{i=1}^n \int q_2(\pi, \mu, \lambda | \vec{x}) \cdot \log p(x_i | u_i, \mu, \lambda) d\phi$$

Con esto voy a optimizar $Q_1(\vec{u} | \vec{x})$, así q' lo q' me frega $\vec{u}$ no me interesa

Además: $q_2(\pi, \mu, \lambda | \vec{x}) = q_2(\pi | \vec{x}) \cdot q(\mu, \lambda | \vec{x})$

lo q' simplifica las integrales

$$= \sum_{i=1}^n \int q_2(\pi | \vec{x}) \cdot \log p(u_i | \pi) d\pi + \sum_{i=1}^n \int q_2(\lambda, \mu | \vec{x}) \cdot \log p(x_i | u_i, \mu, \lambda) d\mu \cdot d\lambda \quad (1)$$

Para $E_2(\vec{x}, \phi)$:

no dependen de u , salen de la integral y q_1 integra 1

$$E_2(\vec{x}, \phi) = \int q_1(\vec{u} | \vec{x}) \cdot \log p(\vec{x}, \vec{u}, \phi) d\vec{u} = \log p(\pi) + \sum_{k=1}^K \log p(\mu_k | \lambda_k) + \sum_{k=1}^K \log p(\lambda_k) +$$

$$= \int q_1(u_1, \dots, u_m | \vec{x}) \cdot \sum_{i=1}^n p(u_i | \pi) \cdot du_1 \dots du_m + \int q_1(u_1, \dots, u_m) \sum_{i=1}^n p(x_i | u_i, \mu, \lambda) du_1 \dots du_m$$

C. Aux:

$$\int q_1(u_1, \dots, u_m | \vec{x}) \cdot \sum_{i=1}^n p(u_i | \pi) \cdot du_1 \dots du_m = \sum_{i=1}^n \int q_1(\vec{u} | \vec{x}) \cdot p(u_i | \pi) du_1 \dots du_m =$$

$$= \sum_{i=1}^n \int q_1(u_i | \vec{x}) \cdot p(u_i | \pi) du_i = \sum_{i=1}^n \sum_{k=1}^K Q_1(u_i = k | \vec{x}) \cdot p(u_i = k | \pi)$$

sale como cte, excepto para la integral sobre u_i
y para el último término la misma

$$E_2(\vec{x}, \phi) = \log p(\pi) + \sum_{k=1}^K \log p(\mu_k | \lambda_k) + \sum_{k=1}^K \log p(\lambda_k) + \\ + \sum_{i=1}^n \sum_{k=1}^K Q_i(u_i = k | \vec{x}) \log p(u_i = k | \pi) + \sum_{i=1}^n \sum_{k=1}^K Q_i(u_i = k | \vec{x}) \cdot \log p(x_i | u_i = k, \mu, \lambda) \quad (2)$$

Así mismo $Q_i(u_i = k | \vec{x})$ cte. Llamémosles $\gamma_{ik} = Q_i(u_i = k | \vec{x})$. Tenemos que $q_2(\phi | \vec{x}) \propto e^{E_2(\vec{x}, \phi)}$

$$\Rightarrow q_2(\pi, \mu, \lambda | \vec{x}) = p(\pi) \cdot \prod_{k=1}^K p(\mu_k | \lambda_k) \cdot p(\lambda_k) \cdot \prod_{k=1}^K \exp \left\{ \sum_{i=1}^n \gamma_{ik} \cdot \log p(x_i | u_i = k, \mu, \lambda) \right\}$$

→ trabajemos esto

C. A. V. K.: $\log p(x_i | u_i = k, \mu, \lambda) = \log \pi_k - \frac{1}{2} \log 2\pi + \frac{1}{2} \log \lambda_k - \frac{1}{2} \lambda_k (x_i - \mu_k)^2 =$

$$= \log \pi_k - \frac{1}{2} \log 2\pi + \frac{1}{2} \log \lambda_k - \frac{1}{2} \lambda_k x_i^2 + \lambda_k x_i \cdot \mu_k - \frac{1}{2} \lambda_k \mu_k^2$$

Reescriba todo el exponente, definiendo $N_k = \sum_{i=1}^n \gamma_{ik}$ $f_k = \sum_{i=1}^n \gamma_{ik} \cdot x_i$ $s_k = \sum_{i=1}^n \gamma_{ik} x_i^2$

$$\Rightarrow \text{exponente: } N_k \log \pi_k - \frac{N_k}{2} \log 2\pi + \frac{N_k}{2} \log \lambda_k - \frac{\lambda_k}{2} (s_k - 2f_k \mu_k + N_k \cdot \mu_k^2)$$

$$q_2(\pi, \mu, \lambda | \tilde{x}) \propto p(\pi) \cdot \prod_{k=1}^K p(\mu_k | \lambda_k) \cdot p(\lambda_k) \cdot \prod_{k=1}^K \exp\{N_k \log \pi_k\}.$$

$$\cdot \prod_{k=1}^K \exp \left\{ \underbrace{-\frac{N_k}{2} \log 2\pi}_{\text{CTE}} + \frac{N_k}{2} \log \lambda_k - \frac{\lambda_k}{2} \left(1_k - 2\mathbf{1}_k \cdot \mu_k + N_k \mu_k^2 \right) \right\} \propto$$

$$\propto \underbrace{p(\pi) \prod_{k=1}^K \pi_k^{N_k}}_{q_2(\pi | \tilde{x})} \cdot \underbrace{\prod_{k=1}^K p(\mu_k | \lambda_k) \cdot p(\lambda_k) \cdot \prod_{k=1}^K \lambda_k^{N_k/2} \cdot \exp \left\{ -\frac{\lambda_k}{2} (1_k - 2\mathbf{1}_k \mu_k + N_k \mu_k^2) \right\}}_{q_2(\mu, \lambda | \tilde{x})}$$

$$q_2(\pi | \tilde{x}) \propto \prod_{k=1}^K \pi_k^{\alpha_k - 1} \cdot \mathbb{1}_{\left\{ \sum_{k=1}^K \pi_k = 1, \pi_k \geq 0 \right\}} \cdot \prod_{k=1}^K \pi_k^{N_k} = \prod_{k=1}^K \pi_k^{\alpha_k + N_k - 1} \mathbb{1}_{\left\{ \sum_{k=1}^K \pi_k = 1 \right\}} \dots$$

$$\Rightarrow \pi | \tilde{x} \sim \text{Dir}[\alpha_1 + N_1, \dots, \alpha_K + N_K] \Rightarrow \alpha_k^* = \alpha_k + N_k$$

$$q_2(\lambda, \mu | \tilde{x}) \propto \prod_{k=1}^K p(\mu_k | \lambda_k) \cdot p(\lambda_k) \lambda_k^{N_k/2} \exp \left\{ -\frac{\lambda_k}{2} (1_k - 2\mathbf{1}_k \mu_k + N_k \mu_k^2) \right\} = \prod_{k=1}^K q_2(\mu_k | \lambda_k | \tilde{x})$$

$$\propto \phi(\lambda_k)$$

$$\propto \phi(\mu_k | \lambda_k)$$

$$\rightarrow q_2(\mu_k, \lambda_k | \tilde{X}) \propto \lambda_k^{\alpha-1} e^{-\beta \lambda_k} \mathbb{1}\{\lambda_k \geq 0\} \cdot \lambda_k^{1/2} \exp\left\{-\delta \frac{\lambda_k}{2} (\mu_k^2 - 2m\mu_k + m^2)\right\}.$$

$$\cdot \lambda_k^{N_k/2} \cdot \exp\left\{-\frac{\lambda_k}{2} (\lambda_k - 2b_k \mu_k + N_k \mu_k^2)\right\} =$$

Agrupar los exp{ } y los teoremas

$$= -\beta \lambda_k - \delta \frac{\lambda_k}{2} (\mu_k^2 - 2m\mu_k + m^2) - \frac{\lambda_k}{2} (\lambda_k - 2b_k \mu_k + N_k \mu_k^2)$$

lo tengo q' llevar a algo de la forma $-\beta^* \lambda_k - \frac{\delta^*}{2} \lambda_k (\mu_k^2 - 2m^* \mu_k + m^{*2})$.

$$\rightarrow -\beta \lambda_k - \frac{\lambda_k}{2} (\delta \mu_k^2 + N_k \mu_k^2 - 2m\delta \mu_k - 2b_k \mu_k + \delta m^2 + \lambda_k) =$$

$$= -\beta \lambda_k - \frac{\lambda_k}{2} [(\delta + N_k) \mu_k^2 - 2(m\delta + b_k) \mu_k + \delta m^2 + \lambda_k] =$$

$$= -\beta \lambda_k - \frac{\lambda_k}{2} (\delta + N_k) \left[\mu_k^2 - 2 \frac{m\delta + b_k}{\delta + N_k} \mu_k + \frac{\delta m^2 + \lambda_k}{\delta + N_k} \right] =$$

$$= -\beta \lambda_k - \frac{\lambda_k (s + N_k)}{2} \left[\mu_k^2 - 2 \frac{ms + bk}{s + N_k} \mu_k + \left(\frac{ms + bk}{s + N_k} \right)^2 + \frac{s m^2 + \lambda_k}{s + N_k} - \left(\frac{ms + bk}{s + N_k} \right)^2 \right] =$$

$$= -\beta \lambda_k - \frac{\lambda_k}{2} \cancel{(s + N_k)} \cdot \frac{s m^2 + \lambda_k}{\cancel{s + N_k}} + \frac{\lambda_k}{2} \cancel{(s + N_k)} \cdot \frac{(ms + bk)^2}{(\cancel{s + N_k})} - \frac{\lambda_k}{2} (s + N_k) \cdot \left[\mu_k - \frac{ms + bk}{s + N_k} \right]^2 =$$

$$= - \left(\beta + \frac{s m^2 + \lambda_k}{2} - \frac{1}{2} \frac{(ms + bk)^2}{s + N_k} \right) \lambda_k - \frac{\lambda_k (s + N_k)}{2} \left[\mu_k - \frac{ms + bk}{s + N_k} \right]^2$$

$$\Rightarrow q_2(\pi, \lambda, \mu | \vec{x}) \propto \lambda_k^{\cancel{s + N_k} - 1/2} \exp \left\{ - \left(\beta + \frac{s m^2 + \lambda_k}{2} - \frac{1}{2} \frac{(ms + bk)^2}{s + N_k} \right) \lambda_k \right\} \cdot \exp \left\{ - \frac{\lambda_k}{2} (s + N_k) \left(\mu_k - \frac{ms + bk}{s + N_k} \right)^2 \right\}$$

$$\tau^k = \tau + N_k / 2$$

$$\beta^k = \beta + \frac{S m^2 + 1}{2} - \frac{1}{2} \frac{(m + \delta b_k)^2}{S + N_k}$$

$$S^k = S + N_k$$

$$m^k = \frac{mS + N_k}{S + N_k}$$

Sangre, sudor y lagrimas

En realidad es más fácil como está en el apunte, agrupando los 2 exponentes en la distribución normal-gamma y comparando con eso

REHACER

Este paso se conoce como **actualización de los parámetros a posteriori** (se actualizan los ϕ)

ya consideramos Q_1 fijo y recalculamos $q_2(\phi | \vec{x}) = q_2(\pi | \vec{x}) \cdot q_2(\mu, \lambda | \vec{x})$

Ahora consideremos q_2 fijo y recalculamos Q_1

Propiedades importantes: 1) si $\lambda \sim \Gamma(r, \beta) \Rightarrow E[\log \lambda] = \psi(r) - \log(\beta)$ donde $\psi(\cdot) = \frac{\Gamma'(\cdot)}{\Gamma(\cdot)}$

2) si $\pi \sim \beta(a, b) \Rightarrow E[\log \pi] = \psi(a) - \psi(a+b)$

Recordemos que $Q_1(\vec{u}|\vec{x}) \propto e^{E_1(\vec{u}, \vec{x})}$ donde

$$E_1(\vec{u}, \vec{x}) = \sum_{i=1}^n \int q_2(\pi|\vec{x}) \cdot \log P(u_i|\pi) d\pi + \sum_{i=1}^n \int q_2(\lambda, \mu|\vec{x}) \cdot \log p(x_i|u_i, \mu, \lambda) d\lambda d\mu$$

$$\Rightarrow Q_1(\vec{u}|\vec{x}) = Q_1(u_1 \dots u_n|\vec{x}) = \prod_{i=1}^n \exp \left\{ \int q_2(\pi|\vec{x}) \log P(u_i|\pi) d\pi + \int q_2(\lambda, \mu|\vec{x}) \log p(x_i|u_i, \mu, \lambda) d\lambda d\mu \right\}$$

$$= \prod_{i=1}^n Q(u_i|\vec{x})$$

Siendo $Q_1(u_i|\vec{x}) \propto \exp \left\{ \int q_2(\pi|\vec{x}) \log P(u_i|\pi) d\pi + \int q_2(\lambda, \mu|\vec{x}) \log p(x_i|u_i, \mu, \lambda) d\lambda d\mu \right\}$

o sea, los $u_1 \dots u_n$ son indep.

⊕ → En realidad esta está mal, si bien Q_1 es proporcional a eso, no es linealmente proporcional. El detalle importa xq' con esa exponencial después aparece el softmax. La relación lineal es $Q_1 \propto \exp\{E_1(\vec{x}, \vec{u})\}$

$$Q_1(u_i = k|\vec{x}) \propto \int q_2(\pi|\vec{x}) \cdot \log P(u_i = k|\pi) d\pi + \int q_2(\lambda, \mu|\vec{x}) \log p(x_i|u_i = k, \mu, \lambda) d\lambda d\mu =$$

$$= \underbrace{\int q_2(\pi_1 \dots \pi_k|\vec{x}) \log \pi_k d\pi}_{\text{Integral sobre todos los } \pi, \text{ menos } \pi_k} + \underbrace{\int q_2(\lambda, \mu|\vec{x}) \log \mathcal{N}(x_i|\mu_k, \lambda \vec{\sigma}') d\lambda d\mu}_{\text{Integral sobre todos los } (\lambda, \mu) \text{ menos } (\lambda_k, \mu_k)} =$$

Integral sobre todos los π , menos π_k

Integral sobre todos los (λ, μ) menos (λ_k, μ_k)

$$= \int q_2(\pi_k | \vec{x}) \cdot \log \pi_k \cdot d\pi_k + \int q_2(\lambda_k, \mu_k | \vec{x}) \cdot \log N(x_i | \mu_k, \lambda_k^{-1}) \cdot d\lambda_k d\mu_k$$

$\pi | \vec{x} \sim \text{Dir}(\alpha_1^*, \dots, \alpha_K^*)$ y las marginales son β indep de k

$$= \mathbb{E}_{q_2(\pi_k)} \left[\log \pi_k | \vec{x} = \vec{x} \right] + \int q_2(\lambda_k, \mu_k | \vec{x}) \cdot \left[\frac{1}{2} \log(\lambda_k) - \frac{1}{2} \log 2\pi - \frac{\lambda_k}{2} (x_i - \mu_k)^2 \right] d\lambda_k d\mu_k$$

$$\propto \psi(\alpha_k^*) - \psi\left(\sum_{c=1}^K \alpha_c^*\right) + \frac{1}{2} \int q_2(\lambda_k | \vec{x}) \cdot \log \lambda_k \cdot d\lambda_k - \frac{1}{2} \int q_2(\lambda_k, \mu_k | \vec{x}) \frac{\lambda_k}{2} (x_i - \mu_k)^2 \cdot d\lambda_k d\mu_k$$

$\sim P(\tau_k^*, \beta_k^*)$

$$= \psi(\alpha_k^*) - \psi\left(\sum_{c=1}^K \alpha_c^*\right) + \mathbb{E}_{q_2(\lambda_k)} [\log \lambda_k | \vec{x} = \vec{x}] - \frac{1}{2} \mathbb{E}_{q_2(\lambda_k, \mu_k)} \left[\frac{\lambda_k}{2} (x_i - \mu_k)^2 | \vec{x} = \vec{x} \right] =$$

$$= \psi(\alpha_k^*) - \psi\left(\sum_{c=1}^K \alpha_c^*\right) + \frac{1}{2} \left(\psi(\tau_k^*) - \log \beta_k^* \right) - \frac{1}{2} \mathbb{E}_{q_2} \left[\lambda_k (x_i - \mu_k)^2 | \vec{x} = \vec{x} \right]$$

Trabajamos con el segundo término:

Nota: Recordar que $\mu_k | \lambda_k, \vec{x}$

$$\sim \mathcal{N}(m_k^*, (S_k^* \cdot \lambda_k)^{-1})$$

$$\Rightarrow E_{q_2}[\mu_k | \lambda_k, \vec{x}] = m_k^*$$

$$\text{y } E_{q_2}[(\mu_k - m_k^*)^2 | \lambda_k, \vec{x}] = 1/S_k^* \lambda_k$$

$$E_{q_2}[\lambda_k (x_i - \mu_k)^2 | \vec{x}] = E_{q_2}[\lambda_k E_{q_2}[(x_i - \mu_k)^2 | \lambda_k, \vec{x}] | \vec{x}] =$$

$$= E_{q_2}[\lambda_k E_{q_2}[(x_i - m_k^* + m_k^* - \mu_k)^2 | \lambda_k, \vec{x}] | \vec{x}] =$$

$$= E_{q_2}[\lambda_k E_{q_2}[(x_i - m_k^*)^2 + 2(x_i - m_k^*)(m_k^* - \mu_k) + (m_k^* - \mu_k)^2 | \lambda_k, \vec{x}] | \vec{x}] =$$

todo lo q' no dependa de μ_k o λ_k puede salir xq' la integral es sobre μ_k o λ_k

es sobre μ_k o λ_k

= 0

$$\text{var}(\mu_k | \lambda_k, \vec{x}) = 1/S_k^* \cdot \lambda_k$$

$$= E_{q_2}[\lambda_k (x_i - m_k^*)^2 + \lambda_k 2(x_i - m_k^*) \cdot \underbrace{E_{q_2}[m_k^* - \mu_k | \lambda_k, \vec{x}]}_{=0} + \lambda_k E_{q_2}[(\mu_k - m_k^*)^2 | \lambda_k, \vec{x}] | \vec{x}] =$$

$$\sim \mathcal{P}(v_k^*, \beta_k^*)$$

$$= E_{q_2}[\lambda_k | \vec{x}] \cdot (x_i - m_k^*)^2 + 0 + \frac{1}{S_k^*} =$$

$$= \frac{v_k^*}{\beta_k^*} \cdot (x_i - m_k^*)^2 + \frac{1}{S_k^*}$$

$$\therefore Q_i(u_i=k|\vec{x}) \propto \exp\left(\psi(\alpha_k^*) - \psi\left(\sum_{c=1}^K \alpha_c\right) + \frac{1}{2}\left(\psi(\tau_k^*) - \log \beta_k^*\right) - \frac{1}{2} \frac{\tau_k^*}{\beta_k^*} (x_i - m_k^*)^2 - \frac{1}{2 \cdot \delta_k^*}\right)$$

$\Rightarrow Q_i(u_i=k|\vec{x})$ se actualiza haciendo el softmax en k del vector:

$$\left\{ \psi(\alpha_k) - \psi\left(\sum_{c=1}^K \alpha_c\right) + \frac{\psi(\tau_k^*) - \log \beta_k^*}{2} - \frac{1}{2} \frac{\tau_k^*}{\beta_k^*} (x_i - m_k^*)^2 - \frac{1}{2 \delta_k^*} \right\}_{k=1}^K$$

Resultado final

Paso 1) Asumiendo $Q_i(\vec{u}|\vec{x})$ fijo se actualizan los parámetros del modelo luego de observar los datos $\vec{x}$

siendo $N_k = \sum_i \gamma_{ik}$, $f_k = \sum_i \gamma_{ik} x_i$ y $s_k = \sum_i \gamma_{ik} x_i^2$ como:

$$\alpha_k^* = \alpha_k + N_k \quad \text{Distribución de } \pi$$

$$\tau_k^* = \tau_k + \frac{N_k}{2} \quad \text{Distribución de } \lambda$$

$$\beta_k^* = \beta + \frac{s_k + f_k^2}{2} - \frac{(s_k + f_k)^2}{(s + N_k)}$$

(optimización de la KL)

$$\delta_k^* = \delta + N_k \quad m_k^* = \frac{s_k + f_k}{s_k + N_k}$$

Distribución de μ_k

Esto sale de asumir $Q_1 = \text{cte}$, aplicar $q_2 \propto e^{E_2(\vec{x}, \phi)}$, reemplazar

E_2 por ② y comparar el resultado con las distribuciones conocidas

Este paso se llama **actualización de los parámetros a posteriori**

Paso 2) Asumiendo $q_2(\phi|\vec{x})$ cte se actualiza $Q_1(\vec{u}|\vec{x})$.

$Q(u_i = k|\vec{x})$ es el softmax en k de:

$$\left\{ \psi(\alpha_k^*) - \psi\left(\sum_{c=1}^K \alpha_c^*\right) + \frac{\psi(v_k^*) - \log \beta_k^*}{2} - \frac{v_k^*}{2\beta_k^*} (x_i - m_k^*)^2 - \frac{1}{2\sigma_k^*} \right\}_{k=1}^K$$

Esto sale de asumir $q_2 = \text{cte}$, $Q_1(\vec{u}|\vec{x}) \propto e^{E_1(\vec{x}, \vec{u})}$, acá se observa que los $u_1, \dots, u_m$ son independientes y que $Q_1(\vec{u}|\vec{x}) = Q_1(u_1, \dots, u_m|\vec{x}) = \prod_{i=1}^m Q(u_i = k|\vec{x})$. Trabajando la expresión que da $e^{E_1(\vec{x}, \vec{u})}$ aparecen las esperanzas que se simplifican en el resultado final. Este paso se llama **actualización de la distribución de las variables ocultas** (Las variables ocultas son $\vec{u} = (u_1, \dots, u_m)$)

Predictiva

La gracia de Bayes era calcular la predictiva ¿no?

$$p(x_{\text{test}} | \vec{x}) = \int_{\theta \in \Theta} p(x_{\text{test}} | \theta) \cdot p(\theta | \vec{x}) \cdot d\theta = \mathbb{E}_{p(\theta)} [p(x_{\text{test}} | \tau) | \vec{x} = \vec{x}]$$

Como cambiamos la notación, en lugar de θ ponemos ϕ , donde $\phi = (\pi, \mu, \lambda)$ para el modelo de mezcla de y ϕ se distribuye según $q_2(\pi, \mu, \lambda | \vec{x})$

$$\Rightarrow p(x_{\text{test}} | \vec{x}) = \mathbb{E}_{q_2} [p(x_{\text{test}} | \phi) | \vec{x}]$$

2 cosas importantes: $\rightarrow p(x_{\text{test}} | \phi)$ es una mezcla de gaussianas $\Rightarrow p(x_{\text{test}} | \pi, \mu, \lambda) = \sum_{k=1}^K \pi_k \cdot \mathcal{N}(x_{\text{test}} | \mu_k, \lambda_k^{-1})$

$\rightarrow q_2(\phi | \vec{x})$ puede factorizarse como $q_2(\pi, \mu, \lambda | \vec{x}) = \overset{\text{Dir}}{\uparrow} q_2(\pi | \vec{x}) \cdot \prod_{k=1}^K p(\mu_k, \lambda_k | \vec{x}) \rightarrow \text{Normal-Gamma}$

Esto es importante, xq' me va a permitir factorizar la esperanza $\mathbb{E}_{q_2} [p(x_{\text{test}} | \phi) | \vec{x}]$

Distribuye y aplico linealidad de la integral

$$\rightarrow p(x_{\text{test}} | \vec{x}) = \int_{\pi, \mu, \lambda} \sum_k \left[\pi_k \cdot \mathcal{N}(x_{\text{test}} | \mu_k, \lambda_k^{-1}) \right] \cdot q_2(\pi | \vec{x}) q_2(\mu, \lambda | \vec{x}) d\pi d\mu d\lambda =$$

$$= \sum_{k=1}^K \int_{\pi, \mu, \lambda} \pi_k \cdot q_2(\pi | \vec{x}) \cdot \mathcal{N}(x_{\text{test}} | \mu_k, \lambda_k) \cdot q_2(\mu, \lambda | \vec{x}) d\pi d\mu d\lambda =$$

integro sobre todas, menos π_k y me queda la marginal de π_k , que es una β

$$= \sum_{k=1}^K \int_{\mu, \lambda} \mathcal{N}(x_{\text{test}} | \mu_k, \lambda_k) \cdot q_2(\mu, \lambda | \vec{x}) \cdot \left(\int_{\pi} \pi_k \cdot q_2(\pi | \vec{x}) d\pi \right) d\mu d\lambda =$$

$$= \sum_{k=1}^K \int_{\mu, \lambda} \mathcal{N}(x_{\text{test}} | \mu_k, \lambda_k) \cdot q_2(\mu, \lambda | \vec{x}) \cdot \mathbb{E}_{q_2}[\pi_k | \vec{x}] d\mu d\lambda =$$

→ mismo razonamiento para λ y μ

$$= \sum_{k=1}^K \mathbb{E}_{q_2}[\pi_k | \vec{x}] \cdot \mathbb{E}_{q_2}[\mathcal{N}(x_{\text{test}} | \mu_k, \lambda_k) | \vec{x}]$$

→ Esperanza de la beta

$$\therefore p(x_{\text{test}} | \vec{x}) = \sum_{k=1}^K \frac{\alpha_k^x}{\sum_{c=1}^K \alpha_c^{\text{dt}}} \cdot \tilde{p}(x_{\text{test}} | \vec{x}) \rightarrow \text{trabajo este término, teniendo en cuenta que}$$

$$\mathcal{N}(x_{\text{test}} | \mu_k, \lambda_k^{-1}) \propto \sqrt{\lambda_k} e^{-\frac{\lambda_k}{2} (x_{\text{test}} - \mu_k)^2} \text{ y que}$$

$$q_2(\mu_k, \lambda_k | \vec{x}) \propto \lambda_k^{\frac{v_k^{\text{dt}} - 1}{2}} e^{-\lambda_k \left(\beta_k^x + \frac{\delta_k^x}{2} \mu_k^2 - \delta_k^{\text{dt}} \mu_k^{\text{dt}} \mu_k + \frac{\delta_k^{\text{dt}}}{2} \mu_k^{\text{dt}^2} \right)}$$

$$\hat{p}(x_{\text{test}} | \vec{x}) = \iint \mathcal{N}(x_{\text{test}} | \mu_K, \lambda_K^{-1}) \cdot q_2(\mu_K, \lambda_K | \vec{x}) d\mu_K d\lambda_K \propto$$

$$\propto \iint \lambda_K^{\tau_K^{\downarrow}} \cdot \exp \left\{ -\lambda_K \left(\beta_K^{\downarrow} + \frac{\delta_K^{\downarrow}}{2} \mu_K^2 - \delta_K^{\downarrow} m_K^{\downarrow} \mu_K + \frac{\delta_K^{\downarrow} m_K^{\downarrow 2}}{2} + \frac{\mu_K^2}{2} - x_{\text{test}} \mu_K + \frac{x_{\text{test}}^2}{2} \right) \right\} d\mu_K d\lambda_K =$$

$$= \iint \lambda_K^{\tau_K^{\downarrow}} \exp \left\{ -\lambda_K \left(\frac{\delta_K^{\downarrow} + 1}{2} \mu_K^2 - (\delta_K^{\downarrow} m_K^{\downarrow} + x_{\text{test}}) \mu_K + \left[\beta_K^{\downarrow} + \frac{\delta_K^{\downarrow} m_K^{\downarrow 2}}{2} + \frac{x_{\text{test}}^2}{2} \right] \right) \right\} d\mu_K d\lambda_K$$

El núcleo de esa integral es el de una distribución Normal-Gamma de parámetros $(\tilde{\nu}, \tilde{\beta}, \tilde{m}, \tilde{\delta})$

Definición 6.2 Un vector aleatorio normal-gamma (ν, β, m, δ) tiene una densidad conjunta de la forma:

$$p(\lambda, \mu) = \frac{\beta^\nu}{\Gamma(\nu)} \sqrt{\frac{\delta}{2\pi}} \lambda^{\nu-\frac{1}{2}} e^{-\lambda \left(\beta + \frac{\delta \mu^2}{2} - \delta m \mu + \frac{\delta m^2}{2} \right)} \mathbf{1}\{\lambda > 0\} \quad (6.28)$$

donde $\lambda \sim \Gamma(\nu, \beta)$ y $\mu | \lambda \sim \mathcal{N}(m, (\delta\lambda)^{-1})$.

$$\bullet \tilde{\delta} = \delta_K^{\downarrow} + 1 \quad \bullet \tilde{\nu} = \tau_K^{\downarrow} + 1/2$$

$$\bullet \tilde{\delta} \tilde{m} = \delta_K^{\downarrow} m_K^{\downarrow} + x_{\text{test}} \rightarrow (\delta_K^{\downarrow} + 1) \tilde{m} = \delta_K^{\downarrow} m_K^{\downarrow} + x_{\text{test}}$$

$$\Rightarrow \tilde{m} = \frac{\delta_K^{\downarrow} m_K^{\downarrow} + x_{\text{test}}}{\delta_K^{\downarrow} + 1}$$

$$\bullet \tilde{\beta} + \frac{\tilde{\delta} \tilde{m}^2}{2} = \beta_K^{\downarrow} + \frac{\delta_K^{\downarrow} m_K^{\downarrow 2}}{2} + \frac{x_{\text{test}}^2}{2}$$

$$\Rightarrow \tilde{\beta} = \beta_K^* + \frac{\delta_K^* \cdot m_K^{*2} + x_{test}^2}{2} - \frac{\tilde{\sigma} \tilde{m}^2}{2} = \beta_K^* + \frac{\delta_K^* \cdot m_K^{*2} + x_{test}^2}{2} - \frac{1}{2} \left(\cancel{\delta_K^* + 1} \right) \frac{(\delta_K^* m_K^{*2} + x_{test}^2)^2}{(\delta_K^* + 1)^2}$$

$$\Rightarrow \tilde{\beta} = \beta_K^* + \frac{(\delta_K^* m_K^{*2} + x_{test}^2)(\delta_K^* + 1) - (x_{test}^2 + 2x_{test} \delta_K^* m_K^* + \delta_K^{*2} m_K^{*2})}{2(\delta_K^* + 1)}$$

$$= \beta_K^* + \frac{1}{2(\delta_K^* + 1)} \left(\underbrace{\delta_K^{*2} m_K^{*2}} + \underbrace{\delta_K^* m_K^{*2}} + x_{test}^2 \underbrace{\delta_K^*} + \cancel{x_{test}^2} - \cancel{x_{test}^2} - 2x_{test} \underbrace{\delta_K^* m_K^*} - \underbrace{\delta_K^{*2} m_K^{*2}} \right)$$

$$= \beta_K^* + \frac{1}{2(\delta_K^* + 1)} \delta_K^* \left(x_{test}^2 - 2x_{test} m_K^* + \cancel{\delta_K^* m_K^{*2}} + m_K^{*2} - \cancel{\delta_K^* m_K^{*2}} \right)$$

$$= \beta_K^* + \frac{1}{2(\delta_K^* + 1)} \delta_K^* (x_{test} - m_K^*)^2 \Rightarrow \bullet \tilde{\beta} = \beta_K^* + \frac{\delta_K^* (x_{test} - m_K^*)^2}{2(\delta_K^* + 1)}$$

Multiplica y divide por $\frac{\tilde{\beta}^{\tilde{r}}}{\Gamma(\tilde{r})} \cdot \frac{\sqrt{\tilde{\sigma}}}{\sqrt{2\pi}}$ para q' la integral de 1

$$\Rightarrow \tilde{p}(x_{test} | \vec{x}) \propto \frac{P(\tilde{\sigma}) \cdot \sqrt{2\pi}}{\tilde{\beta} \tilde{\sigma} \cdot \sqrt{\tilde{\sigma}}} \propto \tilde{\beta}^{-\tilde{\sigma}} = \left(\beta_K^* + \frac{\delta_K^* (x_{test} - m_K^*)^2}{2(\delta_K^* + 1)} \right)^{-\nu_K^* + 1/2}$$

$\tilde{\beta}$ $\nearrow$ cte $\nearrow$ cte
 $\tilde{\sigma}$ $\nwarrow$ depende de x_{test} $\rightarrow$ cte

$$\propto \left(1 + \frac{\delta_K^* \beta_K^*}{(\delta_K^* + 1) \beta_K^*} \frac{(x_{test} - m_K^*)^2}{2 \nu_K^*} \right)^{-\frac{2 \nu_K^* + 1}{2}}$$

Esto es una t-student generalizada: $X \sim t(\mu, \Sigma, \nu)$ si

$$p(x) = \frac{P(\frac{\nu+1}{2})}{P(\nu/2)} \frac{\sqrt{\Sigma}}{\sqrt{\pi \nu}} \left(1 + \frac{\Sigma}{\nu} \frac{(x_{test} - \mu)^2}{\nu} \right)^{-\frac{\nu+1}{2}}$$

$$\Rightarrow \tilde{p}(x_{test} | \vec{x}) = t(x_{test} | m_K^*, \frac{\delta_K^* \nu_K^*}{(\delta_K^* + 1) \beta_K^*}, 2 \nu_K^*)$$

Finalmente, la predictiva es:

$$p(x_{\text{test}} | \vec{x}) = \sum_{k=1}^K \frac{\alpha_k^*}{\sum_{c=1}^K \alpha_c^*} \cdot t(x_{\text{test}} | \mu, \Sigma, r) \rightarrow \text{mezcla de t-student}$$

Si además quisiéramos asignarle una clase a x_{test} :

$$p(x_{\text{test}} | \vec{x}) = \sum_{k=1}^K p(x_{\text{test}}, k | \vec{x})$$

$$\Rightarrow p(k | x_{\text{test}}, \vec{x}) \propto p(x_{\text{test}}, k | \vec{x}) = \frac{\alpha_k^*}{\sum_c \alpha_c^*} \cdot t(x_{\text{test}} | \mu, \Sigma, r)$$

↓
y hacemos el Argmax de eso

11/02 ÚLTIMO TEMA

MCMC

Bayes + Monte Carlo

Entram Bayes y Montecarlo a un bat...
completat el chiste. Entra en el examen

$$p(x_{\text{test}} | \vec{x}) = E \left[p(x_{\text{test}} | T) | \vec{x} = \vec{x} \right] \stackrel{\text{MC}}{\approx} \frac{1}{t_{\text{max}}} \sum_{t=1}^{t_{\text{max}}} p(x_{\text{test}} | T = \theta_t)$$

$\theta_1, \dots, \theta_{t_{\text{max}}}$ son realizaciones de θ según la dist. a post.
Son muestras de $p(\theta | \vec{x})$

Cadena de Markov: Secuencia de variables aleatorias $\{\theta_t\}_{t \in \mathbb{N}}$ q' tiene falta de memoria

$$p(\theta_{t+1} | \theta_t, \theta_{t-1}, \dots, \theta_0) = p(\theta_{t+1} | \theta_t) = \boxed{P(\theta_t \rightarrow \theta_{t+1})} \rightarrow \text{esto con la notación}$$

Densidad de transición de θ_t a θ_{t+1}

Homogeneidad: Cuando la prob. de transición no depende del tiempo t : $p(\theta_0 \rightarrow \theta_1) = p(\theta_t \rightarrow \theta_{t+1}) =$
 $= P(\theta \rightarrow \theta')$

Estacionariedad: Si θ y θ' tienen la misma dist. decimos q' la cadena es estacionaria

La idea sería hacer una cadena de Markov q' converja a la dist. a posteriori $p(x_{\text{test}} | T = \theta)$ y poder calcular la esperanza de arriba como un promedio

Ejemplo 6.2 Encontrar el estado estacionario de una cadena de Markov homogénea, donde θ es una variable discreta que toma valores en $\{0, 1, 2\}$ y las probabilidades de transición se definen con la matriz $P = \begin{pmatrix} 0.7 & 0.2 & 0.1 \\ 0.4 & 0.6 & 0.0 \\ 0.0 & 0.9 & 0.1 \end{pmatrix}$.

$$P = \begin{pmatrix} P(0 \rightarrow 0) & P(0 \rightarrow 1) & P(0 \rightarrow 2) \\ P(1 \rightarrow 0) & P(1 \rightarrow 1) & P(1 \rightarrow 2) \\ P(2 \rightarrow 0) & P(2 \rightarrow 1) & P(2 \rightarrow 2) \end{pmatrix} \quad \theta \sim \text{cat}\{\pi(0), \pi(1), \pi(2)\}$$

Por alguna razón la condición de estacionariedad se expresa como:

$$\pi(\theta') = \int \pi(\theta) \cdot P(\theta \rightarrow \theta') d\theta \quad \theta' = \sum_{\theta \in \Theta} \pi(\theta) \cdot P(\theta \rightarrow \theta')$$

Además: $\sum_{\theta} \pi(\theta) = 1 \rightarrow P \cdot \begin{pmatrix} \pi(0) \\ \pi(1) \\ \pi(2) \end{pmatrix} = \begin{pmatrix} \pi(0) \\ \pi(1) \\ \pi(2) \end{pmatrix} \quad \text{y} \quad \pi(0) + \pi(1) + \pi(2) = 1$

$$\begin{cases} 0,7 \cdot \pi(0) + 0,2 \cdot \pi(1) + 0,1 \cdot \pi(2) = \pi(0) \\ 0,4 \cdot \pi(0) + 0,6 \pi(1) + 0 = \pi(1) \rightarrow \pi(1) = \pi(0) \\ 0 + 0,9 \cdot \pi(1) + 0,1 \cdot \pi(2) = \pi(2) \rightarrow \pi(1) = \pi(2) \end{cases} \Rightarrow \pi(0) = \pi(1) = \pi(2)$$

$$\pi(0) + \pi(1) + \pi(2) = 1 \Rightarrow \pi(0) = \pi(1) = \pi(2) = 1/3$$

{ Irreducible, aperiódica, recurrente positiva? }

Explicación de la fórmula: $P(\theta \rightarrow \theta') = p(\theta' | \theta)$

$\Rightarrow$ La conjunta es: $\pi(\theta', \theta) = p(\theta' | \theta) \cdot \pi(\theta) = P(\theta \rightarrow \theta') \cdot \pi(\theta)$

Normalizo integrando sobre θ : $\pi(\theta') = \int \pi(\theta', \theta) d\theta = \int P(\theta \rightarrow \theta') \cdot \pi(\theta) d\theta$

$\pi(\theta')$: prob. de q' T' valga θ' . Para conocer esta prob. considere todas las transiciones posibles q' terminan en θ' , las peso x' la prob. de alcanzar en θ y las sumo. De ahí $\int P(\theta \rightarrow \theta') \cdot \pi(\theta) d\theta$
 "La integral reproduce todas las maneras de llegar a θ' "

Si la cadena no fuera estacionaria: $\pi_{t+1}(\theta') = \int \pi_t(\theta) \cdot P(\theta \rightarrow \theta') d\theta$

Muestreo con Cadenas

de Markov

Time: Cantidad de muestras antes de alcanzar el estado estacionario

Draw: " " " tambores de la cadema

Se hacen varias cadenas en paralelo para corroborar q' se alcance el estado estacionario

Hay diferentes técnicas de Muestras

Muestreo de Gibbs: No comienza $\pi(x_t, y_t)$, pero sí comienza $\pi(x_t | y_t)$ y $\pi(y_t | x_t)$

→ Aproximação com x_0 .

La Cadema avanza como:

→ muestreo $y_1 \sim \pi(y_1 | x_0)$

$$(x_0, y_0) \rightarrow (x_0, y_1) \rightarrow (x_1, y_1) \rightarrow (x_1, y_2) \rightarrow \dots$$

→ investies $x_1 \sim \pi(x_1 | y_1)$

?		
		?

Ejemplo 6.3 Sea la distribución correspondiente al modelo gráfico:

$$P(x, y) \propto e^{x^T a + y^T b + x^T W y} \cdot \mathbf{1}\{x \in \{0, 1\}^{d_x}, y \in \{0, 1\}^{d_y}\} \quad (6.70)$$

donde $\{a, b, w\}$ son valores conocidos. Explicar el procedimiento para muestrear esta distribución utilizando muestreo de Gibbs.

$$P(y|x) = \frac{P(y, x)}{P(x)} \propto \frac{e^{x^T a}}{P(x)} \cdot e^{y^T b} e^{x^T W y} \mathbf{1}\{\dots\} \propto$$

se va todo lo q' no sea y

$$\propto e^{(b^T + x^T W) y} \mathbf{1}\{\dots\} = e^{(b + Wx)^T y} \mathbf{1}\{y \in \{0, 1\}^{d_y}\} = \prod_{j=1}^{d_y} e^{[b + Wx]_j \cdot y_j} \mathbf{1}\{y_j \in \{0, 1\}\}$$

$$\propto \prod_{j=1}^{d_y} P(y_j = y_j) \text{ , con } y_j \in \{0, 1\}$$

$$\Rightarrow P(y_j = 0) \propto 1 \quad ; \quad P(y_j = 1) \propto e^{[b + Wx]_j}$$

$$\Rightarrow P(y_j = 0) = \frac{1}{1 + e^{[b + Wx]_j}} \quad ; \quad P(y_j = 1) = \frac{e^{[b + Wx]_j}}{1 + e^{[b + Wx]_j}} = \frac{1}{e^{-[b + Wx]_j} + 1}$$

↪ dividido x' esto para q' ambas sumen 1

$$\Rightarrow y_j | x = x \sim \text{Ber}(\sigma([b + wx]_j))$$

$$\Rightarrow y | x = x \sim \text{Ber}(\sigma(b + wx)) \text{ donde } \sigma(b + wx) \in \mathbb{R}^{d_y} \text{ e } y \text{ es un vector de componentes independientes}$$

De forma análoga se llega a $x | y = y \sim \text{Ber}(\sigma(a + wy))$, donde x es un vector de componentes bernoulli independientes, distribuidas según $x_i | y = y \sim \text{Ber}([\sigma(a + wy)]_i)$

El muestreo de Gibbs te queda:

→ Inicializa un x_0

→ Genera y_k a partir de $y_k | x_k \sim \text{Ber}(\sigma(b + wx_k))$

→ Genera x_{k+1} a partir de $x_{k+1} | y_k \sim \text{Ber}(\sigma(a + wy_k))$

Muestreo Metropolis → Útil para variables aleatorias q' toman valores enteros o V.A. continuas

→ Necesito conocer $\pi(\theta)$ salvo una cte de proporcionalidad, $\pi(\theta) = \frac{f(\theta)}{Z}$ no diferenciables (?)

Funciona así: Parto de un θ_t

1) Genero un $\theta' = \theta_t + S$, donde $S \sim \mathcal{U}(\{-1, 0, 1\})$ si es discreta o $S \sim \mathcal{N}(0, \sigma^2)$ si es continua

2) Se sortea una Bernoulli, de probabilidad $\alpha(\theta_t, \theta')$, $0 \leq \alpha \leq 1$

Si sale 1 → actualizo $\theta_{t+1} = \theta'$

Si sale 0 → me queda $\theta_{t+1} = \theta_t$

$$\text{Además, } \alpha(\theta_t, \theta') = \min \left\{ 1, \frac{f(\theta')}{f(\theta_t)} \right\}$$

¿Por qué es así el α ? → Si $f(\theta')/f(\theta_t) > 1 \Rightarrow f(\theta') > f(\theta_t) \Rightarrow \pi(\theta') > \pi(\theta_t)$

⇒ La prob. de θ' es mayor q' la prob de θ_t , θ' es más verosímil

En tal caso me conviene actualizar

→ Si $f(\theta')/f(\theta_t) < 1$, pasa lo contrario. Igual es probable q' actualice si $\alpha =$

$= \frac{f(\theta')}{f(\theta_t)} \approx 1$. Si en cambio $\alpha = \frac{f(\theta')}{f(\theta_t)} \approx 0$ es improbable q' actualice

Aca hay una demostración q' no entiendo . página 131 del PDF

Muestreo NUTS : Una Cagada

Métricas de calidad :

ESS : Effective Sample Size . Las muestras no son realmente independientes.

Si tengo N muestras dependientes equivale a tener ESS muestras independientes

$$ESS = \frac{t_{\max}}{1 + 2 \sum_{t=1}^{t_{\max}} \rho_t}$$

$t_{\max}$: largo de la cadena

ρ_t : "autocorrelación de la cadena" o covarianza de 2 elementos separados t unidades

Hay una demostración muy falopa

R-hat : Cociente entre las varianzas dentro de las cadenas y entre las cadenas.

Si las cadenas alcanzan el estado estacionario $\Rightarrow \hat{R} \approx 1$