

Regresión

10/1 → Regresión lineal, hasta OHE. Hasta gradiente descendiente (sin incluir)

Algunos términos y definiciones:

$l(x, y) \rightarrow$ función costo $\rightarrow$ En general $l(x, y) = (y - \hat{y})^2 = (y - \varphi(x))^2$

$E[l(x, y)] \rightarrow$ Riesgo esperado $\rightarrow$ Esto queremos minimizar

Error Bayesiano: Riesgo esperado de la solución óptima

Def: Esperanza condicional.

Sean X e $Y|X=x$ variables aleatorias. $\exists E[Y|X=x] = \varphi(x) \rightarrow$ un numerito por cada posible valor de x

$\varphi(x)$ sea otra V.A., y la notaremos $E[Y|x]$

Teorema: Elegir $\varphi(x) = E[Y|X=x]$ minimiza el ECM

D/ $\hat{y} = \varphi(x) \rightarrow$ regresión sumamos y restamos

$$\text{Riesgo esperado: } E[(Y - \varphi(x))^2] \stackrel{+}{=} E[(Y - E[Y|X] + E[Y|X] - \varphi(x))^2] =$$

$$= E[(Y - E[Y|X])^2] + \rightarrow \textcircled{\text{I}}$$

$$+ 2E[(Y - E[Y|X]) \cdot (E[Y|X] - \varphi(x))] + \rightarrow \textcircled{\text{II}}$$

$$+ E[(E[Y|X] - \varphi(x))^2] \rightarrow \textcircled{\text{III}}$$

2 propiedades q' nos van a ayudar:

$$1) E[Y] = E[E[Y|X]] \quad 2) E[Y \cdot g(x)] = E[E[Y|X] \cdot g(x)]$$

↓

Promedio de promedios, esperanza
iterada

$$\textcircled{I} \quad E[(Y - E[Y|X])^2] = E[E[(Y - E[Y|X])^2 | X]] = \text{Var}(Y|X)$$

→ ¿xq? → ①

$$\textcircled{II} \quad E[(Y - E[Y|X]) \cdot (E[Y|X] - \varphi(X))] = E[E[Y - E[Y|X] | X] \cdot (E[Y|X] - \varphi(X))]$$

→ ¿xq? → ②

$$= E[(E[Y|X] - E[E[Y|X] | X]) \cdot (E[Y|X] - \varphi(X))] = 0$$

E[Y|X] → ¿está bien? → SI

= 0

$$\textcircled{III} \quad E[(E[Y|X] - \varphi(X))^2] \geq 0$$

$$\Rightarrow E[(Y - \varphi(X))^2] = \text{Var}(Y|X) + E[(E[Y|X] - \varphi(X))^2] \geq \text{Var}(Y|X)$$

com igualdade $\Leftrightarrow \varphi(X) = E[Y|X]$

Duda existencial: ¿Qué significa la operación $E[\cdot|x]$?

por ejemplo en $E[Y|X]$ o en $E[Y - E[Y|X]]$ o en $E[E[Y|X]|x]$

Preguntarle al Shat

Conceptualmente, lo importante es: La esperanza condicional es el mejor predictor, es el que minimiza el ECM. El error NUNCA será menor que la varianza condicional

Detalles: ① ¿por qué $E[(Y - E[Y|X])^2] = E[E[(Y - E[Y|X])^2|x]]$

sea $Z = (Y - E[Y|X])^2$, Z es una V.A. (q' depende de x)

$\Rightarrow$ cumple que $E[Z] = E[E[Z|x]]$

② Hay que entender bien $E[g(x) \cdot Y] = E[g(x) \cdot E[Y|x]]$

$$D/ \overbrace{E[g(x) \cdot Y]}^Z = E[\overbrace{E[g(x) \cdot Y | x]}^Z] = E[g(x) \cdot E[Y|x]]$$

↓
puedo sacarlo, como si x fuera x , sería una constante

$$\Rightarrow E[\overbrace{(Y - E[Y|X])}^0 \cdot \overbrace{(E[Y|X] - \varphi(X))}^0] =$$

$$= E[E[(Y - E[Y|X]) \cdot (E[Y|X] - \varphi(X)) | X]]$$

$g(X) = (E[Y|X] - \varphi(X)) \rightarrow$ puede salir $g(X)$


$$\rightarrow E[E[Y - E[Y|X] | X] \cdot \overbrace{(E[Y|X] - \varphi(X))}^{g(X)}]$$

$$\rightarrow E[Y|X] - E[E[Y|X] | X] = E[Y|X] - E[E[Y|X] \cdot 1 | X] =$$

$$= E[Y|X] - E[Y|X] \cdot E[1 | X] = 0$$

$$\underbrace{\mathbb{E}[\ell(X, Y)]}_{\text{Riesgo esperado}} = \underbrace{\frac{1}{n_{\text{tr}}} \sum_{i=1}^{n_{\text{tr}}} \ell(x_i, y_i)}_{\text{Riesgo empírico}} + \underbrace{\left(\mathbb{E}[\ell(X, Y)] - \frac{1}{n_{\text{tr}}} \sum_{i=1}^{n_{\text{tr}}} \ell(x_i, y_i) \right)}_{\text{Gap de generalización}}$$

Gap de generalización: Qué tanto mayor es el riesgo esperado respecto del empírico



Tener muchos datos ayuda a resolver el overfitting

overfitting $\rightarrow$ problema de variancia

underfitting $\rightarrow$ problema de sesgo

$\left\{ \begin{array}{l} \text{¿} xq! \end{array} \right\}?$

Regresión Lineal

Nos limitamos a soluciones del tipo $\hat{y} = w^T \cdot x + b$

$$x = \mathbb{R}^{d_x \times 1}, \quad w' \in \mathbb{R}^{d_x \times 1}, \quad b \in \mathbb{R}$$

El problema ahora es hallar w, b (se minimice el riesgo empírico)

$$(w', b) = \arg \min_{w', b} \frac{1}{n} \sum_{i=1}^n (b + w'^T x_i - y_i)^2 = \frac{1}{n} \sum_{i=1}^n (b + x_i^T \cdot w' - y_i)^2$$

$\downarrow$
nro de muestras

Para resolver esto hay q' vectorizar

$$X = \begin{pmatrix} 1 & x_1^T \\ 1 & x_2^T \\ \vdots & \vdots \\ 1 & x_m^T \end{pmatrix}, \quad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}, \quad w = \begin{pmatrix} b \\ w' \end{pmatrix}$$

⇒ La función a minimizar es: $J(w) = \frac{1}{n} \|X \cdot w - y\|^2$

→ Hay q' derivar $J(w)$ respecto de w

$$\begin{aligned} J(w) &= \frac{1}{n} (X \cdot w - y)^T (X \cdot w - y) = \frac{1}{n} (w^T X^T - y^T) (X w - y) = \\ &= \frac{1}{n} (w^T X^T X \cdot w - w^T X^T y - y^T X w + y^T y) \end{aligned}$$

$$\nabla J(w) = \frac{1}{n} (\sum x^T x w - x^T \cdot y - x^T y + 0) = 0 \rightarrow \text{para maximizar}$$

$$\rightarrow \sum x^T x w = \sum x^T y$$

$$w = (x^T x)^{-1} x^T y$$

¿Cómo me acuerdo de todas esas propiedades?

Ejemplo 2.2 Se desea hacer una regresión lineal (sin normalizar) sobre el siguiente conjunto de datos:

	x_1	x_2	x_3	x_4
x	0.2	1.4	-1.4	-0.2
y	20.0	10.0	10.0	0.0

- Hallar los parámetros del modelo.
- Predecir y para $x = 0.1$.

Sol: $\hat{y} = (w')^T \cdot x + b$

Minimizar $E[l(x, y)] = \frac{1}{n} \sum_{i=1}^n [(w')^T \cdot x_i + b - y_i]^2$

Vectorización: $X = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{pmatrix} = \begin{pmatrix} 1 & 0,2 \\ 1 & 1,4 \\ 1 & -1,4 \\ 1 & -0,2 \end{pmatrix}$ $y = \begin{pmatrix} 20 \\ 10 \\ 10 \\ 0 \end{pmatrix}$ $w = \begin{pmatrix} b \\ w_1 \end{pmatrix}$

$$\rightarrow \frac{1}{4} \sum_{i=1}^4 [(w')^T \cdot x_i + b - y_i]^2 = \frac{1}{4} \|X \cdot w - y\|^2 = \frac{1}{4} (Xw - y)^T \cdot (Xw - y) =$$

$$\propto (w^T X^T - y^T)(Xw - y) = \overbrace{w^T X^T X w}^{1 \times 2 \quad 2 \times 4 \quad 4 \times 1} - \overbrace{w^T X^T y}^{1 \times 2 \quad 2 \times 4 \quad 4 \times 1} - \underbrace{y^T X w}_{1 \times 4 \quad 4 \times 2 \quad 2 \times 1} - y^T y = J(w)$$

$$= w^T x^T x w - 2 y^T x w - y^T y$$

$$\nabla (a^T w) = a$$

$$\nabla (w^T A w) = (A + A^T) w$$

$$\rightarrow \nabla J(w) = 2 x^T x w - 2 x^T y = 0$$

↓

$$A = x^T x$$

$$w = (x^T x)^{-1} x^T y = \begin{pmatrix} 1.9 \\ 1 \end{pmatrix}$$

OHE: Para vectorizar los problemas hay que codificar las variables categóricas. Si no tienen un orden específico usamos OHE

EJ: Gato, Perro, Caballo --> Posibles categorías

Gato = (1, 0, 0)

Perro = (0, 1, 0)

Caballo = (0, 0, 1)

Cada categoría se representa como un 1 en un vector de ceros

TS/O1 $\rightarrow$ GD, reg. Pol., ¿Regularización?

Gradiente descendente

Tengo una función $J(\theta)$. Quiero minimizarla para $\theta \in \mathbb{H}$, $\min_{\theta \in \mathbb{H}} J(\theta) = J^*$


Hallar J^*

$$\theta_{t+1} = \theta_t - \alpha \cdot \nabla J(\theta_t) \quad \alpha: \text{learning rate, hiperparámetro}$$

Normalización: Aquí conviene normalizar para hacer la convergencia más rápida y menos errática


Si no normalizar:

Cuanto más achatada sea esta elipse más se nota



El gradiente siempre $\rightarrow$ es perpendicular a las curvas de nivel

Normalizando:



$\vec{x}_i$: muestra $\vec{x}_i = \begin{pmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{iM} \end{pmatrix}$

N : # de muestras

variables de entrada o predictores
 N muestras con M componentes

$$k \in [1, M]$$

$$\mu_k = \frac{1}{N} \sum_i^N (\vec{x}_i)_k \quad \sigma_k^2 = \frac{1}{N} \sum_i^N [(\vec{x}_i)_k - \mu_k]^2$$

y luego hacer la reasignación: $\frac{(\vec{x}_i)_k - \mu_k}{\sigma_k} \rightarrow (\vec{x}_i)_k \quad \forall i \in [1, N]$

No siempre conviene normalizar. ojo al piezo.


Si quieres comparar predictores que tengan distintas unidades conviene

Learning rate óptimo: Sea $\theta^* / J(\theta^*)$ es mínimo $\Rightarrow \nabla J(\theta^*) = 0$

Además, asumamos q' $H_J(\theta)$ es definida positiva.

t. de Taylor aplicado a $\nabla J(\theta)$, centrado en θ^*

$$\nabla J(\theta_t) = \nabla J(\theta^*) + H_J(\tilde{\theta})(\theta_t - \theta^*), \text{ donde } \tilde{\theta} \text{ está en la línea}$$



Para encontrar α óptimo hacemos 2 cosas:

i) $H_J(\tilde{\theta}) = Q^T \Lambda Q$ (se puede, es DP)

ii) trabajar con la diferencia

$$\theta_{t+1} - \theta^*$$

Vamos a terminar con algo q' se parece a una serie geométrica (por lo q' la diferencia tiende a 0)

$$\theta_{t+1} = \theta_t - \alpha \cdot \nabla J(\theta_t)$$

$$\theta_{t+1} - \theta^* = \theta_t - \theta^* - \alpha \left[\cancel{\nabla J(\theta^*)} + H_J(\tilde{\theta})(\theta_t - \theta^*) \right]$$

$$\theta_{t+1} - \theta^* = (\theta_t - \theta^*) - \alpha \cdot Q^T \Lambda Q (\theta_t - \theta^*)$$

$$\theta_{t+1} - \theta^* = (I - \alpha Q^T \Lambda Q) \cdot (\theta_t - \theta^*)$$

$$\theta_{t+1} - \theta^* = Q^T \left(\underbrace{Q^{T-1} \cdot Q^{-1}}_I - \alpha \Lambda \right) Q \cdot (\theta_t - \theta^*)$$

Multiplico por
Q a Eq.

$$\underbrace{Q(\theta_{t+1} - \theta^*)}_{v_{t+1}} = (I - \alpha \cdot \Lambda) \cdot \underbrace{Q(\theta_t - \theta^*)}_{v_t}$$

$$v_{t+1} = (I - \alpha \cdot \Lambda) \cdot v_t$$

Que θ_t converja a θ^* equivale a que r_t converja a 0

Cada paso es multiplicar por la misma CTE

$$\rightarrow r_t = (I - \alpha \cdot \mathcal{L})^t \cdot r_0$$

OBS: $I - \alpha \cdot \mathcal{L} = \begin{pmatrix} 1 - \alpha \cdot \lambda_1 & 0 & 0 & \dots & 0 \\ 0 & 1 - \alpha \lambda_2 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 & 1 - \alpha \lambda_m \end{pmatrix}$

$$(I - \alpha \mathcal{L})^t = \text{diag} \left((1 - \alpha \lambda_j)^t \right) \text{ con } j \in [1, m]$$

Para un α fijo, cuanto mayor sea $|1 - \alpha \cdot \lambda_j|$ más lento convergerá

($0,8^n$ converge más lento que $0,1^n$)

La joda ahora es: i) Elige el $|1 - \alpha \lambda_j|$ que más lento converge


$$\rightarrow \max_j |1 - \alpha \lambda_j|$$

ii) Lo minimiza con α para q' converja más rápido

$$\min_{\alpha} \left[\max_{ij} |1 - \alpha \lambda_{ij}| \right]$$

OBS: de esta manera α no es el mejor posible en cada caso individual, pero es el mejor posible para el peor de los casos, el resto de los casos será más rápido q' este

¿Cómo se resuelve? → Gráficamente:



$$\max_{ij} |1 - \alpha \lambda_{ij}|$$

Se observa que α^* es tal que:

$$1 - \alpha^* \lambda_{\max} = 1 - \alpha^* \lambda_{\min}$$

$$\Rightarrow \alpha^* = \frac{2}{\lambda_{\max} + \lambda_{\min}}$$

QBS: El learning rate óptimo y el máximo learning rate convergente son distintos

α' : máximo convergente. $|1 - \alpha \cdot \lambda_j| < 1 \rightarrow -1 < 1 - \alpha \lambda_j < 1$

$$0 < \alpha \cdot \lambda_j < 2 \rightarrow \alpha < 2/\lambda_j \quad \forall j$$

$$\Rightarrow \alpha' = 2/\lambda_{\max} \neq \alpha^*$$

Moraleja: dar saltos más grandes no siempre me hace llegar más rápido

Regresión Polinómica

Regresión lineal (con 2 predictores o features y m muestras de cada uno)

$$X = \begin{pmatrix} 1 & x_{1,1} & x_{1,2} \\ 1 & x_{2,1} & x_{2,2} \\ \vdots & \vdots & \vdots \\ 1 & x_{m,1} & x_{m,2} \end{pmatrix}$$

$$\hat{y}_i = b + w_1 \cdot x_{i,1} + w_2 \cdot x_{i,2}$$

Puede q' esto no sea lo suficientemente complejo. Mapa polinómico:

$$X = \begin{pmatrix} 1 & x_{1,1} & x_{1,2} & x_{1,1}^2 & x_{2,1}^2 & x_{1,1} \cdot x_{1,2} \\ 1 & x_{2,1} & x_{2,2} & x_{2,1}^2 & x_{2,2}^2 & x_{2,1} \cdot x_{2,2} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{m,1} & x_{m,2} & x_{m,1}^2 & x_{m,2}^2 & x_{m,1} \cdot x_{m,2} \end{pmatrix}$$

$$\Rightarrow \hat{y}_i = b + w_1 \cdot x_{i,1} + w_2 x_{i,2} + w_3 x_{i,1}^2 + w_4 \cdot x_{i,2}^2 + w_5 \cdot x_{i,1} \cdot x_{i,2}$$

Pregunta importante: ¿Cuántos features (columns) tiene un mapa polinómico de orden r con d variables? $x_1, x_2, \dots, x_d \rightarrow$ mis variables

La verdad que no entiendo por qué, pero da $\binom{r+d}{r}$

Esto da una medida de complejidad

Importante: El mapa polinómico devuelve magnitudes no comparables.
Hay q' normalizar las columnas



La columna de 1's no se normaliza para poder agregar un sesgo

Ejemplo 2.3 Preprocesar el siguiente conjunto de datos, para iniciar el entrenamiento de una regresión polinómica de orden 2. ¿Que cantidad de parámetros tendrá el modelo?

x_1	1.2	0.8	1.0
x_2	2.3	1.3	1.6

Coefficientes: $1, x_1, x_2, x_1^2, x_2^2, x_1 \cdot x_2 \rightarrow 6$ Coeficientes

x_1	x_2	x_1^2	x_2^2	$x_1 \cdot x_2$
1,2	2,3	1,44	5,29	2,76
0,8	1,3	0,64	1,69	1,04
1	1,6	1	2,56	1,6

μ	1	1,73	1,03	3,18	1,73
σ	0,163	0,413	0,327	1,534	0,703

$$X = \begin{pmatrix} 1 & 1,22 & 1,35 & 1,26 & 1,38 & 1,34 \\ 1 & -1,22 & -1,03 & -1,19 & -0,97 & -1,06 \\ 1 & 0 & -0,32 & -0,08 & -0,40 & -0,28 \end{pmatrix}$$



Conjuntos de datos 21/01 → conjunto de datos, regularización, validación

¿cómo detectamos el underfitting? → Alto riesgo empírico

$$\rightarrow \frac{1}{n} \sum_{i=1}^n l(x_i, y_i) = \text{ALTO}$$

¿y el overfitting? → Hay q' calcular el riesgo esperado, $E[l(x, y)]$

Para calcularlo como dis manda debería conocer la distribución de x e y

Solo lo vamos a estimar separando el conjunto de datos

1) Entrenamiento: Datos q' se usan para entrenar al algoritmo. con este se definen los parámetros.

2) Validación: Datos q' se usan para comparar modelos. con estos datos se definen los hiperparámetros (como r en el mapa polinómico o α)
ej: los hiperparámetros pueden definirse antes del entrenamiento.

3) Testeo: Este conjunto se usa para calcular las métricas finales del algoritmo

EJ: tengo distintos mapas polinómicos con distintos valores de r .

→ A todos los entreno con el conjunto de entrenamiento

→ con el conjunto de validación los comparo ¿cuál tiene menor error medio con este conjunto?

→ con los datos del conjunto de testeo estimo el error esperado y evalúo si hay overfitting

Under fitting $\rightarrow$ alto riesgo empírico (entrenamiento)

overfitting $\rightarrow$ bajo riesgo empírico (entrenamiento) y alto riesgo esperado (testes)

Regularización

Problema de sesgo $\rightarrow$ alto riesgo empírico con el conjunto de entrenamiento
(Comparado con el bayesiano) $\rightarrow$ UNDERFITTING

Problema de varianza $\rightarrow$ Alto riesgo esperado (estimado a partir del conjunto de validación) Comparado con el empírico $\rightarrow$ OVERFITTING

Distintos nombres para la misma cosa

¿Cómo resolvemos el problema de varianza? $\rightarrow$ con más datos

No es tan fácil

Regularización: técnicas para combatir el overfitting sin agregar más datos

la técnica q' vemos nosotros consiste en agregar un término de penalización a la función a minimizar

$$J(\theta) = \underbrace{\frac{1}{n} \sum_{i=1}^n \ell(x_i, y_i)}_{\text{Riesgo empírico}} + \lambda \cdot R(\theta)$$

Regulador
↗
↳ hiperparámetro

En lugar de optimizar el riesgo empírico solamente optimizamos el riesgo empírico + $\lambda \cdot R(\theta)$. Si $\lambda \cdot R(\theta)$ se parece al gap de generalización estamos optimizando el riesgo esperado. Recordar:

$$\overset{\text{esperado}}{\uparrow} E[\ell(x, y)] = \frac{1}{n} \sum_{i=1}^n \ell(x_i, y_i) + \underbrace{\left[E[\ell(x, y)] - \frac{1}{n} \sum_{i=1}^n \ell(x_i, y_i) \right]}_{\text{empírico} \rightarrow \text{gap}}$$

Similar a:

$$J(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(x_i, y_i) + \lambda \cdot R(\theta)$$

↓ ↓ ↓
"esperado" empírico "gap"

Regularizador L2: $R(b, w) = \frac{1}{n} \|w\|^2$ $n = \#$ de muestras

Esta regularización hace q' el vector de pesos w tienda a ser más chico

Ejemplo 2.4 Hallar una solución matricial al problema de regresión lineal sin sesgo y con regularización L2. Analizar el comportamiento para algoritmos no regularizados y muy regularizados.

$$\hat{y} = w^T \cdot x_i + b, \quad b = 0 = x_i^T \cdot w$$

$$X = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$$

$$y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

$$J(\theta) = \frac{1}{n} \sum_{i=1}^n (w^T \cdot x_i - y_i)^2 + \lambda \cdot \frac{1}{n} \|w\|^2$$

$$= \frac{1}{n} \|X \cdot w - y\|^2 + \frac{\lambda}{n} \|w\|^2$$

$$= \frac{1}{n} (X \cdot w - y)^T (X \cdot w - y) + \frac{\lambda}{n} \|w\|^2$$

$$= \frac{1}{n} (w^T X^T - y^T) (X \cdot w - y) + \frac{\lambda}{n} \|w\|^2$$

$$= \frac{1}{n} \left(w^T x^T x w - w^T x^T y - y^T x w - \|y\|^2 \right) + \frac{\lambda}{n} \|w\|^2$$

oBS $w^T x^T \cdot y \in \mathbb{R}^{1 \times 1} \rightarrow w^T x^T \cdot y = (w^T x^T y)^T = y^T x w$

$$\Rightarrow J(w) = \frac{1}{n} \left(w^T x^T x w - 2 y^T x w - \|y\|^2 \right) + \frac{\lambda}{n} \|w\|^2$$

Propiedades:

$$\nabla (a^T w) = a$$

$$\nabla J(w) = \frac{1}{n} \left[(x^T x + x^T x) w - 2 x^T y - 0 \right] + \frac{\lambda}{n} 2 w = 0$$

$$\nabla (w^T A w) = (A + A^T) w$$

$$\nabla \|w\|^2 = 2 w$$

$$= 2 x^T x w - 2 x^T y + 2 \lambda w = 0$$

$$\rightarrow x^T x w + \lambda w = x^T y$$

$$\rightarrow (x^T x + \lambda \cdot I) w = x^T y$$

$$\Rightarrow w = (x^T x + \lambda \cdot I)^{-1} x^T \cdot y$$

i) $\lambda = 0 \Rightarrow w = (X^T \cdot X)^{-1} X^T \cdot Y \rightarrow$ la misma solución de antes

ii) λ grande / $X^T X + \lambda I \approx \lambda I$

$$\Rightarrow w = \frac{1}{\lambda} X^T \cdot Y \quad \text{Multiplica a izquierda por } X: XW = Y = X \cdot \frac{1}{\lambda} X^T Y$$

$$\Rightarrow X^{-1} \approx \frac{1}{\lambda} X^T$$

"El algoritmo muy regularizado interpreta la

traspuesta como operación inversa"

Etapas de validación

Si quiero entrenar 2 hiperparámetros con V valores cada uno tengo que hacer V^2 validaciones. Esto es costoso. La cantidad de validaciones a realizar crece exponencialmente con el número de hiperparámetros (maldición de la dimensionalidad)

Además, puede ser que un solo hiperparámetro influya sobre el error (lo que a priori se desconoce).

Entonces, conviene más usar una grilla aleatoria, porque terminas probando más valores del hiperparámetro relevante.

Otra opción es validar primero en una región, "hacer zoom" en una región de interés (la de menor error) y validar por etapas

Me explicó para el orto, pero yo me entiendo

Validación Cruzada

Muchas veces no hay suficientes datos como para armar un conjunto de validación

Leave-one-out cross-validation (LOOCV): Tengo n datos. Uso $n-1$ datos para el entrenamiento y con el último dato hago la validación.

Por ejemplo, quiero probar V valores para λ .

Con el primer valor de λ hago n entrenamientos (con los $n-1$ datos) y n validaciones (con el último dato) y considero el promedio de los errores como el error de validación

Con el segundo valor de λ hago n entrenamientos y validaciones, etc

Termino haciendo $V * n$ entrenamientos.

K-folds: punto medio entre conjunto de validación y LOOCV

Separo mis datos en K subconjuntos. Entreno con los $K-1$ primeros y valido con el último. Eso lo hago K veces, cambiando el subconjunto con el cual valido, y considero el promedio de los errores como el error de validación

EJERCICIO

1.3 Sea la función de densidad de probabilidad


$$p_{XY}(x, y) = \frac{4}{5} \mathbb{1}_{\{0 < y < 1 + x^3, 0 < x < 1\}}$$

(a) Calcular y graficar en una misma figura el soporte, la esperanza condicional $E[Y|X = x]$ y la recta de regresión.

(b) Calcular el error bayesiano.

📌: Las únicas integrales que debe resolver son con respecto a la marginal $p_X(x)$. El resto de los cálculos debe hacerse utilizando propiedades.

a)



$$Y|X=x \sim ? \quad p_{X,Y}(x,y) = p_X(x) \cdot p_{Y|X=x}(y)$$

$$p_{X,Y}(x,y) = \mathbb{1}_{\{0 < x < 1\}} \cdot \frac{4}{5} \mathbb{1}_{\{0 < y < 1+x^3\}} =$$

$$= \mathbb{1}_{\{0 < x < 1\}} \cdot \frac{4}{5} \cdot \frac{1}{1+x^3-0} \cdot (1+x^3) \mathbb{1}_{\{0 < y < 1+x^3\}} =$$

$$= \underbrace{\frac{4}{5} (1+x^3) \mathbb{1}_{\{0 < x < 1\}}}_{p_X(x)} \cdot \underbrace{\frac{1}{1+x^3} \mathbb{1}_{\{0 < y < 1+x^3\}}}_{p_{Y|X=x}(y) \sim \mathcal{U}(0, 1+x^3)}$$

$$p_X(x)$$

$$p_{Y|X=x}(y) \sim \mathcal{U}(0, 1+x^3)$$

$$\Rightarrow E[Y|X=x] = \frac{1+x^3}{2}$$

¿Recta de regresión? → Recta q' minimiza el ECM

Recta: $a \cdot x + b$ - Minimizar $E[(Y - (ax+b))^2]$

$$E[(Y - (ax+b))^2] = E[Y^2 - 2Y(ax+b) + (ax+b)^2] =$$

$$= E[Y^2 - 2YaX - 2Yb + a^2X^2 + 2aXb + b^2] =$$

$$= E[Y^2] - 2aE[XY] - 2bE[Y] + a^2E[X^2] + 2abE[X] + b^2$$

Deriva respecto de b:

$$0 - 0 - \cancel{2}E[Y] + 0 + \cancel{2}aE[X] + \cancel{2}b = 0$$

$$\Rightarrow b = E[Y] - aE[X]$$

Deriva respecto de a:

$$0 - \cancel{2}E[X \cdot Y] - 0 + \cancel{2}aE[X^2] + \cancel{2}bE[X] + 0 = 0$$

$$aE[X^2] + b \cdot E[X] = E[X \cdot Y]$$

$$aE[X^2] + (E[Y] - aE[X])E[X] = E[X \cdot Y]$$

$$aE[X^2] + E[Y] \cdot E[X] - aE^2[X] = E[X \cdot Y]$$

$$a(E[X^2] - E^2[X]) + E[Y] \cdot E[X] = E[X \cdot Y]$$

$$\Rightarrow a = \frac{E[X \cdot Y] - E[X] \cdot E[Y]}{E[X^2] - E^2[X]} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

$$\Rightarrow a = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

$$b = E[Y] - \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \cdot E[X]$$

$$p_x(x) = \frac{4}{5} (1 + x^3) \cdot \mathbb{1}_{\{0 < x < 1\}} \rightarrow \text{puedo sacar } E[X], E[X^2], E[X^3]$$

$$E[Y] = E[E[Y|X]] = E\left[\frac{1 + x^3}{2}\right]$$

$$\{E[Y \cdot X]\} \rightarrow E[Y \cdot g(x)] = E[E[Y|X] \cdot g(x)]$$

$$\Rightarrow E[Y \cdot X] = E[E[Y|X] \cdot X] = E\left[\frac{1 + x^3}{2} \cdot x\right] = E\left[\frac{x + x^4}{2}\right]$$

$$\Rightarrow \text{busco } E[X^m], \text{ con } m = 1, \dots, 4$$

$$E[X^n] = \int_0^1 x^n \frac{4}{5} (1+x^3) dx = \frac{4}{5} \int_0^1 x^n + x^{n+3} dx = \frac{4}{5} \left[\frac{1}{n+1} x^{n+1} + \frac{1}{n+4} x^{n+4} \right] \Big|_0^1 =$$

$$= \frac{4}{5} \left[\frac{1}{n+1} + \frac{1}{n+4} \right] = \frac{4}{5} \cdot \frac{2n+5}{(n+1)(n+4)}$$

$$E[X] = \frac{14}{25} \quad E[X^2] = \frac{2}{5} \quad E[X^3] = \frac{11}{35} \quad E[X^4] = \frac{13}{50} \quad E[X^6] = \frac{34}{175}$$

$$E[Y] = E\left[\frac{1+X^3}{2}\right] = \frac{1}{2} + \frac{1}{2} \frac{11}{35} = \frac{23}{35}$$

$$E[Y \cdot X] = E\left[\frac{X+X^4}{2}\right] = \frac{1}{2} E[X] + \frac{1}{2} E[X^4] = 41/100$$

$$\text{cov}(X, Y) = E[X \cdot Y] - E[X] \cdot E[Y] = \frac{41}{100} - \frac{14}{25} \cdot \frac{23}{35} = \frac{21}{500}$$

$$\text{Var}(X) = E[X^2] - E^2[X] = \frac{2}{5} - \left(\frac{14}{25}\right)^2 = \frac{54}{625}$$

$$a = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = \frac{21/500}{54/625} = \frac{35}{72} \approx 0,49$$

$$b = \frac{23}{35} - a \cdot \frac{14}{25} = 97/252 \approx 0,38$$

$$\Rightarrow 0,49 \cdot X + 0,38$$

b) Error bayesiano:


$$E[\text{Var}(Y|X)]$$

$$Y|X=x \sim U(0, 1+x^3)$$

$$\text{Var}(Y|X=x) = \frac{(1+x^3 - 0)^2}{12}$$

$$= \frac{1 + 2x^3 + x^6}{12}$$

$$\Rightarrow \text{Var}(Y|X) = \frac{1}{12} + \frac{1}{6} X^3 + \frac{1}{12} X^6$$



$$\Rightarrow E[\text{Var}(Y|X)] = \frac{1}{12} + \frac{1}{6} E[X^3] + \frac{1}{12} E[X^6] =$$

$$E[X^3] = \frac{11}{35}$$

$$E[X^6] = 34/175$$

$$= \frac{1}{12} + \frac{1}{6} \cdot \frac{11}{35} + \frac{1}{12} \cdot \frac{34}{175} = \frac{319}{2100} \approx 0,152$$

Obs: se puede calcular la variança de Y con la siguiente propiedad:

$$\text{Var}(Y) = E[\text{Var}(Y|X)] + \text{Var}(E[Y|X]) \quad E[Y|X] = \frac{1+X^3}{2}$$

$$= 71/420$$

$$\text{Var}\left(\frac{1+X^3}{2}\right) = \left(\frac{1}{2}\right)^2 \text{Var}(X^3) = \frac{1}{4} (E[X^6] - E^2[X^3]) = \frac{1}{4} \left(\frac{17}{70} - \left(\frac{11}{28}\right)^2\right) = \frac{347}{15680}$$

$$\Rightarrow \text{Var}(Y) = \frac{71}{420} + \frac{347}{15680} = \frac{8933}{47040}$$

$\text{Var}(Y) \rightarrow$ Error al predecir con una cte = $E[Y]$

$E[\text{Var}(Y|X)] \rightarrow$ Error al predecir con $E[Y|X]$

La diferencia es $\text{Var}(E[Y|X]) = \frac{347}{15680} \approx 0,022$ ¿vale la pena?