

Clasificación

Taller de Procesamiento de Señales / Introducción a la Inteligencia Artificial

Agenda

- 1 Introducción al problema de clasificación
- 2 Regresión Logística
 - Regresión Logística Binaria
 - Regresión Logística Categórica
 - Regresión Logística Polinómica
- 3 Linear Discriminant Analysis
- 4 K-Vecinos más cercanos
- 5 Support Vector Machines
- 6 Árboles de decisión

Teoría de Clasificación

Bases

Objetivo: Clasificar Y (con $|\mathcal{Y}|$ finito) a partir del valor de X : $\hat{Y} = \varphi(X)$

Función costo: Hard $\rightarrow \ell(x, y) = \mathbb{1}\{y \neq \varphi(x)\}$

Riesgo Esperado: Probabilidad de error $\rightarrow \mathbb{P}(Y \neq \varphi(X))$

La esperanza de una indicadora es una probabilidad

$$E[\mathbb{1}\{y \neq \varphi(x)\}] = P(y \neq \varphi(x))$$

Teoría de Clasificación

Bases

Objetivo: Clasificar Y (con $|\mathcal{Y}|$ finito) a partir del valor de X : $\hat{Y} = \varphi(X)$

Función costo: Hard $\rightarrow \ell(x, y) = \mathbb{1}\{y \neq \varphi(x)\}$

Riesgo Esperado: Probabilidad de error $\rightarrow \mathbb{P}(Y \neq \varphi(X))$

Optimalidad

$$\mathbb{P}(Y \neq \varphi(X)) \geq 1 - \mathbb{E} \left[\max_y P_{Y|X}(y|X) \right]$$

con igualdad si y solo si $\varphi(x) = \arg \max_y P_{Y|X}(y|x)$.

Clasificador Bayesiano: $\varphi(x) = \arg \max_y P_{Y|X}(y|x)$

Error Bayesiano: $1 - \mathbb{E} \left[\max_y P_{Y|X}(y|X) \right]$

Clasificadores extremos

Clasificador bayesiano

El mejor clasificador (en términos de la probabilidad de error) es:

$$\mathbb{P}(Y \neq \varphi(X)) \geq 1 - \mathbb{E} \left[\max_y P_{Y|X}(y|X) \right]$$

Clasificador al azar para k clases

Cualquier clasificador razonable debe ganarle a la decisión al azar:

$$\mathbb{P}(Y \neq \varphi(X)) \leq 1 - \frac{1}{k}$$

Clasificador dummy

Otro clasificador muy precario (pero mejor que el azaroso) es elegir siempre la clase más probable. La probabilidad de error del dummy es:

$$\mathbb{P}(Y \neq \varphi(X)) \leq 1 - \max_y P_Y(y)$$


Demostración: $P(y \neq \varphi(x)) = 1 - \underbrace{P(y = \varphi(x))}_{\text{Accuracy}} = 1 - E[\mathbb{1}\{y = \varphi(x)\}] =$
 $= 1 - E[E[\mathbb{1}\{y = \varphi(x)\} | x]] = 1 - E[P(y = \varphi(x) | x)]$

veamos qué pasa: $P(y = \varphi(x) | x = x) = p_{y|x=x}(\varphi(x)) \leq \max_y p_{y|x=x}(y)$
 con igualdad si: $\varphi(x) = \arg \max_y p_{y|x=x}(y)$

$$\Rightarrow P(y \neq \varphi(x)) = 1 - E[\max_y p_{y|x}(y)]$$

Hay que elegir siempre el clasificador más probable.
 Y sí?????

$\rightarrow$ espacio de las x



$\rightarrow$ partición

Clasificador bayesiano

Interpretación Gráfica

$$1 - \mathbb{E} \left[\max_y P_{Y|X}(y|X) \right] = \sum_{y \in \mathcal{Y}} P_Y(y) \mathbb{P}(X \notin \mathcal{R}_y | Y = y)$$

donde $\mathcal{R}_y$ es el conjunto de $x \in \mathcal{X}$ donde y es el máximo de $P_{Y|X=x}(y)$:

→ ¿qué mierda es esto?

$$\mathcal{R}_y = \left\{ x \in \mathcal{X} : P_{Y|X=x}(y) = \max_{y' \in \mathcal{Y}} P_{Y|X=x}(y') \right\}$$

Para los $x \in \mathcal{X}$ donde haya dos o más máximos de $P_{Y|X=x}(y)$, se asigna dicho x a solo una de dichas $\mathcal{R}_y$ elegida arbitrariamente.

$$1 - E[\max_y p_{y|x}(y)] = \text{DELIRIO}$$

En resumen demostró que el error bayesiano es $\sum_{y \in \mathcal{Y}} p_y(y) \cdot \mathbb{P}(x \notin \mathcal{R}_y / y = y)$


Clasificador bayesiano

Interpretación Gráfica

$$1 - \mathbb{E} \left[\max_y P_{Y|X}(y|X) \right] = \sum_{y \in \mathcal{Y}} P_Y(y) \mathbb{P}(X \notin \mathcal{R}_y | Y = y)$$

donde $\mathcal{R}_y$ es el conjunto de $x \in \mathcal{X}$ donde y es el máximo de $P_{Y|X=x}(y)$:

$$\mathcal{R}_y = \left\{ x \in \mathcal{X} : P_{Y|X=x}(y) = \max_{y' \in \mathcal{Y}} P_{Y|X=x}(y') \right\}$$



Para los $x \in \mathcal{X}$ donde haya dos o más máximos de $P_{Y|X=x}(y)$, se asigna dicho x a solo una de dichas $\mathcal{R}_y$ elegida arbitrariamente.

2 señales arriban a un receptor con distribución $\exp(3)$ ó $U(1, 3)$ con probabilidades 0,9 y 0,1 respectivamente. Queremos clasificar las señales recibidas en exponenciales o uniformes

a) Clasificador bayesiano

b) calcular el error bayesiano y compararlo con un dummy

a)
$$\varphi(x) = \arg \max_y P_{Y|X=x}(y) = \arg \max_y \frac{f_{X|Y=y}(x) P_Y(y)}{f_X(x)} = \arg \max_y f_{X|Y=y}(x) \cdot P_Y(y)$$


Se puede ir xq no influye en y

$y = 1 \rightarrow \exp \quad P_Y(1) = 0,9 \rightarrow f_{X|Y=1}(x) = 3e^{-3x} \mathbb{1}_{\{x > 0\}}$

$y = 2 \rightarrow \text{Uni} \quad P_Y(2) = 0,1 \rightarrow f_{X|Y=2}(x) = \frac{1}{2} \mathbb{1}_{\{1 \leq x < 3\}}$

Gráfiquemos $f_{X|Y=y}(x) \cdot P_Y(y)$

En cada región me fijo qué distribución encierra más área. Ver notas amarillas en el gráfico



$$\Rightarrow \varphi(x) = \arg \max_y P_Y(y) \cdot f_{X|Y=y}(x) = \begin{cases} 1 & 0 < x < 1,33 \\ 2 & 1,33 < x < 3 \\ 1 & 3 < x \end{cases}$$

Clasificador bayesiano

$$\text{Ett bay} = 0,33 \cdot 0,05 + \int_{1,33}^3 0,3 \cdot 3 e^{-3x} dx = 1260 = 0,01 (\text{pamele})$$

Clasificador bayesiano

Objetivo

Quiero buscar $\varphi(\cdot)$ que minimice $\mathbb{P}(Y \neq \varphi(X))$. Es decir aprender el “clasificador bayesiano”: $\varphi(x) = \arg \max_y P_{Y|X}(y|x)$.

Clasificador bayesiano

Objetivo

Quiero buscar $\varphi(\cdot)$ que minimice $\mathbb{P}(Y \neq \varphi(X))$. Es decir aprender el “clasificador bayesiano”: $\varphi(x) = \arg \max_y P_{Y|X}(y|x)$.

Problemas numéricos

La propuesta de buscar $\varphi(\cdot)$ que minimice el riesgo empírico: $\frac{1}{n} \sum_{i=1}^n \mathbb{1}\{Y_i \neq \varphi(X_i)\}$ suele tener problemas numéricos (no derivable).

Clasificador bayesiano

Objetivo

Quiero buscar $\varphi(\cdot)$ que minimice $\mathbb{P}(Y \neq \varphi(X))$. Es decir aprender el “clasificador bayesiano”: $\varphi(x) = \arg \max_y P_{Y|X}(y|x)$.

Problemas numéricos

La propuesta de buscar $\varphi(\cdot)$ que minimice el riesgo empírico: $\frac{1}{n} \sum_{i=1}^n \mathbb{1}\{Y_i \neq \varphi(X_i)\}$ suele tener problemas numéricos (no derivable).

Posible solución

El clasificador bayesiano se aprenderá en dos etapas:

- Aprender toda $P_{Y|X}(y|x)$.
- Quedarse con el máximo.

Divergencia de Kullback Leibler

Definición: Divergencia de Kullback Leibler

Sean $P(\cdot)$ y $Q(\cdot)$ dos funciones de masa de probabilidad tales que si $Q(y) = 0$ entonces $P(y) = 0$. Se define la divergencia KL como:

$$KL(P\|Q) = \sum_{y \in \mathcal{Y}} P(y) \log \left(\frac{P(y)}{Q(y)} \right) = \mathbb{E}_P \left[\log \left(\frac{P(Y)}{Q(Y)} \right) \right]$$

donde el subíndice P en la esperanza hace referencia a que medida se utiliza para calcularla.

Se llama divergencia y no distancia porque no es simétrica

$$KL(P\|Q) \neq KL(Q\|P)$$

Pero da una idea de "Distancia".

Divergencia es un sinónimo ponele, porque si le ponés distancia los matemáticos se enojan

Divergencia de Kullback Leibler

Definición: Divergencia de Kullback Leibler

Sean $P(\cdot)$ y $Q(\cdot)$ dos funciones de masa de probabilidad tales que si $Q(y) = 0$ entonces $P(y) = 0$. Se define la divergencia KL como:

$$\text{KL}(P\|Q) = \sum_{y \in \mathcal{Y}} P(y) \log \left(\frac{P(y)}{Q(y)} \right) = \mathbb{E}_P \left[\log \left(\frac{P(Y)}{Q(Y)} \right) \right]$$


donde el subíndice P en la esperanza hace referencia a que medida se utiliza para calcularla.

Teorema

$$\text{KL}(P\|Q) \geq 0$$

con igualdad si y solo si $P(y) = Q(y)$ para todo $y \in \mathcal{Y}$.

(Hint: $\log(x) \leq x - 1$).



consideremos $g(x) = x - 1 - \ln(x)$ ¿Para qué x $g(x) \geq 0$?

$$g'(x) = 1 - \frac{1}{x} \begin{array}{l} \longrightarrow \text{entre } 0 < x < 1 \quad g'(x) < 0 \\ \searrow \text{para } 1 < x \quad g'(x) > 0 \end{array}$$

$$\Rightarrow g(x) \geq g(1) = 0 \quad \forall x$$

$$\therefore \ln(x) \leq x - 1 \quad \forall x \quad (\text{Q.E.D.}) \quad \rightarrow \text{AH BUENENO}$$

$$KL(P \parallel Q) = E_P \left[\log \left(\frac{P(y)}{Q(y)} \right) \right] = -E_P \left[\log \left(\frac{Q(y)}{P(y)} \right) \right] \geq -E_P \left[\frac{Q(y)}{P(y)} - 1 \right] = 1 - E_P \left[\frac{Q(y)}{P(y)} \right] = 0$$

$\downarrow$
 $-\log(x) \geq -(x-1)$

$\downarrow$
 $\circledast$

$$\circledast \rightarrow E_P \left[\frac{Q(y)}{P(y)} \right] = \sum_y P(y) \frac{Q(y)}{P(y)} = 1$$

Esta divergencia es nuestra nueva distancia entre distribuciones y la vamos a querer minimizar.
Es continua y en algún lado se minimiza, lo que resuelve el problema que implican las indicadoras

Divergencia de Kullback Leibler

Busco $\hat{P}(y|x)$ que minimice

$$\underbrace{\mathbb{E} \left[KL \left(P_{Y|X}(\cdot|X) \parallel \hat{P}(\cdot|X) \right) \right]}_{\text{Kullback Leibler}} = \underbrace{\mathbb{E} \left[-\log \hat{P}(Y|X) \right]}_{\text{Entropía Cruzada}} - \underbrace{\mathbb{E} \left[-\log P_{Y|X}(Y|X) \right]}_{\text{Entropía condicional}}$$

$$D/ \quad E \left[E \left[\log \left(\frac{P_{Y|X}(Y|X)}{\hat{P}(Y|X)} \right) \mid X \right] \right] = E \left[\log \left(\frac{P_{Y|X}(Y|X)}{\hat{P}(Y|X)} \right) \right] = E \left[-\log(\hat{P}(Y|X)) \right] - E \left[-\log(P_{Y|X}(Y|X)) \right]$$

↓
Esta esperanza es respecto de la distribución conjunta

Divergencia de Kullback Leibler

Busco $\hat{P}(y|x)$ que minimice

$$\underbrace{\mathbb{E} \left[KL \left(P_{Y|X}(\cdot|X) \parallel \hat{P}(\cdot|X) \right) \right]}_{\text{Kullback Leibler}} = \underbrace{\mathbb{E} \left[-\log \hat{P}(Y|X) \right]}_{\text{Entropía Cruzada}} - \underbrace{\mathbb{E} \left[-\log P_{Y|X}(Y|X) \right]}_{\text{Entropía condicional}}$$

Optimalidad para $\ell(x, y) = -\log \hat{P}(y|x)$

$$\mathbb{E} \left[-\log \hat{P}(Y|X) \right] \geq \mathbb{E} \left[-\log P_{Y|X}(Y|X) \right]$$

son igualdad si y solo si $\hat{P}(y|x) = P_{Y|X}(y|x)$ para todo (x, y) .

Tenemos una nueva medida y una nueva cota mínima para el error

Divergencia de Kullback Leibler

Busco $\hat{P}(y|x)$ que minimice

$$\underbrace{\mathbb{E} \left[KL \left(P_{Y|X}(\cdot|X) \parallel \hat{P}(\cdot|X) \right) \right]}_{\text{Kullback Leibler}} = \underbrace{\mathbb{E} \left[-\log \hat{P}(Y|X) \right]}_{\text{Entropía Cruzada}} - \underbrace{\mathbb{E} \left[-\log P_{Y|X}(Y|X) \right]}_{\text{Entropía condicional}}$$

Optimalidad para $\ell(x, y) = -\log \hat{P}(y|x)$

$$\mathbb{E} \left[-\log \hat{P}(Y|X) \right] \geq \mathbb{E} \left[-\log P_{Y|X}(Y|X) \right]$$

son igualdad si y solo si $\hat{P}(y|x) = P_{Y|X}(y|x)$ para todo (x, y) .

Entropías

- Entropía: $H(Y) = \mathbb{E}[-\log P_Y(Y)]$.
- Entropía Condicional: $H(Y|X) = \mathbb{E}[-\log P_{Y|X=X}(Y)]$.
- Entropía Cruzada: $\mathbb{E} \left[-\log \hat{P}(Y|X) \right]$.

Si hay mucha entropía hay mucha información.
El log es para convertir productos en sumas

Hard/Soft Decision

Mismatch de métricas

El mínimo de la cross entropy no tiene por que coincidir exactamente con el mínimo de la probabilidad de error. En general se mira la cross entropy para reducir el bias y la probabilidad de error para prevenir el overfitting.

Hard/Soft Decision

Mismatch de métricas

El mínimo de la cross entropy no tiene por que coincidir exactamente con el mínimo de la probabilidad de error. En general se mira la cross entropy para reducir el bias y la probabilidad de error para prevenir el overfitting.

Decisión Suave

Sea $x \in \mathbb{R}^d$, llamamos predicción *soft* de un algoritmo a la predicción de las probabilidades estimadas $\hat{P}(\cdot|x)$. Esta estimación es un vector de probabilidades de todas las clases posibles (no negativas y suman 1). Su desempeño se suele medir con la entropía cruzada $\mathbb{E}[-\log \hat{P}(Y|X)]$.

Decisión Dura

Sea $x \in \mathbb{R}^d$, llamamos predicción *hard* de un algoritmo a la predicción final de la clase estimada $\varphi(x)$ (estimación del valor de Y). Se la define como $\varphi(x) = \arg \max_{y \in \mathcal{Y}} \hat{P}(y|x)$ y su desempeño se suele medir con la probabilidad de acierto $\mathbb{P}(Y = \varphi(X))$.

Outline

1 Introducción al problema de clasificación

2 Regresión Logística

- Regresión Logística Binaria
- Regresión Logística Categórica
- Regresión Logística Polinómica

Que quilombo esto lcdmm

{ Nueva versión de regresión lineal

Queremos predecir y , siendo q'
 $y \in \{0, 1\}$

3 Linear Discriminant Analysis

4 K-Vecinos más cercanos

Acá no tendría sentido hacer una regresión lineal. ¿Qué sentido tendría predecir que Y vale -1,3?

5 Support Vector Machines


6 Árboles de decisión

Regresión Logística Binaria

Función Sigmoide

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

- $\sigma(z)$ representa probabilidades.
- z recibe el nombre de *logit*.




Regresión Logística Binaria

Función Sigmoide

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

- $\sigma(z)$ representa probabilidades. $\text{Obs: } 0 < \sigma(z) < 1$
- z recibe el nombre de *logit*. *como una probabilidad*

$\sigma(z)$ Se usa para representar probabilidades



Propuesta

$$\begin{aligned}\hat{P}(1|x) &= \sigma(w^T x + b) \\ \hat{P}(0|x) &= 1 - \sigma(w^T x + b)\end{aligned}$$

Regresión Logística Binaria

Riesgo empírico

$$\ell(x, y) = -\log(\hat{P}(y|x))$$

$$\frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i) =$$

$$-\frac{1}{n} \sum_{i=1}^n Y_i \log(\sigma(w^T X_i + b)) + (1 - Y_i) \log(1 - \sigma(w^T X_i + b))$$

$$\hat{P}(y|x) = \begin{cases} \sigma(w^T x + b) & \text{si } y = 1 \\ 1 - \sigma(w^T x + b) & \text{si } y = 0 \end{cases} = \sigma(w^T x + b)^y [1 - \sigma(w^T x + b)]^{1-y}$$

↓
así es más fácil aplicar el logaritmo

Regresión Logística Binaria

Riesgo empírico


$$\frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i) = -\frac{1}{n} \sum_{i=1}^n Y_i \log(\sigma(w^T X_i + b)) + (1 - Y_i) \log(1 - \sigma(w^T X_i + b))$$

Elección del máximo

mayor o menor que

$$\hat{P}(1|x) \leq \hat{P}(0|x) \Leftrightarrow \hat{P}(1|x) \leq \frac{1}{2} \Leftrightarrow w^T x + b \leq 0$$

Accuracy empírico:

$$\frac{1}{n} \sum_{i=1}^n \mathbb{1}\{y_i = \varphi(x_i)\}$$


Esto es una recta
o plano o hiperplano
o hiperhiperplano o
archimaga plano
pequeños errores

Métricas para clases desbalanceadas

Precision-Recall

Cuando el costo de las clases está desbalanceado se utilizan las métricas *Precision* y *Recall*.

- $\text{Precision} = \mathbb{P}(Y = \varphi(X) | \varphi(X) = 1)$. *Precision* se utiliza cuando los falsos positivos tiene consecuencias graves. Por ejemplo, diagnosticar erróneamente una enfermedad a una persona sana
- $\text{Recall (TPR)} = \mathbb{P}(Y = \varphi(X) | Y = 1)$. *Recall* se utiliza cuando cuando los falsos negativos tiene consecuencias graves. Por ejemplo, en la detección de fraudes, no detectar una transacción fraudulenta.

Métricas para clases desbalanceadas

Precision-Recall

Cuando el costo de las clases está desbalanceado se utilizan las métricas *Precision* y *Recall*.

- $\text{Precision} = \mathbb{P}(Y = \varphi(X) | \varphi(X) = 1)$. *Precision* se utiliza cuando los falsos positivos tiene consecuencias graves. Por ejemplo, diagnosticar erróneamente una enfermedad a una persona sana
- $\text{Recall (TPR)} = \mathbb{P}(Y = \varphi(X) | Y = 1)$. *Recall* se utiliza cuando cuando los falsos negativos tiene consecuencias graves. Por ejemplo, en la detección de fraudes, no detectar una transacción fraudulenta.

F1-score

*una clase es mucho más frecuente que la otra
como en el ejemplo de antes*

Cuando la proporción de las clases está desbalanceada se utiliza la métrica F1:

$$F_1 = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

*→ como el promedio de
2 resistencias*

Curvas ROC → Region operative Curve o algo así

Agregar un umbral


Puedo darle más peso a una clase:

$$w^T x + b \leq t$$

antes iba un 0
Cero acá

$$\text{TPR} = \mathbb{P}(Y = \varphi(X) | Y = 1)$$

$$\text{FPR} = \mathbb{P}(Y \neq \varphi(X) | Y = 0)$$



Area Under the Curve (AUC) → criterion para comparar

El AUC es el área bajo la curva ROC. umbrales distintos

Equal Error Rate (EER)

El EER es el error para el cuál los errores $\text{FPR} = 1 - \text{TPR}$.

$$\varphi(x) = \mathbb{1}_{\{w^T x + b > 0\}} \rightarrow \text{si } w^T x + b > 0 \text{ digamos } 1, \text{ si no } 0$$

$$\varphi_t(x) = \mathbb{1}_{\{w^T x + b > t\}} \rightarrow \text{umbral}$$

$$\text{Si } t=0 \Rightarrow \varphi(x) = \varphi_t(x)$$


$$\text{Si } t \rightarrow +\infty \Rightarrow \varphi_t(x) = 1, \text{ digamos siempre } 1$$

$$\text{Si } t \rightarrow -\infty \Rightarrow \varphi_t(x) = 0, \text{ digamos siempre } 0$$

Este t me permite perillar.

Puedo alterar la performance del algoritmo sin tener que entrenar de nuevo

Curvas ROC



Outline

1 Introducción al problema de clasificación

El TP es solo de regresión logística binaria.

2 Regresión Logística

- Regresión Logística Binaria
- Regresión Logística Categórica
- Regresión Logística Polinómica

3 Linear Discriminant Analysis

4 K-Vecinos más cercanos

5 Support Vector Machines

6 Árboles de decisión

Sobre el TP:

El 0 es par

En regresión lineal podíamos usar la pseudo-inversa o el gradiente descendiente

Acá solo hay gradiente descendiente. No hay una fórmula cerrada para w y b

Regresión Logística Categórica (k clases)

Regresión logística clásica

¿y si tengo más de 2 clases?
Tienes q' trabajar con esta mieda

$$\hat{P}(y|x) = \begin{cases} \frac{e^{w_y^T x + b_y}}{1 + \sum_{j=1}^{k-1} e^{w_j^T x + b_j}} & y \in \{1, \dots, k-1\} \\ \frac{1}{1 + \sum_{j=1}^{k-1} e^{w_j^T x + b_j}} & y = k \end{cases}$$

separamos en 2 clases y podemos hacer lo q' ya sabemos

Esta implementación es copada para hacer teoría y fue la que primera se usó.

Pero parece que es bastante chota de programar.

Está acá por razones históricas

La que vamos a usar es la softmax, que es la que viene dsp:

Regresión Logística Categórica (k clases)

Regresión logística clásica

$$\hat{P}(y|x) = \begin{cases} \frac{e^{w_y^T x + b_y}}{1 + \sum_{j=1}^{k-1} e^{w_j^T x + b_j}} & y \in \{1, \dots, k-1\} \\ \frac{1}{1 + \sum_{j=1}^{k-1} e^{w_j^T x + b_j}} & y = k \end{cases}$$

Softmax

acá hay un w y un b por clase

$$\hat{P}(y|x) = \frac{e^{w_y^T x + b_y}}{\sum_{j=1}^k e^{w_j^T x + b_j}}, \quad y \in \{1, \dots, k\}$$

Regresión Logística Categórica (k clases)

Regresión logística clásica

$$\hat{P}(y|x) = \begin{cases} \frac{e^{w_y^T x + b_y}}{1 + \sum_{j=1}^{k-1} e^{w_j^T x + b_j}} & y \in \{1, \dots, k-1\} \\ \frac{1}{1 + \sum_{j=1}^{k-1} e^{w_j^T x + b_j}} & y = k \end{cases}$$

Softmax

$$\hat{P}(y|x) = \frac{e^{w_y^T x + b_y}}{\sum_{j=1}^k e^{w_j^T x + b_j}}, \quad y \in \{1, \dots, k\}$$

Riesgo empírico


$$\frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i) = \frac{1}{n} \sum_{i=1}^n \left[\log \left(\sum_{j=1}^k e^{w_j^T X_i + b_j} \right) - (w_{Y_i}^T X_i + b_{Y_i}) \right]$$

Regresión Softmax

Elección del máximo


$$\arg \max_y \hat{P}(y|x) = \arg \max_y w_y^T x + b_y$$

Se separa con hiperplanos!



Confusion Matrix

me confunde esta matrix
faja jentendes?



Generalización del F1 score

		Predicted		
		 Airplane	 Boat	 Car
Actual	 Airplane	2	1	0
	 Boat	0	1	0
	 Car	1	2	3

Generalización del F1 score

		Predicted		
		 Airplane	 Boat	 Car
Actual	 Airplane	2	1	0
	 Boat	0	1	0
	 Car	1	2	3

Label	True Positive (TP)	False Positive (FP)	False Negative (FN)	Precision	Recall	F1 Score
 Airplane	2	1	1	0.67	0.67	$2 * (0.67 * 0.67) / (0.67 + 0.67)$ = 0.67
 Boat	1	3	0	0.25	1.00	$2 * (0.25 * 1.00) / (0.25 + 1.00)$ = 0.40
 Car	3	0	3	1.00	0.50	$2 * (1.00 * 0.50) / (1.00 + 0.50)$ = 0.67

Generalización del F1 score

		Predicted		
		 Airplane	 Boat	 Car
Actual	 Airplane	2	1	0
	 Boat	0	1	0
	 Car	1	2	3


Label	True Positive (TP)	False Positive (FP)	False Negative (FN)	Precision	Recall	F1 Score
 Airplane	2	1	1	0.67	0.67	$2 * (0.67 * 0.67) / (0.67 + 0.67)$ = 0.67
 Boat	1	3	0	0.25	1.00	$2 * (0.25 * 1.00) / (0.25 + 1.00)$ = 0.40
 Car	3	0	3	1.00	0.50	$2 * (1.00 * 0.50) / (1.00 + 0.50)$ = 0.67

$$\text{Macro-}F_1 = \frac{0.67 + 0.40 + 0.67}{3} = 0.58$$

Outline

- 1 Introducción al problema de clasificación
- 2 Regresión Logística
 - Regresión Logística Binaria
 - Regresión Logística Categórica
 - Regresión Logística Polinómica
- 3 Linear Discriminant Analysis
- 4 K-Vecinos más cercanos
- 5 Support Vector Machines
- 6 Árboles de decisión

Overfitting/Underfitting




Regresión Logística Polinómica

El mapa polinómico se puede utilizar, combinándolo con su correspondiente regularización:

- $J(w, b) = \frac{1}{n_{tr}} \sum_{i=1}^n -\log \hat{P}(y_i|x_i) + \frac{\lambda}{n_{tr}} \|w\|^2$ (binario)
- $J(\theta) = \frac{1}{n_{tr}} \sum_{i=1}^n -\log \hat{P}(y_i|x_i) + \frac{\lambda}{n_{tr}} \sum_{j=1}^K \|w_j\|^2$ (categórico)

La etapa de validación se hace utilizando el *accuracy* como métrica.

Overfitting/Underfitting



Regresión Logística Polinómica

El mapa polinómico se puede utilizar, combinándolo con su correspondiente regularización:

- $J(w, b) = \frac{1}{n_{tr}} \sum_{i=1}^n -\log \hat{P}(y_i|x_i) + \frac{\lambda}{n_{tr}} \|w\|^2$ (binario)
- $J(\theta) = \frac{1}{n_{tr}} \sum_{i=1}^n -\log \hat{P}(y_i|x_i) + \frac{\lambda}{n_{tr}} \sum_{j=1}^K \|w_j\|^2$ (categórico)

La etapa de validación se hace utilizando el *accuracy* como métrica.

Calibración

La etapa de validación consiste en ajustar $\varphi(x)$ sin tener en cuenta las predicciones *soft*. Seguir considerando $\hat{P}(y|x)$ una estimación de la probabilidad puede ser problemático luego de una etapa exhaustiva de validación. Se denomina calibración a una etapa de re-ajuste de $\hat{P}(y|x)$.

ES: calcular el gradiente de esto

trivial alívia Rey Vega

Riesgo empírico

$$\frac{1}{n} \sum_{i=1}^n \ell(X_i, Y_i) = \frac{1}{n} \sum_{i=1}^n \left[\log \left(\sum_{j=1}^k e^{w_j^T X_i + b_j} \right) - (w_{Y_i}^T X_i + b_{Y_i}) \right] = \mathcal{J}(\theta)$$

$$\ell(x, y) = -\log(\hat{p}(y|x))$$

$$\frac{\partial \ell(x, y)}{\partial w_{ij}} = \frac{1}{\sum_{m=1}^K e^{w_m \cdot x + b_m}} \cdot e^{w_{ij} \cdot x + b_{ij}} \cdot x - x \mathbb{1}\{y = j\} = x [\hat{p}(y|x) - \mathbb{1}\{y = j\}]$$

derivada del log

regla de la cadena

factor común x

$\hat{p}(y|x)$

Nosotros tenemos q' hacer lo mismo, pero para la binaria

1 Introducción al problema de clasificación

2 Regresión Logística

- Regresión Logística Binaria
- Regresión Logística Categórica
- Regresión Logística Polinómica

3 Linear Discriminant Analysis

4 K-Vecinos más cercanos

5 Support Vector Machines (SVM)

6 Árboles de decisión

Modelos Discriminativos y Generativos

Clasificación de Algoritmos

- **Modelos Discriminativos:** Modelan la dist. condicional $\hat{P}(y|x)$.
- **Modelos Generativos:** Modelan la dist. conjunta $\hat{P}(x, y)$.

Los modelos generativos permiten generar datos sintéticos!

Se usan por ejemplo para generar nuevos datos. No es lo mismo que tener datos reales, pero algo hace

Modelos Discriminativos y Generativos

Clasificación de Algoritmos

- **Modelos Discriminativos:** Modelan la dist. condicional $\hat{P}(y|x)$.
- **Modelos Generativos:** Modelan la dist. conjunta $\hat{P}(x, y)$.

Los modelos generativos permiten generar datos sintéticos!

Linear Discriminant Analysis (LDA)

$$Y \sim \text{Cat}(\{c_1, \dots, c_K\}), \quad X|Y = k \sim \mathcal{N}(\mu_k, \Sigma)$$

probabilidades


misma covarianza

$$c_k = \mathbb{P}(Y=k)$$

GMM

Gaussian mixture models

$\forall k$



$$\begin{aligned} \hat{P}(x|y=k) &= e^{-\frac{1}{2}(x-\mu_k)^T \Sigma^{-1}(x-\mu_k)} \\ &= \frac{1}{(2\pi)^{n/2} \sqrt{|\Sigma|}} \end{aligned}$$

Linear Discriminant Analysis

Expresiones Matemáticas

$$\hat{p}(x) = \sum_{k=1}^K c_k \frac{e^{-\frac{1}{2}(x-\mu_k)^T \Sigma^{-1}(x-\mu_k)}}{(2\pi)^{d_x/2} |\Sigma|^{1/2}}$$
$$\hat{P}(y|x) = \frac{e^{\mu_y^T \Sigma^{-1} x - \frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \log(c_y)}}{\sum_{k=1}^K e^{\mu_k^T \Sigma^{-1} x - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log(c_k)}}$$

¿Cómo llevo de acá a allá?
Demostración en la siguiente página

Relación con Regresión Logística

Si $w_y = \Sigma^{-1} \mu_y$ y $b_y = -\frac{1}{2} \mu_y^T \Sigma^{-1} \mu_y + \log(c_y)$, $\hat{P}(y|x)$ es el softmax.

LDA utiliza hipótesis más fuertes ya que no solo asume $\hat{P}(y|x)$ softmax, sino también $\hat{p}(x)$ mezcla de gaussianas.

$$\hat{p}(k) \cdot \hat{p}(x|k) = \hat{p}(x) \cdot \hat{p}(k|x) = c_k \cdot \frac{1}{(2\pi)^{d_x/2} \sqrt{|\Sigma|}} e^{-\frac{1}{2}(x-u_k)^T \Sigma^{-1} (x-u_k)}$$

Dist. conjunta

Nota: $\hat{p}(x|k) = \hat{p}(x|y=k)$

$$\hat{p}(x) = \sum_{k=1}^K \hat{p}(k) \cdot \hat{p}(x|k)$$

$$= e^{\log(c_y)}$$

$$e^{-\frac{1}{2} (x-u_y)^T \Sigma^{-1} (x-u_y)}$$

$$\hat{p}(y|x) = \frac{\hat{p}(y) \cdot \hat{p}(x|y)}{\sum_k \hat{p}(k) \hat{p}(x|k)} = \frac{\frac{c_y}{(2\pi)^{d_x/2} \sqrt{|\Sigma|}} \cdot e^{-\frac{1}{2} (x-u_y)^T \Sigma^{-1} (x-u_y)}}{\sum_{k=1}^K \frac{c_k}{(2\pi)^{d_x/2} \sqrt{|\Sigma|}} e^{-\frac{1}{2} (x-u_k)^T \Sigma^{-1} (x-u_k)}} =$$

Por def

$$\textcircled{*} \rightarrow x^T \Sigma^{-1} x - 2 u_y^T \Sigma^{-1} x + u_y^T \Sigma^{-1} u_y$$

¿SOFTMAX?

Reparar regresión logística

$$= \frac{e^{\log(c_y) + u_y^T \Sigma^{-1} x - \frac{1}{2} u_y^T \Sigma^{-1} u_y} \cdot e^{-\frac{1}{2} x^T \Sigma^{-1} x}}{\sum_{k=1}^K e^{\log(c_k) + u_k^T \Sigma^{-1} x - \frac{1}{2} u_k^T \Sigma^{-1} u_k} \cdot e^{-\frac{1}{2} x^T \Sigma^{-1} x}}$$

$\hat{p}(y|x) = \text{softmax}(w_y^T \cdot x + b_y) \rightarrow$ Lo q' antes era la sigmoide

$$\psi(x) = \arg \max_y \{ w_y^T \cdot x + b_y \}$$

Función discriminante


$$\delta_y(x) = \log(c_y) + u_y^T \Sigma^{-1} x - \frac{1}{2} u_y^T \Sigma^{-1} \cdot u_y \rightarrow$$

Regresión Softmax

Elección del máximo

$$\arg \max_y \hat{P}(y|x) = \arg \max_y w_y^T x + b_y$$

Se separa con hiperplanos!



Estimación Insesgada de Parámetros

Estimadores

$\mathcal{D}_k = \{x_i : 1 \leq i \leq n \wedge y_i = k\}$ → Particionamos el conjunto de datos (el conjunto de x_i) según las etiquetas correspondientes a cada x_i

$$c_k = \frac{\#(\mathcal{D}_k)}{n} \rightarrow \text{cantidad de elementos en } \mathcal{D}_k$$

$$\mu_k = \frac{1}{\#(\mathcal{D}_k)} \sum_{x \in \mathcal{D}_k} x$$

Una matriz por conjunto $\mathcal{D}_k$

$$\Sigma_k = \frac{1}{\#(\mathcal{D}_k) - 1} \sum_{x \in \mathcal{D}_k} (x - \mu_k)(x - \mu_k)^T$$

← Para evitar el sesgo

$$\Sigma = \frac{1}{n - K} \sum_{k=1}^K (\#(\mathcal{D}_k) - 1) \Sigma_k$$

→ promedio ponderado de todas las Σ_k

Quadratic Discriminant Analysis

Una matriz de covarianza

Quadratic Discriminant Analysis (QDA)

por clase

$$Y \sim \text{Cat}(\{c_1, \dots, c_K\}), \quad X|Y = k \sim \mathcal{N}(\mu_k, \Sigma_k)$$

Quadratic Discriminant Analysis

Quadratic Discriminant Analysis (QDA)

$$Y \sim \text{Cat}(\{c_1, \dots, c_K\}), \quad X|Y = k \sim \mathcal{N}(\mu_k, \Sigma_k)$$

Expresiones Matemáticas

$$\hat{p}(x) = \sum_{k=1}^K c_k \frac{e^{-\frac{1}{2}(x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k)}}{(2\pi)^{d_x/2} |\Sigma_k|^{1/2}}$$

¿cómo llego de acá a allá?

$$\hat{P}(y|x) = \frac{e^{-\frac{1}{2}(x-\mu_y)^T \Sigma_y^{-1}(x-\mu_y) + \log(c_y) - \frac{\log |\Sigma_y|}{2}}}{\sum_{k=1}^K e^{-\frac{1}{2}(x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k) + \log(c_k) - \frac{\log |\Sigma_k|}{2}}}$$

Es la misma cuenta que antes, solo que hay cosas que no se simplifican en este caso
En LDA la frontera de decisión es lineal (hiperplano)
En QDA es cuadrática (hiper-parabola?)

¿Qué es mejor? ¿QDA o LDA? Depende
Si tienes muchas muestras, QDA. Si no, LDA
QDA agrega complejidad, posible sobreajuste

término Cuadrático

Discriminante

$$\text{QDA)} S_y(x) = \log(c_y) - \frac{1}{2} \log |\Sigma_y| - \frac{1}{2} (x - \mu_y)^T \Sigma_y^{-1} (x - \mu_y)$$

Quadratic Discriminant Analysis

Quadratic Discriminant Analysis (QDA)

$$Y \sim \text{Cat}(\{c_1, \dots, c_K\}), \quad X|Y = k \sim \mathcal{N}(\mu_k, \Sigma_k)$$

Expresiones Matemáticas

$$\hat{p}(x) = \sum_{k=1}^K c_k \frac{e^{-\frac{1}{2}(x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k)}}{(2\pi)^{d_x/2} |\Sigma_k|^{1/2}}$$

$$\hat{P}(y|x) = \frac{e^{-\frac{1}{2}(x-\mu_y)^T \Sigma_y^{-1}(x-\mu_y) + \log(c_y) - \frac{\log |\Sigma_y|}{2}}}{\sum_{k=1}^K e^{-\frac{1}{2}(x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k) + \log(c_k) - \frac{\log |\Sigma_k|}{2}}}$$

Elección del máximo: NO ES LINEAL, ES CUADRÁTICO

$$\arg \max_y -\frac{1}{2}(x - \mu_y)^T \Sigma_y^{-1}(x - \mu_y) + \log(c_y) - \frac{\log |\Sigma_y|}{2}$$

$$\underline{EJ}: Y \sim \text{Ber}(1/2) \quad X|_{Y=0} \sim N\left(\begin{bmatrix} 0 \\ 1 \end{bmatrix}; \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}\right)$$

Un algoritmo aprendió el modelo

$$X|_{Y=1} \sim N\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}; \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}\right) \quad \leftarrow$$

- a) ¿Puede provenir de LDA/QDA? >>> No puede ser LDA xq las matrices de covarianza cambian para distintos valor de y. Puede ser QDA
 b) Hallar la frontera de decisión >>> La frontera de decisión puede ser una parabola/hipérbola/elipse
 c) Hallar el clasificador bayesiano del modelo

C. AUX: $|\Sigma_0| = 1$ $\Sigma_0^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ llamamos $X = (x_1, x_2)$

$$|\Sigma_1| = 2 \quad \Sigma_1^{-1} = \begin{bmatrix} 1/2 & 0 \\ 0 & 1 \end{bmatrix}$$

$$C_0 = C_1 = 1/2 \quad (\text{xq } Y \sim \text{Ber}(1/2))$$

$$\begin{aligned} \delta_0(X) &= -\frac{1}{2} (x_1 - 0, x_2 - 1) \cdot \Sigma_0^{-1} (x_1 - 0, x_2 - 1) + \log(1/2) - \cancel{\log(1)} = \\ &= -\frac{1}{2} [x_1^2 + (x_2 - 1)^2] - \log(2) \end{aligned}$$

$$\delta_1(X) = -\frac{1}{2} (x_1, x_2) \begin{pmatrix} 1/2 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \log(1/2) + \frac{1}{2} \log(1/2) = -\frac{1}{4} x_1^2 - \frac{1}{2} x_2^2 - \log(2) - \frac{1}{2} \log(2)$$


Frontera: $\{x \in \mathbb{R}^2 / \delta_0(x) = \delta_1(x)\}$

$$-\frac{1}{2} [x_1^2 + (x_2 - 1)^2] - \log(2) = -\frac{1}{4} x_1^2 - \frac{1}{2} x_2^2 - \log(2) - \frac{1}{2} \log(2)$$

$$-\frac{1}{2} x_1^2 - \frac{1}{2} x_2^2 + \underbrace{x_2} - \frac{1}{2} = -\frac{1}{4} x_1^2 - \frac{1}{2} x_2^2 - \frac{1}{2} \log(2)$$

despejamos esto

$$x_2 = \frac{1}{2} x_1^2 + \frac{1}{2} - \frac{1}{2} \log(2) \Rightarrow \text{Frontera: } \left\{ x_1, x_2 \in \mathbb{R}^2 / x_2 = \frac{1}{4} x_1^2 + \frac{1 - \log(2)}{2} \right\}$$



clasificador bayesiano:

$$Q(x) = \mathbb{1} \left\{ x_2 \leq \frac{1}{4} x_1^2 + \frac{1 - \log(2)}{2} \right\}$$

→ curvas de nivel

Outline

- 1 Introducción al problema de clasificación
- 2 Regresión Logística
 - Regresión Logística Binaria
 - Regresión Logística Categórica
 - Regresión Logística Polinómica
- 3 Linear Discriminant Analysis
- 4 K-Vecinos más cercanos → Tiemblan los kukas
- 5 Support Vector Machines
- 6 Árboles de decisión

Modelos Paramétricos y No Paramétricos

Clasificación de Algoritmos

- **Modelos Paramétricos:** Asumen conocimiento parcial sobre la distribución, indexándola por parámetros.
- **Modelos No Paramétricos:** No se asume una estructura a priori para la distribución.


Modelos Paramétricos y No Paramétricos

Clasificación de Algoritmos

- **Modelos Paramétricos:** Asumen conocimiento parcial sobre la distribución, indexándola por parámetros.
- **Modelos No Paramétricos:** No se asume una estructura a priori para la distribución.

Histograma

El histograma asume una densidad constante por regiones. En cada región asigna $\hat{p}(x) = \frac{K}{n \cdot V}$ donde n es la cantidad de muestras totales, K la cantidad de muestras en dicha región y V el volumen de la región.



Hablamos de Volumen porque volumen puede ser una recta, una región en el plano, un volumen, un hipervolumen, etc

K-Vecinos más cercanos (KNN)

Adaptando el concepto a aprendizaje supervisado

Asumiendo que $\hat{P}(y) = \frac{N_y}{n}$ con N_y el número de muestras de la clase y , y que (en cada región) $\hat{p}(x|y) = \frac{K_y}{N_y \cdot V}$ con K_y la cantidad de muestras que caen en la región de la clase y , se obtiene:

$$\hat{P}(y|x) = \frac{\hat{p}(x|y)\hat{P}(y)}{\sum_{i \in \mathcal{Y}} \hat{p}(x|i)\hat{P}(i)} = \frac{K_y}{K}$$

donde K es la cantidad de muestras totales en la región. Es decir, la proporción de muestras de la clase y en la región.

$$\hat{P}(y|x) = \frac{\hat{p}(x|y) \cdot \hat{p}(y)}{\sum_{i \in Y} p(x|i) \hat{p}(i)} = \frac{\frac{k_y}{N_y} \cdot \frac{N_y}{n}}{\sum_{i=1}^K \frac{k_i}{N_i} \cdot \frac{N_i}{n}} = \frac{k_y}{\sum_{i=1}^K k_i}$$

¿Qué queremos significar esto?

K-Vecinos más cercanos (KNN)

Adaptando el concepto a aprendizaje supervisado

Asumiendo que $\hat{P}(y) = \frac{N_y}{n}$ con N_y el número de muestras de la clase y , y que (en cada región) $\hat{p}(x|y) = \frac{K_y}{N_y \cdot V}$ con K_y la cantidad de muestras que caen en la región de la clase y , se obtiene:


$$\hat{P}(y|x) = \frac{\hat{p}(x|y)\hat{P}(y)}{\sum_{i \in \mathcal{Y}} \hat{p}(x|i)\hat{P}(i)} = \frac{K_y}{K}$$

donde K es la cantidad de muestras totales en la región. Es decir, la proporción de muestras de la clase y en la región.

K-Vecinos más cercanos

KNN fija el valor de vecinos K y en base a esto define las regiones. Por ejemplo, la región utilizada para computar un *feature* x es la región centrada en x que posee K muestras (las K más cercanas a x).


K-Vecinos más cercanos (KNN)



NO ENTiendo NADA

K-Vecinos más cercanos (KNN)

Buena x' lo
memos es
contra el
tema




Elección del máximo

Notar que para quedarse con el máximo de $\hat{P}(y|x)$ no hace falta computarla. Simplemente se clasifica según sus K vecinos más cercanos, por mayoría.

X	0,2	0,4	1	1,2	1,6	2	2,3	2,5	2,7
Y	0	1	0	1	0	1	1	0	0

¿cómo es el algoritmo
2NN?



$$\frac{1,6 + 2,3}{2} = 1,95$$

$$\frac{2 + 2,5}{2} = 2,25$$

$$\frac{2,7 + 2,3}{2} = 2,5$$

Vengo de izquierda a derecha: en principio mis dos vecinos más cercanos son 1,6 y 2
Uno es naranja y el otro es verde, así que la probabilidad de ser naranja es 1/2
A partir del 1,95, el 1,6 está más lejos que el 2,3, así que mis dos vecinos más cercanos pasan a ser 2 y 2,3
Ambos son verdes, así que la probabilidad de ser naranja es 0

Outline

1 Introducción al problema de clasificación

2 Regresión Logística

- Regresión Logística Binaria
- Regresión Logística Categórica
- Regresión Logística Polinómica

3 Linear Discriminant Analysis

4 K-Vecinos más cercanos

5 Support Vector Machines

→ Lo atrancamos hoy, pero
me lo vamos a terminar

6 Árboles de decisión

Support Vector Machines

Clases linealmente separables


Sea la clasificación binaria $y \in \{-1, 1\}$ y $z(x) = w^T \cdot x + b = 0$ su frontera de decisión. Decimos que las clases son linealmente separables, si existen w y b tales que $y \cdot z(x) > 0$ para todo $(x, y) \in \mathcal{D}_n$ (set de entrenamiento). Llamamos $f_i(w, b) = y_i z(x_i) > 0$ con $1 \leq i \leq n$.

Cuando $z(x) > 0 \Rightarrow y = 1$
Cuando $z(x) < 0 \Rightarrow y = -1$
 $\Rightarrow z(x_i) \cdot y_i > 0 \forall (x_i, y_i)$
en el conjunto de
entrenamiento

Support Vector Machines

Clases linealmente separables

Sea la clasificación binaria $y \in \{-1, 1\}$ y $z(x) = w^T \cdot x + b = 0$ su frontera de decisión. Decimos que las clases son linealmente separables, si existen w y b tales que $y \cdot z(x) > 0$ para todo $(x, y) \in \mathcal{D}_n$ (set de entrenamiento). Llamamos $f_i(w, b) = y_i z(x_i) > 0$ con $1 \leq i \leq n$.



- w es ortogonal a la frontera y por lo tanto $w \parallel (x - x_*)$ con x_* la proyección ortogonal de x sobre la frontera.

$$|w^T(x - x_*)| = \|w\| \|x - x_*\|$$

- Dado que x_* está sobre la frontera, $w^T(x - x_*) = z(x)$ y por lo tanto:


$$d(x_i) = \|x_i - x_*\| = \frac{|z(x_i)|}{\|w\|} = \frac{y_i \cdot z(x_i)}{\|w\|}$$

w ortogonal a la frontera: frontera: $\{x \in \mathbb{R}^3 \mid w^T x + b = 0\}$

Si $x \in \text{frontera} \Rightarrow w^T x = w_1 x_1 + w_2 x_2 + w_3 x_3 = -b$

Coordenadas
↑
↓
coeficientes del plano
(vector normal)

Recordar la ecuación
del plano
Frontera



Support Vector Machines

Margen

Se define el margen unilateral como criterio de peor caso:

$$m(w, b) = \min_{1 \leq i \leq n} \frac{y_i(w^T \cdot x_i + b)}{\|w\|} = \frac{1}{\|w\|} \min_{1 \leq i \leq n} f_i(w, b) = \frac{f_k(w, b)}{\|w\|}$$

con k un índice óptimo (función de w y b). Por lo tanto, el problema a resolver es maximizar el margen: $\max_{w, b} m(w, b)$ st. $f_i(w, b) > 0$ para $i = 1, \dots, n$.



Support Vector Machines

Margen

Se define el margen unilateral como criterio de peor caso:

$$m(w, b) = \min_{1 \leq i \leq n} \frac{y_i(w^T \cdot x_i + b)}{\|w\|} = \frac{1}{\|w\|} \min_{1 \leq i \leq n} f_i(w, b) = \frac{f_k(w, b)}{\|w\|}$$

con k un índice óptimo (función de w y b). Por lo tanto, el problema a resolver es maximizar el margen: $\max_{w, b} m(w, b)$ st. $f_i(w, b) > 0$ para $i = 1, \dots, n$.

Escala

Sea $\alpha > 0$, está claro la decisión $z(x) \geq 0$ no se ve afectada si reescalamos los parámetros $w \leftarrow \alpha w$ y $b \leftarrow \alpha b$. Esto mismo ocurre con el margen $m(\alpha w, \alpha b) = m(w, b)$. Con lo cual no se pierde generalidad al asumir $f_k(w, b) = 1$. Luego $m(w, b) = \frac{1}{\|w\|}$ y $f_i(w, b) \geq 1$ para todo $1 \leq i \leq n$.

Las muestras en las que $f_i(w, b) = 1$ se denominan vectores soporte.

Support Vector Machines

Problema de optimización primal

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i(w^T x_i + b) \geq 1 \quad (\forall 1 \leq i \leq n)$$

Support Vector Machines


Problema de optimización primal

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i(w^T x_i + b) \geq 1 \quad (\forall 1 \leq i \leq n)$$

Relajando los márgenes

Mitigar problemas con outliers. Sea $C \geq 0$,

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad \text{s.t.} \quad \begin{cases} y_i(w^T x_i + b) \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases} \quad (\forall 1 \leq i \leq n)$$




Bishop - "Pattern Recognition and Machine Learning" Capítulo 7.

Support Vector Machines

Generalización a fronteras no lineales

Este método es adaptable a diferentes fronteras $z(x) = w^T \phi(x) + b$. Se puede demostrar, que el resultado final del entrenamiento depende de los predictores a través de $k(x_1, x_2) = \phi^T(x_1)\phi(x_2)$, función que recibe el nombre de kernel. Es por este motivo que se elige el kernel en lugar de $\phi(\cdot)$, siendo el más utilizado en SVM el denominado gaussiano o rbf: $k(x_1, x_2) = e^{-\gamma \|x_1 - x_2\|^2}$.



Support Vector Machines

Generalización a K -clases

- *one-vs-one*: Se toman todas las combinaciones de pares de clases (son $\frac{K(K-1)}{2}$) y se entrenan clasificadores binarios. Se clasifica seleccionando a la clase con más *votos*.
- *one-vs-the-rest*: Se entrenan K clasificadores binarios, donde cada uno toma una clase como positiva y el resto como negativa. Se clasifica según $\arg \max_k w_k^T \phi(x) + b_k$.

Support Vector Machines

Generalización a K -clases

- *one-vs-one*: Se toman todas las combinaciones de pares de clases (son $\frac{K(K-1)}{2}$) y se entrenan clasificadores binarios. Se clasifica seleccionando a la clase con más *votos*.
- *one-vs-the-rest*: Se entrenan K clasificadores binarios, donde cada uno toma una clase como positiva y el resto como negativa. Se clasifica según $\arg \max_k w_k^T \phi(x) + b_k$.

Generalización a Regresión

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad |w^T x_i + b - y_i| \leq \epsilon \quad (\forall 1 \leq i \leq n)$$

Optimización Convexa

Tomemos el problema básico de SVM. Sea

$$J_1 = \min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i(w^T \phi(x_i) + b) \geq 1 \quad (\forall 1 \leq i \leq n)$$

Dicho problema puede reescribirse usando multiplicadores de Lagrange α_i :

$$J_1 = \min_{w,b} \max_{\alpha_i \geq 0} \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i [y_i(w^T \phi(x_i) + b) - 1]$$

Vectores Soportes

Notar que, el multiplicador óptimo (la solución del problema) debe cumplir que $\alpha_i = 0$ para toda muestra que no sea vector soporte. En contraste, para los vectores soporte ocurre que $y_i(w^T \phi(x_i) + b) = 1$.

Llamamos problema dual al problema definido a partir de invertir el mínimo y el máximo:

$$J_2 = \max_{\alpha_i \geq 0} \min_{w,b} \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i [y_i(w^T \phi(x_i) + b) - 1]$$

Optimización Convexa

Teorema: Weak and Strong duality

Para cualquier problema de optimización $J_1 \geq J_2$. En el caso particular del problema de SVM, por ser convexo, se obtiene que $J_1 = J_2$.

Fijo los multiplicadores $\alpha_i \geq 0$, igualamos a cero la derivada respecto de los parámetros para buscar el mínimo:

- $w - \sum_{i=1}^n \alpha_i y_i \phi(x_i) = 0 \quad \rightarrow \quad w = \sum_{i=1}^n \alpha_i y_i \phi(x_i)$

- $-\sum_{i=1}^n \alpha_i y_i = 0 \quad \rightarrow \quad \sum_{i=1}^n \alpha_i y_i = 0$

La suma dentro de J_2 queda como:

$$\begin{aligned} \sum_{i=1}^n \alpha_i [y_i (w^T \phi(x_i) + b) - 1] &= \sum_{i=1}^n \alpha_i y_i w^T \phi(x_i) + \sum_{i=1}^n \alpha_i y_i b - \sum_{i=1}^n \alpha_i \\ &= \|w\|^2 + 0 - \sum_{i=1}^n \alpha_i \end{aligned}$$

Optimización Convexa

La función a optimizar se puede reescribir como

$$\frac{1}{2}\|w\|^2 - \sum_{i=1}^n \alpha_i [y_i(w^T \phi(x_i) + b) - 1] = \left(\sum_{i=1}^n \alpha_i \right) - \frac{1}{2}\|w\|^2$$

La norma cuadrática puede vectorizarse como

$$\|w\|^2 = \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \phi(x_i)^T \phi(x_j) = \alpha^T Q \alpha$$

donde Q es una matriz de elementos $Q_{i,j} = y_i y_j \phi(x_i)^T \phi(x_j)$ (depende de los predictores a través del kernel). Entonces, el problema se reduce a:

Problema de optimización dual

$$\max_{\alpha} \alpha^T \mathbf{1} - \frac{1}{2} \alpha^T Q \alpha \quad \text{s.t.} \quad \alpha^T y = 0, \quad \alpha_i \geq 0$$

Por cuestiones numéricas, suele traer complicaciones detectar vectores soportes como $\alpha_i > 0$. En la práctica suele compararse $\alpha_i > \epsilon$ con $\epsilon > 0$ un número pequeño.

Bias

Sea $\mathcal{S}$ el conjunto de índices de vectores soporte y $N_{\mathcal{S}}$ la cantidad de elementos de dicho conjunto; luego $y_i(w^T \phi(x_i) + b) = 1 \forall i \in \mathcal{S}$ y $\alpha_i = 0 \forall i \notin \mathcal{S}$. El bias solo depende de los predictores a través del kernel:

$$b = \frac{1}{N_{\mathcal{S}}} \sum_{i \in \mathcal{S}} (y_i - w^T \phi(x_i)) = \frac{1}{N_{\mathcal{S}}} \sum_{i \in \mathcal{S}} \left(y_i - \sum_{j \in \mathcal{S}} \alpha_j y_j \phi(x_j)^T \phi(x_i) \right)$$

Regla de decisión



Una vez entrenado, la regla de decisión es simplemente evaluar el signo de $z(x)$. Dicha decisión solo depende de los predictores a través del kernel:

$$z(x) = \sum_{j \in \mathcal{S}} \alpha_j y_j \phi(x_j)^T \phi(x) + b$$


Outline

- 1 Introducción al problema de clasificación
- 2 Regresión Logística
 - Regresión Logística Binaria
 - Regresión Logística Categórica
 - Regresión Logística Polinómica
- 3 Linear Discriminant Analysis
- 4 K-Vecinos más cercanos
- 5 Support Vector Machines
- 6 Árboles de decisión

CART: Classification and Regression Trees



Árboles de decisión



Árboles de decisión

Modelado matemático por nodo

Llamamos:

- Q_m al conjunto de datos en el nodo m .
- $Q_m^L(j_m, t_m) = \{(x, y) \in Q_m : x_{j_m} \leq t_m\}$.
- $Q_m^R(j_m, t_m) = \{(x, y) \in Q_m : x_{j_m} > t_m\}$.
- $H(Q_m)$ a la función impureza del conjunto Q_m .
- $G_m(j_m, t_m) = \frac{|Q_m^L(j_m, t_m)|}{|Q_m|} H(Q_m^L(j_m, t_m)) + \frac{|Q_m^R(j_m, t_m)|}{|Q_m|} H(Q_m^R(j_m, t_m))$.
- Busco para cada nodo $(j_m^*, t_m^*) = \arg \min_{j_m, t_m} G_m(j_m, t_m)$

Árboles de decisión

Modelado matemático por nodo

Llamamos:

- Q_m al conjunto de datos en el nodo m .
- $Q_m^L(j_m, t_m) = \{(x, y) \in Q_m : x_{j_m} \leq t_m\}$.
- $Q_m^R(j_m, t_m) = \{(x, y) \in Q_m : x_{j_m} > t_m\}$.
- $H(Q_m)$ a la función impureza del conjunto Q_m .
- $G_m(j_m, t_m) = \frac{|Q_m^L(j_m, t_m)|}{|Q_m|} H(Q_m^L(j_m, t_m)) + \frac{|Q_m^R(j_m, t_m)|}{|Q_m|} H(Q_m^R(j_m, t_m))$.
- Busco para cada nodo $(j_m^*, t_m^*) = \arg \min_{j_m, t_m} G_m(j_m, t_m)$

Funciones impurezas habituales

Sea $p_{m,k}$ la proporción de muestras de la clase k en el nodo m :

- Gini: $H(Q_m) = \sum_k p_{m,k} (1 - p_{m,k})$.
- Entropía: $H(Q_m) = \sum_k -p_{m,k} \log_2(p_{m,k})$.

Árboles de decisión

Condiciones de Parada

- Todas las observaciones tienen la misma etiqueta.
- Si la rama tiene menos de un número preestablecido de observaciones.
- Poda.

Árboles de decisión

Condiciones de Parada

- Todas las observaciones tienen la misma etiqueta.
- Si la rama tiene menos de un número preestablecido de observaciones.
- Poda.

No se Normaliza

Dado que los árboles trabajan comparando de a un feature por vez, no tiene sentido normalizar. Además al no utilizar gradientes para la optimización, no hay problemas de convergencia.

Árboles de decisión

Condiciones de Parada

- Todas las observaciones tienen la misma etiqueta.
- Si la rama tiene menos de un número preestablecido de observaciones.
- Poda.

No se Normaliza

Dado que los árboles trabajan comparando de a un feature por vez, no tiene sentido normalizar. Además al no utilizar gradientes para la optimización, no hay problemas de convergencia.

Importancia de cada Feature

La *Feature Importance* de un feature se define como la suma de las ganancias, en impureza, de cada nodo (Δ_m) donde se haya utilizado dicho feature para el split con $\Delta_m = H(Q_m) - G_m(j_m^*, t_m^*)$. Habitualmente el resultado se expresa normalizado para que sumen 1.

Árboles de decisión

Problemas de regresión

Modelando la función regresión como constante por regiones, este método puede ser adaptado. Como función impureza suele usarse el error cuadrático medio:

$$H(Q_m) = \sum_{(x,y) \in Q_m} (y - \bar{y}_m)^2$$

donde $\bar{y}_m$ es el promedio de las y en Q_m .

Árboles de decisión

Problemas de regresión

Modelando la función regresión como constante por regiones, este método puede ser adaptado. Como función impureza suele usarse el error cuadrático medio:

$$H(Q_m) = \sum_{(x,y) \in Q_m} (y - \bar{y}_m)^2$$

donde $\bar{y}_m$ es el promedio de las y en Q_m .


Podado: Regularización

Sea T un árbol determinado (sin condiciones de parado fuertes), $L(T)$ su respectivo conjunto de hojas y α el parámetro de complejidad. Se denomina medida de costo-complejidad a

$$H_\alpha(T) = \sum_{m \in L(T)} \frac{|Q_m|}{n} \cdot H(Q_m) + \alpha \cdot |L(T)|$$


La poda se basa en quedarse con el subárbol de menor costo-complejidad.

T_1




$$H_{\alpha}(T) = 0 + 5\alpha$$

T_2




$$H_{\alpha}(T) = 0.13 + 4\alpha$$

T_3



$$H_{\alpha}(T) = 0.16 + 3\alpha$$

T_4




$$H_{\alpha}(T) = 0.3 + 2\alpha$$


T_5



$$H_{\alpha}(T) = 0.58 + \alpha$$

Poda





- La cantidad de candidatos a óptimos es menor a la cantidad de subárboles (el T_2 nunca es el de menor costo-complejidad).
- El subárbol se elige por validación (típicamente sobre el error de clasificación) comparando todos los casos posibles (en este caso 4 candidatos).

Bosques aleatorios

Bagging

El problema de los árboles de decisión es el *overfitting*. Las condiciones de stop y la poda ayudan a combatirlo, pero muchas veces no son suficiente. Es por eso que surge *Bagging*: Entrenar múltiples algoritmos y decidir por mayoría o promedio (en clasificación o regresión respectivamente). Un algoritmo de múltiples árboles se llama bosque.

¿Por que promediar?

- El promedio mantiene la esperanza y reduce la varianza en muestras i.i.d:

$$\mathbb{E} \left[\frac{1}{B} \sum_{b=1}^B Z_b \right] = \mu, \quad \text{var} \left(\frac{1}{B} \sum_{b=1}^B Z_b \right) = \frac{\sigma^2}{B}$$

- En clasificación, si se piensan etiquetas en codificación *one-hot*, promediar para luego elegir el máximo equivale a elegir la respuesta mayoritaria.

Bosques aleatorios

Se desea entrenar varios algoritmos (de manera que sean variados). Para asegurar ésto, se toman dos decisiones:

No usar todos los features

En lugar de usar todos los d_x *features*, para asegurar variedad en los árboles, para cada nodo se eligen al azar $\sqrt{d_x}$ *features*.

Bosques aleatorios

Se desea entrenar varios algoritmos (de manera que sean variados). Para asegurar ésto, se toman dos decisiones:

No usar todos los features

En lugar de usar todos los d_x features, para asegurar variedad en los árboles, para cada nodo se eligen al azar $\sqrt{d_x}$ features.

Bootstrap

Generar B conjuntos de datos diferentes del mismo tamaño que el dataset original n . Para esto, se utiliza una técnica llamada Bootstrap: Se eligen al azar n datos del conjunto *con reposición* y se arma cada conjunto Bootstrap, de manera que la probabilidad que un dato no esté en el conjunto es del $\approx 37\%$:

$$\left(1 - \frac{1}{n}\right)^n \rightarrow e^{-1}$$