

Modelos Bayesianos

Taller de Procesamiento de Señales

Agenda

- 1 Inferencia Bayesiana
- 2 Naive Bayes
- 3 Multinomial Naive Bayes
- 4 Variational Bayes
- 5 Monte Carlo Markov Chain


Redes Bayesianas

Modelos Gráficos

Modelos probabilísticos capaz de representarse con un grafo.

Red Bayesiana

Grafo acíclico dirigido que representa la relación de causalidad e independencia de sus variables. Dos variables aleatorias cualesquiera son condicionalmente independientes dados los valores de sus padres causales (y por lo tanto las raíces son independientes).



$$p(A, B, C, D) = p(A) \cdot p(B|A) \cdot p(C|A) \cdot p(D|A, C)$$

Inferencia Bayesiana

- Los parámetros θ deben ser considerado realizaciones de una variable aleatoria T con una distribución a priori conocida $p(\theta)$.
- Las muestras son i.i.d. **cuando** se conoce el parámetro.
- La distribución a posteriori de los parámetros se calcula como:

$$p(\theta | D_n) = \frac{p(\theta) \cdot P(D_n | \theta)}{P(D_n)} \quad p(\theta | D_n) \propto p(\theta) \prod_{i=1}^n p(x_i | \theta)$$

$\rightarrow$ indep. de θ

con $D_n = \{x_1, \dots, x_n\} \rightarrow$ datos

- Como estimador puntual suele elegirse el *maximo a posteriori* (θ discreto) y el estimador bayesiano o *media a posteriori* (θ continuo).
- No son necesarios los estimadores puntuales para predecir:

$$p(x_{\text{test}} | D_n) = \int_{\Theta} p(x_{\text{test}} | \theta) p(\theta | D_n) d\theta = \mathbb{E}[p(x_{\text{test}} | T) | D_n]$$

Es muy gordo esto. No sé por qué

Ejemplo 1.3 El tiempo de vida (en años) de un transistor es una variable aleatoria con distribución exponencial de parámetro θ . A priori se modela θ como una variable aleatoria con distribución $\Gamma(2,3)$. Si en 20 transistores se observó una duración total $\sum_{i=1}^{20} x_i = 7$.


1. Hallar la distribución a posteriori del parámetro θ .
2. Hallar la distribución predictiva del tiempo de vida de un transistor.

x_i : tiempo de vida del i -ésimo transistor


$x_i | T = \theta \sim \mathcal{E}(\theta)$ observa $\sum_{i=1}^{20} x_i = 7$

$T \sim \Gamma(2,3)$

Grafo:



Mejor escribir el grafo así:



1) Distribución a posteriori:

$$\underbrace{p(\theta | D_n)}_{\text{densidad a posteriori}} \propto \underbrace{P(\theta)}_{\text{densidad a priori}} \cdot \underbrace{\prod_{i=1}^{20} P(x_i | \theta)}_{\text{verosimilitud}}$$

$$P(\theta | D_n) \propto \theta^{2-1} e^{-3\theta} \mathbb{1}\{\theta > 0\} \cdot \prod_{i=1}^{20} \theta e^{-\theta x_i} =$$

↓
No tenemos las CTEs, solo nos interesa la proporcionalidad

→ Nos interesa el NUCLEO

$$= \theta^{21} e^{-(3 + \sum_{i=1}^{20} x_i) \theta} \mathbb{1}\{\theta > 0\} = \theta^{21} e^{-10 \cdot \theta} \mathbb{1}\{\theta > 0\}$$

Tiene cara de Γ

$\theta | D_m \sim \Gamma(22, 10) \rightarrow$ sé la distribución exacta.

no me hizo falta la cte de proporcionalidad

2) Distribución predictiva: otra vez, solo interesa el núcleo

$$P(x_{\text{test}} | D_m) = \int_0^{+\infty} P(\theta | D_m) \cdot P(x_{\text{test}} | \theta) d\theta \propto \int_0^{+\infty} \theta^{21} e^{-10\theta} \cdot \theta e^{-x_{\text{test}} \cdot \theta} d\theta$$

Densidad de la vida del próximo transistor

$$\propto \int_0^{+\infty} \underbrace{\theta^{22} e^{-10\theta}}_{P(22, 10)} \underbrace{\theta e^{-\theta \cdot x_{\text{test}}}}_{\xi(\theta)} \mathbb{1}\{x_{\text{test}} > 0\} d\theta =$$

$$= \left(\int_0^{+\infty} \theta^{22} e^{-(10 + x_{\text{test}})\theta} d\theta \right) \mathbb{1}\{x_{\text{test}} > 0\} =$$

OBS: $\int_0^{+\infty} x^{r-1} \cdot e^{-\beta x} dx = \frac{\Gamma(r)}{\beta^r} \quad \begin{matrix} \rightarrow r=23 \\ \rightarrow \beta = 10 + x_{\text{test}} \end{matrix}$

$$= \Gamma(23) (10 + x_{\text{test}})^{-23} \mathbb{1}\{x_{\text{test}} > 0\} \propto$$

$$\propto (10 + x_{\text{test}})^{-23} \mathbb{1}\{x_{\text{test}} > 0\} \sim L_{\text{max}}(22, 10)$$

Este método anda de casualidad

¿Qué pasa cuando no puedo hacer esta cuenta?

Inferencia Bayesiana

Filosofía Bayesiana

La estadística bayesiana interpreta la probabilidad como una medida de credibilidad en un evento. Por eso se habla de que el enfoque Bayesiano busca verdades en contexto de incertidumbre.

Inferencia Bayesiana

Filosofía Bayesiana

La estadística bayesiana interpreta la probabilidad como una medida de credibilidad en un evento. Por eso se habla de que el enfoque Bayesiano busca verdades en contexto de incertidumbre.

No confundir Bayesiano con Relativista

¿Es posible entonces alcanzar verdades en las ciencias empíricas en las que es inevitable decir “no sé”? Sí. Podemos evitar mentir: maximizando incertidumbre (no afirmar más de lo que se sabe) dada la información disponible (sin ocultar lo que sí se sabe).

Inferencia Bayesiana

Filosofía Bayesiana

La estadística bayesiana interpreta la probabilidad como una medida de credibilidad en un evento. Por eso se habla de que el enfoque Bayesiano busca verdades en contexto de incertidumbre.


No confundir Bayesiano con Relativista

¿Es posible entonces alcanzar verdades en las ciencias empíricas en las que es inevitable decir “no sé”? Sí. Podemos evitar mentir: maximizando incertidumbre (no afirmar más de lo que se sabe) dada la información disponible (sin ocultar lo que sí se sabe).

¿Son prácticos los métodos Bayesianos?

Si, no solo por poder *adaptarse* a intentar resolver los mismos problemas que la estadística frecuentista (por ejemplo predicciones), sino que también pueden intentar resolver problemas donde la estadística clásica es insuficiente o iluminar el sistema subyacente con un modelado más flexible.

Ejemplo de modelado Bayesiano



Problema

Un usuario proporciona una serie de recuentos diarios de mensajes de whatsapp enviados. Tiene curiosidad por saber si los hábitos de envío de mensajes han cambiado con el tiempo. ¿Cómo puedes modelar esto?


Ejemplo de modelado Bayesiano ¿xq? → ¿xq' m? → ¿cómo da y si da mal cambiamos?

- La cantidad de mensajes en un día deberá ser modelada como una variable discreta cuyos átomos es $\mathbb{N}_0$. (Por ejemplo $X_i \sim \text{Poi}(\lambda_i)$.)
- Si observamos los datos, parecería que el valor de λ_i aumenta en algún momento durante las observaciones. ¿Cómo podemos representar matemáticamente esta observación? Supongamos que algún día τ durante el período de observación, el parámetro λ_i se incrementa repentinamente. Entonces realmente tenemos dos tasas: una para el período anterior a τ y otro para el resto del período:

$$\lambda_i = \begin{cases} \beta_1 & i < \tau \\ \beta_2 & i \geq \tau \end{cases}$$

- idem*
- Tanto β_1 como β_2 toman valores reales no negativos. Por ejemplo $[\beta_1, \beta_2 \sim \mathcal{E}(\alpha)]$. Nuestra estimación de α no influye demasiado en el modelo, por lo que tenemos cierta flexibilidad en nuestra elección.

Para evitar ser demasiado obstinados con este parámetro se sugiere:



Ejemplo de modelado Bayesiano

→ El parámetro de la exponencial es la inversa de la media


- ¿Qué pasa con τ ? Debido a la varianza de los datos, es difícil caracterizarlo en detalle. En cambio, podemos asignar la creencia menos informativa posibles $\tau \sim \mathcal{U}\{1 : T\}$.

Si bien la decisión para el valor de alfa puede parecer tosca, ya nos alejamos bastante del X, así que pesa poco
Se va licuando

Ejemplo de modelado Bayesiano

- ¿Qué pasa con τ ? Debido a la varianza de los datos, es difícil caracterizarlo en detalle. En cambio, podemos asignar la creencia menos informativa posibles $\tau \sim \mathcal{U}\{1 : T\}$. En realidad α no

es una variable aleatoria



Outline


- 1 Inferencia Bayesiana
- 2 Naive Bayes
- 3 Multinomial Naive Bayes
- 4 Variational Bayes
- 5 Monte Carlo Markov Chain

Naive Bayes

Naive Bayes

Estimar los parámetros (máxima verosimilitud o bayesiano) asumiendo que una relación de causalidad $Y \rightarrow X$ con las diferentes componentes $X_j | Y = k$ independientes.

Red Bayesiana



Cálculo


$$p(y|\mathbf{x}) = \frac{p(y) \prod_{j=1}^d p(x_j|y)}{p(\mathbf{x})}$$

Naive Bayes

Naive Bayes

Estimar los parámetros (máxima verosimilitud o bayesiano) asumiendo que una relación de causalidad $Y \rightarrow X$ con las diferentes componentes $X_j|Y = k$ independientes.

Red Bayesiana



Cálculo *features*

$$p(y|\mathbf{x}) = \frac{p(y) \prod_{j=1}^d p(x_j|y)}{p(\mathbf{x})}$$

$\uparrow$




Gaussian Naive Bayes

Sea $\pi = \{c_1, \dots, c_K\}$ y $\theta^{(k)} = \{(\mu_1^{(k)}, \sigma_1^{2(k)}), \dots, (\mu_d^{(k)}, \sigma_d^{2(k)})\}$, se modela $Y \sim \text{Cat}(\{c_1, \dots, c_K\})$ y $X_j|Y = k \sim \mathcal{N}(\mu_j^{(k)}, \sigma_j^{2(k)})$, para luego estimar los parámetros. *Tiene θ a QDA*

Gaussian Naive Bayes (GNB)

Diferencias entre QDA, LDA y GNB

- QDA acepta como Σ_k cualquier conjunto de matrices definidas positiva.
- LDA acepta como Σ_k cualquier matriz pero todas iguales.
- GNB permite tener matrices Σ_k diferentes pero todas diagonales.



Gaussian Naive Bayes (GNB)

QDA $\rightarrow$ Es el más general de los 3

$$\Sigma_k = \frac{1}{|\mathcal{D}_k| - 1} \sum_{x \in \mathcal{D}_k} (x - \mu^{(k)}) (x - \mu^{(k)})^T$$

LDA

$$\Sigma = \frac{1}{n - K} \sum_{k=1}^K (|\mathcal{D}_k| - 1) \Sigma_k$$

GNB

$$\Sigma_k = \text{DIAG} \left(\sigma_1^{2(k)}, \dots, \sigma_d^{2(k)} \right), \quad \sigma_j^{2(k)} = \frac{1}{|\mathcal{D}_k| - 1} \sum_{x \in \mathcal{D}_k} (x_j - \mu_j^{(k)})^2$$

QDA $\rightarrow$ k matrices simétricas de $d \times d \rightarrow$ son $\frac{d \cdot (d+1)}{2}$ coeficientes
por matriz

$$\# \text{parámetros} = k \cdot \frac{d \cdot (d+1)}{2}$$

TE QUIERO MUCHO
GAUß

LDA $\rightarrow$ una matrix simétrica de $d \times d$

$$\# \text{parámetros} = \frac{d \cdot (d+1)}{2}$$

GNB $\rightarrow$ k matrices diagonales

$$\# \text{parámetros} = k \cdot d$$

la cantidad de parámetros
es una medida de la
complejidad

Aunque es debatible

Outline

- 1 Inferencia Bayesiana
- 2 Naive Bayes
- 3 Multinomial Naive Bayes**
- 4 Variational Bayes
- 5 Monte Carlo Markov Chain

Multinomial Naive Bayes

Multinomial Naive Bayes (MNB)

Sea $\pi = \{c_1, \dots, c_K\}$ y $\theta^{(k)} = \{\theta_1^{(k)}, \dots, \theta_V^{(k)}\}$, se modela como $Y \sim \text{Cat}(\{c_1, \dots, c_K\})$ y $X_j | Y = k \sim \text{Cat}(\{\theta_1^{(k)}, \dots, \theta_V^{(k)}\})$, utilizando estimadores puntuales.

.

Multinomial Naive Bayes

Multinomial Naive Bayes (MNB)

Sea $\pi = \{c_1, \dots, c_K\}$ y $\theta^{(k)} = \{\theta_1^{(k)}, \dots, \theta_V^{(k)}\}$, se modela como $Y \sim \text{Cat}(\{c_1, \dots, c_K\})$ y $X_j | Y = k \sim \text{Cat}(\{\theta_1^{(k)}, \dots, \theta_V^{(k)}\})$, utilizando estimadores puntuales.

agrupar las palabras del vocabulario

Inferencia

$$p(y|\mathbf{x}) \propto c_y \prod_{j=1}^d \theta_{x_j}^{(y)} \stackrel{\uparrow}{=} c_y \prod_{m=1}^V \left(\theta_m^{(y)}\right)^{N_m}$$

con N_m : Cantidad de predictores con valor m .

Multinomial Naive Bayes

Multinomial Naive Bayes (MNB)

Sea $\pi = \{c_1, \dots, c_K\}$ y $\theta^{(k)} = \{\theta_1^{(k)}, \dots, \theta_V^{(k)}\}$, se modela como $Y \sim \text{Cat}(\{c_1, \dots, c_K\})$ y $X_j|Y = k \sim \text{Cat}(\{\theta_1^{(k)}, \dots, \theta_V^{(k)}\})$, utilizando estimadores puntuales.

Inferencia

$$p(y|\mathbf{x}) \propto c_y \prod_{j=1}^d \theta_{x_j}^{(y)} = c_y \prod_{m=1}^V \left(\theta_m^{(y)}\right)^{N_m}$$

con N_m : Cantidad de predictores con valor m .

Sobre las variables contadoras

Sea $\mathbf{N} = (N_1, \dots, N_V)$, es sencillo notar que $\sum_{m=1}^V N_m = d$ y $\mathbf{N}|_{Y=k} \sim \mathcal{M}_n(d, [\theta_1^{(k)}, \dots, \theta_V^{(k)}])$.

Multinomial Naive Bayes

En inferencia se elige el máximo de una transformación afín

$$\arg \max_y p(y|\mathbf{x}) = \arg \max_y \log(c_y) + \sum_{m=1}^V N_m \log(\theta_m^{(y)})$$

Multinomial Naive Bayes

En inferencia se elige el máximo de una transformación afín

$$\arg \max_y p(y|\mathbf{x}) = \arg \max_y \log(c_y) + \sum_{m=1}^V N_m \log(\theta_m^{(y)})$$

Probabilidades de las Clases

Los parámetros $c_1, \dots, c_K$ son estimados por máxima verosimilitud como:

$$\hat{c}_k = \frac{\#\{y_i = k\}}{n}$$

Multinomial Naive Bayes

En inferencia se elige el máximo de una transformación afín

$$\arg \max_y p(y|\mathbf{x}) = \arg \max_y \log(c_y) + \sum_{m=1}^V N_m \log(\theta_m^{(y)})$$

Probabilidades de las Clases

Los parámetros $c_1, \dots, c_K$ son estimados por máxima verosimilitud como:

$$\hat{c}_k = \frac{\#\{y_i = k\}}{n}$$

Sobre el valor d

Cada muestra puede poseer un valor de d diferente. Eso es típico en texto, donde cada documento posee una cantidad diferente de palabras.

Multinomial Naive Bayes

Estimación de $\theta_m^{(k)}$

Se cuenta con datos $\{(\mathbf{N}_i, y_i)\}_{i=1}^n$. Sin embargo, para cada clase k se utilizarán solamente los datos con $\{y_i = k\}$ distribuidos como una multinomial de probabilidades $\theta_1^{(k)}, \dots, \theta_V^{(k)}$. A su vez, dado que las variables N_m cuentan ocurrencias, puedo compactar todas las muestras de entrenamiento de cada clase en una sola (suficiencia estadística).

$$\tilde{N}_m^{(k)} = \sum_{i=1}^n N_{i,m} \cdot \mathbb{1}\{y_i = k\} \rightarrow \text{Concatenar documentos}$$

Sumo todas las veces que apareció la palabra m a lo largo de todos los documentos de clase k

i : em qué documento estoy $1 \leq i \leq m$

k : em qué clase estoy $1 \leq k \leq K$

m : em qué palabra estoy $1 \leq m \leq V$

Multinomial Naive Bayes

Estimación de $\theta_m^{(k)}$

Se cuenta con datos $\{(\mathbf{N}_i, y_i)\}_{i=1}^n$. Sin embargo, para cada clase k se utilizarán solamente los datos con $\{y_i = k\}$ distribuidos como una multinomial de probabilidades $\theta_1^{(k)}, \dots, \theta_V^{(k)}$. A su vez, dado que las variables N_m cuentan ocurrencias, puedo compactar todas las muestras de entrenamiento de cada clase en una sola (suficiencia estadística).

$$\tilde{N}_m^{(k)} = \sum_{i=1}^n N_{i,m} \cdot \mathbb{1}\{y_i = k\}$$

Modelado: Estimador Bayesiano

Como modelado para el entrenamiento se supone $\mathbf{T} \sim \text{Dir}([\alpha_1, \dots, \alpha_V])$ y $(\tilde{N}_1^{(k)}, \dots, \tilde{N}_V^{(k)}) |_{\mathbf{T}=\theta} \sim \mathcal{M}_n(\tilde{d}^{(k)}, [\theta_1^{(k)}, \dots, \theta_V^{(k)}])$.

Multinomial Naive Bayes

Dirichlett Distribution

El vector aleatorio $(T_1, \dots, T_V) \sim \text{Dir}([\alpha_1, \dots, \alpha_V])$ puede ser pensado como una beta multivariada. Su densidad es de la forma

$$p(\theta_1, \dots, \theta_V) = \frac{\prod_{m=1}^V \Gamma(\alpha_m)}{\Gamma\left(\sum_{m=1}^V \alpha_m\right)} \left(\prod_{m=1}^V \theta_m^{\alpha_m-1} \right) \cdot \mathbb{1} \left\{ \sum_{m=1}^V \theta_m = 1, \theta_m \geq 0 \right\}$$

con sus marginales $T_m \sim \beta(\alpha_m, \sum_{\eta \neq m} \alpha_\eta)$. ah hell mah

Sobre la beta

Recordar que si $T \sim \beta(a, b)$, entonces $\mathbb{E}[T] = \frac{a}{a+b}$.

Multinomial Naive Bayes

Distribución a Posteriori

$$\begin{aligned} & p\left(\theta_1^{(k)}, \dots, \theta_V^{(k)} \mid \tilde{N}_1^{(k)}, \dots, \tilde{N}_V^{(k)}\right) \\ & \propto P\left(\tilde{N}_1^{(k)}, \dots, \tilde{N}_V^{(k)} \mid \theta_1^{(k)}, \dots, \theta_V^{(k)}\right) \cdot p\left(\theta_1^{(k)}, \dots, \theta_V^{(k)}\right) \\ & \propto \left(\prod_{m=1}^V (\theta_m^{(k)})^{\tilde{N}_m^{(k)}}\right) \left(\prod_{m=1}^V (\theta_m^{(k)})^{\alpha_m - 1} \cdot \mathbb{1}\left\{\theta_m^{(k)} \geq 0\right\}\right) \cdot \mathbb{1}\left\{\sum_{m=1}^V \theta_m^{(k)} = 1\right\} \end{aligned}$$

con lo cual $\mathbf{T} \mid \tilde{N}_1^{(k)}, \dots, \tilde{N}_V^{(k)} \sim \text{Dir}([\tilde{N}_1^{(k)} + \alpha_1, \dots, \tilde{N}_V^{(k)} + \alpha_V])$

Multinomial Naive Bayes

Distribución a Posteriori

$$\begin{aligned} p\left(\theta_1^{(k)}, \dots, \theta_V^{(k)} \mid \tilde{N}_1^{(k)}, \dots, \tilde{N}_V^{(k)}\right) \\ \propto P\left(\tilde{N}_1^{(k)}, \dots, \tilde{N}_V^{(k)} \mid \theta_1^{(k)}, \dots, \theta_V^{(k)}\right) \cdot p\left(\theta_1^{(k)}, \dots, \theta_V^{(k)}\right) \\ \propto \left(\prod_{m=1}^V (\theta_m^{(k)})^{\tilde{N}_m^{(k)}}\right) \left(\prod_{m=1}^V (\theta_m^{(k)})^{\alpha_m - 1} \cdot \mathbb{1}\left\{\theta_m^{(k)} \geq 0\right\}\right) \cdot \mathbb{1}\left\{\sum_{m=1}^V \theta_m^{(k)} = 1\right\} \end{aligned}$$

con lo cual $\mathbf{T} \mid \tilde{N}_1^{(k)}, \dots, \tilde{N}_V^{(k)} \sim \text{Dir}([\tilde{N}_1^{(k)} + \alpha_1, \dots, \tilde{N}_V^{(k)} + \alpha_V])$

Estimador Bayesiano

$$\hat{\theta}_m^{(k)} = \mathbb{E}[T_m \mid \tilde{N}_1^{(k)}, \dots, \tilde{N}_V^{(k)}] = \left[\frac{\tilde{N}_m^{(k)} + \alpha_m}{\sum_{\eta=1}^V \tilde{N}_\eta^{(k)} + \alpha_\eta} \right]$$

Esto es lo q' hay q' implementar

Outline

Sobre el TP: Cada libro tiene más de una categoría
Hay que filtrar, de manera que cada libro tenga una sola categoría
¿Con qué criterio? No hay uno solo. Elegir uno y justificar

1 Inferencia Bayesiana

Generador por compresión:

Si tuviera una lista muy larga la RAM puede estallar

Un generador es como una lista, pero no usa tanta RAM. Creo que es xq se guarda la regla de cómo generar el elemento y no todos los elementos.

Preguntarle al shat. Recordar el ejemplo de la clase cuando a V. le estalló la RAM en la cara

2 Naive Bayes

NOTA IMPORTANTE:

Hay que borrar el ñuflo del URL

3 Multinomial Naive Bayes

4 Variational Bayes

5 Monte Carlo Markov Chain

Ejemplo 6.1 Lucas dispara a un blanco y el disparo impacta en un punto aleatorio $(X, 0)$ con X (en decímetros) una variable aleatoria con distribución normal de media nula y varianza $1/\tau$, donde τ representa la precisión de Lucas. A priori la precisión τ tiene una distribución chi-cuadrado de 8 grados de libertad. Lucas tiro 10 veces al blanco y observó $\sum_{i=1}^{10} x_i^2 = 17$. En virtud a la información muestral,

1. Hallar la distribución a posteriori.

2. Hallar la distribución predictiva.


$$x_i | \tau = \tau \sim N(0, 1/\tau)$$

$$\tau \sim \chi^2_8 \quad 10 \text{ tiros: } \sum_{i=1}^{10} x_i^2 = 17$$

Gráfico:

1) a posteriori:

$$P(\tau | D_n) \propto P(\tau) \prod_{i=1}^{10} p(x_i | \tau) \propto$$



$$\propto \tau^3 e^{-\tau/2} \mathbb{1}\{\tau \geq 0\} \prod_{i=1}^{10} \frac{1}{\sqrt{1/\tau}} e^{-\frac{(x_i)^2}{2/\tau}} =$$

$$= \tau^3 e^{-\tau/2} \mathbb{1}\{\tau \geq 0\} \prod_{i=1}^{10} \tau^{1/2} e^{-\frac{\tau (x_i)^2}{2}} =$$

$$= \tau^8 e^{-\frac{\tau}{2} \left(1 + \sum_{i=1}^{10} x_i^2\right)} \mathbb{1}\{\tau \geq 1\} \rightarrow \Gamma(9, 9)$$

$\tau | D_n \sim \Gamma(9, 9) \rightarrow$ distribución a posteriori

Predictiva:

$$p(x_{\text{test}} | D_n) = \int p(\tau | D_n) \cdot p(x_{\text{test}} | \tau) d\tau \propto$$

$$\propto \int_0^{+\infty} \underbrace{\tau^8 e^{-9\tau}}_{\propto \tau} \cdot \underbrace{\frac{1}{\sqrt{1/\tau}} e^{-\frac{x_{\text{test}}^2}{2\tau}}}_{\propto \sqrt{\tau}} d\tau =$$

$$= \int_0^{+\infty} \tau^{8,5} e^{-\tau(9 + \frac{x_{\text{test}}^2}{2})} d\tau \propto$$

$$\propto \left(9 + \frac{x_{\text{test}}^2}{2}\right)^{-9,5} \propto \left(1 + \frac{x_{\text{test}}^2}{18}\right)^{-\frac{18+1}{2}}$$

obs: $\int_0^{+\infty} x^{\tau-1} e^{-\beta x} dx = \Gamma(\tau) \beta^{-\tau}$

$$\tau - 1 = 8,5 \rightarrow \tau = 9,5$$

$$\beta = 9 + \frac{x_{\text{test}}^2}{2}$$

$$\Rightarrow X_{\text{test}} | D_n \sim t_{18}$$

Variational Bayes

Variational Bayes

La idea es considerar los parámetros como parte del espacio latente. Sea $\mathbf{Z}$ un vector no observable del problema, en general será prohibitivo calcular la distribución a posteriori $p(\mathbf{z}|\mathbf{x})$. Con lo cuál, uno aproximará dicha distribución con la solución de

$$\begin{aligned}\arg \min_{q \in \mathcal{P}} \text{KL}(q(\cdot|\mathbf{x})||p(\cdot|\mathbf{x})) &= \arg \max_{q \in \mathcal{P}} H(q(\cdot|\mathbf{x})) + \mathbb{E}_q[\log p(\mathbf{x}, \mathbf{Z})|\mathbf{X} = \mathbf{x}] \\ &= \arg \max_{q \in \mathcal{P}} \text{ELBO}(q)\end{aligned}$$



donde $q(\mathbf{z}|\mathbf{x})$ cumple ciertas restricciones $\mathcal{P}$.

$$D/ \quad K(q(\cdot|x) || p(\cdot|x)) = \mathbb{E}_q \left[\log \frac{q(z|x)}{p(z|x)} \middle| x \right] = \mathbb{E}_q \left[\log \frac{q(z|x) \cdot p(x)}{p(x,z)} \middle| x \right] =$$

$$p(z|x) = \frac{p(x,z)}{p(x)}$$

$$= \underbrace{\mathbb{E}_q \left[\log q(z|x) \right]}_{-H(q(\cdot|x))} + \underbrace{\log p(x)}_{\text{Indep de } q} - \mathbb{E}_q \left[\log p(x,z) | x \right] = - (H + \mathbb{E}_q)$$

para a máxima por el -

$$\therefore \arg \min_q KL(q(\cdot|x) || p(\cdot|x)) = \arg \max_q H(q(\cdot|x)) + \mathbb{E}_q [\log p(x,z) | x]$$

Variational Bayes

Variational Bayes

La idea es considerar los parámetros como parte del espacio latente. Sea $\mathbf{Z}$ un vector no observable del problema, en general será prohibitivo calcular la distribución a posteriori $p(\mathbf{z}|\mathbf{x})$. Con lo cuál, uno aproximará dicha distribución con la solución de

$$\begin{aligned}\arg \min_{q \in \mathcal{P}} \text{KL}(q(\cdot|\mathbf{x})||p(\cdot|\mathbf{x})) &= \arg \max_{q \in \mathcal{P}} H(q(\cdot|\mathbf{x})) + \mathbb{E}_q[\log p(\mathbf{x}, \mathbf{Z})|\mathbf{X} = \mathbf{x}] \\ &= \arg \max_{q \in \mathcal{P}} \text{ELBO}(q)\end{aligned}$$

donde $q(\mathbf{z}|\mathbf{x})$ cumple ciertas restricciones $\mathcal{P}$.

Mean field approximation → *añadimos una condición para q*

Aproximación que relaja el problema al suponer que q se puede factorizar como productos de densidades tratables. Por ejemplo, sea $\mathbf{z} = (\mathbf{u}, \phi)$ se relaja el problema suponiendo $q(\mathbf{z}|\mathbf{x}) = q_1(\mathbf{u}|\mathbf{x})q_2(\phi|\mathbf{x})$ para todo $q \in \mathcal{P}$.

→ Latentes → parámetros

$$H(q) = H(q_1) + H(q_2)$$

Variational Bayes

Planteo del problema

Se buscan q_1 y q_2 que maximicen

ELBO(q)

$$\begin{aligned} &= H(q_1(\cdot|\mathbf{x})) + H(q_2(\cdot|\mathbf{x})) + \int_{\mathcal{U}} q_1(\mathbf{u}|\mathbf{x}) \left(\int_{\Phi} q_2(\phi|\mathbf{x}) \log p(\mathbf{x}, \mathbf{u}, \phi) d\phi \right) d\mathbf{u} \\ &= H(q_1(\cdot|\mathbf{x})) + H(q_2(\cdot|\mathbf{x})) + \int_{\Phi} q_2(\phi|\mathbf{x}) \left(\int_{\mathcal{U}} q_1(\mathbf{u}|\mathbf{x}) \log p(\mathbf{x}, \mathbf{u}, \phi) d\mathbf{u} \right) d\phi \end{aligned}$$

Variational Bayes

Planteo del problema

Se buscan q_1 y q_2 que maximicen

ELBO(q)

$$\begin{aligned} &= H(q_1(\cdot|\mathbf{x})) + H(q_2(\cdot|\mathbf{x})) + \int_{\mathcal{U}} q_1(\mathbf{u}|\mathbf{x}) \left(\int_{\Phi} q_2(\phi|\mathbf{x}) \log p(\mathbf{x}, \mathbf{u}, \phi) d\phi \right) d\mathbf{u} \\ &= H(q_1(\cdot|\mathbf{x})) + H(q_2(\cdot|\mathbf{x})) + \int_{\Phi} q_2(\phi|\mathbf{x}) \left(\int_{\mathcal{U}} q_1(\mathbf{u}|\mathbf{x}) \log p(\mathbf{x}, \mathbf{u}, \phi) d\mathbf{u} \right) d\phi \end{aligned}$$

Resolución Iterativa

Se simplificará el problema resolviéndolo de forma iterativa. Definimos

$$E_1(\mathbf{x}, \mathbf{u}) = \int_{\Phi} q_2(\phi|\mathbf{x}) \log p(\mathbf{x}, \mathbf{u}, \phi) d\phi \equiv f(q_2)$$

$$E_2(\mathbf{x}, \phi) = \int_{\mathcal{U}} q_1(\mathbf{u}|\mathbf{x}) \log p(\mathbf{x}, \mathbf{u}, \phi) d\mathbf{u} \equiv f(q_1)$$

$$\begin{aligned} \arg \max_{q_1} H(q_1(\cdot|x)) + \int_U q_1(u|x) E_1(x,u) du &= \arg \max_{q_1} \int_U q_1(u|x) \left[\log \frac{1}{q_1(u|x)} + E_1(x,u) \right] du = \\ &= \arg \max_{q_1} \int_U q_1(u|x) \cdot \log \frac{e^{E_1(x,u)}}{q_1(u|x)} du = \arg \max_{q_1} \int_U q_1(u|x) \cdot \log \frac{e^{E_1(x,u)}/k(x)}{q_1(u|x)} + \underbrace{\log(k(x))}_{\text{Indep de } q_1} du \\ &\quad \xrightarrow{\text{Casi una KL}} \end{aligned}$$

$$\text{Donde } k(x) = \frac{1}{\int_U e^{E_1(x,u)} du}$$

$$-KL(q_1(\cdot|x) \parallel \frac{e^{E_1(x,u)}}{k(x)})$$

Maximizar la $-KL$ es minimizar la KL , q^* es cuando los argumentos son iguales

El q_1 óptimo es: $q_1(u|x) \propto e^{E_1(u|x)}$

Y o quise de lo q^* fumaba Bayes

Variational Bayes

Problemas

$$q_1(\cdot|\mathbf{x}) = \arg \max_{q_1} \int_{\mathcal{U}} q_1(\mathbf{u}|\mathbf{x}) \log \frac{e^{E_1(\mathbf{x}, \mathbf{u})}}{q_1(\mathbf{u}|\mathbf{x})} d\mathbf{u}$$

$$q_2(\cdot|\mathbf{x}) = \arg \max_{q_2} \int_{\Phi} q_2(\phi|\mathbf{x}) \log \frac{e^{E_2(\mathbf{x}, \phi)}}{q_2(\phi|\mathbf{x})} d\phi$$

Variational Bayes

Problemas

$$q_1(\cdot|\mathbf{x}) = \arg \max_{q_1} \int_{\mathcal{U}} q_1(\mathbf{u}|\mathbf{x}) \log \frac{e^{E_1(\mathbf{x},\mathbf{u})}}{q_1(\mathbf{u}|\mathbf{x})} d\mathbf{u}$$

$$q_2(\cdot|\mathbf{x}) = \arg \max_{q_2} \int_{\Phi} q_2(\phi|\mathbf{x}) \log \frac{e^{E_2(\mathbf{x},\phi)}}{q_2(\phi|\mathbf{x})} d\phi$$

Soluciones

La solución consiste en iterar entre

$$q_1(\mathbf{u}|\mathbf{x}) \propto e^{E_1(\mathbf{x},\mathbf{u})}, \quad q_2(\phi|\mathbf{x}) \propto e^{E_2(\mathbf{x},\phi)}$$

Variational Bayes

Problemas

$$q_1(\cdot|\mathbf{x}) = \arg \max_{q_1} \int_{\mathcal{U}} q_1(\mathbf{u}|\mathbf{x}) \log \frac{e^{E_1(\mathbf{x},\mathbf{u})}}{q_1(\mathbf{u}|\mathbf{x})} d\mathbf{u}$$

$$q_2(\cdot|\mathbf{x}) = \arg \max_{q_2} \int_{\Phi} q_2(\phi|\mathbf{x}) \log \frac{e^{E_2(\mathbf{x},\phi)}}{q_2(\phi|\mathbf{x})} d\phi$$

Soluciones

La solución consiste en iterar entre


$$q_1(\mathbf{u}|\mathbf{x}) \propto e^{E_1(\mathbf{x},\mathbf{u})}, \quad q_2(\phi|\mathbf{x}) \propto e^{E_2(\mathbf{x},\phi)}$$

Sobre el ELBO

$$\text{ELBO}(q) = \log p(\mathbf{x}) - \text{KL}(q(\cdot|\mathbf{x})||p(\cdot|\mathbf{x})) \leq \log p(\mathbf{x})$$

$$\text{ELBO}(q) = \mathbb{E}_q[\log p(\mathbf{x}|\mathbf{z})|\mathbf{x}] - \text{KL}(q(\cdot|\mathbf{x})||p(\cdot)) \leq \mathbb{E}_q[\log p(\mathbf{x}|\mathbf{z})|\mathbf{x}]$$

Gaussian Variational Bayes



Modelo

$$p(\mathbf{x}, \mathbf{u}, \pi, \lambda, \mu) = p(\pi) \left(\prod_{k=1}^K p(\lambda_k) p(\mu_k | \lambda_k) \right) \left(\prod_{i=1}^n P(u_i | \pi) p(x_i | u_i, \mu, \lambda) \right)$$

con

¿Es una clase de griego esto???

$$\pi \sim \text{Dir}(\alpha), \quad \lambda_k \sim \Gamma(\nu, \beta), \quad \mu_k | \lambda_k \sim \mathcal{N}(m, (\delta \lambda_k)^{-1})$$

$$u | \pi \sim \text{Cat}(\pi), \quad x | u, \mu, \lambda \sim \mathcal{N}(\mu_u, \lambda_u^{-1})$$

Repaso: Distribuciones

Normal(μ, σ^2)

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Gamma(ν, β)

$$p(x) = \frac{\beta^\nu}{\Gamma(\nu)} x^{\nu-1} e^{-\beta x} \mathbb{1}\{x > 0\}$$

T-Student generalizada(μ, Λ, ν)

$$p(x) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right)} \sqrt{\frac{\Lambda}{\pi\nu}} \left(1 + \Lambda \frac{(x-\mu)^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

Dirichlett($\alpha_1 \dots, \alpha_K$)

$$p(x_1, \dots, x_K) = \frac{\prod_{k=1}^K \Gamma(\alpha_k)}{\Gamma\left(\sum_{k=1}^K \alpha_k\right)} \left(\prod_{k=1}^K x_k^{\alpha_k-1}\right) \cdot \mathbb{1}\left\{\sum_{k=1}^K x_k = 1, x_k \geq 0\right\}$$

Gaussian Variational Bayes

Mean field approximation

Se aproxima $q(\mathbf{u}, \pi, \lambda, \mu | \mathbf{x}) = Q_1(\mathbf{u} | \mathbf{x}) q_2(\pi, \lambda, \mu | \mathbf{x})$ y luego

$$E_1(\mathbf{x}, \mathbf{u}) = \text{cte} + \sum_{i=1}^n \int q_2(\pi | \mathbf{x}) \log P(u_i | \pi) d\pi \\ + \sum_{i=1}^n \int \int q_2(\mu, \lambda | \mathbf{x}) \log p(x_i | u_i, \mu, \lambda) d\mu d\lambda$$

$$E_2(\mathbf{x}, \pi, \lambda, \mu) = \log p(\pi) + \sum_{k=1}^K \log p(\lambda_k) + \sum_{k=1}^K \log p(\mu_k | \lambda_k) \\ + \sum_{i=1}^n \sum_{k=1}^K Q_1(u_i = k | \mathbf{x}) \log P(u_i = k | \pi) \\ + \sum_{i=1}^n \sum_{k=1}^K Q_1(u_i = k | \mathbf{x}) \log p(x_i | u_i = k, \mu, \lambda)$$

Gaussian Variational Bayes

C  mputo de $q_2(\pi, \lambda, \mu|\mathbf{x})$

Lo primero a notar es la factorizaci  n. Sea $\gamma_{i,k} = Q_1(u_i = k|\mathbf{x})$, luego

$$q_2(\pi, \lambda, \mu|\mathbf{x}) \propto p(\pi) \left(\prod_{k=1}^K p(\lambda_k) p(\mu_k|\lambda_k) \right) \prod_{k=1}^K e^{\sum_{i=1}^n \gamma_{i,k} [\log \pi_k + \log \mathcal{N}_{x_i}(\mu_k, \lambda_k^{-1})]}$$

Luego $q_2(\pi, \lambda, \mu|\mathbf{x}) = q_2(\pi|\mathbf{x}) \prod_{k=1}^K q_2(\mu_k, \lambda_k|\mathbf{x})$.

$\downarrow$
densidad de la normal
en x_i

Gaussian Variational Bayes

C  puto de $q_2(\pi, \lambda, \mu|\mathbf{x})$

Lo primero a notar es la factorizaci  n. Sea $\gamma_{i,k} = Q_1(u_i = k|\mathbf{x})$, luego

$$q_2(\pi, \lambda, \mu|\mathbf{x}) \propto p(\pi) \left(\prod_{k=1}^K p(\lambda_k) p(\mu_k|\lambda_k) \right) \prod_{k=1}^K e^{\sum_{i=1}^n \gamma_{i,k} [\log \pi_k + \log \mathcal{N}_{x_i}(\mu_k, \lambda_k^{-1})]}$$

Luego $q_2(\pi, \lambda, \mu|\mathbf{x}) = q_2(\pi|\mathbf{x}) \prod_{k=1}^K q_2(\mu_k, \lambda_k|\mathbf{x})$.

C  puto de $q_2(\pi|\mathbf{x})$

$$q_2(\pi|\mathbf{x}) \propto \left(\prod_{k=1}^K \pi_k^{\alpha_k - 1} e^{\sum_{i=1}^n \gamma_{i,k} \log \pi_k} \right) \mathbb{1} \left\{ \sum_{k=1}^K \pi_k = 1, \pi_k \geq 0 \right\}$$

con lo cual $\pi|\mathbf{x} \sim \text{Dir}([\alpha_1 + \sum_{i=1}^n \gamma_{i,1}, \dots, \alpha_K + \sum_{i=1}^n \gamma_{i,K}])$

Gaussian Variational Bayes

C  mputo de $q_2(\mu_k, \lambda_k | \mathbf{x})$

$$q_2(\mu_k, \lambda_k | \mathbf{x})$$

$$\propto \underbrace{\lambda_k^{\nu-1} e^{-\beta \lambda_k} \mathbb{1}\{\lambda_k > 0\}}_{\propto p(\lambda_k)} \underbrace{\lambda_k^{1/2} e^{\frac{-\delta \lambda_k (\mu_k - m)^2}{2}}}_{\propto p(\mu_k | \lambda_k)} \lambda_k^{\frac{1}{2} \sum_{i=1}^n \gamma_{i,k}} e^{\frac{-\lambda_k \sum_{i=1}^n \gamma_{i,k} (x_i - \mu_k)^2}{2}}$$

con lo cual $\mu_k | \lambda_k, \mathbf{x} \sim \mathcal{N} \left(\frac{\delta m + \sum_{i=1}^n \gamma_{i,k} x_i}{\delta + \sum_{i=1}^n \gamma_{i,k}}, \frac{1}{\lambda_k (\delta + \sum_{i=1}^n \gamma_{i,k})} \right)$ y

$$\lambda_k | \mathbf{x} \sim \Gamma \left(\nu + \frac{1}{2} \sum_{i=1}^n \gamma_{i,k}, \beta + \frac{\delta m^2}{2} + \frac{1}{2} \sum_{i=1}^n \gamma_{i,k} x_i^2 - \frac{(\delta m + \sum_{i=1}^n \gamma_{i,k} x_i)^2}{2(\delta + \sum_{i=1}^n \gamma_{i,k})} \right)$$

Gaussian Variational Bayes

Cómputo de $q_2(\mu_k, \lambda_k | \mathbf{x})$

$$q_2(\mu_k, \lambda_k | \mathbf{x})$$

$$\propto \underbrace{\lambda_k^{\nu-1} e^{-\beta \lambda_k} \mathbb{1}\{\lambda_k > 0\}}_{\propto p(\lambda_k)} \underbrace{\lambda_k^{1/2} e^{\frac{-\delta \lambda_k (\mu_k - m)^2}{2}}}_{\propto p(\mu_k | \lambda_k)} \lambda_k^{\frac{1}{2} \sum_{i=1}^n \gamma_{i,k}} e^{\frac{-\lambda_k \sum_{i=1}^n \gamma_{i,k} (x_i - \mu_k)^2}{2}}$$

con lo cual $\mu_k | \lambda_k, \mathbf{x} \sim \mathcal{N} \left(\frac{\delta m + \sum_{i=1}^n \gamma_{i,k} x_i}{\delta + \sum_{i=1}^n \gamma_{i,k}}, \frac{1}{\lambda_k (\delta + \sum_{i=1}^n \gamma_{i,k})} \right)$ y

$$\lambda_k | \mathbf{x} \sim \Gamma \left(\nu + \frac{1}{2} \sum_{i=1}^n \gamma_{i,k}, \beta + \frac{\delta m^2}{2} + \frac{1}{2} \sum_{i=1}^n \gamma_{i,k} x_i^2 - \frac{(\delta m + \sum_{i=1}^n \gamma_{i,k} x_i)^2}{2(\delta + \sum_{i=1}^n \gamma_{i,k})} \right)$$

Estadísticos Suficientes

Basta con computar $N_k = \sum_{i=1}^n \gamma_{i,k}$, $f_k = \sum_{i=1}^n \gamma_{i,k} x_i$ y $s_k = \sum_{i=1}^n \gamma_{i,k} x_i^2$.

Gaussian Variational Bayes

Propiedad de las distribuciones Gamma y Dirichlett

Sean $\lambda \sim \Gamma(\nu, \beta)$ y $\pi \sim \text{Dir}(\alpha)$, se puede demostrar que

- $\mathbb{E}[\log \lambda] = \psi(\nu) - \log(\beta)$
- $\mathbb{E}[\log \pi_k] = \psi(\alpha_k) - \psi\left(\sum_{c=1}^K \alpha_c\right)$

donde $\psi(\cdot)$ es la función digamma $\psi(z) = \frac{\Gamma'(z)}{\Gamma(z)}$.

Gaussian Variational Bayes

Propiedad de las distribuciones Gamma y Dirichlet

Sean $\lambda \sim \Gamma(\nu, \beta)$ y $\pi \sim \text{Dir}(\alpha)$, se puede demostrar que

- $\mathbb{E}[\log \lambda] = \psi(\nu) - \log(\beta)$
- $\mathbb{E}[\log \pi_k] = \psi(\alpha_k) - \psi\left(\sum_{c=1}^K \alpha_c\right)$

donde $\psi(\cdot)$ es la función digamma $\psi(z) = \frac{\Gamma'(z)}{\Gamma(z)}$.

Cómputo de $Q_1(\mathbf{u}|\mathbf{x})$

Lo primero a notar es la independencia

$$\begin{aligned} Q_1(\mathbf{u}|\mathbf{x}) &\propto \prod_{i=1}^n e^{\int q_2(\pi|\mathbf{x}) \log P(u_i|\pi) d\pi + \int \int q_2(\mu, \lambda|\mathbf{x}) \log p(x_i|u_i, \mu, \lambda) d\mu d\lambda} \\ &= \prod_{i=1}^n Q_1(u_i|\mathbf{x}) \end{aligned}$$

Gaussian Variational Bayes

C  puto de $Q_1(u_i = k|\mathbf{x})$

Sean los par  metros de q_2 definidos como $\pi|\mathbf{x} \sim \text{Dir}(\alpha^*)$, $\mu_k|\lambda_k, \mathbf{x} \sim \mathcal{N}(m_k^*, (\delta_k^* \lambda_k)^{-1})$ y $\lambda_k|\mathbf{x} \sim \Gamma(\nu_k^*, \beta_k^*)$. Luego

$$Q_1(u_i = k|\mathbf{x}) \propto e^{\psi(\alpha_k^*) - \psi(\sum_{c=1}^K \alpha_c^*) + \frac{\psi(\nu_k^*) - \log(\beta_k^*)}{2} - \frac{1}{2} \mathbb{E}_{q_2}[\lambda_k(x_i - \mu_k)^2]}$$

con

$$\begin{aligned} \mathbb{E}_{q_2}[\lambda_k(x_i - \mu_k)^2] &= \mathbb{E}_{q_2}[\lambda_k \mathbb{E}_{q_2}[(x_i - \mu_k)^2 | \lambda_k]] \\ &= \mathbb{E}_{q_2}[\lambda_k (\mathbb{E}_{q_2}[(\mu_k - m_k^*)^2 | \lambda_k] + (m_k^* - x_i)^2)] \\ &= \frac{1}{\delta_k^*} + \frac{\nu_k^*}{\beta_k^*} (m_k^* - x_i)^2 \end{aligned}$$

Finalmente

$$Q_1(u_i = k|\mathbf{x}) \propto e^{\psi(\alpha_k^*) - \psi(\sum_{c=1}^K \alpha_c^*) + \frac{\psi(\nu_k^*) - \log(\beta_k^*)}{2} - \frac{1}{2\delta_k^*} - \frac{\nu_k^*}{2\beta_k^*} (m_k^* - x_i)^2}$$

Gaussian Variational Bayes

Solución: Inicializar $\gamma_{i,k}$ con EM e iterar entre

- Calcular $(\alpha_k^*, m_k^*, \delta_k^*, \nu_k^*, \beta_k^*)$ a partir de $\gamma_{i,k}$ como

$$\alpha_k^* = \alpha_k + \sum_{i=1}^n \gamma_{i,k}, \quad m_k^* = \frac{\delta m + \sum_{i=1}^n \gamma_{i,k} x_i}{\delta + \sum_{i=1}^n \gamma_{i,k}}$$

$$\delta_k^* = \delta + \sum_{i=1}^n \gamma_{i,k}, \quad \nu_k^* = \nu + \frac{1}{2} \sum_{i=1}^n \gamma_{i,k}$$

$$\beta_k^* = \beta + \frac{\delta m^2}{2} + \frac{1}{2} \sum_{i=1}^n \gamma_{i,k} x_i^2 - \frac{(\delta m + \sum_{i=1}^n \gamma_{i,k} x_i)^2}{2(\delta + \sum_{i=1}^n \gamma_{i,k})}$$

- Calcular $\gamma_{i,k} = \frac{\rho_{i,k}}{\sum_{c=1}^K \rho_{i,c}}$ a partir de $(\alpha_k^*, m_k^*, \delta_k^*, \nu_k^*, \beta_k^*)$ como

$$\rho_{i,k} = e^{\psi(\alpha_k^*) - \psi(\sum_{c=1}^K \alpha_c^*) + \frac{\psi(\nu_k^*) - \log(\beta_k^*)}{2} - \frac{1}{2\delta_k^*} - \frac{\nu_k^*}{2\beta_k^*} (m_k^* - x_i)^2}$$

Gaussian Variational Bayes

Predictiva: Es una mezcla!

$$\begin{aligned}p(x_{\text{test}}|\mathcal{D}_n) &= \mathbb{E}[p(x_{\text{test}}|\phi)|\mathcal{D}_n] \\&= \sum_{k=1}^K \mathbb{E}[\pi_k|\mathcal{D}_n] \cdot \mathbb{E}\left[\sqrt{\frac{\lambda_k}{2\pi}} e^{\frac{-\lambda_k}{2}(x_{\text{test}}-\mu_k)^2} \middle| \mathcal{D}_n\right] \\&= \sum_{k=1}^K \frac{\alpha_k^*}{\sum_{c=1}^K \alpha_c^*} \cdot \tilde{p}_k(x_{\text{test}}|\mathcal{D}_n)\end{aligned}$$

Gaussian Variational Bayes

Predictiva: Es una mezcla!

$$\begin{aligned}p(x_{\text{test}}|\mathcal{D}_n) &= \mathbb{E}[p(x_{\text{test}}|\phi)|\mathcal{D}_n] \\&= \sum_{k=1}^K \mathbb{E}[\pi_k|\mathcal{D}_n] \cdot \mathbb{E}\left[\sqrt{\frac{\lambda_k}{2\pi}} e^{\frac{-\lambda_k}{2}(x_{\text{test}}-\mu_k)^2} \middle| \mathcal{D}_n\right] \\&= \sum_{k=1}^K \frac{\alpha_k^*}{\sum_{c=1}^K \alpha_c^*} \cdot \tilde{p}_k(x_{\text{test}}|\mathcal{D}_n)\end{aligned}$$

Normal-Gamma Distribution

$$\begin{aligned}1 &= \int_0^\infty \int_{-\infty}^\infty \frac{\tilde{\beta}^{\tilde{\nu}}}{\Gamma(\tilde{\nu})} \lambda^{\tilde{\nu}-1} e^{-\tilde{\beta}\lambda} \sqrt{\frac{\tilde{\delta}\lambda}{2\pi}} e^{\frac{-\tilde{\delta}\lambda}{2}(\mu-\tilde{m})^2} d\mu d\lambda \\&\int_0^\infty \int_{-\infty}^\infty \lambda^{\tilde{\nu}-\frac{1}{2}} e^{\frac{-\tilde{\delta}\lambda}{2}(\mu-\tilde{m})^2 - \lambda\tilde{\beta}} d\mu d\lambda = \sqrt{\frac{2\pi}{\tilde{\delta}}} \frac{\Gamma(\tilde{\nu})}{\tilde{\beta}^{\tilde{\nu}}}\end{aligned}$$

Gaussian Variational Bayes

Calculo auxiliar de las densidades a mezclar

$$\begin{aligned} & \mathbb{E} \left[\sqrt{\frac{\lambda_k}{2\pi}} e^{\frac{-\lambda_k}{2}(x_{\text{test}} - \mu_k)^2} \middle| \mathcal{D}_n \right] \\ &= \int_0^\infty \int_{-\infty}^\infty \sqrt{\frac{\lambda}{2\pi}} e^{\frac{-\lambda}{2}(x_{\text{test}} - \mu)^2} \frac{\beta_k^{*\nu_k^*} \sqrt{\delta_k^*}}{\sqrt{2\pi} \Gamma(\nu_k^*)} \lambda^{\nu_k^* - \frac{1}{2}} e^{\frac{-\delta_k^* \lambda}{2}(\mu - m_k^*)^2 - \lambda \beta_k^*} d\mu d\lambda \\ &\propto \int_0^\infty \int_{-\infty}^\infty \lambda^{\nu_k^*} e^{\frac{-\lambda}{2}(x_{\text{test}} - \mu)^2 - \frac{\delta_k^* \lambda}{2}(\mu - m_k^*)^2 - \lambda \beta_k^*} d\mu d\lambda \end{aligned}$$

Gaussian Variational Bayes

Calculo auxiliar de las densidades a mezclar

$$\begin{aligned} & \mathbb{E} \left[\sqrt{\frac{\lambda_k}{2\pi}} e^{\frac{-\lambda_k}{2}(x_{\text{test}} - \mu_k)^2} \middle| \mathcal{D}_n \right] \\ &= \int_0^\infty \int_{-\infty}^\infty \sqrt{\frac{\lambda}{2\pi}} e^{\frac{-\lambda}{2}(x_{\text{test}} - \mu)^2} \frac{\beta_k^{*\nu_k^*} \sqrt{\delta_k^*}}{\sqrt{2\pi} \Gamma(\nu_k^*)} \lambda^{\nu_k^* - \frac{1}{2}} e^{\frac{-\delta_k^* \lambda}{2}(\mu - m_k^*)^2 - \lambda \beta_k^*} d\mu d\lambda \\ &\propto \int_0^\infty \int_{-\infty}^\infty \lambda^{\nu_k^*} e^{\frac{-\lambda}{2}(x_{\text{test}} - \mu)^2 - \frac{\delta_k^* \lambda}{2}(\mu - m_k^*)^2 - \lambda \beta_k^*} d\mu d\lambda \end{aligned}$$

Sustitución dentro de la integral

$$\tilde{\nu} = \nu_k^* + \frac{1}{2}, \quad \tilde{\delta} = \delta_k^* + 1, \quad \tilde{m} = \frac{x_{\text{test}} + \delta_k^* m_k^*}{\delta_k^* + 1}$$

$$\tilde{\beta} = \beta_k^* + \frac{\delta_k^* (x_{\text{test}} - m_k^*)^2}{2(\delta_k^* + 1)}$$

Gaussian Variational Bayes

Calculo auxiliar de las densidades a mezclar

$$\begin{aligned}\mathbb{E} \left[\sqrt{\frac{\lambda_k}{2\pi}} e^{\frac{-\lambda_k}{2}(x_{\text{test}} - \mu_k)^2} \middle| \mathcal{D}_n \right] &\propto \left(\beta_k^* + \frac{\delta_k^*(x_{\text{test}} - m_k^*)^2}{2(\delta_k^* + 1)} \right)^{-(\nu_k^* + 1/2)} \\ &\propto \left(1 + \frac{\delta_k^* \nu_k^*}{(\delta_k^* + 1) \beta_k^*} \frac{(x_{\text{test}} - m_k^*)^2}{2\nu_k^*} \right)^{-\frac{2\nu_k^* + 1}{2}}\end{aligned}$$

Gaussian Variational Bayes

Calculo auxiliar de las densidades a mezclar

$$\begin{aligned}\mathbb{E} \left[\sqrt{\frac{\lambda_k}{2\pi}} e^{\frac{-\lambda_k}{2}(x_{\text{test}} - \mu_k)^2} \middle| \mathcal{D}_n \right] &\propto \left(\beta_k^* + \frac{\delta_k^*(x_{\text{test}} - m_k^*)^2}{2(\delta_k^* + 1)} \right)^{-(\nu_k^* + 1/2)} \\ &\propto \left(1 + \frac{\delta_k^* \nu_k^*}{(\delta_k^* + 1) \beta_k^*} \frac{(x_{\text{test}} - m_k^*)^2}{2\nu_k^*} \right)^{-\frac{2\nu_k^* + 1}{2}}\end{aligned}$$

Distribución t-Student Generalizada: $X \sim t(\mu, \Lambda, \nu)$ si

$$p(x) = \frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2})} \sqrt{\frac{\Lambda}{\pi\nu}} \left(1 + \Lambda \frac{(x - \mu)^2}{\nu} \right)^{-\frac{\nu+1}{2}}$$

Gaussian Variational Bayes

Calculo auxiliar de las densidades a mezclar

$$\begin{aligned}\mathbb{E} \left[\sqrt{\frac{\lambda_k}{2\pi}} e^{\frac{-\lambda_k}{2}(x_{\text{test}} - \mu_k)^2} \middle| \mathcal{D}_n \right] &\propto \left(\beta_k^* + \frac{\delta_k^*(x_{\text{test}} - m_k^*)^2}{2(\delta_k^* + 1)} \right)^{-(\nu_k^* + 1/2)} \\ &\propto \left(1 + \frac{\delta_k^* \nu_k^*}{(\delta_k^* + 1) \beta_k^*} \frac{(x_{\text{test}} - m_k^*)^2}{2\nu_k^*} \right)^{-\frac{2\nu_k^* + 1}{2}}\end{aligned}$$

Distribución t-Student Generalizada: $X \sim t(\mu, \Lambda, \nu)$ si

$$p(x) = \frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2})} \sqrt{\frac{\Lambda}{\pi\nu}} \left(1 + \Lambda \frac{(x - \mu)^2}{\nu} \right)^{-\frac{\nu+1}{2}}$$

Predictiva

$$p(x_{\text{test}} | \mathcal{D}_n) = \sum_{k=1}^K \frac{\alpha_k^*}{\sum_{c=1}^K \alpha_c^*} \cdot t \left(m_k^*, \frac{\delta_k^* \nu_k^*}{(\delta_k^* + 1) \beta_k^*}, 2\nu_k^* \right)$$

Outline

14/11 Bayes es básicamente:

1 Inferencia Bayesiana

$$\frac{P(x_i|\theta)}{P(\theta)} \left\{ \begin{array}{l} \Rightarrow P(\theta|x_i) = p(\theta) \cdot \prod_{i=1}^n p(x_i|\theta) \end{array} \right. \begin{array}{l} \rightarrow (1) \\ \rightarrow (2) \end{array}$$

+ datos

2 Naive Bayes

$$(1) \hat{\theta}_{\text{Bay}} = \mathbb{E}[\theta | \underline{x}]$$

3 Multinomial Naive Bayes

$$(2) P(x_{\text{test}} | \underline{x}) = \int P(x_{\text{test}} | \theta) \cdot p(\theta | \underline{x}) d\theta =$$

(H) $\rightarrow$ Dist. predictiva

4 Variational Bayes

5 Monte Carlo Markov Chain

$$= \mathbb{E} \left[P(x_{\text{test}} | \theta) \mid \underline{x} \right]$$

(1) TP03

(2) TP10, no la hice ja ja

Son muchas cuentas

Monte-Carlo

Ley de los grandes números

Sean X_i variables aleatorias i.i.d. con esperanza finita $\mathbb{E}[X]$, entonces $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{n \rightarrow \infty} \mathbb{E}[X]$ (w.p.1).

Obs: en ① y en ② siempre calculamos esperanzas
¿cómo podemos usar la ley de los grandes números para esto?

Monte-Carlo

Ley de los grandes números

Sean X_i variables aleatorias i.i.d. con esperanza finita $\mathbb{E}[X]$, entonces $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{n \rightarrow \infty} \mathbb{E}[X]$ (w.p.1).

Método de Monte-Carlo

Sean X_i variables aleatorias i.i.d. con pdf $p(x)$ o pmf $P(x)$, entonces

$$\int_{\mathbb{R}} g(x)p(x)dx \approx \frac{1}{n} \sum_{i=1}^n g(X_i), \quad \sum_{x \in \mathbb{A}} g(x)P(x) \approx \frac{1}{n} \sum_{i=1}^n g(X_i)$$

Monte-Carlo

Ley de los grandes números

Sean X_i variables aleatorias i.i.d. con esperanza finita $\mathbb{E}[X]$, entonces $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{n \rightarrow \infty} \mathbb{E}[X]$ (w.p.1).

Método de Monte-Carlo

Sean X_i variables aleatorias i.i.d. con pdf $p(x)$ o pmf $P(x)$, entonces

$$\int_{\mathbb{R}} g(x)p(x)dx \approx \frac{1}{n} \sum_{i=1}^n g(X_i), \quad \sum_{x \in \mathbb{A}} g(x)P(x) \approx \frac{1}{n} \sum_{i=1}^n g(X_i)$$

Ideas Principales

En lugar de obtener la distribución a posteriori, vamos a generar muestras de esta distribución y aproximar la predictiva por Monte-Carlo.

$$p(x_{\text{test}}|\mathcal{D}_n) \approx \frac{1}{N_s} \sum_{i=1}^{N_s} p(x_{\text{test}}|T_i)$$

Cadenas de Markov

Teorema de Ergódico

No es sencillo generar muestras independientes de la posterior sin una expresión analítica. El Teorema de Ergódico nos permite aplicar la ley de los grandes números, sin la hipótesis de independencia, para sucesiones de variables aleatorias con ciertas características.

$$\mathbb{E}[g(X)] \approx \frac{1}{n} \sum_{i=1}^n g(X_i)$$


Cadenas de Markov

Teorema de Ergódico

No es sencillo generar muestras independientes de la posterior sin una expresión analítica. El Teorema de Ergódico nos permite aplicar la ley de los grandes números, sin la hipótesis de independencia, para sucesiones de variables aleatorias con ciertas características.

$$\mathbb{E}[g(X)] \approx \frac{1}{n} \sum_{i=1}^n g(X_i)$$

Proceso de Markov



Una **cadena de Markov** es una sucesión de variables aleatorias $\{T_t\}_{t \in \mathbb{N}_0}$ que cumple la propiedad de *falta de memoria*: "La información va avanzando"

π : Dist. a posteriori

Si conozco T_2 , no me hace falta conocer T_1 y T_0

$$P(T_t = \theta \rightarrow T_{t+1} = \theta') = \pi(\theta' | \theta)$$

→ la distribución π es la misma, no importa si paso de T_0 a T_2 o de T_2 a T_3


Monte Carlo Markov Chain (MCMC)

Homogeneidad

¿Que busco de una cadena de Markov?

- **Ergodicidad:** Que los promedios tiendan a las esperanzas
- **Estado Estacionario:** Que la distribución de las variables de la cadena alcancen el estado estacionario de la distribución deseada:

$$\pi(\theta') = \int_{\Theta} \underbrace{P(\theta \rightarrow \theta')}_{\text{marginales}} \pi(\theta) d\theta = \int \pi(\theta, \theta') \underbrace{d\theta}_{\text{conjunta}}$$



Ejemplo 6.2 Encontrar el estado estacionario de una cadena de Markov homogénea, donde θ es una variable discreta que toma valores en $\{0, 1, 2\}$ y las probabilidades de transición se definen con la matriz $P = \begin{pmatrix} 0.7 & 0.2 & 0.1 \\ 0.4 & 0.6 & 0.0 \\ 0.0 & 0.9 & 0.1 \end{pmatrix}$.

$\pi(\theta'|\theta)$ indep de T

$$\begin{pmatrix} \pi(0) \\ \pi(1) \\ \pi(2) \end{pmatrix} = \begin{pmatrix} 0.7 & 0.2 & 0.1 \\ 0.4 & 0.6 & 0 \\ 0 & 0.9 & 0.1 \end{pmatrix} \begin{pmatrix} \pi(0) \\ \pi(1) \\ \pi(2) \end{pmatrix}$$

Además, debe cumplirse que

$$\pi(0) + \pi(1) + \pi(2) = 1$$

$$\begin{cases} 0.7 \cdot \pi(0) + 0.2 \pi(1) + 0.1 \pi(2) = \pi(0) \quad \bullet \\ 0.4 \pi(0) + 0.6 \pi(1) + 0 = \pi(1) \quad \bullet \rightarrow 0.4 \pi(0) = 0.4 \pi(1) \Rightarrow \boxed{\pi(0) = \pi(1)} \\ 0 + 0.9 \pi(1) + 0.1 \pi(2) = \pi(2) \quad \bullet \end{cases}$$

- $0,9 \pi(0) + 0,1 \pi(2) = \pi(2) \rightarrow 0,9 \pi(0) = 0,9 \cdot \pi(2)$

- $\pi(0) = \pi(1) = \pi(2)$

- $\pi(0) + \pi(1) + \pi(2) = 3 \pi(0) = 1 \rightarrow \boxed{\pi(0) = 1/3}$

- $0,7 \cdot \frac{1}{3} + 0,2 \cdot \frac{1}{3} + 0,1 \cdot \frac{1}{3} = \frac{1}{3}$ *correcta*


Decimos q' la distribución π converge a $\pi(0) = \pi(1) = \pi(2) = 1/3$

Técnicas de Muestreo

Muestreo de Gibbs

Muestreo utilizado cuando la conjunta $\pi(\alpha, \beta)$ es difícil de muestrear pero las condicionales, $\pi(\alpha|\beta)$ y $\pi(\beta|\alpha)$, son factibles. Itera entre:

$$\beta_k \sim \pi(\beta|\alpha_k), \quad \alpha_{k+1} \sim \pi(\alpha|\beta_k)$$



Técnicas de Muestreo

Muestreo de Gibbs

Muestreo utilizado cuando la conjunta $\pi(\alpha, \beta)$ es difícil de muestrear pero las condicionales, $\pi(\alpha|\beta)$ y $\pi(\beta|\alpha)$, son factibles. Itera entre:

$$\beta_k \sim \pi(\beta|\alpha_k), \quad \alpha_{k+1} \sim \pi(\alpha|\beta_k)$$

Muestreo Metrópolis

Muestreo utilizado cuando la dificultad de la posteriori radica en la constante de multiplicación $\pi(\theta) = \frac{f(\theta)}{Z}$. Itera entre

- Generar $\overset{\text{candidate}}{\theta'} = \theta_t + \delta$. Para el caso discreto, $\delta \sim \mathcal{U}\{-1, 0, 1\}$ (uniforme discreta de 3 átomos). Para el caso continuo $\delta \sim \mathcal{N}(0, \sigma^2)$.
- Sortear una Bernoulli de probabilidad $\alpha(\theta_t, \theta')$. Si dicha variable vale 1, $\theta_{t+1} = \theta'$; caso contrario $\theta_{t+1} = \theta_t$. $\chi \sim \text{Ber}(\alpha)$ donde α

$$\alpha(\theta_a, \theta_b) = \min \left\{ 1, \frac{f(\theta_b)}{f(\theta_a)} \right\} \quad \text{depende de } \theta_t, \theta'$$

Se ve mejor escrita así: $\alpha(\theta_t, \theta') = \min \left\{ 1, \frac{f(\theta')}{f(\theta_t)} \right\}$

$$\frac{f(\theta')}{f(\theta_t)} = \frac{\pi(\theta')}{\pi(\theta_t)}$$

Si $\frac{\pi(\theta')}{\pi(\theta_t)} > 1 \Rightarrow \theta'$ es más verosímil q $\theta \Rightarrow \alpha = 1 \Rightarrow \text{actualiza } \theta$

Algorithm 6 No-U-Turn Sampler with Dual Averaging

Given $\theta^0, \delta, \mathcal{L}, M, M^{\text{adapt}}$:
 Set $\epsilon_0 = \text{FindReasonableEpsilon}(\theta), \mu = \log(10\epsilon_0), \bar{\epsilon}_0 = 1, \bar{H}_0 = 0, \gamma = 0.05, t_0 = 10, \kappa = 0.75$.
for $m = 1$ to M **do**
 Sample $r^0 \sim \mathcal{N}(0, I)$.
 Resample $u \sim \text{Uniform}([0, \exp\{\mathcal{L}(\theta^{m-1} - \frac{1}{2}r^0 \cdot r^0)\}])$
 Initialize $\theta^- = \theta^{m-1}, \theta^+ = \theta^{m-1}, r^- = r^0, r^+ = r^0, j = 0, \theta^m = \theta^{m-1}, n = 1, s = 1$.
 while $s = 1$ **do**
 Choose a direction $v_j \sim \text{Uniform}(\{-1, 1\})$.
 if $v_j = -1$ **then**
 $\theta^-, r^-, -, -, \theta', n', s', \alpha, n_\alpha \leftarrow \text{BuildTree}(\theta^-, r^-, u, v_j, j, \epsilon_{m-1}\theta^{m-1}, r^0)$.
 else
 $-, -, \theta^+, r^+, \theta', n', s', \alpha, n_\alpha \leftarrow \text{BuildTree}(\theta^+, r^+, u, v_j, j, \epsilon_{m-1}, \theta^{m-1}, r^0)$.
 end if
 if $s' = 1$ **then**
 With probability $\min\{1, \frac{n'}{n}\}$, set $\theta^m \leftarrow \theta'$.
 end if
 $n \leftarrow n + n'$.
 $s \leftarrow s' \mathbb{I}[(\theta^+ - \theta^-) \cdot r^- \geq 0] \mathbb{I}[(\theta^+ - \theta^-) \cdot r^+ \geq 0]$.
 $j \leftarrow j + 1$.
 end while
 if $m \leq M^{\text{adapt}}$ **then**
 Set $\bar{H}_m = \left(1 - \frac{1}{m+t_0}\right) \bar{H}_{m-1} + \frac{1}{m+t_0} (\delta - \frac{\alpha}{n_\alpha})$.
 Set $\log \epsilon_m = \mu - \frac{\sqrt{m}}{\gamma} \bar{H}_m, \log \bar{\epsilon}_m = m^{-\kappa} \log \epsilon_m + (1 - m^{-\kappa}) \log \bar{\epsilon}_{m-1}$.
 else
 Set $\epsilon_m = \bar{\epsilon}_{M^{\text{adapt}}}$.
 end if
end for

No-U-Turn Sampler (NUTS)

Muestreo para variables continuas con posterior diferenciable. Explora soluciones sobre curvas de nivel de

$$-\log \pi(\theta) + \|r\|^2$$

Hoffman - Gelman 2014: "The No-U-Turn Sampler: Adaptively Setting Path Lengths in Hamiltonian Monte Carlo".

No-U-Turn Sampler (NUTS)

Leapfrog

NUTS simula una trayectoria de posibles valores de (θ, r) (partiendo de un $r_0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ inicial) aplicando el método leapfrog, el cual se desliza dentro de la curva de nivel de la log-posterior normalizada $\log p_r(\theta) = \log \pi(\theta) - \frac{1}{2}\|r\|^2$.

No-U-Turn

Leapfrog trabaja de forma equivalente al gradiente descendente, con un *step-size*. La condición de parada es detectar un U-turn, es decir, que continuar explorando llevaría a volver hacia zonas ya cubiertas.

Target accept

Con esta probabilidad normalizada, se elige al azar uno de los puntos de la trayectoria (θ', r') . Similar a Metrópolis, se acepta el cambio con probabilidad $\min \left\{ 1, \frac{p_{r'}(\theta')}{p_{r_t}(\theta_t)} \right\}$. El *step-size* se fija durante la etapa *tune*, de manera que la probabilidad de aceptar el cambio sea el `target_accept`.

Calidad de las muestras

Tamaño efectivo de la muestra: ESS bulk

El teorema ergódico permite aproximar esperanzas a partir de promedios sin la hipótesis de independencia, pero con una convergencia más lenta. El tamaño efectivo de la muestra (Effective Sample Size, ESS) es la cantidad de datos independientes necesarios para alcanzar la misma varianza que posee el promedio de las muestras.

Por ej: generar 10.000 muestras dependientes sería equivalente a ver 15 datos indep $\Rightarrow ESS = 15$

Calidad de las muestras


Tamaño efectivo de la muestra: ESS bulk

El teorema ergódico permite aproximar esperanzas a partir de promedios sin la hipótesis de independencia, pero con una convergencia más lenta. El tamaño efectivo de la muestra (Effective Sample Size, ESS) es la cantidad de datos independientes necesarios para alcanzar la misma varianza que posee el promedio de las muestras.

Diagnóstico Gelman-Rubin: $\hat{R}$

Tener muchas cadenas de experimento nos permite corroborar si se alcanzó el estado estacionario. Si todas convergieron a la misma distribución, entonces la varianza entre cadenas debería ser similar a la varianza dentro de cada cadena. Se denomina $\hat{R}$ al cociente entre estas varianzas. Suele considerarse $\hat{R} > 1.01$ una señal de alerta y un valor $\hat{R} > 1.1$ un problema a resolver.


Ejemplo de modelado Bayesiano



Problema

Un usuario proporciona una serie de recuentos diarios de mensajes de whatsapp enviados. Tiene curiosidad por saber si los hábitos de envío de mensajes han cambiado con el tiempo. ¿Cómo puedes modelar esto?

PYMC: Programación Probabilística con MCMC




- $\beta_1 \sim \mathcal{E}(\alpha)$
- $\beta_2 \sim \mathcal{E}(\alpha)$
- $\tau \sim \mathcal{U}\{1 : T\}$
- $\lambda_i = \begin{cases} \beta_1 & i < \tau \\ \beta_2 & i \geq \tau \end{cases}$
- $X_i | \lambda_i \sim \text{Poi}(\lambda_i)$

```
import pymc as pm
import numpy as np
import matplotlib.pyplot as plt
```

```
count_data = np.loadtxt("txtdata.csv")
n_count_data = len(count_data)
with pm.Model() as model:
    alpha = 1.0/count_data.mean()
    beta_1 = pm.Exponential("beta_1", alpha)
    beta_2 = pm.Exponential("beta_2", alpha)
    tau = pm.DiscreteUniform("tau", lower=0, upper=n_count_data - 1)
    idx = np.arange(n_count_data) # Index
    lambda_ = pm.Deterministic("lambda", pm.math.switch(tau > idx, beta_1, beta_2))
    observation = pm.Poisson("obs", lambda_, observed=count_data)
    trace = pm.sample(draws=1000, tune=1000, chains=2)
```

```
pm.model_to_graphviz(model)
```


→ atanca la descripción del grafo



```
import pymc as pm
import numpy as np
import matplotlib.pyplot as plt

count_data = np.loadtxt("txtdata.csv")
n_count_data = len(count_data)
with pm.Model() as model:
    alpha = 1.0/count_data.mean()
    beta_1 = pm.Exponential("beta_1", alpha)
    beta_2 = pm.Exponential("beta_2", alpha)
    tau = pm.DiscreteUniform("tau", lower=0, upper=n_count_data - 1)
    idx = np.arange(n_count_data) # Index
    lambda_ = pm.Deterministic("lambda", pm.math.switch(tau > idx, beta_1, beta_2))
    observation = pm.Poisson("obs", lambda_, observed=count_data)
    trace = pm.sample(draws=1000, tune=1000, chains=2)

pm.model_to_graphviz(model)
```



```
import arviz as az

summary = az.summary(trace, var_names=["beta_1", "beta_2", "tau"])
print(summary)
```

	mean	sd	ess_bulk	r_hat
beta_1	17.772	0.630	1834.0	1.0
beta_2	22.677	0.887	1515.0	1.0
tau	44.287	0.863	247.0	1.0


PYMC

```
beta_1_samples = trace.posterior['beta_1'].values
beta_2_samples = trace.posterior['beta_2'].values
tau_samples = trace.posterior['tau'].values
lambda_samples = trace.posterior['lambda'].values

_ = pm.plot_posterior(trace.posterior[['beta_1', 'beta_2', 'tau']], figsize=(7,4))

with model:
    posterior_pred = pm.sample_posterior_predictive(trace, predictions=True)

pred_samples = posterior_pred.predictions['obs'].values
```




```
beta_1_samples = trace.posterior['beta_1'].values
beta_2_samples = trace.posterior['beta_2'].values
tau_samples = trace.posterior['tau'].values
lambda_samples = trace.posterior['lambda'].values


_ = pm.plot_posterior(trace.posterior[['beta_1', 'beta_2', 'tau']], figsize=(7,4))

with model:
    posterior_pred = pm.sample_posterior_predictive(trace, predictions=True)

pred_samples = posterior_pred.predictions['obs'].values
```



```
plt.bar(np.arange(n_count_data), pred_samples[0,-1], color="#348AB0")
plt.xlabel("Tiempo (días)")
plt.ylabel("Cantidad de mensajes")
plt.xlim(-1, n_count_data)
plt.ylim(0, 75)
plt.show()
```



Sobre el TP:

A: "el usuario 4 resuelve 2"

$$P(A|\underline{x}) = E[P(A|\textcircled{H})|\underline{x}] = E[\sigma(\theta_4 - \beta_{12})|\underline{x}] \rightarrow \text{promedio sobre los valores q' tenga de } \theta_4 \text{ y } \beta_2$$

$\textcircled{H}$: todos los parámetros, β y σ

$$P(X_{4,12} = 1 | \textcircled{H}) = \sigma(\theta_4 - \beta_{12})$$

↓

$$X_{4,12} \sim \text{Ber}(\sigma(\theta_4 - \beta_{12}))$$